

# 基于充电数据的多阶段锂离子电池健康状态估计

魏中宝, 阮浩凯, 何洪文

(北京理工大学 机械与车辆学院, 北京 100081)

**摘要:** 锂离子电池的健康状态估计是锂离子电池寿命评估和健康管理的基础. 文中针对实际应用场景中充电数据的缺失, 提出一种实用的多阶段电池的健康状态估计方法. 研究中根据电压大小, 将充电过程划分为 3 个阶段, 分别提出了具有针对性的电池的健康状态估计方法. 特别是对于恒流电压过渡阶段, 在恒流数据和电压数据都严重缺失地情况下, 利用卷积神经网络的数据挖掘能力, 直接建立了电压电流数据与电池的健康状态的关系, 在锂离子电池的长期老化实验数据研究基础上对所提出的方法进行了验证. 结果表明, 该方法具有估计精度高、应对严重数据缺失的能力强、对电池不一致性鲁棒性强等优点.

**关键词:** 锂离子电池; 健康因子; 健康状态估计; 机器学习算法; 恒流; 卷积神经网络

中图分类号: U469.72

文献标志码: A

文章编号: 1001-0645(2022)11-1184-07

DOI: 10.15918/j.tbit1001-0645.2021.336

## Multi-Stage State of Health Estimation Based on Charging Phase for Lithium-Ion Battery

WEI Zhongbao, RUAN Haokai, HE Hongwen

(School of Mechanic Engineering, Beijing Institute of Technology, Beijing 100081, China)

**Abstract:** State of health estimation of lithium-ion battery is the basis of lithium-ion battery life assessment and health management. A practical multi-stage state of health estimation method was proposed to deal with different charging stages, including the scene of serious lack of charging data. According to the voltage, the constant current-constant voltage charging process was divided into three stages and their target state of health estimation methods were proposed respectively. Especially for the constant current-constant voltage transition stage, being a lack of constant current data and constant voltage data heavily, the relationship between raw voltage/current data and battery state of health was directly established taking the strong data mining capability of convolutional neural network. The proposed method was evaluated by long-term aging experiments on lithium-ion battery. The results show that this method possesses the advantages of high estimation accuracy, strong ability to deal with serious data loss, and strong robustness to battery inconsistency.

**Key words:** lithium-ion battery (LIB); health indicators; state of health estimation; machine learning method; constant current-constant voltage (CCCV); convolutional neural network (CNN)

锂离子电池因为其成本低、能量密度高、可靠性强等优点, 成为了电动汽车常用的储能工具. 准确监测电池的健康状态对于电动汽车的安全性和可靠性有重要意义.

电池的健康状态的估计方法通常分为基于模型的方法和基于数据的方法. 基于模型的方法将电池

健康状态作为状态变量或模型参数, 并使用自适应滤波器对参数进行更新以获得健康状态估计值<sup>[1-2]</sup>. 尽管这种方法有较高的估计精度, 但对模型精度和扰动的敏感性限制了其在实际场景中的应用<sup>[3]</sup>.

基于数据的方法构建简单的映射关系, 根据提取的健康因子推断健康状态<sup>[4-5]</sup>. 目前, 基于数据的

收稿日期: 2021-12-01

基金项目: 国家自然科学基金资助项目 (52072038)

作者简介: 魏中宝(1988—), 男, 教授, E-mail: weizb@bit.edu.cn.

方法主要利用标准的恒流恒压充电数据提取健康因子, 估计电池的健康状态. 增量容量分析和差分电压分析是该领域最常用的方法. 由于健康因子在电池全寿命周期的一致性, 增量容量分析 (incremental capacity analysis, ICA) 和差分电压分析 (differential voltage analysis, DVA) 相比得到了更广泛的应用<sup>[6]</sup>. 基于增量容量曲线的健康因子, 即增量容量峰的位置、高度和面积, 与电池的老化过程有直接联系<sup>[7-8]</sup>. 但是这种方法需要繁琐的数据预处理, 而且需要一个相对完整的恒流充电数据. 完整恒流充电数据在实车充电中很难得到, 因为驾驶员倾向于在锂离子电池电量完全耗尽之前给电动汽车充电. 因此, 这激发了学者们对恒压阶段充电数据的研究. 研究表明利用指数函数拟合恒压电流提取时间常数, 能有效估计健康状态<sup>[9]</sup>. 相似的研究还有采用等效电路模型来反映恒压电流的动态变化, 并提取健康因子估计健康状态<sup>[10]</sup>. 此外, 研究发现恒压充电电流的变化率和恒压充电时间与电池容量均有很强相关性<sup>[11]</sup>. 尽管已

有大量研究验证了恒压充电数据的利用价值, 但实际工况中, 恒压充电阶段通常耗时, 获取完整的恒压充电数据同样十分困难.

研究旨在解决上述问题, 并提出一种实用的多阶段健康状态估算方法, 该方法具有广泛的应用范围, 包括应对实际工况中充电数据严重缺失的场景.

## 1 多阶段健康状态估计算法

### 1.1 电池数据获取

4 个编号为 5、6、7 和 18 的标定容量为 2Ah 的 LiNiCoAlO<sub>2</sub>(NCA) 电池在室温条件下 (约 25 °C), 进行恒流恒压充电和恒流放电循环, 如图 1 所示. 首先, B5、B6、B7 和 B18 以 1.5 A 的电流放电, 直到端电压分别下降到 2.7 V、2.5 V、2.2 V 和 2.5 V; 然后, 电池以恒流恒压模式充电, 其中恒流电流、电压上限和恒压截止电流分别为 1.5 A、4.2 V 和 50 mA. 最后, 重复充电和放电循环, 直到电池容量衰减 30%.


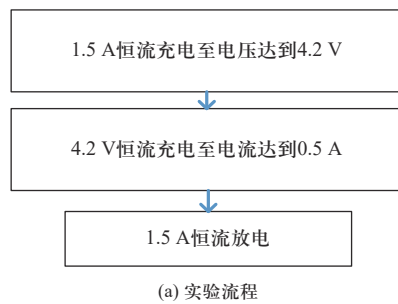


图 1 实验流程和电池容量衰减曲线

Fig. 1 Experimental procedure and battery capacity degradation curve

### 1.2 基于完整恒流充电数据的电池健康状态估计

对于可以获得完整恒流充电数据的情景, ICA 是目前最普遍的方法. 增量容量曲线是根据恒流充电数据将增量容量与升高的电压相关联而得出的. 然而, 离散的电压数据通常导致原始增量容量曲线充满了噪声 (图 2(b) 中波动较大的曲线), 这极大地阻碍了健康因子的提取. 为了弥补这一缺陷, 研究采用高斯函数来拟合曲线, 在提取可用健康因子之前消除强噪声. 基于高斯函数, 以电池端电压  $V$  作为自变量,  $dQ/dV$  可表示为

$$\frac{dQ}{dV} = \sum_{i=1}^n \sqrt{\frac{2}{\pi}} \frac{A_i}{\omega_i} \exp\left(-2\left(\frac{V - V_{0i}}{\omega_i}\right)^2\right) \quad (1)$$

式中:  $n$  为曲线中的峰的个数;  $A_i$  是第  $i$  个峰的面积,

$A \cdot h$ ;  $\omega_i$  为第  $i$  个峰的宽度,  $V$ ;  $V_{0i}$  为第  $i$  个峰的几何中心位置,  $V$ . 通过滤波算法, 可以从  $Q-V$  曲线上难以识别的电压区域获得易于提取的增量容量峰的参数值. 滤波后的  $Q-V$  曲线和增量容量曲线与原始曲线的对比如图 2 所示.

增量容量曲线随老化的变化规律如图 3(b) 所示. 从图中可以看出增量容量曲线随电池老化呈现出规律的变化. 由此推断出, 公式 (1) 中的 9 个参数均具有作为健康因子的潜力. 为了选取合适的电池健康因子, 这些参数与电池容量之间的相关性系数如表 1 所示. 从表中可以看出,  $A_1$ 、 $A_2$ 、 $A_3$ 、 $V_2$  和  $w_3$  与电池容量的相关性系数较高, 因此被选作电池健康状态的健康因子.




图 2 原始和滤波后的  $Q$ - $V$  和增量容量曲线  
Fig. 2 Original and filtered  $Q$ - $V$  and IC curves




图 3 充电曲线随循环数变化:  
Fig. 3 Voltage and IC change with cyclic usage

表 1 参数与电池容量的关系

Tab. 1 Relationship between parameter and battery capacity

参数	第1个峰	第2个峰	第3个峰
$A_i/(A \cdot h)$	0.900 5	0.907 8	0.856 5
$V_i/V$	0.528 5	0.932 3	0.468 4
$w_i/V$	0.233 5	0.304 4	0.830 0

1.3 基于局部恒流充电数据的电池健康状态估计

从图 3(b)中可以看出,当电压超过 3.9V 时,增量容量曲线中最明显的峰已经不能完全显示出来.这象征着用增量容量方法估计电池健康状态的效率降低,需要提出新的健康因子弥补增量容量特征的缺失.

之前的研究已经表明,恒流充电时长  $T$  与电池健康状态有很强的相关性<sup>[12-13]</sup>.但是单独的  $T$  并不能实现与增量容量方法相似的估计精度,新的健康因子需要被提出.如图 3(a)所示,随着电池老化,恒流充电过程中的电压增加得更快.为此,模糊熵(Fuzzy entropy, FE),作为描述时间序列数据混沌程度的有效特征,被提取来描述电压上升速率的变化.FE 的详细算法如表 2 所示.

$T$  和  $FE$  分别代表图 3(a)横向和纵向维度上的电压曲线的规律性.结合增量容量曲线第三个峰值

表 2 FE 计算流程

Tab. 2 Detailed procedures to determine the FE of charging voltage

初始化参数向量 $m, r$ 和 $n$
步骤1: 将时间 $\{X_i, i = 1, 2, \dots, n\}$ 通过窗口大小 $m$ 分为 $k = n - m + 1$ 个小序列 $x_i = (X_i, X_{i+1}, \dots, X_{i+m})$ ;
步骤2: 计算每个序列与所有其他序列之间的距离,该距离是两个向量对应元素之间差值的最大绝对值, $d_{ij} = \max  x_i(t) - x_j(t) $ ;
步骤3: 根据距离 $d$ 计算模糊程度 $D$ ; $D_{ij}^m = \mu(d_{ij}^m, n, r) = \exp\left(\frac{-(d_{ij}^m)^r}{r}\right)$ 计算除自身之外的所有隶属度的平均值: $\Phi^m(n, r) = \frac{1}{N-m} \sum_{j=1}^{N-m} \left[ \frac{1}{N-m-1} \sum_{j=1, j \neq i}^{N-m} D_{ij}^m \right]$
步骤4: 将 $m$ 变为 $m+1$ , 重复步骤 1 至 3;
步骤5: 计算模糊熵: $FE = \ln \Phi^m - \ln \Phi^{m+1}$

的 3 个特征,共融合 5 个健康因子进行健康状态估计,期望解决初始充电电压超过 3.9 V 时恒流充电数据缺失的不利情况.

1.4 基于恒流恒压过渡阶段的电池健康状态估计

当起始充电电压超过 4V 以后,图 3(b)中可以看出,增量容量曲线的第三个峰也逐渐变得不完整,基于局部恒流充电的方法也开始失效,同时充电电压接近恒流截止电压,意味着充电数据来到了恒流恒

压过渡阶段. 在恒流相位向恒压相位转换的过程中, 恒流和恒压段数据都处于严重缺失的状态, 都没有充足的数据来提取合适的健康因子, 如图 4 所示. 虽然数据缺失, 但是恒流阶段结束时的电压斜率和恒压阶段开始时的电流斜率随循环使用而有规律地变化, 这其中必然包含与电池老化相关的信息. 为了充分利用数据的形态学特征, 一种常见的处理图像问题的 CNN 模型被建立起来, 以原始的恒流电压和恒压电流数据直接作为模型输入, 估计电池的健康状态.




图 4 恒流恒压充电过程中电压和电流曲线  
Fig. 4 Charging curves during CCCV phase

CNN 是一种强大的深度学习算法, 用于图像等多维数据处理. 它由卷积层、池化层和全连接层组

成. 由于卷积核参数的共享和层间连接的稀疏性, 使得卷积神经网络在计算量较小的情况下捕捉图像的拓扑特征, 并且对原始数据没有额外的特征要求. 因此, 研究利用 CNN 建立输入到电流和电压数据与电池健康状态之间的关系. CNN 使用滤波器或核  $K$  执行卷积, 该滤波器或核  $K$  用于从输入向量  $a$  获得特征映射  $S$ . 表示为

$$S(i, j) = \sum_m \sum_n A(i-m, j-n) \cdot K(m, n) \quad (2)$$

卷积之后, 通常添加偏置, 并引入非线性激活函数. 这里, 偏差定义为  $b$ , 激活函数为  $h$ , 卷积层输出  $z_{ij}$  为

$$z_{ij} = h(S(i, j) + b) \quad (3)$$

针对恒流恒压过渡段数据, CNN 模型的输入是一个 2 行 100 列的矩阵, 其中包含 100 个采样间隔为 2.5 s 的电压和电流数据. 权衡模型复杂度和估计精度, CNN 由具有 16 个大小为 2 的卷积核的一维卷积层、一个具有 32 个大小为 1 的核的一维卷积层和两个分别具有 16 个和 1 个神经元的全连接层组成. 由于空间特征与图形输入相比受到限制, 因此没有池化层. 此外, 卷积核移动步幅为 1, 并选择 *ReLU* 函数作为激活函数. 方法的流程图如图 5 所示.

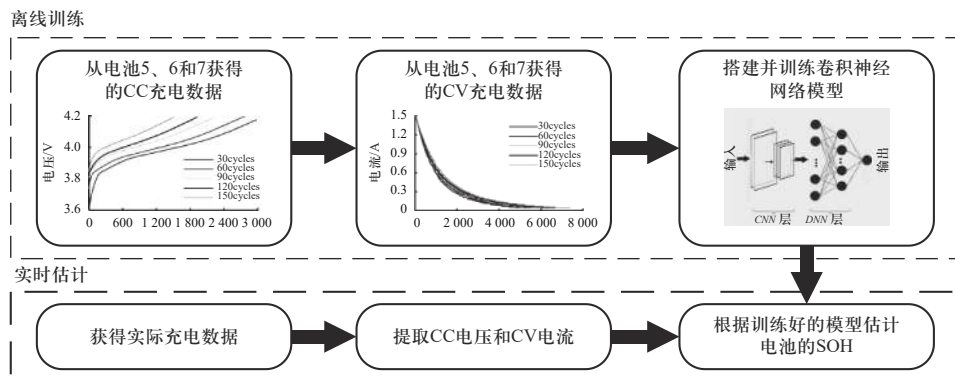


图 5 CNN 估计电池健康状态的流程图  
Fig. 5 SOH estimation flowchart based on CNN

## 2 结果与分析

### 2.1 基于完整恒流充电数据的电池健康状态估计验证

在第 2 章的讨论中, 公式 (1) 中的 5 个参数被选作估计电池健康状态的健康因子. 充分权衡电池的非线性特征和算法的复杂度, BP 神经网络被用来建立健康因子与电池健康状态之间的关系. 基于训练电池 B5 获得的估计结果如图 6(a) 所示. 结果表明, 健康状态估计值与实验基准值吻合较好, 估计误差大多在 3% 的误差范围内. 尽管电池的化学成分相同,

但不同的电池在制造过程中可能会相互偏离. 随着电池老化, 电池不一致性也会显著增大. 因此, 必须评估所提出方法对电池不一致性的鲁棒性能. 在这方面, 使用经过 B5 训练的模型来估计电池 B6、B7 和 B18 的健康状态, 结果如图 6(b)~(d) 所示. 在所研究的锂离子电池的整个寿命期间, 估算的健康状态与实测的容量衰退轨迹非常相似. 由于电池的不一致性, 模型在新电池上的估计精度有一定程度下降, 但是, 其明显小于 5% 的误差说明模型的性能是令人满意的.



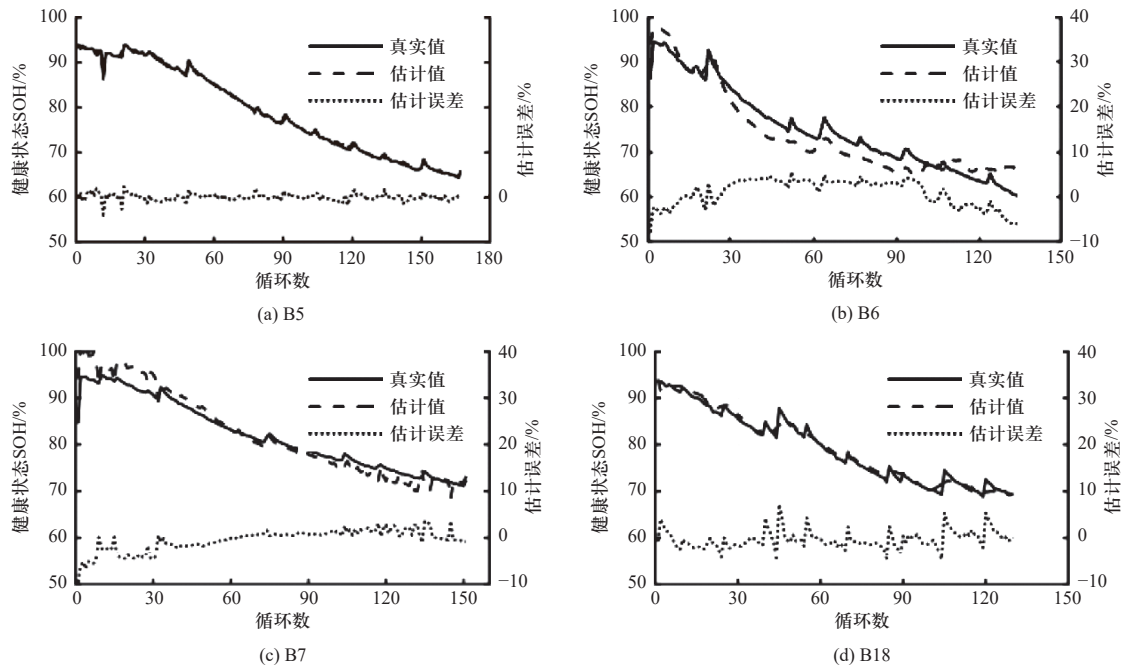


图 6 基于完整恒流充电数据的电池健康状态估计.

Fig. 6 SOH estimation based on complete CC charging data

## 2.2 基于局部恒流充电数据的电池健康状态估计验证

接下来,考察健康状态估计方法在电流数据相对缺失情况下的性能.此时,充电数据已经损失一部分,初始充电电压在  $3.9 \sim 4 \text{ V}$  范围内,对应的电池的 SOC 范围是  $30\% \sim 70\%$ ,这是驾驶员由于充电焦虑最可能开始进行充电的 SOC 阶段.提取  $FE$ 、 $T_{RCC}$ 、 $A_3$ 、

$\omega_3$  和  $V_{03}$  作为健康状态估计的健康因子,考虑到模型的估计精度和计算复杂度,同样使用 BP 神经网络来拟合健康因子与电池健康状态的关系.估算结果如图 7 所示.

从图中不难观察到,即使只有部分充电数据可用,在整个生命周期内,无论是经过训练的电池还是

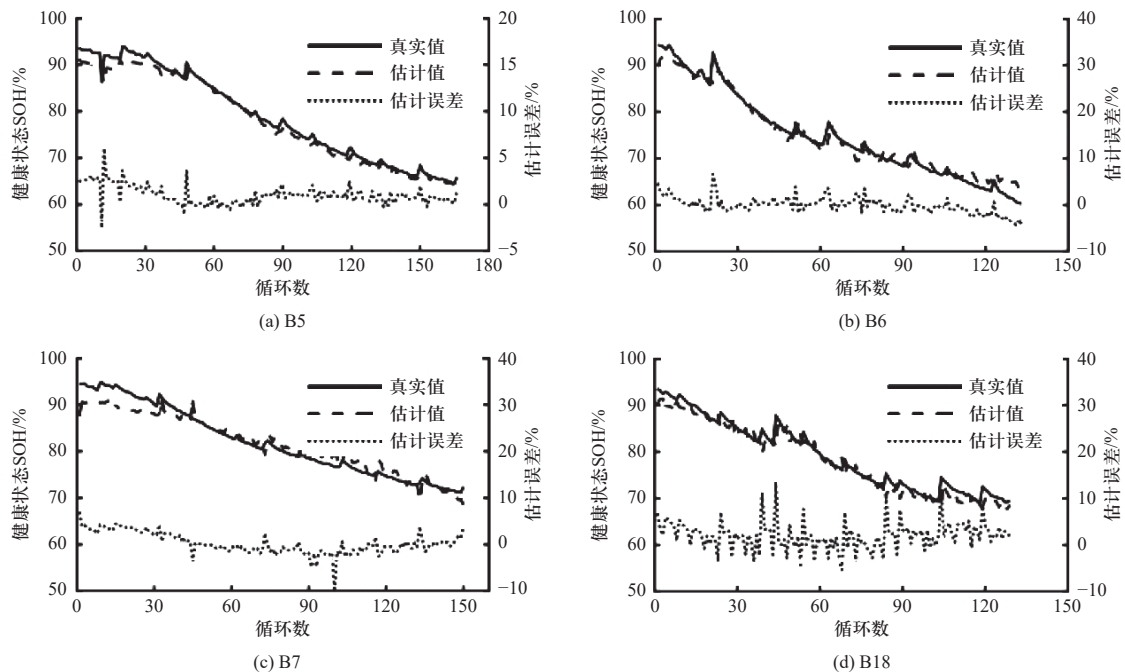


图 7 基于局部恒流充电数据的电池健康状态估计

Fig. 7 SOH estimation based on partial-CC charging data

新电池, 估计的健康状态仍然与实验标定的真实情况非常一致. 与第 3.1 节中的结果相比, 可以观察到, 估计误差仅略微增大. 即使在初始电压达到 4V (对应于 [45%, 70%] 范围内的初始充电 SOC) 的情况下, 也可以精确估计健康状态, MAE 被控制在 3% 左右. 换言之, 多阶段、多类别特征融合的健康状态估计方法, 使健康状态的估计精度并不会随充电数据减少而明显下降.

### 2.3 基于恒流恒压过渡段的电池健康状态估计验证

按照图 5 中总结的流程, CNN 模型通过电池 B5、

B6 和 B7 进行训练, 然后在电池 B18 上进行健康状态估计验证. 结果如图 8 所示. 结果表明, 基于恒流恒压过渡段的充电数据的健康状态估计值与实验基准值吻合较好, 估计误差大多在 5% 的误差范围内. 在电池 B18 上对训练模型的鲁棒性进行验证, 结果如图 8(d) 所示. 从图中可以看出, CNN 模型可以很好地推广到新电池, 即使电池在初始老化状态和循环条件下都不同 (如第 2.1 节所述). 在缺少充电数据的情况下, 证明了该方法对电池不一致性的鲁棒性.

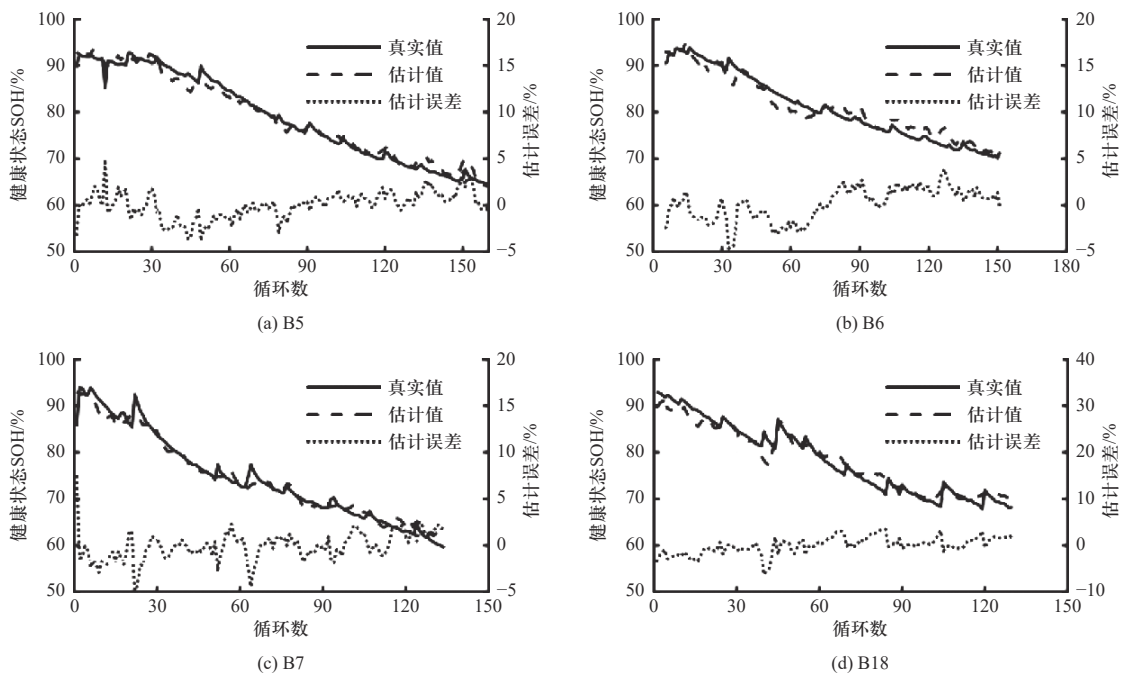


图 8 基于恒流恒压过渡段充电数据的电池健康状态估计

Fig. 8 SOH estimation based on CCCV transition phase

与第 3.1 和 3.2 节中的结果相比, 估计误差相对增大. 但是考虑到恒流恒压过渡段数据严重缺失的情况, 最大不超过 5% 的健康状态估计误差是满足需求的. 换言之, 由于多阶段和多类别特征融合的实施, 多阶段的方法能在实际工况中更加有效地估计电池的健康状态.

## 3 结 论

文中提出了一种多阶段健康状态估计方法, 该方法对充电数据严重缺失的情况具有很高的鲁棒性. 根据初始充电电压的不同, 从有限的充电数据中提取不同组健康因子. 使用神经网络算法对健康因子进行进一步融合, 以实时估计电池健康状态. 研究在

NCA 电池上进行了长期老化实验, 并用实验数据验证方法的可靠性. 主要结论总结如下.

① 提取了基于局部恒流充电数据的模糊熵和充电时间作为两个健康因子估计电池的健康状态, 弥补了在恒流起始阶段充电数据缺失的场景中增量容量方法的失效. 与使用完整充电数据的情况相比, 提出的方法具有相似的高精度.

② 提出了基于恒流恒压过渡段数据的电池健康状态估计方法. 利用卷积神经网络从严重缺失的数据中挖掘老化信息. 该方法对实际充电工况有很强的鲁棒性. 即使在初始充电电压达到 4.1 V (起始 SOC 大于 50%) 的不利情况下, 健康状态估计的最大误差也不超过 5%.

③ 结合了增量容量方法提出了一种具有实际应用价值的多阶段健康状态估计方法. 该方法对电池不一致性具有很强的鲁棒性, 在训练和测试的锂离子电池上都有很高的估计精度.

#### 参考文献:

- [1] 李司光, 张承宁. 锂离子电池荷电状态预测方法研究[J]. *北京理工大学学报*, 2012, 32(2): 125 – 129.  
LI Siguang, ZHANG Chengning. State of charge evaluation of lithium-ion batteries[J]. *Transactions of Beijing Institute of Technology*, 2012, 32(2): 125 – 129. (in Chinese)
- [2] WEI Z, ZHAO J, JI D, et al. A multi-timescale estimator for battery state of charge and capacity dual estimation based on an online identified model[J]. *Applied Energy*. 2017: S030626191730140X.
- [3] 熊瑞. 动力电池管理系统核心算法[M]. 北京: 机械工业出版社, 2018.  
XIONG Rui. Core algorithm of power battery management system[M]. Beijing: Mechanical Industry Press, 2018. (in Chinese)
- [4] 南金瑞, 孙路. 基于粒子群算法估计实际工况下锂电池 SOH[J]. *北京理工大学学报(自然科学版)*, 2021, 41(1): 59 – 64.  
NAN Jinrui, SUN Lu. Estimation of lithium battery soh under actual operating conditions based on particle swarm optimization[J]. *Transactions of Beijing Institute of Technology*, 2021, 41(1): 59 – 64. (in Chinese)
- [5] 董汉成, 凌明祥, 王常虹, 等. 锂离子电池健康状态估计与剩余寿命预测[J]. *北京理工大学学报*, 2015, 35(10): 1074 – 1078.  
DONG Hancheng, LING Mingxiang, WANG Changhong, et al. Lithium-ion battery state-of-health estimation and remaining useful life prediction[J]. *Transactions of Beijing Institute of Technology*, 2015, 35(10): 1074 – 1078. (in Chinese)
- [6] HE J, WEI Z, BIAN X, Yan F. State-of-health estimation of lithium-ion batteries using incremental capacity analysis based on voltage – capacity mode[J]. *IEEE Transactions on Transportation Electrification*. 2020, 6: 417 – 26.
- [7] LI X, YUAN C, LI X, et al. State of health estimation for Li-Ion battery using incremental capacity analysis and Gaussian process regression. *Energy*. 2020, 190: 116467.
- [8] LI Y, ABDEL-MONEM M, GOPALAKRISHNAN R, et al. A quick on-line state of health estimation method for Li-ion battery with incremental capacity curves processed by Gaussian filter[J]. *Journal of Power Sources*, 2018, 373: 40 – 53.
- [9] WANG Z, ZENG S, GUO J, et al. State of health estimation of lithium-ion batteries based on the constant voltage charging curve[J]. *Energy*, 2019, 167: 661 – 669.
- [10] YANG Jufeng, CAI Yingfeng, PAN Chaofeng, et al. A novel resistor-inductor network-based equivalent circuit model of lithium-ion batteries under constant-voltage charging condition[J]. *Applied Energy*. 2019, 254: 113726
- [11] 钟景瑜, 廖凯, 李波, 等. 基于随机片段数据的锂电池状态估计方法[J]. *电力自动化设备*, 2021, 41(10): 205 – 212.  
ZHONG Jingyu, LIAO Kai, Li Bo, et al. Lithium battery state estimation method based on random fragment data[J]. *Electric Power Automation Equipment*, 2021, 41(10): 205 – 212. (in Chinese)
- [12] YUN Z, QIN W. Remaining useful life estimation of lithium-ion batteries based on optimal time series health indicator[J]. *IEEE Access*, 2020, 8: 55447 – 55461.
- [13] GOU B, XU Y, FENG X. State-of-health estimation and remaining-useful-life prediction for lithium-ion battery using a hybrid data-driven method[J]. *IEEE Transactions on Vehicular Technology*, 2020, 69(10): 10854 – 10867.

(责任编辑: 孙竹凤)