

DOI:10.19595/j.cnki.1000-6753.tces.210860

基于数据预处理和长短期记忆神经网络的 锂离子电池寿命预测

黄 凯¹ 丁 恒¹ 郭永芳² 田海建¹

(1. 省部共建电工装备可靠性与智能化国家重点实验室(河北工业大学) 天津 300130

2. 河北工业大学人工智能与数据科学学院 天津 300130)

摘要 锂离子电池剩余使用寿命(RUL)可以评估电池的可靠性,是电池健康管理的重要参数。准确地预测电池的 RUL 可以有效提高设备的安全性并降低工作风险。该文提出一种自适应数据预处理结合长短期记忆神经网络(LSTM)的 RUL 预测框架。选取容量作为健康因子,数据预处理阶段,首先使用自适应双指数模型平滑方法减少容量回升现象产生的负面影响,然后通过自适应白噪声完整集成经验模态分解(CEEMDAN)对数据进行降噪;模型构建阶段,利用预处理后的数据训练得到用于 RUL 预测的 LSTM 模型。以 NASA 和 CALCE 公开数据集为研究对象进行算法性能测试,实验结果表明,所提方法鲁棒性好,能够提供精确的 RUL 预测结果。

关键词: 锂电池 剩余使用寿命 自适应双指数模型平滑方法 自适应白噪声完整集成经验模态分解 长短期记忆神经网络

中图分类号: TM912

Prediction of Remaining Useful Life of Lithium-Ion Battery Based on Adaptive Data Preprocessing and Long Short-Term Memory Network

Huang Kai¹ Ding Heng¹ Guo Yongfang² Tian Haijian¹

(1.State Key Laboratory of Reliability and Intelligence of Electrical Equipment

Hebei University of Technology Tianjin 300130 China

2. School of Artificial Intelligence Hebei University of Technology Tianjin 300130 China)

Abstract The remaining useful life (RUL) of lithium-ion battery can evaluate the reliability of battery, which is an important parameter of battery health management. Accurate prediction of RUL of battery can effectively improve the safety of equipment and reduce the working risk. In this paper, a RUL prediction framework combined with the adaptive data preprocessing method and long-term and short-term memory neural network (LSTM) was proposed. Selecting capacity as the health factor, in the data preprocessing stage, the adaptive double exponential model smoothing method was used to reduce the negative effect of capacity recovery and the adaptive white noise integrated empirical mode decomposition (CEEMDAN) is used to suppress the noise. In the model constructing stage, the LSTM model was built for RUL prediction by training the preprocessed data. The NASA and CALCE open source data were selected to verify the performance of the proposed method. The experimental results show that it has good robustness and can provide RUL prediction results with high precision.

Keywords: Lithium-ion battery, remaining useful life, adaptive bi-exponential model smooth method, the complete ensemble empirical mode decomposition with adaptive noise, long short-term memory network

0 引言

锂离子电池因其能量密度高、自放电率低、循环寿命长、节能环保等优点被广泛应用于航空航天、电动汽车、电子设备和通信系统等众多领域^[1-3]。然而,随着锂离子电池使用时间的增加,电池将会不可避免地老化,如果在失效前无法及时更换电池,将会导致设备运行异常并引起事故的发生。电池剩余寿命(Remaining Useful Life, RUL)指的是电池在性能退化到失效阈值之前剩余的充放电循环次数,是表征电池性能的一个重要指标。准确地预测电池 RUL 可以为电池的及时维修和更换提供参考,以实现设备的预防性维护^[4-5]。

在现有文献中,电池 RUL 预测方法主要分为基于模型的方法和数据驱动方法。

基于模型的预测方法通过探究电池的物理化学反应和内部构造来建立动态模型,结合粒子滤波(Particle Filter, PF)及其衍生算法对参数进行估计,实现 RUL 预测^[6-8]。但存在两个主要缺点阻碍了基于模型预测方法在实际应用中的可行性:①粒子滤波方法存在粒子贫化的问题,很容易导致 RUL 预测结果不准确;②由于电池内部反应机制过于复杂,建立精确的退化模型有很大难度^[9-11]。相比之下,数据驱动方法操作简易、使用方便,可以有效地避免上述问题。

基于数据驱动的预测方法不需要考虑复杂的电化学特性,而是从原始数据中提取可以反映退化趋势的健康因子(电压、电流、电阻、容量等),通过智能算法进行学习并完成 RUL 预测。数据驱动方法主要包括支持向量回归(Support Vector Regression, SVR)、相关向量机(Relevance Vector Machine, RVM)、高斯过程回归(Gaussian Process Regression, GPR)及神经网络(Artificial Neural Network, ANN)等。文献[12]以容量和等压降放电时间作为健康因子,采用集成经验模式分解(Ensemble Empirical Mode Decomposition, EEMD)对健康因子进行预处理,以减少原始数据中容量回升和噪声的影响,引入相空间重构技术(Phase Space Reconstruction, PSR)优化输入序列,与 SVR 结合完成 RUL 预测。文献[13]采用期望最大化算法更新时变参数,结合 RVM 算法建立了多步预测模型。但由于 RVM 的高稀疏性,基于 RVM 的预测方法往往不够稳定。文献[14]通过对容量曲线的分析,从斜率、截距、峰值等不同尺度中提取四种退化特征,通过 GPR 算法进行建模并完成 RUL 预测。相比于长短期记忆神经网络

(Long Short-Term Memory Network, LSTM), GPR 算法的超参数调整过程较为复杂,且建模困难。文献[15]利用 EEMD 方法将电池的退化趋势分解成多个分量,然后采用自回归积分滑动平均模型(Autoregressive Integrated Moving Average, ARIMA)进行建模,从而获得 RUL。文献[16]为模拟电动汽车实际工作情况,将锂离子电池置于振动应力下进行实验,提取等压降放电时间,建立了基于 Elman 神经网络的预测模型。相比 LSTM 神经网络,Elman 神经网络在处理时间序列预测问题时不够稳定。文献[17]通过分析电池充电过程端电压曲线的变化规律,得到退化特征作为前馈神经网络(Feed Forward Neural Network, FFNN)输入完成 RUL 预测。

除了上述数据驱动方法外,深度学习在复杂系统建模中具有更好的学习能力,已成为电池健康管理的热点研究领域。LSTM 是一种深度学习神经网络,由于结构的特殊性,更适合处理时间序列预测问题^[18]。文献[19]对 LSTM 进行改进,设计了一个电池间可以共享信息的预测框架,加入恒定误差选择轮盘(Constant Error Carousel, CEC)隔绝噪声,建立 SOH 和 RUL 预测模型,但是对数据的预处理程度不够,使模型会受到原始数据噪声分量的干扰。文献[20]将双向 LSTM 应用在非生命周期数据集中,选取新的隐含层丢弃技术防止模型过拟合。文献[21]采用经验模态分解(Empirical Mode Decomposition, EMD)将容量数据分解为低频和高频两种分量,分别通过 Elman 和 LSTM 神经网络建模,并整合预测结果预测 RUL,但并未考虑 EMD 本身的局限性,相比于自适应白噪声完整集成经验模态分解(Complete Ensemble Empirical Mode Decomposition with Adaptive Noise, CEEMDAN),EMD 更容易出现模式混合问题。文献[22-25]表明,CEEMDAN 广泛应用于股票投资、生物医学、光伏发电等领域,可以与 LSTM 组合构成相对理想的预测模型。

基于上述分析可知,影响 RUL 预测精度的主要因素在于数据预处理技术和 RUL 建模方法。考虑到实际应用中容量回升问题,提出一种自适应数据预处理方法,结合 LSTM 建立了 RUL 预测模型。论文以容量作为健康因子,通过自适应双指数模型平滑方法(Adaptive Bi-exponential Model Smooth, ABMS)消除了容量回升现象,利用 CEEMDAN 分解出容量数据中的噪声分量,最终选择擅长时序预测的 LSTM 神经网络建立 RUL 预测框架。这种数据预处理方法既对容量进行了平滑处理,又保留了

数据的原始特征,而且避免了噪声分量的影响,采用的 LSTM 神经网络对长时间依赖问题有更好的处理策略。实验结果表明,ABMS-CEEMDAN-LSTM 可有效应用于电池 RUL 预测。

1 CEEMDAN 和 LSTM 理论基础

1.1 CEEMDAN

CEEMDAN 是基于 EEMD 和 EMD 的改进算法,具有模谱分离效果好、屏蔽迭代次数少、计算成本低等优点,常用于处理非平稳和非线性信号^[26-28]。CEEMDAN 具体步骤如下。

(1) 向原始信号 $S(t)$ 加入初始振幅为 ε_0 的高斯白噪声 $\varepsilon_0\omega_i(t)$, 得到 $S_i(t) = S(t) + \varepsilon_0\omega_i(t)$, ($i=1,2,\dots,I$), 使用 EMD 对 $S_i(t)$ 进行分解, 得出第一阶段的 i 个模态分量 IMF_1^i , 对 IMF_1^i 取平均值得到第一个模态分量 $\overline{\text{IMF}}_1$ 。

$$\overline{\text{IMF}}_1 = \frac{1}{I} \sum_{i=1}^I \text{IMF}_1^i \quad (1)$$

(2) 计算第一个残差。

$$R_1(t) = S_i(t) - \overline{\text{IMF}}_1 \quad (2)$$

(3) 用 $E_k(\cdot)$ 表示经过 EMD 处理后得到的第 k 个模态分量, 对信号 $R_1(t) + \varepsilon_1 E_1(\omega_i(t))$ 进行分解得到第二个模态分量为

$$\overline{\text{IMF}}_2 = \frac{1}{I} \sum_{i=1}^I E_1(R_1(t) + \varepsilon_1 E_1(\omega_i(t))) \quad (3)$$

(4) 对于 $k=1,2,\dots,n$, 计算第 k 个残差为

$$R_k(t) = R_{k-1}(t) - \overline{\text{IMF}}_k \quad (4)$$

(5) 对信号 $R_k(t) + \varepsilon_k E_k(\omega_i(t))$ 进行分解, 得到第 $k+1$ 个模态分量为

$$\overline{\text{IMF}}_{k+1} = \frac{1}{I} \sum_{i=1}^I E_k(R_k(t) + \varepsilon_k E_k(\omega_i(t))) \quad (5)$$

(6) 重复步骤(4)和步骤(5), 直至最后的 $R_k(t)$ 无法分解, 得到最终残差为

$$R_n(t) = S_i(t) - \sum_{k=1}^n \overline{\text{IMF}}_k \quad (6)$$

式中, n 为模态分量总数。

1.2 LSTM

LSTM 是递归神经网络 (Recurrent Neural Network, RNN) 的一种改进版本, 它克服了 RNN 梯度爆炸和梯度消失的缺点^[29]。LSTM 的神经元内部

结构如图 1 所示, LSTM 神经元由输入门、遗忘门和输出门三部分组成, 这些门用于更新或丢弃历史信息, 使 LSTM 具备了长期记忆能力, 其原理公式为

$$f_t = \sigma(W_f[h_{t-1} \ x_t] + b_f) \quad (7)$$

$$i_t = \sigma(W_i[h_{t-1} \ x_t] + b_i) \quad (8)$$

$$\overline{C}_t = \tanh(W_c[h_{t-1} \ x_t] + b_c) \quad (9)$$

$$C_t = f_t C_{t-1} + i_t \overline{C}_t \quad (10)$$

$$O_t = \sigma(W_o[h_{t-1} \ x_t] + b_o) \quad (11)$$

$$h_t = O_t \tanh(C_t) \quad (12)$$

式中, x_t 、 h_t 分别为时间 t 对应的输入和隐藏状态; f_t 、 i_t 和 o_t 分别为遗忘门、输入门和输出门状态; \overline{C}_t 、 C_t 和 h_t 分别为待更新神经元和单元状态; W_f 、 W_i 、 W_c 、 W_o 和 b_f 、 b_i 、 b_c 、 b_o 分别为各个门权重矩阵和偏置项; σ 为隐藏层中的 Sigmoid 激活函数。




图 1 LSTM 神经元内部结构

Fig.1 Internal structure of LSTM neurons

2 基于自适应数据预处理和 LSTM 的预测方法

2.1 方法框架

本文提出的 RUL 估计框架如图 2 所示。

该框架涉及实现目标的三个主要阶段。

(1) 选取容量作为反映 RUL 退化趋势的健康因子, 通过自适应双指数模型平滑方法去除原始数据中由容量回升现象产生的波动, 得到退化趋势相对平稳的容量序列。

(2) 采用 CEEMDAN 分解平滑处理后的容量序列, 得到可以反映退化主趋势的残差 $R_n(t)$ 和有限个模态分量 $\overline{\text{IMF}}_k$ 。

(3) 选取残差 $R_n(t)$ 组建训练样本集, 结合 LSTM 神经网络建立容量前期与后期的映射关系, 并对未知的容量序列进行预测。通过迭代预测得到起点后每一个循环的容量预测值, 进而计算出锂离子电池 RUL。

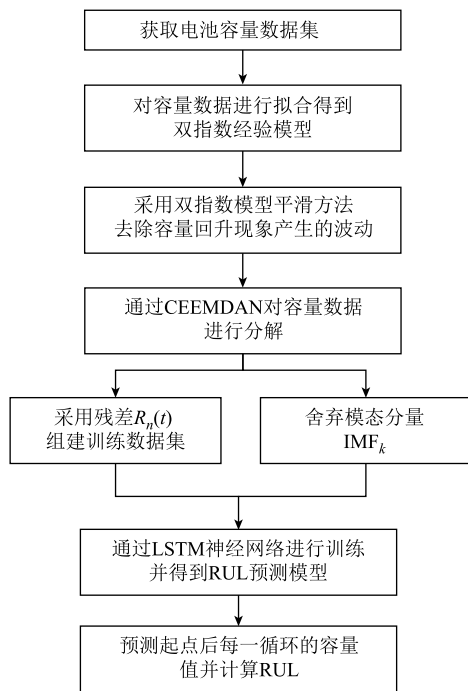


图 2 本文提出方法的预测框架

Fig.2 Prediction framework of the paper

2.2 实验数据集介绍与分析

采用两种具有不同电极材料和放电环境的锂离子电池数据集验证本文算法的性能。

第一组数据来自 NASA PCoE 研究中心的公开数据集,选取其中的 B5、B6、B7、B18 号电池作为研究对象^[30]。电池额定容量为 2A·h,在室温下进行充放电过程:首先以 1.5A 恒定电流进行充电,直到达到 4.2V 截止电压;然后继续以恒压模式充电,直到充电电流降至 20mA;最后以 2A 恒定电流进行放电,直到 B5、B6、B7、B18 电池电压分别降至 2.7V、2.5V、2.2V 和 2.5V 时停止。

第二组数据来自马里兰大学 CALCE 中心^[31]。选取标号为 A1、A2、A3 的电池作为研究对象。每个电池的额定容量为 0.9A·h,电池同样进行恒流、恒压充电与恒流放电过程。其中,恒流充电电流为 0.45A,充电截止电压为 4.2V,恒流放电电流为 0.45A,放电截止电压为 2.7V。

实验电池参数见表 1,包括充电截止电压(Charging cut-off Voltage, CV)、放电截止电压(Discharging cut-off Voltage, DV)、恒流充电电流(Constant charging Current, CC)、放电电流(Discharging Current, DC)以及失效阈值(Failure Threshold, FT,也称故障阈值)。国际标准对锂离子电池性能测试的规定为:锂离子电池在常温((25±2)℃)下保持正常工作状态,当电池实际容量降至额定容量的 80%


以下时认为电池失效,为保证系统运行的安全和可靠性需对电池进行更换^[32]。在许多研究中,失效阈值设定为额定容量的 70%~80%^[33-34]。

表 1 老化实验中的电池参数


Tab.1 Battery parameters in aging experiment					
电池编号	CV/V	DV/V	CC/A	DC/A	FT/(A·h)
B5	4.2	2.7	1.5	2	1.4
B6	4.2	2.5	1.5	2	1.4
B7	4.2	2.2	1.5	2	1.45
B18	4.2	2.5	1.5	2	1.4
A1	4.2	2.7	0.45	0.45	0.72
A2	4.2	2.7	0.45	0.45	0.72
A3	4.2	2.7	0.45	0.45	0.72

NASA 数据集的描述文件将本集中电池的失效阈值设定为 70%。同文献^[35],B5、B6、B18 号电池的失效阈值设定为 1.4A·h,考虑到 B7 号电池容量没有下降到 1.4A·h,选取 1.45A·h 作为其失效阈值。

同文献^[36],CALCE 数据集下电池 A1、A2、A3 的失效阈值定义为额定容量的 80%(0.72A·h)。两组数据集的电池容量退化曲线如图 3 所示。



(a) NASA数据集容量退化曲线



(b) 马里兰大学CALCE中心数据集容量退化曲线

图 3 电池容量退化曲线

Fig.3 Capacity degradation curves of batteries

2.3 RUL 定义和模型评估标准

电池 RUL 定义为预测起点至电池寿命结束时的剩余可使用循环数。当电池实际容量退化至失效阈值时认为电池寿命结束,设定 T 为起始循环位置, T_{EOL} 为实际状态下电池寿命结束时的所在周期数,

电池 RUL 为^[37]

$$T_{\text{RUL}} = T_{\text{EOL}} - T \quad (13)$$

电池 RUL 预测值为

$$\hat{T}_{\text{RUL}} = \hat{T}_{\text{EOL}} - T \quad (14)$$

式中, \hat{T}_{EOL} 为预测情况下电池寿命结束时的所在周期数。

采用绝对误差 (Absolute Error, AE)、平均绝对误差 (Mean Absolute Error, MAE) 和方均根误差 (Root Mean Square Error, RMSE) 作为预测模型的评价准则, 公式为

$$\text{AE} = |T_{\text{RUL}} - \hat{T}_{\text{RUL}}| \quad (15)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |x(i) - \hat{x}(i)| \quad (16)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x(i) - \hat{x}(i))^2} \quad (17)$$

式中, n 为预测循环周期数; \hat{T}_{RUL} 为 RUL 预测值; $x(i)$ 为容量真实值; $\hat{x}(i)$ 为容量预测值。需要注意的是, RMSE 是最综合的评价指标, 它可以衡量预测曲线与实际退化趋势的贴合程度。RMSE 越接近 0, 说明预测效果越好。

对于本文方法, 为证明方法稳定性, 加入 90% 置信区间 (Confidence Interval, CI) 作为评价准则。

$$\text{CI} = [L_CI, U_CI] \quad (18)$$

式中, U_CI 为 RUL90% 置信区间的上限; L_CI 为 RUL90% 置信区间的下限。 U_CI 和 L_CI 分别根据 RUL 的概率密度分布函数 (Probability Density Function, PDF) 确定。文中的 PDF 是 ABMS-CEEMDAN-LSTM 方法运行 100 次后的 RUL 预测分布。在 100 次运行条件下, 只有本文方法能够得到 PDF, 其他对比方法均有部分预测曲线未下降至失效阈值, 进而无法计算 RUL, 这从侧面反映出本文方法的鲁棒性较好。

90% 置信区间的上界是 PDF 值为 95% 时横坐标对应的循环位置, 置信区间的下界是 PDF 值为 5% 时横坐标对应的循环位置。

2.4 自适应双指数模型平滑处理

作为 RUL 预测最常用的健康因子, 电池实际容量 (最大放电容量) 可以直接描述锂离子电池老化过程, 因此本文选取容量作为反映 RUL 的退化特征。

如图 3 所示, 容量与周期数之间的关系为非线

性。因受电磁干扰、充放电倍率差异、外部环境变化以及化学反应等因素的影响, 电池老化曲线存在容量回升现象, 并且夹杂着噪声信号, 这为模型的训练过程增加了难度。必要的数据预处理可以帮助模型在训练阶段更好地学习序列信息。

为了能够去除容量曲线中的不规则波动且保留数据的原始特征, 本文提出自适应双指数模型平滑方法 (Adaptive Biexponential Model Smooth, ABMS)。使用双指数模型的拟合曲线替代容量回升区间, 达到对原始数据的选择平滑处理。ABMS 原理如图 4 所示。




图 4 ABMS 处理方法原理

Fig.4 Schematic diagram of ABMS processing method

大量研究表明^[38], 双指数模型能够更准确地描述容量的下降趋势, 表达式为

$$C_j = a \exp(jb) + c \exp(jd) \quad (19)$$

式中, j 为所在的循环位置; C_j 为第 j 循环的容量拟合值; a 、 b 、 c 、 d 为参数。通过拟合工具箱得到四个电池容量数据的双指数模型拟合曲线。 a 、 b 、 c 、 d 和曲线的拟合程度见表 2。四条拟合曲线对应的 RMSE 分别为 0.022 59、0.034 93、0.023 02 和 0.033 03, 表明所得曲线的拟合效果很好。

表 2 拟合曲线参数

电池编号	a	b	c	d	RMSE
B5	1.573	-0.1322	-4.809×10^{-4}	-3.377	0.022 59
B6	0.980 4	-0.2712	0.529 7	0.045 96	0.034 93
B7	1.633	-0.099 82	8.212×10^{-5}	3.603	0.023 02
B18	1.858	-0.002 92	1.91×10^{-4}	0.0482	0.033 03

以 B5 号电池为例, 对原始容量数据进行分析, 找出需要处理的波动区域和需要保留的平稳区域。从图 4 可以看出, “○” 形拟合曲线部分对应的是波动所在循环区间, 而实线部分对应平稳区域所在循环区间。将 “○” 形拟合曲线部分与原始数据单调递减区域进行拼接, 完成对容量数据的自适应平滑

处理, 处理效果如图 5 所示。




图 5 ABMS 处理结果

Fig.5 ABMS processing result chart

经过 ABMS 方法处理后, 电池容量曲线在保留数据原始特征的基础上消除了容量回升现象和异常值, 这使降噪分解过程的工作量相对减少, 使 CEEMDAN 方法专注于去除噪声分量, 尽量保证数据预处理的稳定性, 也减少了不确定因素对降噪过程的影响。

2.5 CEEMDAN 降噪处理

为了减少噪声信号对容量数据的负面影响, 采用 CEEMDAN 对信号进行分解, 得到有限个模态分量和残差。以 B5 号电池为例, 分解后的残差分量如图 6 所示, 模态分量如图 7 所示。对四个电池分




图 6 B5 号电池分解后的残差

Fig.6 Residual after decomposition of B5 battery




图 7 B5 号电池分解后的模态分量

Fig.7 Modal component after decomposition of B5 battery

解分量与原始容量序列进行相关性分析, 结果见表 3。(其中, B6、B7 号电池分解后未出现 IMF₅ 分量, 故表 3 对应 IMF₅ 处用符号 ‘—’ 表示。)

表 3 分解结果与容量的相关系数

Tab.3 Correlation coefficient between decomposition results and capacity

分量	B5	B6	B7	B18
IMF ₁	0.022 9	0.047 5	0.007 9	0.042 0
IMF ₂	0.083 8	0.081 4	0.014 5	0.130 9
IMF ₃	0.016 1	0.052 7	0.037 8	0.034 3
IMF ₄	-0.022 6	0.088 7	0.123 4	0.155 6
IMF ₅	0.004 6	—	—	0.246 3
残差	0.994 0	0.991 1	0.990 4	0.980 6

由图 7 可以看出, B5 号电池分解得到的模态分量与原始容量相关性极低且无规律性, 都可被视为噪声信号。由表 3 可知, 残差的相关系数比其他模态分量要大得多。从图 6 中可以看出, 残差代表了电池的主要退化趋势。因此, 本文选择分解后的残差作为降噪处理的最终结果。通过对数据流的平滑降噪处理, 避免了局部分量的干扰。

2.6 基于 LSTM 的预测模型

对原始容量平滑降噪处理后, 使用预测起点 T 将数据划分为训练集 C_{train} 和测试集 C_{test} , 分别为

$$\begin{cases} C_{\text{train}} = \{C_1, C_2, C_3, \dots, C_{T-1}, C_T\} \\ C_{\text{test}} = \{C_{T+1}, C_{T+2}, \dots, C_{n-1}, C_n\} \end{cases} \quad (20)$$

将训练数据划分为输入层和输出层, 输入层单次输入数据量由滑动窗口 L 控制, 训练集划分流程如图 8 所示。

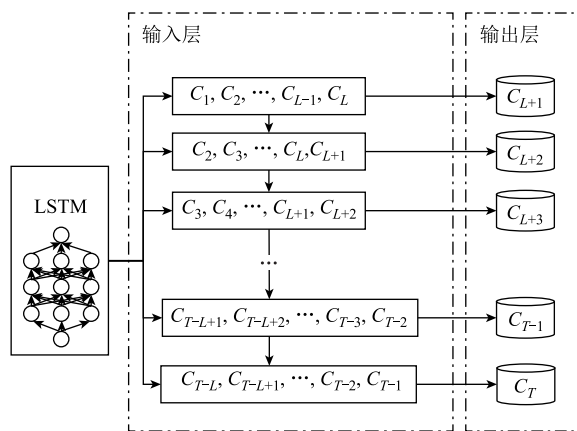


图 8 训练集划分流程

Fig.8 Training set partition process

LSTM 神经网络训练和预测流程如图 9 所示, 由于“门”结构的存在使 LSTM 可以自行判别和筛选过往信息流, 进而完成对训练集的充分学习, 最

终建立了容量前期与后期的非线性映射关系, 将训练过的 LSTM 模型表示为

$$\hat{C}_{i+1} = \text{LSTM}(C_{i-L+1}, C_{i-L+2}, \dots, C_{i-1}, C_i) \quad (21)$$

式中, \hat{C}_{i+1} 为下一循环的容量预测值。将测试集 C_{test} 作为输入数据代入式 (21) 进行迭代预测, 得出起点 T 后每一循环的容量预测值, 从而完成对 RUL 的计算。

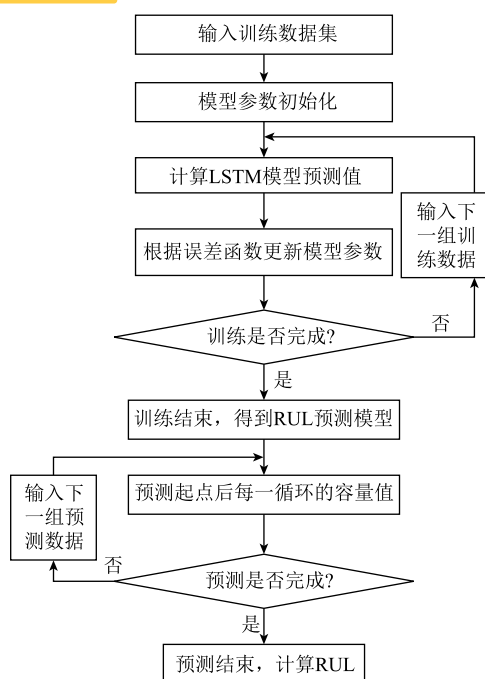


图 9 LSTM 神经网络训练和预测流程

Fig.9 The flow chart LSTM neural network training and prediction

2.7 复杂度分析

采用大 O 表示法从时间和空间这两个方面对 ABMS-CEEMDAN-LSTM 方法进行复杂度分析。本文方法主要由三种算法构成: ABMS 算法、CEEMDAN 算法和 LSTM 算法。

2.7.1 时间复杂度

时间复杂度是指执行算法所需要的计算工作量, 即时间增长趋势。

ABMS 算法本质目的是筛除原始容量序列中的不合理区间, 程序运行和数据量关联不大, 执行时间基本恒定。忽略常量、低阶、系数后复杂度表示为常量阶 $O(1)$ 。

CEEMDAN 算法由于存在双重循环嵌套的原因, 时间复杂度计为二次方阶 $O(n^2)$, 其中, n 为需要处理的容量序列总长度。

LSTM 算法在训练和预测过程中的循环数与容量序列长度呈线性关系, 随着容量序列长度的增

加, 复杂度也随之线性增加。所以复杂度用线性阶 $O(n)$ 表示。

对于本文方法, 只保留最高阶项, 最终时间复杂度的结果为 $O(n^2)$, 与容量序列长度的二次方呈正相关。

2.7.2 空间复杂度

空间复杂度是对算法在运行过程中临时占用存储空间的度量, 表示算法的存储空间与处理数据规模之间的增长关系。

对于 ABMS 算法, 算法执行过程所需要的临时空间不随着某个容量序列长度 n 的大小而变化, 复杂度表示为 $O(1)$ 。对于 CEEMDAN 算法和 LSTM 算法, 算法执行过程会为变量分配空间, 但不会因为加入循环而改变, 所以复杂度表示为 $O(n)$ 。只保留最高阶项, 最终空间复杂度的结果为 $O(n)$ 。

对于 ABMS-CEEMDAN-LSTM, 时间复杂度为二次方阶 $O(n^2)$, 说明运行的效率偏低, 耗费时间较长, 处理数据长度增加会导致运行时间的大幅度延长。但是本文中应用的数据长度适中, 所以不会对时间复杂度产生较大影响。空间复杂度为线性阶 $O(n)$, 在本文条件下, 运行所占存储空间较少, 效率较高。

综上所述, 本文方法运行时消耗的时间和空间资源在可接受范围内, 复杂度较好。

3 实验结果分析

为验证本文提出的 ABMS-CEEMDAN-LSTM 方法 (M1) 的可靠性, 设计了三种对比方法。其中, M2 为本文提出的自适应数据预处理方法与 RVM 的组合方法; M3 直接采用未处理的容量数据对 LSTM 进行建模; M4 为小波降噪 (Wavelet Denoising, WD) 与 LSTM 的组合方法。通过 M2 来展现 LSTM 在时序预测方面的准确性, M3 和 M4 则用来说明本文提出的自适应数据预处理方法的优越性。

比较标准为 AE、MAE、RMSE, 通过 NASA PCoE 电池数据集和马里兰大学 CALCE 中心的电池数据集进行实验, 每个测试电池设置两个或三个不同的预测起点, 在电池数据和起点的多样性下均获得预测效果, 检验提出方法的鲁棒性和适应性。起点 T 设置见表 4, 四种方法见表 5。

表 4 起点设置状况

电池编号	B5	B6	B7	B18	A1	A2	A3
起点 1	80	80	80	65	130	110	85
起点 2	100	100	100	75	160	140	100

表 5 方法说明

Tab.5 Methods statement

方 法	描 述
M1	ABMS-CEEMDAN-LSTM
M2	混合 RVM
M3	LSTM
M4	WD-LSTM

图 10~图 13 分别为四种方法在 NASA 数据集下的 RUL 单次预测结果, 图 14~图 16 分别为 M1、





图 10 B5 号电池 RUL 预测结果

Fig.10 RUL prediction results of B5 battery





图 11 B6 号电池 RUL 预测结果

Fig.11 RUL prediction results of B6 battery





图 12 B7 号电池 RUL 预测结果

Fig.12 RUL prediction results of B7 battery






图 13 B18 号电池 RUL 预测结果

Fig.13 RUL prediction results of B18 battery






图 14 A1 号电池 RUL 预测结果

Fig.14 RUL prediction results of A1 battery





图 15 A2 号电池 RUL 预测结果

Fig.15 RUL prediction results of A2 battery

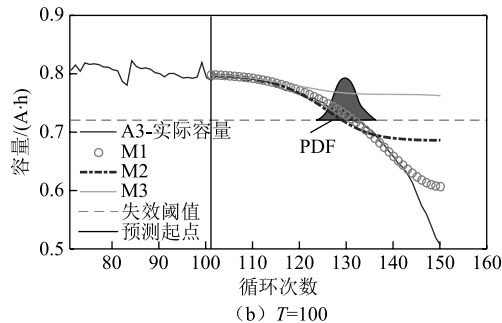



图 16 A3 号电池 RUL 预测结果

Fig.16 RUL prediction results of A3 battery

M2、M3 方法在马里兰大学 CALCE 中心数据集下的 RUL 单次预测结果。NASA 数据集下四种方法的评价指标对比见表 6, B5、B6、B7 号电池在 90 起点下的评价指标对比见表 7, CALCE 数据集下三种方法的评价指标对比见表 8。为提高说服力, 增设 100 次运行结果的 RUL 概率密度函数和 90%置信区间, 由于 M2、M3、M4 的部分运行曲线未下降至失

表 6 四种方法在 NASA 数据集下的评价指标对比

Tab.6 Comparison of evaluation indexes of four methods in NASA data set

电池	预测 起点	预测 方法	RUL 预测值	AE	MAE(%)	RMSE(%)
B5	80	M1	49	4	1.66	2.00
		M2	40	5	3.58	4.81
		M3	—	—	6.66	8.08
		M4	62	17	3.72	4.52
	100	M1	27	2	1.46	1.83
		M2	18	7	8.28	10.45
		M3	45	20	5.12	5.52
		M4	32	7	2.56	2.75
B6	80	M1	26	3	2.40	3.08
		M2	41	12	6.81	8.07
		M3	59	30	9.41	10.67
		M4	36	7	4.65	5.55
	100	M1	9	0	1.49	2.11
		M2	32	23	9.40	10.28
		M3	21	12	6.65	7.35
		M4	4	5	2.92	3.75
B7	80	M1	68	5	1.21	1.76
		M2	50	13	3.65	4.15
		M3	—	—	4.71	5.43
		M4	—	—	2.57	3.28
	100	M1	49	6	0.89	1.16
		M2	29	14	5.08	6.18
		M3	—	—	2.90	3.54
		M4	67	24	1.77	2.22
B18	65	M1	36	4	2.19	2.76
		M2	18	14	3.59	4.24
		M3	—	—	3.34	3.93
		M4	50	18	2.15	2.59
	75	M1	22	0	2.45	3.28
		M2	—	—	2.78	3.28
		M3	13	9	7.00	8.35
		M4	37	15	2.74	3.19

表 7 评价指标对比(起点为 90)-NASA

Tab.7 Comparison of evaluation indexes (the starting point is 90) -NASA

电池	预测方法	RUL 预测值	AE	MAE(%)	RMSE(%)
B5	M1	36	1	1.50	1.90
	M2	24	11	6.23	7.75
	M3	44	9	5.59	6.04
	M4	42	7	3.01	3.63
B6	M1	20	1	1.53	1.94
	M2	34	15	8.32	8.69
	M3	29	10	7.62	8.14
	M4	23	4	3.12	4.08
B7	M1	58	5	1.03	1.55
	M2	—	—	3.38	4.01
	M3	—	—	3.23	3.89
	M4	69	16	1.94	1.96

表 8 评价指标对比-CALCE

Tab.8 Comparison of evaluation indexes-CALCE

电 池	预测 起点	预测 方法	RUL 预 测值	AE	MAE(%)	RMSE(%)
A1	130	M1	75	4	0.74	1.37
		M2	—	—	5.48	8.13
		M3	78	1	1.83	3.77
	160	M1	44	5	0.80	1.00
		M2	65	16	3.98	5.84
		M3	47	2	2.72	5.24
A2	110	M1	79	0	0.47	0.89
		M2	—	—	3.99	6.92
		M3	79	0	0.66	1.74
	140	M1	49	0	0.88	1.90
		M2	—	—	6.65	9.41
		M3	—	—	3.95	6.85
A3	85	M1	45	2	1.32	1.99
		M2	—	—	5.02	8.41
		M3	—	—	4.65	7.10
	100	M1	31	1	1.18	2.45
		M2	—	—	5.77	9.13
		M3	29	3	2.67	5.23

效阈值, 导致无法计算 RUL, 所以只添加 M1 方法的 PDF 如图 10~图 16 所示, 本文方法在所有运行条件下的 RUL90%置信区间见表 9。由于比较方法 M2、M3、M4 部分预测曲线并未到达失效阈值, 未计算出 RUL 和 AE,故表 6~表 8 对应部分采用 ‘—’

表 9 本文方法在所有运行条件下的 RUL90%置信区间 (100 次运行结果)

Tab.9 The 90% confidence interval (100 run results) of this method under all running conditions

电池	预测起点	90%置信区间
B5	80	[35, 51]
	90	[26, 40]
	100	[16, 29]
B7	80	[52, 73]
	90	[41, 62]
	100	[33, 50]
A1	130	[66, 85]
	160	[36, 54]
A3	85	[37, 49]
	100	[24, 35]
B6	80	[16, 36]
	90	[10, 23]
	100	[3, 15]
B18	65	[26, 37]
	75	[15, 27]
A2	110	[70, 85]
	140	[36, 53]

表示。

通过仿真结果和评价指标对比可概括规律如下:

(1) 从图 10~图 16 中可以看出, 本文提出的方法预测趋势更接近真实的容量退化曲线, 预测精度明显优于混合 RVM、LSTM 和 WD-LSTM 方法, 观察 PDF 可知, M1 方法预测效果十分稳定, 大部分运行结果下的预测 RUL 都集中在真实值附近, 曲线对容量趋势的跟踪效果理想。

(2) 由表 6~表 8 和图 10~图 16 可知, 不同的预测起点下预测效果会有一定差异, 起点靠后情况下四种方法的预测结果明显优于起点靠前情况。起点后移意味着训练数据的增加, 模型通过学习更多的循环数据, 可以获得更精准的预测性能, 跟踪趋势则会更趋近于老化曲线。值得注意的是, 从两类电池预测结果可以看出, 训练数据集的变动基本未对本文方法预测效果产生干扰, 可以看出本文方法预测非常稳定。

(3) 对于马里兰大学 CALCE 中心的电池数据集, 三种方法的 RUL 预测曲线如图 8 所示。相比于下降趋势平缓的 NASA 数据集, A1、A2、A3 号电池容量曲线下降坡度差异明显, 趋势更加难以捕捉。

由图 14~图 16、表 8 可知,基于 ABMS-CEEMDAN-LSTM 方法的容量预测值最接近真实值。而混合 RVM 方法和 LSTM 方法的容量预测曲线在大多数情况下无法对真实退化趋势做到有效跟踪,与实际值偏差较大。结果表明,在使用退化趋势不规则的放电数据集时,M1 方法预测效果十分稳定,与 M2 方法、M3 方法相比仍具有很大的优势。电池种类和预测条件的改变基本未对 M1 方法造成干扰,反映出 M1 方法具有很好的稳定性和适应性。

(4) 由表 6~表 9 和图 10~图 16 可知,在不同种类电池和不同训练数据集下,本文提出的方法可以提供较为准确的 RUL 预测,预测曲线 MAE 和 RMSE 在 2.45%和 3.28%以内,最低为 0.47%和 0.89%。大部分条件下的 RUL90%置信区间在可接受范围内,反映了 RUL 预测的精度和可信度。以 B5 号电池为例,在起点 80、90、100 下 AE 值为 4、1、2,MAE 值为 1.66%、1.50%、1.46%,RMSE 值为 2.00%、1.90%、1.83%,三种指标均为同条件下最小。

值得一提的是,由于 B7、B18 电池容量主趋势变动幅度较大,导致该条件下 M1 预测结果 MAE 值和 RMSE 值均未达到最低值。但所有情况下 M1 的预测曲线与主趋势都非常接近,AE 值均保持较低水平,表明本文方法可以更好预测电池 RUL。

为进一步验证所提方法性能,与现有文献中提到的预测方法进行了比较,M5 为遗传算法(Genetic Algorithm, GA)和极限学习机(Extreme Learning Machine, ELM)的组合方法^[39];M6 为蚁狮算法(Ant Lion Optimization, ALO)和 SVR 的组合方法^[40];M7 为基于 Elman 神经网络的预测方法^[16],通过 MAE 和 RMSE 这两个指标来评估各方法性能。各方法的对比结果如图 17 和图 18 所示,采用 B5、B6、B7 号电池的退化数据作为它们的训练和验证集,预测起点设置为 80 和 100。可以看出,ABMS-CEEMDAN-LSTM 方法的 MAE 和 RMSE 在同条件下都是最小的,说明本文所提方法具有较高的预测精度。





图 17 四种方法 RUL 预测结果 MAE 比较

Fig.17 MAE comparison of RUL prediction results of

four methods





图 18 四种方法 RUL 预测结果 RMSE 比较

Fig.18 RMSE comparison of RUL prediction results of

four methods

4 结论

本文提出了一种由自适应数据预处理方法和 LSTM 神经网络组成的锂离子电池 RUL 预测框架。选取容量作为健康因子,采用自适应双指数模型平滑处理方法消除了原始数据中容量再生现象产生的波动,并使用 CEEMDAN 分解出容量中的噪声分量,通过预处理数据训练 LSTM 网络来构建 RUL 预测模型,选取 NASA 和 CALCE 实验数据集验证了该方法的可靠性,得出结论如下:

1) 电池在工作过程中受到各种不确定因素的影响,使采集到的数据含有大量的噪声和波动。如果

不进行数据预处理,直接采用原始数据进行建模,会使模型准确度大大降低,必要的的数据预处理过程有助于提升预测模型的准确度。

2) LSTM 神经网络更适合处理时间序列方面的问题,通过本文提出的自适应数据预处理方法,对原始容量数据进行平滑处理和降噪,使处理后的数据具有单调递减的平稳趋势。采用 LSTM 学习寿命前期的退化趋势来建立预测模型,并进行 RUL 预测,得到了更精确的结果。

3) 选取两种开源数据进行实验,在不同预测起点下,采用不同算法组合多种实验方案验证本文方法的优越性和迁移性。实验结果表明,在相同预测条件下,ABMS-CEEMDAN-LSTM 方法总能取得更好的预测效果,PDF 和 90%置信区间反映了本文方法的强鲁棒性,MAE 和 RMSE 值分别保持在 2.45% 和 3.28%以内,最低分别为 0.47%和 0.89%。

综上所述,ABMS-CEEMDAN-LSTM 方法具有更高的 RUL 预测精度,降低了预测误差,具有更好的稳定性,为现有锂电池 RUL 预测研究提供了参考。

参考文献

- [1] 王渠,熊瑞,穆浩. 温度和老化意识融合驱动的电动车辆锂离子动力电池电量和容量协同估计[J]. 电工技术学报, 2020, 35(23): 4980-4987.
Wang Ju, Xiong Rui, Mu Hao. Co-estimation of lithium-ion battery state-of-charge and capacity through the temperature and aging awareness model for electric vehicles[J]. Transactions of China Electrotechnical Society, 2020, 35(23): 4980-4987.
- [2] 范兴明,王超,张鑫,等. 基于增量学习相关向量的锂离子电池 SOC 预测方法[J]. 电工技术学报, 2019, 34(13): 2700-2708.
Fan Xingming, Wang Chao, Zhang Xin, et al. A prediction method of li-ion batteries SOC based on incremental learning relevance vector machine[J]. Transactions of China Electrotechnical Society, 2019, 34(13): 2700-2708.
- [3] 郭永芳,黄凯,李志刚. 基于短时搁置端电压压降的快速锂离子电池健康状态预测[J]. 电工技术学报, 2019, 34(19): 3968-3978.
Guo Yongfang, Huang Kai, Li Zhigang. Fast state of health prediction of lithium-ion battery based on terminal voltage drop during rest for short time[J]. Transactions of China Electrotechnical Society, 2019, 34(19): 3968-3978.
- [4] 刘芳,马杰,苏卫星,等. 基于自适应回归扩展卡尔曼滤波的电动汽车动力电池全生命周期的荷电状态估算方法[J]. 电工技术学报, 2020, 35(4): 698-707.
Liu Fang, Ma Jie, Su Weixing, et al. State of charge estimation method of electric vehicle power battery life cycle based on auto regression extended Kalman filter[J]. Transactions of China Electrotechnical Society, 2020, 35(4): 698-707.
- [5] 李超然,肖飞,樊亚翔,等. 基于卷积神经网络的锂离子电池 SOH 估算[J]. 电工技术学报, 2020, 35(19): 4106-4119.
Li Chaoran, Xiao Fei, Fan Yaxiang, et al. An approach to lithium-ion battery soh estimation based on convolutional neural network[J]. Transactions of China Electrotechnical Society, 2020, 35(19): 4106-4119: 1-10.
- [6] Kaveh K S, Xin J, Giorgio R. Prediction of remaining useful life for a composite electrode lithium-ion battery cell using an electrochemical model to estimate the state of health[J]. Journal of Power Sources, 2021, 481: 1-10.
- [7] Ji Yanju, Qiu Shilin, Li Gang. Simulation of second-order RC equivalent circuit model of lithium battery based on variable resistance and capacitance[J]. Journal of Central South University, 2020, 27(9): 2606-2613.
- [8] Chen Lin, An Jingjing, Wang Huimin, et al. Remaining useful life prediction for lithium-ion battery by combining an improved particle filter with sliding-window gray model[J]. Energy Reports, 2020, 6: 2086-2093.
- [9] 焦自权,范兴明,张鑫,等. 基于改进粒子滤波算法的锂离子电池状态跟踪与剩余使用寿命预测方法[J]. 电工技术学报, 2020, 35(18): 3979-3993.
Jiao Ziquan, Fan Xingming, Zhang Xin, et al. State tracking and remaining useful life predictive method of Li-ion battery based on improved particle filter algorithm[J]. Transactions of China Electrotechnical Society, 2020, 35(18): 3979-3993.
- [10] Zhang Kai, Zhang Peng, Sun Canfei, et al. Remaining useful life prediction of aircraft lithium-ion batteries

- based on F-distribution particle filter and kernel smoothing algorithm[J]. Chinese Journal of Aeronautics, 2020, 33(5): 1517-1531.
- [11] Qiu Xianghui, Wu Weixiong, Wang Shuangfeng. Remaining useful life prediction of lithium-ion battery based on improved cuckoo search particle filter and a novel state of charge estimation method[J]. Journal of Power Sources, 2020, 450: 1-13.
- [12] Chen Liaogehao, Zhang Yong, Zheng Ying, et al. Remaining useful life prediction of lithium-ion battery with optimal input sequence selection and error compensation[J]. Neurocomputing, 2020, 414: 245-254.
- [13] Wang Xiuli, Jiang Bin, Lu Ningyun. Adaptive relevant vector machine based RUL prediction under uncertain conditions[J]. ISA Transactions, 2019, 87: 217-224.
- [14] Li Xiaoyu, Yuan Changgui, Wang Zhenpo. Multi-time-scale framework for prognostic health condition of lithium battery using modified Gaussian process regression and nonlinear regression[J]. Journal of Power Sources, 2020, 467: 1-12.
- [15] Zhou Yapeng, Huang Miaohua. Lithium-ion batteries remaining useful life prediction based on a mixture of empirical mode decomposition and ARIMA model[J]. Microelectronics Reliability, 2016, 65: 265-273.
- [16] Li Wenhua, Jiao Zhipeng, Du Le, et al. An indirect RUL prognosis for lithium-ion battery under vibration stress using Elman neural network[J]. International Journal of Hydrogen Energy, 2019, 44(23): 12270-12276.
- [17] Wu Ji, Zhang Chenbin, Chen Zonghai. An online method for lithium-ion battery remaining useful life estimation using importance sampling and neural networks[J]. Applied Energy, 2016, 173: 134-140.
- [18] Shahid F, Zameer A, Muneeb M. A novel genetic LSTM model for wind power forecast[J]. Energy, 2021, 223: 1-11.
- [19] Li Penghua, Zhang Zijian, Xiong Qingyu, et al. State-of-health estimation and remaining useful life prediction for the lithium-ion battery based on a variant long short term memory neural network[J]. Journal of Power Sources, 2020, 459: 1-12.
- [20] Yu Yong, Hu Changhua, Si Xiaosheng, et al. Averaged Bi-LSTM networks for RUL prognostics with non-life-cycle labeled dataset[J]. Neurocomputing, 2020, 402: 134-147.
- [21] Li Xiaoyu, Zhang Lei, Wang Zhenpo, et al. Remaining useful life prediction for lithium-ion batteries based on a hybrid model combining the long short-term memory and Elman neural networks[J]. Journal of Energy Storage, 2019, 21: 510-518.
- [22] Cao Jian, Li Zhi, Li Jian. Financial time series forecasting model based on CEEMDAN and LSTM[J]. Physica A: Statistical Mechanics and its Applications, 2019, 519: 127-139.
- [23] Gao Bixuan, Huang Xiaoqiao, Shi Junsheng, et al. Hourly forecasting of solar irradiance based on CEEMDAN and multi-strategy CNN-LSTM neural networks[J]. Renewable Energy, 2020, 162: 1665-1683.
- [24] Lin Yu, Yan Yan, Xu Jiali, et al. Forecasting stock index price using the CEEMDAN-LSTM model[J]. The North American Journal of Economics and Finance, 2021, 57: 1-14.
- [25] Yao Liping, Pan Zhonglang. A new method based CEEMDAN for removal of baseline wander and powerline interference in ECG signals[J]. Optik - International Journal for Light and Electron Optics, 2020, 223: 1-13.
- [26] Torres ME, Colominas MA, Schlotthauer G, et al. A complete ensemble empirical mode decomposition with adaptive noise[C]//2011 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Prague, 2011: 4144-4147.
- [27] Wu Z, Huang N E. Ensemble empirical mode decomposition: a noise-assisted data analysis method[J]. Advances in Adaptive Data Analysis, 2009, 1(1): 1-41.
- [28] Huang N E, Zheng S, Long S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis[J]. Proceedings Mathematical Physical & Engineering Sciences, 1998, 454(1971): 903-995.
- [29] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1375-1780.
- [30] Saha B, KG. Battery data set. Battery data set. NASA Ames Prognostics Data Repository[DB/OL]. NASA

- Ames Research Center, Moffett Field, CA 2017, <https://ti.arc.nasa.gov/tech/dash/groups/pcoe/prognostic-data-repository>.
- [31] Sun Xiaofei, Zhong Kai, Han Min. A hybrid prognostic strategy with unscented particle filter and optimized multiple kernel relevance vector machine for lithium-ion battery[J]. Measurement, 2021, 170: 1-14.
- [32] Wang Haiyang, Song Wanqing, Zio E, et al. Remaining useful life prediction for lithium-ion batteries using fractional brownian motion and fruit-fly optimization algorithm[J]. Measurement, 2020, 161: 1-9.
- [33] Wei Jingwen, Dong Guangzhong, Chen Zonghai. Remaining useful life prediction and state of health diagnosis for lithium-ion batteries using particle filter and support vector regression[J]. IEEE Transactions on Industrial Electronics, 2018, 65(7): 5634-5643.
- [34] Li Naipeng, Lei Yaguo, Yan Tao, et al. A Wiener process model-based method for remaining useful life prediction considering unit-to-unit variability[J]. IEEE Transactions on Industrial Electronics, 2019, 66(3): 2092-2101.
- [35] Severson K A, Attia P M, Jin N, et al. Data-driven prediction of battery cycle life before capacity degradation[J]. Nature Energy, 2019, 4(5): 383-391.
- [36] Ma Guijun, Zhang Yong, Cheng Cheng, et al. Remaining useful life prediction of lithium-ion batteries based on false nearest neighbors and a hybrid neural network[J]. Applied Energy, 2019, 253: 1-11.
- [37] Hu Yang, Piero B, Francesco D M. A particle filtering and kernel smoothing-based approach for new design component prognostics[J]. Reliability Engineering and System Safety, 2015, 134: 19-31.
- [38] Zhang Xin, Miao Qiang, Liu Zhiwen. Remaining useful life prediction of lithium-ion battery using an improved UPF method based on MCMC[J]. Microelectronics Reliability, 2017, 75: 288-295.
- [39] 陈则王, 李福胜, 林娅, 等. 基于 GA-ELM 的锂离子电池 RUL 间接预测方法[J]. 计量学报, 2020, 41(6): 735-742.
- Chen Zewang, Li Fusheng, Lin Ya, et al. Indirect prediction method of RUL for lithium-ion battery based on GA-ELM[J]. Acta Metrologica Sinica, 2020, 41(6): 735-742.
- [40] 王瀛洲, 倪裕隆, 郑宇清, 等. 基于 ALO-SVR 的锂离子电池剩余使用寿命预测[J]. 中国电机工程学报, 2021, 41(4): 1445-1457, 1550.
- Wang Yingzhou, Ni Yulong, Zheng Yuqing, et al. Remaining useful life prediction of lithium-ion batteries based on support vector regression optimized and ant lion optimizations[J]. Proceedings of the CSEE, 2021, 41(4): 1445-1457, 1550.

作者简介

黄 凯 男, 1980 年生, 博士, 副教授, 硕士生导师, 研究方向为储能与动力电池组测试与建模、电池组性能状态预测与可靠性估计。

E-mail: huangkai@hebut.edu.cn

郭永芳 女, 1979 年生, 博士, 副教授, 硕士生导师, 研究方向为智能算法、锂离子电池建模与寿命估计。

E-mail: guoyongfang@hebut.edu.cn (通信作者)

(编辑 赫蕾)