

引用格式: 耿鑫月, 胡昌华, 郑建飞, 等. 双时间尺度下基于 Transformer 的锂电池剩余寿命预测[J]. 空间控制技术与应用, 2023, 49(4): 119–126. GENG X Y, HU C H, ZHENG J F, et al. Remaining useful life prediction of lithium batteries based on transformer under the dual time scales [J]. Aerospace Control and Application, 2023, 49(4): 119–126 (in Chinese). doi: 10.3969/j.issn.1674-1579.2023.04.013

双时间尺度下基于 Transformer 的锂电池剩余寿命预测

耿鑫月*, 胡昌华, 郑建飞, 裴 洪

火箭军工程大学, 陕西 710025

摘 要: 准确预测锂离子电池剩余使用寿命对于掌握其健康状况和管理备件资源具有重要作用. 现有锂电池剩余寿命预测方法大多局限于以循环次数为主的预测结果, 本质上属于面向单一时间尺度的方法, 忽略了锂电池健康状态受循环次数与工作时长双重时间尺度下的退化综合影响的现实问题. 提出一种双时间尺度下基于 Transformer 的锂电池 RUL 预测模型. 该方法选取容量作为表征其性能退化的关键指标, 通过 Kalman 滤波和滑动时间窗对电池容量数据进行处理获取训练集和测试集, 有效提取双时间尺度中蕴含的寿命信息, 并充分考虑不同时间尺度寿命信息间的相互关系, 建立容量与双重时间尺度的映射关系, 实现了锂电池在双时间尺度下的 RUL 准确预测. 通过锂电池实例验证了所提方法的有效性和潜在应用价值.

关键词: 深度学习; 双时间尺度; Transformer 网络; RUL 预测

中图分类号: TM911

文献标志码: A

文章编号: 1674-1579(2023)04-0119-08

0 引 言

作为具有高储能的新型电池, 锂离子电池由于其快速充电速度、长使用寿命、高能量密度和无记忆效应等特点, 广泛应用于电动汽车、电子设备和无人机等领域^[1-2]. 然而, 随着充放电次数的增多以及工作时长累积, 电池的容量呈下降趋势^[3]. 预测和健康管理的 (prognostics and health management, PHM) 技术是确保电子设备安全和可靠的必要条件, 其中, 电池剩余寿命 (remaining useful life, RUL) 预测是健康管理的先要条件^[4]. 为确保锂电池运行的安全性和可靠性, 预先的 RUL 预测对锂电池的维护和更换提供关键性的信息^[5].

现有锂电池 RUL 预测方法主要分为两类^[6-7]: 传统建模的方法^[8]、数据驱动的方法^[9]. 数据驱动的方法不要求掌握关于锂电池运行原理的先验知

识, 可以利用电池的监测数据直接进行建模, 从监测数据中获得电池的潜在退化规律, 进而预测其 RUL^[10-11]. 对比传统建模方法而言, 数据驱动的方法使用更加便捷, 普适性更高. 数据驱动方法分支中的深度学习具有学习复杂以及高层次特征的能力^[12], 可以更好地适应锂电池的复杂变化和使用情况, 广泛应用于锂电池 RUL 预测中. 史永胜等^[13]结合经验模态分解与长短期记忆 (long short-term memory, LSTM) 网络将锂电池退化趋势分解为若干局部和主退化趋势, 实现锂电池的寿命预测. ZHANG 等^[14]通过递归神经网络 (recurrent neural network, RNN) 和 LSTM 网络捕获退化容量之间潜在的长期依赖关系, 构建锂电池 RUL 预测模型. REN 等^[15]针对锂电池退化数据量不足等提出改进 (convolution neural network, CNN) 和 LSTM 网络, 挖掘有限数据中的深层信息.

现有关于锂电池 RUL 预测的研究中, 通常使用

收稿日期: 2023-05-27; 录用日期: 2023-08-10

基金项目: 国家自然科学基金资助项目 (62227814、61833016 和 62103433)、陕西省科协青年人才托举计划项目 (20230127) 和中国博士后科学基金面上项目 (2023M7342286)

* 通信作者: E-mail: 15229406642@163.com

RNN 网络和 CNN 网络进行学习与预测。然而,使用基于 RNN 框架以循环方式对时间序列数据进行建模,会产生较高的时间成本,并且还会由于长期依赖而降低网络预测性能;而 CNN 网络受到卷积核大小的限制,在对时序特征的处理方面存在不能得到长距离特征的问题。并且,上述文献仅考虑了循环次数单一时间尺度下锂电池的性能退化,忽略了工作时长这一时间尺度下锂电池的性能退化。然而,实际工程中,锂电池在运行过程中的性能退化是由循环次数与工作时长两个时间尺度下的退化耦合作用的。循环使用次数是指电池充放电次数,每个循环都会造成电池性能一定程度的退化,如容量降低、内阻增加和温度升高等。电池的退化速率取决于电池的放电深度、充电速率等,充电速率越高,性能退化越快。工作时长是指电池使用时长,随着电池使用时长的增多以及不规范使用造成的长时间放电和充电,将会导致电池温度的升高以及内部化学反应的加剧,电池内部部件将会承受更多的应力。因此,仅考虑循环次数下锂电池的性能退化,将很难利用到不同时间尺度中包含的寿命信息,对 RUL 预测结果的精确度有所影响,也会导致电池的 RUL 信息不全面,进一步,影响后续健康管理与维护策略的制定。

为解决上述问题,本文采用 VASWANI 等^[16]提出的一种基于自我注意力机制的网络模型 Transformer 网络,以应对 RNN 网络与 CNN 网络在 RUL 预测方面的局限性;并且,本文综合考虑了锂电池运行过程中两种时间尺度中蕴含的寿命信息,进一步提出了双时间尺度下基于 Transformer 网络的锂电池 RUL 预测模型,该模型以锂电池容量为网络输入,剩余循环寿命和剩余工作时长为网络输出,建立了容量与双重时间尺度的映射关系,引入的 Transformer 网络不仅可以有效地学习时间序列中的变化趋势,而且其多头注意力机制可以学习锂电池容量退化的长期依赖性,加速网络的训练性能。最后,通过马里兰大学公开数据集中的 CS2 锂电池数据集实例对比验证了该模型的有效性。

1 Transformer 网络简介

Transformer 网络在 2017 年首次被提出,此网络不仅可以有效学习时间序列的长期依赖性,还可以采用并行运算提高运行效率,在自然语言处理领域

具有显著成果。近年来,Transformer 网络也逐渐被应用于 RUL 预测研究上,比如: DING 等^[17]基于 Transformer 网络编码器,将注意力机制的全局上下文捕获与卷积操作的局部依赖性建模相结合,有效提高了退化的特征提取能力。MO 等^[18]将单独的卷积单元与每个时间步局部上下文信息结合,并利用 Transformer 网络编码器层作为主要预测网络,取得良好的预测结果。

标准的 Transformer 网络是一个由编码器和解码器组成的序列到序列的结构。Transformer 网络的输入序列被编码器映射至一个更高维的向量中,进一步,将向量通过解码器生成一个输出序列。与 RNN 网络的不同之处在于,Transformer 网络通过多头注意力机制建立长期依赖关系。本文利用 Transformer 网络的编码器从电池的监测数据中获取了容量退化的长期依赖性,以及容量退化与不同时间尺度下 RUL 的相互关系,使用一个全连接层对编码器输出进行预测,获得网络的输出结果,其结构如图 1 所示。

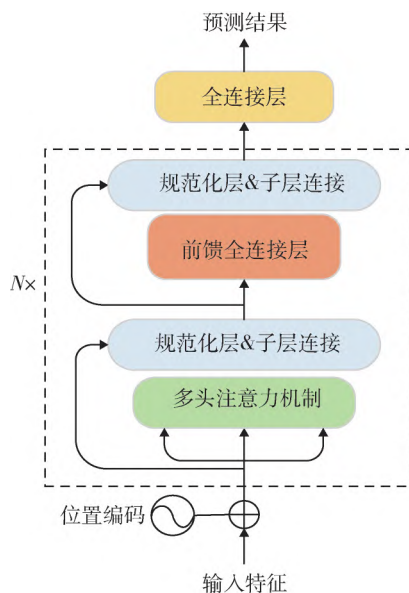


图 1 Transformer_Encode 结构

Fig. 1 Structure of the Transformer_Encode

由图 1 可以看出,每个编码器层由多个结构相同的子编码器堆叠组成。单个子编码器由位置编码层、多头注意力机制层和前馈全连接层构成,且都经过规范化处理,采用残差连接,可有效防止梯度消失,加速模型收敛。在本文中,提出了一种基于 Transformer 解码器的 RUL 预测模型,充分高效地获取锂电池容量中的退化趋势,并建立其与双重时间

尺度的映射关系.

2 双时间尺度下基于 Transformer 网络的 RUL 预测

为应对大多数现有的基于 RNN 网络预测方法的限制,提出了基于 Transformer 的深度学习模型,包括数据预处理、预测和输出层,其体系结构如图 2 所示. 此预测模型的主要目标是从锂电池历史退化数据中获取其运行过程中所包含的双时间尺度寿命信息,进一步得到锂电池剩余循环次数和剩余工作时长. 图中 $x_t = \{x_t(1), x_t(2), \dots, x_t(n)\}$, 表示设备在 t 时刻长度为 n 的输入序列, \hat{y}_t 代表 t 时刻的输出预测向量.

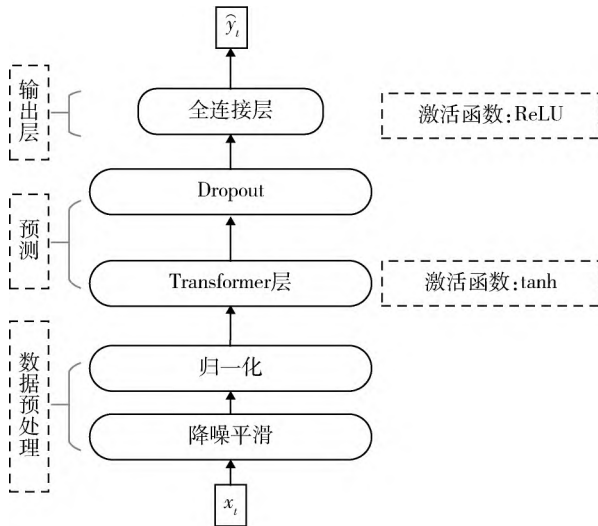


图 2 双时间尺度下基于 Transformer 网络的锂电池 RUL 预测模型

Fig. 2 Lithium battery RUL prediction model based on Transformer network under dual time scales

2.1 数据预处理

数据预处理包括两部分: 第一步是对数据进行平滑处理, 去除数据的异常点; 本文采用卡尔曼滤波对原始数据进行降噪处理, 提高数据的平滑度. 第二步即为归一化处理, 为了减少输入数据分布变化对网络模型的影响, 需对数据进行归一化处理, 本文采用 min-max 归一化法对数据进行处理. 设 $x_t = \{x_t(1), x_t(2), \dots, x_t(n)\}$, 表示长度为 n 的输入序列, 令 x_t 被映射到 $[0, 1]$

$$x'_t = \frac{x_t - \min(x)}{\max(x) - \min(x)} \quad (1)$$

式中, x_t 为设备在 t 时刻的退化监测数据, $\min(x)$

和 $\max(x)$ 分别为设备所有时刻监测数据的最小值和最大值, x'_t 是归一化后的数据.

2.2 Transformer 模型搭建

本文利用 Transformer 编码器从电池运行历史数据中学习容量退化的长期依赖性. Transformer 层有两个子层: 多头注意力层和前馈全连接层, 为了充分考虑序列的位置信息, 利用基础的位置编码对序列进行了一些相对的位置标记. 采用了不同频率的正弦和余弦函数进行位置标注

$$\begin{cases} P_j^{2k} = \sin(j/10000^{2k/d_{\text{model}}}) \\ P_j^{2k+1} = \cos(j/10000^{2k/d_{\text{model}}}) \end{cases} \quad (2)$$

$$X_t = x'_t + P_j \quad (3)$$

式中, P_j 为关于时间步长 j 的位置编码, d_{model} 为输入序列 x'_t 维度, X_t 是经过位置编码处理后的输出序列.

多头注意力层的目的是捕获特征之间的依赖关系. 多头注意力层将位置编码层输出序列 X_t 划分为多组, 并对每组通过独立的自注意力机制处理. 在每组中, 输入序列被转换为 3 个向量: 查询向量、键向量和价值向量. 然后, 计算查询向量和键向量之间的注意力得分, 并将得分用于对价值向量进行加权. 进一步, 将加权的价值向量连接和转换, 产生注意力机制的输出. 最后, 把每组自注意力机制的结果拼接起来进行一次线性变换获得输出序列. 给出第 $L-1$ 层多头注意力机制的表达

$$\begin{cases} Q = X_t W^Q \\ K = X_t W^K \\ V = X_t W^V \end{cases} \quad (4)$$

$$\text{head}_i = \text{Attention}(Q, K, V) \quad (5)$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK}{\sqrt{d_k}}\right)V \quad (6)$$

$$\text{MultiHead}(H^{L-1}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^o \quad (7)$$

式中, Q 代表查询向量, K 是键向量, V 是价值向量, $W^{(\cdot)}$ 代表不同的权重值, H^{L-1} 表示第 $L-1$ 层的注意力函数. 其中, $W_i^Q \in \mathbf{R}^{d_{\text{model}} \times d_k}$, $W_i^K \in \mathbf{R}^{d_{\text{model}} \times d_k}$, $W_i^V \in \mathbf{R}^{d_{\text{model}} \times d_v}$, $W^o \in \mathbf{R}^{d_{\text{model}} \times h d_v}$ 是一个可训练的权重, h 代表多头注意力机制头数, 且 $d_k = d_v = d_{\text{model}}/h$, 可以避免产生极小的梯度.

前馈全连接层由两个线性变换组成, 中间包含一个 ReLU 激活函数. 前馈全连接层的加入可以增强模型学习输入序列前后间的复杂的非线性关系的能力. 非线性激活函数允许层学习输入特征之间

的相互作用,而线性变换允许层学习输入序列中不同位置的不同权重。为防止注意力机制对复杂过程的拟合度不够,加入前馈网络增加非线性表达能力,进而增强模型的能力。从上一层多头注意力层得到

$$H^L = \text{FFN}(\text{MultiHead}(H^{L-1})),$$

$$\text{FFN}(\cdot) = w_2 \cdot \text{ReLU}(w_1 \cdot \cdot + b_1) + b_2 \quad (8)$$

在网络的每个子层后加入一个规范化层,因为随着网络层数增加,网络的计算参数会出现偏大或偏小的情况,有可能会引发网络学习异常,模型收敛速度减缓。因此,引入规范化层对数值进行归一化操作,使其特征值在合理范围。

2.3 锂电池 RUL 预测

网络的输出层为一个全连接层,利用全连接层来映射网络学习获得的剩余寿命信息,进而获得最终的预测结果,锂电池剩余循环次数和剩余工作时长。

$$\hat{y}_t = f(W_p H^L + b_p) \quad (9)$$

式中, W_p 、 b_p 、 H^L 和 $f(\cdot)$ 分别代表预测层的权重、偏差、输入和映射函数, \hat{y}_t 代表 t 时刻的输出预测向量。

2.4 损失函数的定义与训练

在模型训练和学习过程中使用均方误差(mean squared error, MSE) 来评估损失,目标函数定义如下:

$$\text{loss} = \frac{1}{n} \|\hat{y}_t - y_t\|_2^2 + \lambda \Psi(\Theta) \quad (10)$$

式中, n 表示数据总数, \hat{y}_t 表示锂电池第 t 时刻的 RUL 预测值, y_t 表示锂电池第 t 时刻的 RUL 真实值, λ 表示正则化参数, $\Psi(\cdot)$ 表示正则化函数, Θ 表示模型的学习参数。本文采用 Adam 作为最小化损失函数的优化器,Adam 依据动量的思想进行随机梯度下降,迭代更新每次计算梯度的一阶矩和二阶矩,并算出滑动平均数据,进一步更新当前的参数。

3 实例验证和结果分析

3.1 数据集介绍

本文选取美国马里兰大学先进寿命周期工程中心(center for advanced life cycle engineering, CALCE)公开的 CS2 型号电池数据集^[19-20],来验证本文所提基于 Transformer 的双时间尺度设备 RUL 预测模型。将 Arbin BT2000 锂电池系统应用于锂电池退化实验中。室温下将额定容量为 1.1Ah 的 CS2 锂离子电池在 0.55A 的恒定电流下充电,直至达到

额定电压 4.2 V,在 1.1 A 的恒定电流下放电,直至电压降到 2.7 V。数据集中共包含 4 块电池数据:CS2_35、CS2_36、CS2_37 和 CS2_38,数据结构在室温下由电流、电压、运行循环、工作时长和容量 5 种形式构成,其主要测试数据如表 1 所示,不同时间尺度下容量衰减趋势如图 3 所示。

表 1 CS2 电池主要测试数据

Tab. 1 CS2 Lithium-ion battery main test data

电池型号	运行循环/周期	工作时长/天
CS2_35	881	110.53
CS2_36	935	112.09
CS2_37	971	119.32
CS2_38	995	125.26

3.2 数据预处理

数据集中部分电池数据由于测量误差等因素存在异常值,首先对原始数据进行卡尔曼滤波,去除数据中的异常点。然后,采取 min-max 归一化方法对电池容量数据、循环次数以及工作累计时长进行归一化操作,进一步使用滑动时间窗方法生成固定长度的训练样本。设置时间窗长度为 32,步长为 1,每组数据包含训练集、测试集和 RUL 标签 3 部分,训练集和测试集为锂电池的容量数据,RUL 标签为锂电池循环使用次数和锂电池累计工作时长。最后,把经上述预处理的数据输入到 Transformer 网络进行 RUL 预测。

3.3 超参数设置

使用网格搜索法选取网络的最优参数,Transformer 网络的主要参数设置如表 2。

使用表 2 中最优参数,将经处理的训练集输入模型中进行训练和预测。在训练过程中,使用 CS2_36、CS2_37 和 CS2_38 的全部数据和 CS2_35 的前 32 个数据作为训练集进行训练,选用 CS2_35 后 848 个数据作为测试集;采用 Adam 优化器对模型权值进行优化。

3.4 剩余寿命预测

为验证本文所提双时间尺度 Transformer 模型的优越性,引入 3 类常用于时间序列学习的网络模型,即 GRU、LSTM 以及 Bi-LSTM。首先,基于本文所提网络模型验证双时间尺度 RUL 预测相较于单时间尺度 RUL 预测的精确性。然后,再分别实现每种网络考虑双时间尺度下的性能退化预测锂电池 RUL,进一步验证本文使用网络模型的优越性。5 种

RUL 预测方法,分别记为方法 1~5.方法 1 为本文所提 Transformer 网络仅考虑单时间尺度下的性能退化去预测其 RUL;方法 2~5 为 4 种网络考虑双时间尺度协同下的退化进行 RUL 预测,且方法 5 即为本文所提方法.




图 3 CS2 型号电池容量退化轨迹

Fig. 3 Model CS2 battery capacity degradation trajectory

(1) 预测模型对比试验

图 4 给出了仅考虑单时间尺度和同时考虑双时间尺度下的退化,并通过本文所用 Transformer 网络预测方法在一次全测试循环进行 RUL 预测的结果对比图.

表 2 网络参数设置

Tab. 2 Network parameter settings

Transformer 网络参数	数值
网络结构	32-32-128-2
训练次数	500
时间窗	32
优化器	Adam
学习率	0.01
自注意力机制头数	8
Dropout	0.1




图 4 基于 Transformer 的锂电池 RUL 预测结果对比

Fig. 4 Comparison of lithium battery RUL prediction results based on Transformer

从图 4 可以看出,锂电池 RUL 预测结果与退化数据有关,尽管在预测前期预测值波动比较大,但随着获取的退化数据的累积,单时间尺度和双时间尺度模型的预测结果在预测后期都不再发散,收敛在 RUL 真实值附近.同时,本文所提模型的 RUL 预测结果在预测后期更加接近 RUL 真实值.仅考虑单时间尺度的 RUL 预测结果在预测后期大多小于 RUL 真实值,表明仅考虑单一时间尺度下的性能退化往往会低估 RUL,因为没有考虑到另一个时间尺度的退化和寿命信息.由此可得,考虑双时间尺度对退化影响的建模更符合实际工程使用情况,可有效的提高锂电池剩余寿命预测的准确度.

(2) 不同网络对比试验

为定量分析不同网络模型的性能,本文引入两个评价指标,均方根误差 (root mean squared error, RMSE) 和平均绝对误差 (mean absolute error, MAE) 作为评估模型 RUL 预测是否准确的指标.

RMSE 计算公式为

$$\text{RMSE} = \sqrt{\frac{1}{n} \|\hat{y}_i - y_i\|_2} \quad (11)$$

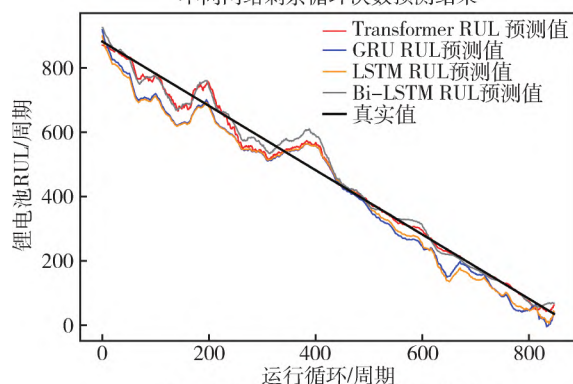
MAE 计算公式为

$$\text{MAE} = \frac{1}{n} \|\hat{y}_i - y_i\|_1 \quad (12)$$

式中, n 表示数据总数, \hat{y}_i 表示锂电池第 i 时刻的 RUL 预测值, y_i 表示锂电池第 i 时刻的 RUL 真实值。


方法 2~5 将本文所提 Transformer 网络模型与 GRU、LSTM 以及 Bi-LSTM 4 种方法在 CS2_35 数据集上的单步预测结果进行对比, 损失通过 RMSE 和 MAE 来表示, 表 3 给出了预测最终趋于稳定时 4 种方法预测结果的损失值。图 5 给出了不同网络下基于双时间尺度影响下锂电池剩余寿命预测图。图 5 (a) 是考虑锂电池工作时长影响的锂电池剩余循环次数预测结果, 图 5 (b) 表示考虑锂电池循环寿命影响的锂电池剩余工作时长预测结果。

不同网络剩余循环次数预测结果



(a) 锂电池剩余循环次数预测结果对比

不同网络剩余工作时长预测结果



(b) 锂电池剩余工作时长预测结果对比

图 5 不同网络双时间尺度下的锂电池 RUL 预测结果对比

Fig. 5 Comparison of lithium battery RUL prediction results under dual time scales of different networks

通过对比图 5 中预测结果和表 3 中的误差值得, 预测后期本文所提方法和 RUL 真值相差较小,

从 RMSE 和 MAE 对比, 本文所提基于 Transformer 的预测方法的预测误差均为最低。相对于基于 GRU 和 LSTM 的预测方法, 基于 Bi-LSTM 网络的预测方法从前后两个方向上对时间相关性进行学习, 因此, 其 RMSE 和 MAE 相对更小一些。而本文所提的 Transformer 网络预测模型, 进一步提高了 RUL 预测的精度, 这得益于 Transformer 网络的多头注意力机制层可以有效学习电池容量退化过程中的长期依赖性, 大大提高网络的预测性能。

表 3 不同方法双时间尺度下的 RUL 预测结果对比

Tab. 3 Comparison of RUL prediction results on dual time scales of different methods

预测方法	RMSE	MAE
GRU	0.068 1	0.042 4
LSTM	0.063 9	0.041 8
Bi-LSTM	0.044 2	0.030 2
Transformer	0.036 1	0.029 8

4 结 论

针对锂电池运行过程中的性能退化由多时间尺度下的退化协同作用这一问题, 本文提出一种基于 Transformer 网络的双时间尺度剩余寿命预测模型。其中应用卡尔曼滤波对原始数据中的异常点进行滤波, 提升数据的平滑度。进一步应用 Transformer 网络有效学习锂电池容量衰减中的退化趋势, 利用网络结构中的多头注意力机制层学习锂电池容量退化的长期依赖性, 提高网络的预测性能。经实例验证, 相比仅考虑单时间尺度影响的预测模型, 本文所提预测模型具有更好的预测精度, 并且此网络模型对比基于 RNN 基本框架的预测模型而言, 可以有效降低长期依赖性对网络预测模型的影响。未来将进一步研究多状态影响下锂电池的性能退化对双时间尺度剩余使用寿命的影响, 以提高锂电池 RUL 预测的精确度。

参 考 文 献

- [1] 陈洪伟, 张新华, 和阳, 等. 航天器能源管理技术研究进展 [J]. 空间控制技术与应用, 2019, 45 (5): 63-71.
CHEN H W, ZHANG X H, HE Y, et al. Research progress of spacecraft energy management technology [J]. Aerospace Control and Application, 2019, 45 (5): 63-71.

- [2] 熊庆 邱振国 汲胜昌. 锂离子电池健康状态估计及寿命预测研究进展综述[J]. 高电压技术, 2023: 1-14.
XIONG Q, DI Z G, JI S C. Review of research progress on state of health estimation and life prediction of lithium-ion batteries[J]. High Voltage Engineering, 2023: 1-14.
- [3] 刘月峰 张公 张晨荣 等. 锂离子电池 RUL 预测方法综述[J]. 计算机工程, 2020 46(4): 11-18.
LIU Y F, ZHANG G, ZHANG C R, et al. Review of RUL prediction methods for lithium-ion batteries[J]. Computer Engineering, 2020, 46(4): 11-18.
- [4] 李彦夫 韩特. 基于深度学习的工业装备 PHM 研究综述[J]. 振动. 测试与诊断, 2022 42(5): 835-847.
LI Y F, HANT T. Review of PHM research on industrial equipment based on deep learning[J]. Journal of Vibration, Measurement & Diagnosis, 2022, 42(5): 835-847.
- [5] QU J, LIU F, MA Y, et al. A neural-network-based method for RUL prediction and SOH monitoring of lithium-ion battery[J]. IEEE Access, 2019(7): 87178-87191.
- [6] 王帅 韩伟 陈黎飞 等. 锂离子电池健康管理问题研究综述[J]. 电源技术, 2020 44(6): 920-923.
WANG S, HAN W, CHEN L F, et al. Review of research on health management of lithium-ion batteries[J]. Chinese Journal of Power Sources, 2020, 44(6): 920-923.
- [7] 梁新成 宋胜 张勉 等. 几种方法在锂电池 RUL 预测中的对比研究[J]. 电源技术, 2022 46(6): 643-646.
LIANG X C, SONG S, ZHANG M, et al. Comparative study of several methods in lithium battery RUL prediction[J]. Chinese Journal of Power Sources, 2022, 46(6): 643-646.
- [8] 刘潺 陈立平 屈严 等. 模型数据混合驱动的航天器健康监测技术[J]. 空间控制技术与应用, 2023 49(1): 121-129.
LIU C, CHEN L P, QU Y, et al. Spacecraft health monitoring technology driven by model data hybrid[J]. Aerospace Control and Application, 2023, 49(1): 121-129.
- [9] 张若可 郭永芳 余湘媛 等. 基于数据驱动的锂离子电池 RUL 预测综述[J/OL]. 电源学报, 2023: 1-15.
ZHANG R K, GUO Y F, YU X Y, et al. Review of data-driven RUL prediction of lithium-ion battery[J]. Journal of Power Supply, 2023: 1-15.
- [10] 郑建飞 胡昌华 司小胜 等. 考虑不完全维护影响的随机退化设备剩余寿命预测[J]. 电子学报, 2017 45(7): 1740-1749.
ZHENG J F, HU C H, SI X S, et al. Remaining useful life prognostic for the stochastic degradation device subject to imperfect maintenance[J]. Acta Electronica Sinica, 2017, 45(7): 1740-1749.
- [11] 刘月峰 赵光权 彭喜元. 多核相关向量机优化模型的锂电池剩余寿命预测方法[J]. 电子学报, 2019, 47(6): 1285-1292.
LIU Y F, ZHAO G Q, PENG X Y. A lithium-ion battery remaining using life prediction method based on multi-kernel relevance vector machine optimized model[J]. Acta Electronica Sinica, 2019, 47(6): 1285-1292.
- [12] 李京峰 陈云翔 项华春 等. 基于 LSTM-DBN 的航空发动机剩余寿命预测[J]. 系统工程与电子技术, 2020 42(7): 1637-1644.
LI J F, CHEN Y X, XIANG H C, et al. Remaining useful life prediction for aircraft engine based on LSTM-DBN[J]. Systems Engineering and Electronics, 2020, 42(7): 1637-1644.
- [13] 史永胜 施梦琢 丁恩松 等. 基于 CEEMDAN-LSTM 组合的锂离子电池寿命预测方法[J]. 工程科学学报, 2021 43(7): 985-994.
SHI Y S, SHI M Z, DING E S, et al. Life prediction method of lithium-ion battery based on CEEMDAN - LSTM combination[J]. Chinese Journal of Engineering, 2021 43(7): 985-994.
- [14] ZHANG Y, XIONG R, HE H, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries[J]. IEEE Transactions on Vehicular Technology, 2018, 67(7): 5695-5705.
- [15] REN L, DONG J, WANG X, et al. A data-driven auto-CNN-LSTM prediction model for lithium-ion battery remaining useful life[J]. IEEE Transactions on Industrial Informatics, 2021, 17(5): 3478-3487.
- [16] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. New York: Curran Associates Inc., 2017: 6000-6010.
- [17] DING Y, JIA M. A convolutional transformer architecture for remaining useful life estimation[C]//Global Reliability and Prognostics and Health Management. New York: IEEE, 2021.
- [18] MO Y, WU Q, LI X, et al. Remaining useful life estimation via transformer encoder enhanced by a gated con-

- volutional unit [J]. Journal of Intelligent Manufacturing , 2021 , 32 (7) : 1997-2006.
- [19] PECHT M , OSTERMAN M. Battery research data , center for advanced life cycle engineering [EB/OL]. [2022-12-23]. <https://web.calce.umd.edu/batteries/data.htm>.
- [20] HE W , WILLIARD N , OSTERMAN M , et al. Prognostics of lithium-ion batteries based on Dempster-Shafer theory and the Bayesian Monte Carlo method [J]. Journal of Power Sources , 2011 , 196 (23) : 10314-10321.
- 作者简介: 耿鑫月(1999—),女,硕士研究生,研究方向为基于深度学习的设备寿命预测; 胡昌华(1966—),男,教授,研究方向为复杂系统故障诊断,寿命预测与容错控制; 郑建飞(1980—),男,副教授,研究方向为预测与健康管理、剩余寿命估计; 裴洪(1992—),男,讲师,研究方向为预测与健康管理、剩余寿命智能预测。

Remaining Useful Life Prediction of Lithium Batteries Based on Transformer Under the Dual Time Scales

GENG Xinyue^{*} , HU Changhua , ZHENG Jianfei , PEI Hong

Rocket Force University of Engineering , Shaanxi 710025 , China

Abstract: Accurately predicting the remaining useful life (RUL) of lithium batteries plays an important role in understanding their health and managing spare parts resources. Most of the existing lithium battery remaining life prediction methods are limited to the prediction results based on the number of cycles. It is essentially a method oriented to a single time scale , ignoring the practical problem that the health state of lithium batteries is affected by the dual time scales of cycle times and working time. In view of this , this article proposes a lithium battery RUL prediction model based on Transformer under the dual time scales. This method selects the capacity as a key index to characterize its performance degradation. The battery capacity data is processed to obtain training sets and test sets through Kalman filtering and sliding time window. The life information contained in the dual time scales , and fully consider the interrelationship between the life information of different time scale , further , establish a mapping relationship between the capacity and the dual time scales , so as to realize the accurate prediction of the RUL of the lithium battery at the dual time scale. Finally , the effectiveness and potential application value of the proposed method are verified by lithium battery examples.

Keywords: deep learning; dual time scale; transformer network; RUL prediction

Received: 2023-05-27; Accepted: 2023-08-10

Foundation items: National Nature Science Foundation of China (62227814 , 61833016 and 62103433) , Shaanxi Provincial Association for Science and Technology Youth Talent Support Project (20230127) and General Project of China Postdoctoral Science Foundation (2023M734286)

* Corresponding author. E-mail: 15229406642@163.com