

储能测试与评价



## 基于SDAE-Transformer-ECA网络的锂电池剩余使用寿命预测

宋兴海<sup>1</sup>, 张小乾<sup>1</sup>, 梁惠施<sup>2</sup>, 史梓男<sup>2</sup>, 李棉刚<sup>2</sup>, 周奎<sup>2</sup>, 贡晓旭<sup>2</sup>

(<sup>1</sup>西南科技大学, 四川 绵阳 621010; <sup>2</sup>清华四川能源互联网研究院, 四川 成都 610213)

**摘要:** 锂离子电池剩余使用寿命(remaining useful life, RUL)的准确预测对于提高电池使用寿命、降低异常事故的概率,起着至关重要的作用。本文结合堆叠噪声自编码器(stacked denoising auto encoder, SDAE)和变压器(transformer)的优势,提出了一种结合高效通道注意力(efficient channel attention, ECA)的SDAE-Transformer-ECA的锂离子电池RUL预测网络。首先,针对电池在使用过程中存在的容量再生现象和数据集采集误差等噪声污染,利用SDAE对输入数据进行重构去噪、提取特征。然后,通过Transformer网络对重构数据进行序列信息的捕获。最后,结合ECA网络对捕获信息进行跨通道整合和交互,从而实现锂离子电池的RUL的预测。本文先基于美国马里兰大学先进生命周期工程中心(Center for Advanced Life Cycle Engineering, CALCE)提供的电池容量数据集进行实验验证,实验证明本文模型的各项误差都较低,具有较高的准确性,且与次优算法Bi-LSTM相比,平均RE相对降低了62.67%,平均MAE相对降低了40.68%,平均RMSE相对降低了34.33%。再使用美国航空航天局(National Aeronautics and Space Administration, NASA)提供的B0007号电池容量数据集进行泛化性验证,实验得到的RE、MAE和RMSE结果分别是1.98%、3.12%和4.16%,与RNN、LSTM、GRU和Bi-LSTM等现有算法相比,本文模型预测准确性更高,证明了该模型的泛化性。

**关键词:** 锂离子电池; SDAE; Transformer; 注意力机制; 剩余使用寿命预测

doi: 10.19799/j.cnki.2095-4239.2023.0369

中图分类号: TM 912

文献标志码: A

文章编号: 2095-4239 (2023) 10-3181-10

## Predicting the remaining service life of lithium batteries based on the SDAE-transformer-ECA network

SONG Xinghai<sup>1</sup>, ZHANG Xiaoqian<sup>1</sup>, LIANG Huishi<sup>2</sup>, SHI Zinan<sup>2</sup>, LI Miangang<sup>2</sup>,  
ZHOU Kui<sup>2</sup>, GONG Xiaoxu<sup>2</sup>

(<sup>1</sup>Southwest University of Science and Technology, Mianyang 621010, Sichuan, China; <sup>2</sup>Tsinghua Sichuan Energy Internet Research Institute, Chengdu 610213, Sichuan, China)

**Abstract:** The accurate prediction of the remaining useful life (RUL) of lithium-ion batteries plays a crucial role in improving the battery life and reducing the probability of accidents. This study combines the advantages of a stacked denoising autoencoder (SDAE) and a transformer to propose a lithium-ion battery RUL prediction network that combines the SDAE, transformer, and efficient channel attention (ECA). Considering the noise pollution brought about by the capacity regeneration phenomenon and the dataset acquisition error during battery usage, the SDAE is used to reconstruct and denoise the input data and extract the

收稿日期: 2023-05-29; 修改稿日期: 2023-06-05。

基金项目: 国家自然科学基金面上项目(62102331); 四川省自然科学基金项目(2022NSFSC0839)。

第一作者: 宋兴海(1998—), 男, 硕士研究生, 主要研究方向为电池安全管理、机器学习, E-mail: 1293857067@qq.com; 通信作者: 梁惠施, 高级工程师, 主要研究方向为光伏运维、储能安全, E-mail: lianghuishi@tinghua-eiri.org。

引用本文: 宋兴海, 张小乾, 梁惠施, 等. 基于SDAE-Transformer-ECA网络的锂电池剩余使用寿命预测[J]. 储能科学与技术, 2023, 12(10): 3181-3190.

Citation: SONG Xinghai, ZHANG Xiaoqian, LIANG Huishi, et al. Predicting the remaining service life of lithium batteries based on the SDAE-transformer-ECA network[J]. Energy Storage Science and Technology, 2023, 12(10): 3181-3190.

features. The sequence information of the reconstructed data is then captured through the transformer network. Finally, the cross-channel integration and interaction of the captured information are performed in combination with the ECA network to realize the RUL prediction of the lithium-ion batteries. This study uses the battery capacity dataset provided by the Center for Advanced Life Cycle Engineering at the University of Maryland. The experimental results show that the proposed algorithm has low error and high accuracy. Compared with that for the suboptimal bi-directional long short-term memory (Bi-LSTM) algorithm, the average RE, mean absolute error (MAE), and root-mean-squared error (RMSE) for the proposed algorithm are relatively reduced by 62.67%, 40.68%, and 34.33%, respectively. Using the B0007 battery capacity dataset provided by the National Aeronautics and Space Administration for generalization verification, the experimental results of the RE, MAE, and RMSE were found to be 1.98%, 3.12%, and 4.16%, respectively. With that being said, the prediction accuracy of the proposed algorithm is higher than that of existing algorithms, such as recurrent neural networks, LSTM, gated recurrent units, and Bi-LSTM. Thus, the generalization of the model is proven.

**Keywords:** lithium-ion battery; SDAE; transformer; attention mechanism; remaining useful life prediction

锂离子电池(简称锂电池)以其能量密度高、功率大和自放电率低等优势而广泛应用于储能领域<sup>[1-2]</sup>。然而,锂离子电池在长时间使用中会发生性能和寿命的衰减,且成组电池中个别电芯性能的衰减极易导致严重安全隐患,这已成为锂电池安全性与可靠性的持续挑战。因此,准确预测锂电池剩余使用寿命(remaining useful life, RUL)<sup>[3]</sup>对完善电池管理策略,降低电池运行风险、提高电池运行稳定性具有重要的意义。在过去的几十年中,众多研究人员已经开发了许多方法和技术来预测锂电池的RUL,这些方法大致可分为基于模型的方法<sup>[4]</sup>和基于数据驱动的方法<sup>[5]</sup>。

基于模型的方法是透过电池的内部机理,来搭建锂电池退化模型<sup>[6]</sup>,然后进行优化求解的一类算法。如文献[7]提出了一种基于可在线实现的分数阶等效电路模型(fractional equivalent circuit model, FOECM)的RUL预测算法,但是这类等效电路算法模型复杂,且是基于特定的测试条件和电池构造的模型,因此适应性较差。文献[8]通过电化学模型研究锂电池的退化规律,来实现RUL的预测,但电化学模型参数难以估计,且模型受到多种因素的影响,例如电池状态和外部环境等。文献[9]构建了基于模型的无迹粒子滤波和最优组合策略结合的RUL预测方法,此类改进粒子滤波的算法一定程度上克

服了粒子退化和粒子多样性匮乏等问题,但模型的建立和求解过程存在大量的运算增加了模型的复杂度。总的来说,基于模型的算法存在参数难以估计、受多种因素影响以及模型过于复杂等问题,因此在实际工程应用中难以实现。

相比之下,基于数据驱动的方法不需要考虑锂电池内部特性,它通过分析锂电池历史运行数据探究电池老化的内在规律<sup>[10]</sup>,从而实现锂电池RUL预测,因此更多学者用此类算法做研究。如文献[11]提出了一种以支持向量机(support vector machine, SVM)算法进行在线估计的RUL方法。文献[12]采用高斯过程回归(Gaussian process regression, GPR)和主成分分析(principal component analysis, PCA)结合的方法实现了锂电池RUL预测。文献[13]针对核函数难以确定的问题,提出采用平方指数协方差函数和周期协方差函数的和作为GPR模型的协方差函数,进行了RUL预测。文献[14]针对网络训练时间长、模型调参困难以及预测结果不稳定等问题,利用相关向量机(relevance vector machine, RVM)实现了RUL预测,并通过量子粒子群对RVM进行了优化,保证了预测输出结果的稳定性。然而,这些传统的方法往往存在特征设计困难和泛化性不足等问题。随着软硬件设施的快速发展,深度学习算法靠着其处理复杂非线性关系的强大能力,

受到了各大领域的广泛关注。目前也有很多研究者采用此类算法进行电池 RUL 预测研究, 主要关注网络构建、数据去噪和数据增强 3 个方面。

网络构建方面, 文献[15]利用循环神经网络(recurrent neural network, RNN), 以容量老化数据作为输入, 较好地对电池老化状态做出了预测, 但是 RNN 本身存在过度拟合和梯度消失的劣势。文献[16]设计了长短期记忆递归神经网络(long short term memory recurrent neural network, LSTM-RNN)来构造明确面向容量的 RUL 预测器, 该方法减小了 RNN 的梯度消失, 缺点是该网络结构复杂且训练参数较多。文献[17-18]以门控卷积单元(gate recurrent unit, GRU)作为 RUL 预测的主干网络, 使得模型在训练时间较短的情况下, 仍能保持不错的精度, 但此类网络能够储存的长期依赖性和记忆能力更弱。文献[19]设计了一种堆叠双向长短期记忆(bi-directional long short-term memory, Bi-LSTM)网络的 SOH 估计方法, 该方法能够有效地适用于快速充电器, 但由于 Bi-LSTM 需要在每个时刻保留原始序列和反向序列的全部信息, 导致其计算量和存储复杂度大幅增加, 不利于工程应用。

数据降噪方面, 一方面电池容量因其与电池寿命的强相关性, 常常作为电池 RUL 预测中非常重要的一个特征, 另一方面, 电池在充放电过程中大多存在容量恢复现象, 该现象的直接影响是给容量数据的长周期下降趋势叠加了短周期上升的噪声, 将严重影响将容量作为直接特征的电池 RUL 预测效果。考虑到该问题, 目前已有一些文献通过分离、去除的特征选择方法进行了研究。如文献[20]通过小波分解将序列分解成波动部分和平滑下降部分来分别预测, 取得了不错的 RUL 预测结果, 但小波分解对数据信号的平滑性要求很高且参数选择敏感。文献[21-22]分别用经验模态分解(empirical mode decomposition, EMD)和集合经验模态分解(ensemble empirical mode decomposition, EEMD)对电池数据去噪处理, 这两种方法比小波分解适应性更强, 但容易出现模态混叠现象。文献[23]使用变分模态分解(variational modal decomposition, VMD)对 RUL 进行预测能够有效避免模态混叠现象, 并且对噪声的鲁棒性强, 其缺点在于需要人工确定模态个数, 寻优过程比较困难。

数据增强方面, 注意力机制可以通过加权考虑序列中的每个元素, 从而使得序列中 useful 信息在训练过程不会丢失。该方法一定程度上缓解了序列长距离依赖性, 因此一些文献也采用此类算法进行电池 RUL 预测研究。如文献[24]提出了一种具有注意力机制的 Bi-LSTM 模型, 实现了 RUL 的在线预测。文献[25]提出了一种深度神经网络和双重注意力机制的混合模型, 通过注意力捕获电池容量再生现象, 从而实现了 RUL 的预测。综上所述, 找到一种匹配的注意力机制能够减少噪声对模型的影响, 提升模型的效率和准确性。

综上所述, 尽管大多数现有的深度学习算法在锂电池 RUL 预测研究中都表现出了良好的性能, 但它们仍存在以下两个主要问题。

(1) 因为数据的长期依赖性, 导致网络容易出现梯度消失和梯度爆炸等问题, 而且计算量和存储复杂度也会增加。

(2) 电池容量原始数据一般存在容量恢复现象和数据采集误差等噪声污染, 这些噪声会严重影响数据驱动方法的性能。

因此, 本文提出了一种基于 SDAE-Transformer-ECA 的锂电池 RUL 预测网络, 以实现提高锂电池 RUL 预测的准确性。该工作的主要贡献如下:

(1) 采用变形器(Transformer)<sup>[26]</sup>网络来捕获序列数据之间的长期依赖性。Transformer 利用自注意力机制使输入序列中的所有元素进行信息聚合, 从而捕获数据的全局特征。它与 RNN、GRU 和 LSTM 算法相比, 在处理长序列数据、建模全局信息需求和计算效率等方面更具优势。

(2) 针对容量数据存在的噪声干扰, 利用堆叠去噪自编码器(stacked denoising auto encoder, SDAE)<sup>[27]</sup>对容量数据进行重构, 使其在去噪的同时丰富数据的特征。SDAE 是使用去噪准则来处理无监督目标, 指导学习更高级表示特征的一种方法, 其在特征提取、噪声处理、自适应性及运算速度等方面均优于 VMD。

(3) 在 Transformer 模型中嵌入高效通道注意力<sup>[28]</sup>(efficient channel attention, ECA), 使模型可以更好地捕捉输入数据中的通道间关系, 从而提高了模型的表示能力。

本文采用美国马里兰大学先进生命周期工程中心(Center for Advanced Life Cycle Engineering,



CALCE)和美国航空航天局(National Aeronautics and Space Administration, NASA)公开的两个公共电池容量数据集对所提模型的准确性和泛化性进行了验证,验证结果表明本文模型的准确性和泛化性均优于RNN、LSTM、GRU和Bi-LSTM四种现有算法。

## 1 基本理论

### 1.1 SDAE网络

SDAE是堆叠自编码器的一种改进版本,在机器学习领域具有广泛的应用价值。它通过加入噪声的训练方式提高模型鲁棒性,从而有效避免了过拟合现象。同时,其本身是一个深层次的特征提取器,能够使模型更准确地学习到数据的抽象表示,从而提高模型的泛化性。因此本文使用SDAE网络对锂电池容量数据进行去噪和丰富特征。SDAE网络的具体结构如图1所示。




图1 SDAE网络结构

Fig. 1 SDAE network structure

该网络训练过程如下:

第1步:根据式(1)对给定的原始的容量信号 $\bar{x}$ 进行噪声分布为 $q_D(\tilde{x}|\bar{x})$ 的加噪处理,得到加噪后的损坏信号 $\tilde{x}$ :

$$\tilde{x} \sim q_D(\tilde{x}|\bar{x}) \quad (1)$$

第2步:根据式(2)对信号 $\tilde{x}$ 进行编码,得到第一个隐层特征 $h_1$ :

$$h_1 = \sigma_E(W_1 \tilde{x} + b_1) \quad (2)$$

式中, $\sigma_E$ 为编码部分的激活函数; $W_1$ 为连接输入层到第1个隐藏层的权重矩阵; $b_1$ 为编码过程

的偏差。

第3步:根据式(3)对隐层特征 $h_1$ 进行解码重构,得到重构后的输出 $\hat{x}$ :

$$\hat{x} = \sigma_D(W_2 h_1 + b_2) \quad (3)$$

式中, $\sigma_D$ 为解码部分的激活函数; $W_2$ 为隐藏层到输出层的权重矩阵; $b_2$ 为解码过程的偏差,本文中采用的激活函数均为ReLU函数。

第4步:采用最小均方差式(4)作为优化代价函数,然后采用梯度下降方法更新权重和偏置。

$$\arg \min [J(\bar{x}, \hat{x})] = \frac{1}{n} \sum_{i=1}^n \|\bar{x} - \hat{x}\|_2^2 \quad (4)$$

式中, $J(\bar{x}, \hat{x})$ 为重构误差; $n$ 为样本数量。

依次重复前面第2~4步进行迭代,直到更新出最后一层DAE模型的最优权重 $W_k$ 和偏置 $b_k$ 以及隐藏特征 $h_k$ 。

### 1.2 Transformer网络

Transformer是一个利用注意力机制来提高模型训练速度的网络,其编码器部分类似一个大型的多层感知机(multilayer perceptron, MLP),数据可以同时输入,并行运算。它在处理长序列数据上的能力相当出色,并且能够有效解决梯度爆炸的问题,因此可用于锂电池的RUL预测。Transformer网络的编码结构如图2所示。

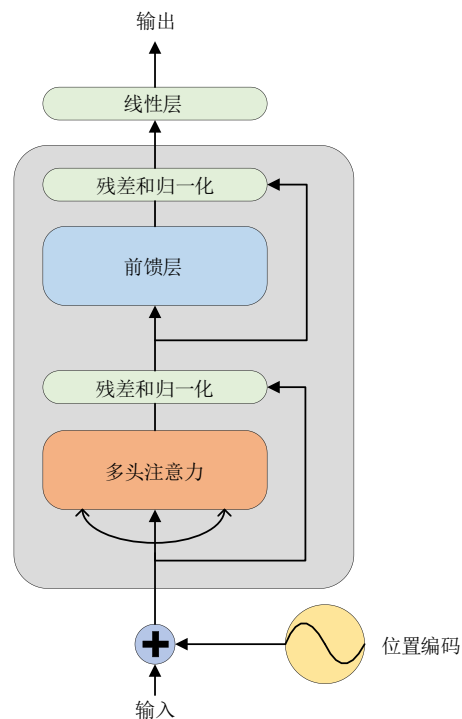


图2 Transformer网络编码结构

Fig. 2 Transformer network encoder structure

Transformer 的算法步骤如下：

(1) 通过位置编码为输入向量嵌入位置信息，使模型能够捕捉容量输入序列的顺序；

(2) 通过多头自注意力计算每个输入向量与所有输入向量的相似度，然后加权求和得到每个输入向量的新表示；

(3) 由前馈网络对自注意力处理后的向量进行非线性变换，使学习到的特征更为抽象；

(4) 最后由线性层进行特征映射得到预测序列结果。

在网络中层间采取的残差连接和归一化操作，目的是解决梯度爆炸和保证输出规范化。

在本文中，使用不同频率的正弦和余弦函数进行位置编码，具体如下：

$$\mathbf{PE}(t, 2k) = \sin(t/10000^{2k/s}) \quad (5)$$

$$\mathbf{PE}(t, 2k+1) = \cos(t/10000^{2k/s}) \quad (6)$$

式中， $\mathbf{PE}$  表示位置编码矩阵； $s$  表示 Transformer 模型中每个位置向量的维度； $t$  表示位置编码的位置； $k$  是  $0 \sim (s/2-1)$  之间的整数值，表示编码向量的维度索引。

多头自注意力旨在使模型能够同时关注多个重点区域，忽略序列之间的距离。多头自注意力的数学表达式如下：

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O \quad (7)$$

$$\text{head}_i = \text{Attention}(\mathbf{QW}_i^Q, \mathbf{KW}_i^K, \mathbf{VW}_i^V) \quad (8)$$

式(7)中， $\mathbf{Q}$ (query)、 $\mathbf{K}$ (key)、 $\mathbf{V}$ (value)是输入序列由 3 个线性映射层映射得到的 3 个向量，其维度分别是  $d_q$ 、 $d_k$ 、 $d_v$ ；Concat 表示拼接函数，作用将所有 head 的输出结果拼接起来。

式(8)中， $\mathbf{W}_i^Q \in \mathbb{R}^{s \times d_k}$ 、 $\mathbf{W}_i^K \in \mathbb{R}^{s \times d_k}$ 、 $\mathbf{W}_i^V \in \mathbb{R}^{s \times d_k}$ 、 $\mathbf{W}_i^O \in \mathbb{R}^{d_v \times s}$  分别表示第  $i$  个 head 的  $\mathbf{Q}$ 、 $\mathbf{K}$ 、 $\mathbf{V}$  向量对应的权重矩阵和降维得到最终输出的权重矩阵。一般地，自注意力头数设置为 8，即  $h=8$ ，而  $d_k=d_v=s/h$ 。Scaled dot-product 注意力定义如下：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{QK}^T}{\sqrt{d_h}}\right) \mathbf{V} \quad (9)$$

式中， $d_h=s/h$ ；softmax 为激活函数； $\mathbf{K}^T$  为  $\mathbf{K}$  的转置，该注意力的定义避免了梯度消失。

Transformer 的前馈网络由两个线性变换层和一个激活函数组成，其中第一个全连接层的激活函数为 ReLU 激活函数。可以表示为：

$$\text{FFN}(\mathbf{x}) = \text{ReLU}(\mathbf{xW}_3 + \mathbf{b}_3) \mathbf{W}_4 + \mathbf{b}_4 \quad (10)$$

式中， $\mathbf{W}_3$ 、 $\mathbf{W}_4$  为分别为两个线性层的权重； $\mathbf{b}_3$ 、 $\mathbf{b}_4$  为两个线性层的偏置。

### 1.3 ECA 网络

为防止在捕获锂离子电池数据信息时，因输入特征的长期相关性导致的信息冗余和局部丢失等问题，本模型引入了与 Transformer 内部的注意力不同的注意力机制——ECA。ECA 是通过分析压缩和激励网络(squeeze-and-excitation networks, SE-Net)<sup>[29]</sup>并对 SE 模块改进得到的一种模型，是一种高效的通道注意力模块。它考虑到降维操作会对通道注意力的预测产生负面的影响，且获取的通道依赖性效率低，因此通过一维卷积避免降维的同时可以捕获通道之间的相关性，得到具有通道注意力的特征  $\hat{\mathbf{X}}^*$ 。如式(11)所示：

$$\hat{\mathbf{X}}^* = \sigma[\text{C1D}_k(\mathbf{X}^*)] \cdot \mathbf{X}^* \quad (11)$$

式中， $\sigma$  为激活函数；C1D 代表一维卷积； $k$  为卷积核大小； $\mathbf{X}^*$  为多通道的特征。

## 2 SDAE-Transformer-ECA 模型构建

### 2.1 SOH 和 RUL 定义

SOH 指的是电池的健康状态，一般以百分比的形式表示电池从寿命开始到寿命结束期间所处的状态，这是定量描述当前电池的性能状态，基于容量的定义如式(12)所示：

$$\text{SOH}_{(t)} = \frac{\text{LBC}_t}{\text{LBC}_0} \times 100\% \quad (12)$$

式中， $\text{LBC}_t$  为锂电池当前最大允许放电容量； $\text{LBC}_0$  为锂电池标称容量。

一般地，电池的失效阈值为额定容量的 70%~80%。锂电池的 RUL 是电池在当前条件下的最大可用容量衰减到失效阈值所经历的充电/放电循环的次数。如式(13)定义：

$$\text{RUL} = N_{\text{EOL}} - n \quad (13)$$

式中， $N_{\text{EOL}}$  为 SOH 值首次失效阈值时经历的总循环次数； $n$  为电池当前充放电循环次数，本文设定的失效阈值是额定容量的 70%。

### 2.2 SDAE-Transformer-ECA 模型架构

本工作将 SDAE、Transformer 和 ECA 三个网络进行组合搭建构成 SDAE-Transformer-ECA 网络模型，三个网络分别进行去噪并特征丰富、捕获序列时序特征和特征整合，利用该网络对电池容量序列数据进行合理预测，具体的预测流程如图 3 所示。

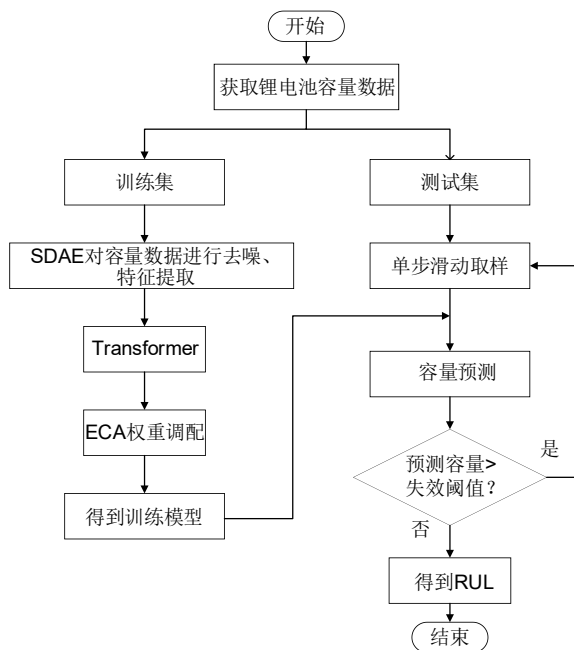


图3 SDAE-Transformer-ECA网络整体流程

Fig. 3 Overall flow chart of SDAE-Transformer-ECA network

SDAE-Transformer-ECA模型的训练流程如下：

Step1: 选择电池容量作为表征电池老化的健康特征；

Step2: 取训练集中  $t$  个循环的容量序列  $\mathbf{X}=(x_{j+1}, x_{j+2}, \dots, x_{j+t})$  作为输入，预测下一个循环的容量，其中  $j=0, 1, 2 \dots$ 。为减小输入数据分布对网络的影响，首先需要对数据进行归一化处理，归一化的方法如下：

$$\bar{\mathbf{X}} = \frac{\mathbf{X}}{\text{LBC}_0} \quad (14)$$

Step3: 将 Step2 归一化后的输入  $\bar{\mathbf{X}}$  加入高斯噪声，得到含噪声的输入  $\tilde{\mathbf{X}}$ ，然后利用 SDAE 进行重构得到去噪后的特征向量  $\hat{\mathbf{X}}$ ；

Step4: 将特征向量  $\hat{\mathbf{X}}$  输入到 Transformer 模型，然后 Transformer 对  $\hat{\mathbf{X}}$  进行逐层处理和编码，得到包含长时间信息的新特征  $\mathbf{X}^*$ ；

Step5: 利用 ECA 注意力对捕获的时序特征  $\mathbf{X}^*$  进行自注意力通道间的交互、整合，从而实现权重的重新调配得到  $\hat{\mathbf{X}}^*$ ；

Step6:  $\hat{\mathbf{X}}^*$  由线性层线性映射得到下一循环的容量值，将该值与真实容量值计算均方根误差，然后再用梯度反传的方式训练模型。

SDAE-Transformer-ECA模型的预测流程如下：

Step1: 将测试集的前  $i \sim t+i$  个循环的容量作为模型输入，预测  $t+i+1$  个循环的容量，其中  $i=0, 1, 2 \dots$

Step2: 将预测  $t+i+1$  的容量结果与失效阈值进行对比，若低于失效阈值则 RUL 值为  $i$ ，否则将  $t+i+1$  的容量预测值回填至原输入序列，输入序列向前滑窗 1 个循环，即  $i+1 \sim t+i+1$  个循环的容量序列作为模型输入，进行迭代循环预测。

Step3: 对预测容量和 RUL 值进行评价指标的计算，作为预测模型性能的评价标准。

### 3 实验验证与结果分析

#### 3.1 数据集和评价指标

本文使用 CALCE 公共数据集的电池容量数据，来对 SDAE-Transformer-ECA 模型进行实验验证。该数据集没有采取人为清洗的数据，目的是使搭建的网络能够适用于实际工程应用。其中，CALCE 选取的 4 个电池分别是 CS2\_35、CS2\_36、CS2\_37、CS2\_38，它们的充电截至电压为 4.2 V，放电截至电压为 2.7 V，额定容量为 1.1 Ah。最后本工作采取留一评估法来评估本文模型，选取其中一个电池作为测试集，其余电池作为训练集，所有电池在经历 10 次迭代之后取平均得分。

为定量评估本文模型的有效性，本文选取领域内 3 个常见指标对所提预测模型进行评估。

电池 RUL 预测的相对误差(relative error, RE) 计算公式如式(15)所示：

$$\text{RE} = \frac{|\text{RUL}_{\text{pr}} - \text{RUL}_{\text{tr}}|}{\text{RUL}_{\text{tr}}} \quad (15)$$

式中， $\text{RUL}_{\text{pr}}$ 、 $\text{RUL}_{\text{tr}}$  分别是电池容量衰退至失效阈值时对应放电循环次数的预测值和真实值。

电池剩余容量预测的平均绝对误差(mean absolute error, MAE)计算公式如式(16)所示：

$$\text{MAE} = \frac{1}{n-L} \sum_{i=L+1}^n |\hat{y}_i - y_i| \quad (16)$$

式中， $\hat{y}_i$  为容量的预测值； $y_i$  为容量的真实值； $n$  为样本的总长度； $L$  为从用于训练的序列的样本长度。

电池剩余容量预测的均方根误差(root mean square error, RMSE)响应误差分布计算公式如式(17)所示：

$$\text{RMSE} = \sqrt{\frac{1}{n-L} \sum_{i=L+1}^n (\hat{y}_i - y_i)^2} \quad (17)$$

以上 3 个指标中, RE 与电池的 RUL 结果呈高度相关, 因此本文将作为最主要的评价指标。

### 3.2 参数设置

本文所有实验结果均在具有 12th Gen Intel (R) Core (TM) i5-12490F@2.50GHz CPU, 16 GB RAM 和 NVIDIA GeForce RTX 3070 GPU (8 GB 缓存)、python3.7、pytorch1.8.0 软硬件设施上实验得到。本文模型的函数及训练得到的关键参数见表 1。

表 1 SDAE-Transformer-ECA 模型参数  
Table 1 SDAE-Transformer-ECA Model parameter

参数名	参数设置
采样窗口 $s$	64
模型学习速率 $lr$	0.005
Transformer 网络深度 $d$	1
Transformer 网络的隐藏层大小 $h$	32
学习正则化 $\alpha$	$10^{-6}$
优化函数	Adam
损失函数 $loss$	MSE

采样窗口( $s$ )可以设置为序列长度的 5%~10%。在本文的实验中, 对于 CALCE 和 NASA,  $s$  分别固定在 64 和 16。

### 3.3 对比分析

为了验证本文所提算法的预测能力及有效性, 本文基于 CACLE 四种电池与 RNN、LSTM、GRU 和 Bi-LSTM 等 4 种现有算法进行对比分析, 对比结果见表 2, 其中最优值由粗体进行显示。

对于 RE、MAE 和 RMSE 而言, 其值越小, 代

表 2 CACLE 性能评价

Table 2 CACLE performance evaluation

算法	RE/%	MAE/%	RMSE/%
RNN	6.51	9.10	11.39
LSTM	3.94	3.77	4.78
GRU	5.54	4.28	5.11
Bi-LSTM	3.08	4.13	5.01
Transformer	79.92	60.88	70.80
SDAE-Transformer	6.33	3.13	4.27
SDAE-Transformer-ECA	<b>1.15</b>	<b>2.45</b>	<b>3.29</b>

表模型的预测准确性越高。表 2 给出了不同算法下 4 种电池预测结果误差的平均值, 结果显示本文所提模型的误差均低于 4 种现有算法, 具有较高准确性。本文所提的 SDAE-Transformer-ECA 模型的平均 RE、平均 MAE 和平均 RMSE 分别为 1.15%、2.45% 和 3.29%, 与次优算法 Bi-LSTM 相比, 平均 RE 相对降低了 62.67%, 平均 MAE 相对降低了 40.68%, 平均 RMSE 相对降低了 34.33%。

另外本文进行了模型消融实验, 从表 2 后 3 行结果可以看出 Transformer 本身不能直接用于电池的 RUL 预测, 这是因为在电池容量变化的时间序列中, 存在一些噪声和不规律性, 如果直接将电池容量序列作为模型的输入, 会使得模型学到这些噪声和不规律性, 并且不能很好地区分这些变化是由于电池健康状态的衰减造成, 还是由于其他原因导致的。而当 SDAE 对输入容量序列进行特征提取和去噪之后, Transformer 网络就可以完成电池 RUL 的预测任务且精度超过了 RNN, 预测结果也较为稳定。考虑到 Transformer 的自注意力是按照位置计算的, 它会将所有的通道考虑在内, 忽略通道之间的相关性。因此利用 ECA 注意力机制来捕获和利用通道之间的相关性, 帮助 Transformer 更好地表达输入序列的特征和减少计算量, 表 2 中后两行的结果验证了加入 ECA 的有效性。

图 4 是基于 CS2\_35、CS2\_36、CS2\_37 和 CS2\_38 4 种电池不同算法下的容量预测结果, 从图中可以看出本文模型的预测结果更接近于真实的电池容量退化曲线, 预测的结果更稳定。

图 5 是本文模型及 4 种对比算法的容量误差对比, 从图 5 中的误差结果可以看出, 本文所提模型的容量预测值和真实值相当接近, 误差曲线也较为平稳, 具有较高的精度和适应性。

图 6 是本文模型对于 4 种电池的 RUL 预测结果, 从图可以看出, 当 CS2\_35、CS2\_36、CS2\_37 和 CS2\_38 4 种电池 RUL 预测起点为 64 时, 预测值与真实值之间的绝对误差分别是 20、1、6 和 0, 该结果表明本文所提的 SDAE-Transformer-ECA 模型具有可接受的准确性。

### 3.4 模型泛化性验证

在 NASA 所提供的电池数据集上进行了本文所提的 SDAE-Transformer-ECA 模型的泛化性, 该实






图4 不同算法的4组电池容量预测结果对比

Fig. 4 Comparison chart of 4 groups of battery capacity prediction results of different algorithms




图5 本文模型及4种对比算法的容量误差对比

Fig. 5 Comparison chart of capacity error of the model and four comparison algorithms

验数据与 CALCE 数据在类似实验条件下取得,但电池的特性不同,所以选用本数据可以更好地反映模型的泛化性。本节选取 B0007 号电池的数据进行验证,该电池的充电截止电压为 4.2 V,放电截止电压为 2.2 V,额定容量为 2 Ah。图 7 是本文模型

与 4 种对比算法的容量预测对比及容量误差对比。本文模型对 B0007 电池的预测结果较为稳定,RE、MAE 和 RMSE 分别是 1.98%、3.12% 和 4.16%,与另外 4 种算法对比,预测准确性较高,因此证明了本文模型的泛化性。








图6 4种电池的RUL预测结果

Fig. 6 RUL prediction results for four types of batteries



(a) 容量对比



(b) 误差对比

图7 本文模型与4种对比算法的容量预测对比及容量误差对比

Fig. 7 In this paper, the capacity prediction comparison chart and capacity error comparison chart of the model and the four comparison algorithms are compared

## 4 结 论

为了提高锂电池 RUL 预测的准确性, 本文将 SDAE、Transformer 和 ECA 相结合, 提出了 SDAE-Transformer-ECA 预测模型。实验验证和分析得到如下结论: ①SADE 是一个很好的特征降噪网络, 能够有效减少容量恢复等噪声对数据驱动的影响, 提高预测精度; ②Transformer 通过内部注意力和残差网络能够高效捕获时序特征及减小梯度爆炸; ③ECA 网络能够捕获和利用通道之间的相关性, 提高预测精度和效率。从实验结果来说, 本文所提的 SDAE-Transformer-ECA 模型能够很好地描

述锂离子电池的衰减特性。

实际工程数据采集困难且工况复杂多变, 而公共实验数据和工程实际数据相比, 分布上存在着巨大差异, 这些因素造成了模型的一对一。考虑到这些问题, 本研究后续将尝试提取满足实际工程需求的新特征, 并利用知识迁移的方法来提高模型的泛化能力。

## 参 考 文 献

- [1] GAO Y Z, ZHANG X, GUO B J, et al. Health-aware multiobjective optimal charging strategy with coupled electrochemical-thermal-aging model for lithium-ion battery[J]. IEEE Transactions on Industrial Informatics, 2020, 16(5): 3417-3429.
- [2] SU C, CHEN H J, WEN Z J. Prediction of remaining useful life for lithium-ion battery with multiple health indicators[J]. Eksploatacja i Niezawodność-Maintenance and Reliability, 2021, 23(1): 176-183.
- [3] 黄凯, 丁恒, 郭永芳, 等. 基于数据预处理和长短期记忆神经网络的锂离子电池寿命预测[J]. 电工技术学报, 2022, 37(15): 3753-3766.
- [4] HUANG K, DING H, GUO Y F, et al. Prediction of remaining useful life of lithium-ion battery based on adaptive data preprocessing and long short-term memory network[J]. Transactions of China Electrotechnical Society, 2022, 37(15): 3753-3766.
- [5] 段双明, 杨耀微. 基于分数阶模型的锂电池 SOC 估计[J]. 电源技术, 2022, 46(8): 862-866.
- [6] DUAN S M, YANG Y W. State of charge estimation of lithium batteries based on fractional model[J]. Chinese Journal of Power Sources, 2022, 46(8): 862-866.
- [7] 叶乙福. 基于数据驱动的锂离子电池剩余使用寿命预测方法研究[D]. 湖州: 湖州师范学院, 2022.
- [8] YE Y F. Research on prediction method of remaining useful life of lithium-ion battery based on data drive[D]. Huzhou: Huzhou University, 2022.
- [9] 李彦梅, 刘惠汉, 张朝龙, 等. 基于双高斯模型的锂电池剩余使用寿命预测方法[J]. 电气工程学报, 2022, 17(4): 32-40.
- [10] LI Y M, LIU H H, ZHANG C L, et al. Lithium-ion battery RUL prediction method based on double Gaussian model[J]. Journal of Electrical Engineering, 2022, 17(4): 32-40.
- [11] GUHA A, PATRA A. Online estimation of the electrochemical impedance spectrum and remaining useful life of lithium-ion batteries[J]. IEEE Transactions on Instrumentation and Measurement, 2018, 67(8): 1836-1849.
- [12] 宋胜, 李云伍, 赵颖, 等. 锂离子电池片段数据的荷电状态估计研究[J]. 电源技术, 2022, 46(7): 734-738.
- [13] SONG S, LI Y W, ZHAO Y, et al. Research on SOC estimation based on fragment data of lithium-ion battery[J]. Chinese Journal of Power Sources, 2022, 46(7): 734-738.
- [14] YANG J S, FANG W G, CHEN J Y, et al. A lithium-ion battery remaining useful life prediction method based on unscented particle filter and optimal combination strategy[J]. Journal of Energy Storage, 2022, 55: 105648.

- [10] LIU K L, SHANG Y L, OUYANG Q, et al. A data-driven approach with uncertainty quantification for predicting future capacities and remaining useful life of lithium-ion battery[J]. IEEE Transactions on Industrial Electronics, 2020, 68(4): 3170-3180.
- [11] LI X Y, SHU X, SHEN J W, et al. An on-board remaining useful life estimation algorithm for lithium-ion batteries of electric vehicles[J]. Energies, 2017, 10(5): 691.
- [12] 何冰琛, 杨薛明, 王劲松, 等. 基于PCA-GPR的锂离子电池剩余使用寿命预测[J]. 太阳能学报, 2022, 43(5): 484-491.
- HE B C, YANG X M, WANG J S, et al. Prediction of remaining useful life of lithium-ion batteries based on pca-gpr[J]. Acta Energiae Solaris Sinica, 2022, 43(5): 484-491.
- [13] 刘健, 陈自强, 黄德扬, 等. 基于等压差充电时间的锂离子电池寿命预测[J]. 上海交通大学学报, 2019, 53(9): 1058-1065.
- LIU J, CHEN Z Q, HUANG D Y, et al. Remaining useful life prediction for lithium-ion batteries based on time interval of equal charging voltage difference[J]. Journal of Shanghai Jiao Tong University, 2019, 53(9): 1058-1065.
- [14] 何畏, 罗潇, 曾珍, 等. 利用QPSO改进相关向量机的电池寿命预测[J]. 电子测量与仪器学报, 2020, 34(6): 18-24.
- HE W, LUO X, ZENG Z, et al. Battery life prediction based on QPSO improved relevant vector machine[J]. Journal of Electronic Measurement and Instrumentation, 2020, 34(6): 18-24.
- [15] 徐帅, 刘雨辰, 周飞. 基于RNN的锂离子电池SOC估算研究进展[J]. 电源技术, 2021, 45(2): 263-269.
- XU S, LIU Y C, ZHOU F. Research progress of SOC estimation of lithium ion batteries based on RNN[J]. Chinese Journal of Power Sources, 2021, 45(2): 263-269.
- [16] ZHANG Y Z, XIONG R, HE H W, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries[J]. IEEE Transactions on Vehicular Technology, 2018, 67(7): 5695-5705.
- [17] 高峰, 贾建芳, 元淑芳, 等. 基于GRU-UKF的锂离子电池SOC估计方法研究[J]. 电子测量与仪器学报, 2022, 36(11): 160-169.
- GAO F, JIA J F, YUAN S F, et al. Research on SOC estimation method of lithium-ion battery based on GRU-UKF[J]. Journal of Electronic Measurement and Instrumentation, 2022, 36(11): 160-169.
- [18] 闫志远, 孙桓五, 刘世闯, 等. 一种基于GRU的氢燃料重卡汽车工况下锂离子电池温度预测模型[J/OL]. 中国电机工程学报: 1-12[2023-04-26]. <https://doi.org/10.13334/j.0258-8013.pcsee.221789>.
- YAN Z Y, SUN H W, LIU S C, et al. Temperature prediction model of lithium-ion battery under working conditions of hydrogen fuel heavy trucks based on GRU[J/OL]. Proceedings of the CSEE: 1-12 [2023-04-26]. <https://doi.org/10.13334/j.0258-8013.pcsee.221789>.
- [19] YAYAN U, ARSLAN A T, YUCEL H. A novel method for SoH prediction of batteries based on stacked LSTM with quick charge data[J]. Applied Artificial Intelligence, 2021, 35(6): 421-439.
- [20] 邢子轩, 张凡, 武明虎, 等. 基于WD-GRU的锂离子电池剩余寿命预测[J]. 电源技术, 2022, 46(8): 867-871.
- XING Z X, ZHANG F, WU M H, et al. Remaining life prediction of lithium ion batteries based on WD-GRU[J]. Chinese Journal of Power Sources, 2022, 46(8): 867-871.
- [21] 张朝龙, 何怡刚, 袁莉芬. 基于EEMD和MKRVM的锂电池剩余寿命预测方法[J]. 电力系统及其自动化学报, 2018, 30(7): 38-44.
- ZHANG C L, HE Y G, YUAN L F. Prediction approach for remaining useful life of lithium-ion battery based on EEMD and MKRVM[J]. Proceedings of the CSU-EPSS, 2018, 30(7): 38-44.
- [22] 赵沁峰, 蔡艳平, 王新军. 锂电池在不同放电区间下的剩余寿命预测[J]. 中国测试, 2023, 49(3): 159-165, 180.
- ZHAO Q F, CAI Y P, WANG X J. Remaining useful life prediction of lithium battery under different discharge intervals[J]. China Measurement & Test, 2023, 49(3): 159-165, 180.
- [23] 刘芊彤, 邢远秀. 基于VMD-PSO-GRU模型的锂离子电池剩余寿命预测[J]. 储能科学与技术, 2023, 12(1): 236-246.
- LIU Q T, XING Y X. Remaining life prediction of lithium-ion battery based on VMD-PSO-GRU model[J]. Energy Storage Science and Technology, 2023, 12(1): 236-246.
- [24] WANG F K, AMOGNE Z E, CHOU J H, et al. Online remaining useful life prediction of lithium-ion batteries using bidirectional long short-term memory with attention mechanism[J]. Energy, 2022, 254: 124344.
- [25] LI L, LI Y J, MAO R Z, et al. Remaining useful life prediction for lithium-ion batteries with a hybrid model based on TCN-GRU-DNN and dual attention mechanism[J]. IEEE Transactions on Transportation Electrification, 2023, doi: 10.1109/TTE.2023.3247614.
- [26] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all You need[C]// Proceedings of the 31st International Conference on Neural Information Processing Systems. New York: ACM, 2017: 6000-6010.
- [27] VINCENT P, LAROCHELLE H, LAJOIE I, et al. Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion[J]. Journal of Machine Learning Research, 2010, 11: 3371-3408.
- [28] WANG Q L, WU B G, ZHU P F, et al. ECA-net: Efficient channel attention for deep convolutional neural networks[C]// 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2020: 11531-11539.
- [29] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2018: 7132-7141.