

电工技术学报
Transactions of China Electrotechnical Society
ISSN 1000-6753, CN 11-2188/TM

《电工技术学报》网络首发论文

题目: 基于迁移学习和 DAE-LSTM 的锂离子电池剩余寿命预测
作者: 尹杰, 刘博, 孙国兵, 钱湘伟
DOI: 10.19595/j.cnki.1000-6753.tces.221890
收稿日期: 2022-10-05
网络首发日期: 2023-08-01
引用格式: 尹杰, 刘博, 孙国兵, 钱湘伟. 基于迁移学习和 DAE-LSTM 的锂离子电池剩余寿命预测[J/OL]. 电工技术学报.
<https://doi.org/10.19595/j.cnki.1000-6753.tces.221890>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

DOI: 10.19595/j.cnki.1000-6753.tces.221890
收稿日期 2022-10-05 改稿日期 2023-01-09

基于迁移学习和 DAE-LSTM 的锂离子电池 电池剩余寿命预测

尹 杰¹ 刘 博¹ 孙国兵² 钱湘伟¹

(1. 哈尔滨理工大学测控技术与通信工程学院 哈尔滨 150080
2. 黑龙江大学电子工程学院 哈尔滨 150006)

摘要 针对锂离子电池退化数据噪声大、数据量少以及不同生命时期的退化趋势不同而导致的模型预测精度低、泛化能力差等问题, 本文从数据预处理、预测模型的构建与训练三方面展开研究: 首先结合变分自编码器 (VAE) 和生成对抗网络模型 (GAN) 构建 VAE-GAN 模型生成多组数据, 实现电池的退化数据增强; 然后结合降噪自编码器 (DAE) 和长短时记忆 (LSTM) 神经网络构建 DAE-LSTM 模型进行数据降噪和容量预测, 为了降低模型参数, 此过程中的数据降噪和预测共享同一个损失函数; 最后先利用生成数据对 DAE-LSTM 模型进行预训练, 再利用真实数据对其进行迁移训练。在 CACLE 和 NASA 公开数据集进行性能测试, 实验结果表明本文所提方法精度高、鲁棒性强, 能够有效提高锂离子电池剩余寿命的预测效果。

关键词: 锂离子电池 剩余寿命预测 降噪 自编码器 长短期记忆神经网络 迁移学习
中图分类号: TM912; TP206^{+.3}

0 引言

锂离子电池凭借其能量密度高、使用寿命长且绿色环保等特点, 被广泛的应用于消费电子、新能源汽车以及航空航天领域^[1]。在面对不同的工作环境时, 频繁的充放电以及环境温度变化等因素都可能会导致锂离子电池的使用寿命受到影响^[2]。电池的老化主要表现在容量的减少以及等效内阻的增加上^[3]。当电池达到其规定的寿命阈值时, 便要进行及时的更换, 以保证电池及其运行系统的安全性^[4]。因此, 锂离子电池剩余使用寿命的精准预测是十分必要的。

近年来, 随着机器学习和深度学习的蓬勃发展, 基于数据驱动的锂离子电池剩余使用寿命预测被人们广泛关注。相比于基于等效电路^[5]和物理模型^[6]的传统研究方法而言, 基于数据驱动的预测方法更加灵活, 可以免去繁杂的物理建模过程, 只利用电池工作过程中的历史数据便可进行建模, 实现电池剩余使用寿命的有效预测^[7]。循环神经网络凭借其独特的记忆结构在处理时序数据上具有格外的优势, 因此常适用于各种寿命预测任务中^[8]。Zhang Y 等^[9]采用长短时记忆 (Long Short-Term Memory, LSTM)

神经网络学习锂离子电池退化容量之间的长期相关性, 利用滑动窗口对容量数据进行分割, 通过不断迭代预测的方法获取未来多个时间步的容量退化数据, 这种滑动窗口分割数据以及迭代预测的方法也是锂离子电池剩余使用寿命 (Remaining Useful Life, RUL) 预测中最常用的方法。P. Khumprom 等^[10]提出以 LSTM 网络层为主体的预测模型进行电池寿命预测, 分别采用寿命周期 50% 和 70% 的容量数据进行模型训练, 并进行剩余寿命预测, 实验结果表明采用 70% 的寿命数据训练的模型具有更高的精度。这不仅与训练模型的数据量有关, 也与锂离子电池的退化特性有关, 电池的寿命退化曲线是非线性的, 其寿命前中期的退化速度要远低于寿命后期的退化速度^[11], 所以只对电池早期退化速度缓慢的数据建模, 然后通过自回归的方式进行寿命预测, 往往会导致预测结果偏差较大。

由于锂离子电池在退化过程中常出现容量回升现象^[12], 并且实验过程中的电磁干扰、充放电倍率差异等因素都会导致电池容量数据中包含着噪声, 这对于数据预测模型的建立具有极大的干扰, 所以电池容量数据的降噪处理是有必要的。Huang K 等

人^[13]通过自适应双指数模型(Adaptive Bi-exponential Model Smooth, ABMS)和 CEEMDAN 算法对电池容量数据进行了降噪处理,并利用 LSTM 网络进行容量预测,对比未降噪数据的预测结果,进行数据预处理的预测模型展现出更高精度的预测能力。Wang Z.等^[14]通过局部切线空间对齐(Local tangent dpace alignment, LTSA)的方法进行电池容量数据的特征提取,降低退化数据中的波动数据,并利用自适应滑动窗口 LSTM 模型进行寿命预测,实验结果表明,进行数据降噪的预测模型在预测 RUL 时更加准确。尽管现有的大多数预测模型都展示出了不俗的预测能力,但是他们普遍存在以下三个问题:

(1) 预测模型局限性:由于锂离子电池不同寿命阶段的退化速度不同,只采用局部退化数据进行寿命建模具有一定的局限性。

(2) 降噪预测关联性:大多数的预测方法中,数据降噪和容量预测常常分开处理,被视为两个独立的任务,这忽略了二者之间的关联性。

(3) 退化数据稀缺性:基于深度学习的训练方法需要有一定的数据量作为支撑,但现实的电池退化数据有限,这对于预测模型的建立具有一定的影响。

为了降低上述问题对结果的影响,文本提出基于迁移学习的 DAE-LSTM 锂离子电池 RUL 预测模型。首先,结合变分自编码器(Variational Autoencoder,VAE)和生成对抗网络(Generative Adversarial Nets, GAN)构建 VAE-GAN 数据生成模型:将小样本全周期电池退化数据输入模型中,VAE 的编码器会先提取输入数据的分布状况,然后利用解码器和判别网络实现容量数据的再生,既弥补了 VAE 模型生成数据的单一性,又解决了 GAN 模型难以收敛的问题,最终生成多组电池全周期退化数据;其次,利用降噪自编码器(Denoising Autoencoder, DAE)和 LSTM 网络构建容量预测模型 DAE-LSTM:降噪自编码器对利用滑动窗口分割后的输入数据进行降噪处理,数据输入编码器前会被添加高斯白噪声,以使得整体模型的鲁棒性更强,然后压缩成隐藏向量传输到 LSTM 网络当中。多层的 LSTM 网络学习隐藏向量之间的时序特征,通过全连接层映射为容量预测值。为了使得模型具有更好的泛化能力,本文提出了一个全新的目标函数用来连接数据降噪和寿命预测两个任务,使其能够在学习过程中同时得到优化。

最后,本文通过消融试验,找到最优的训练方式:先利用 VAE-GAN 模型生成的退化数据对 DAE-LSTM 预测模型进行预训练,然后将除被测电池外的真实退化数据对预测模型的全部网络层进行微调,使得模型更加适应真实数据的分布状况,更具针对性。此外,本文增设基础模型的对照试验,通过对比未降噪处理和未数据增强的模型预测结果,验证 DAE-LSTM 模型的优越性。

1 数据增强

1.1 实验数据

本文采用两种电极材料在室温环境下的锂离子电池数据集进行模型性能验证。

第一组数据由马里兰大学 CALCE 研究中心的 CS2_35、CS2_36、CS2_37 和 CS2_38 四组电池的容量退化数据组成^[15]。CS2 系列电池属于钴酸锂电池,以碳作为导电添加剂混合的 LiCoO_2 为阳极,以与聚丙烯氟化物结合在一起的层状石墨作为阴极,额定容量为 $1.1\text{A}\cdot\text{h}$ 。试验过程为:首先以 0.55A 的电流恒流充电,直至截止电压 4.2V ;然后恒压保持,直到充电电流降至 0.05A ,最后以 0.55A 的电流进行恒流放电,将电压降至 2.7V 。锂离子电池寿命循环试验的结束条件为电池容量降为额定容量的 70%。对于此数据集,阈值容量设置为其额定容量的 80%^[16]。

第二组数据由 NASA PcoE 研究中心的 B5、B6、B7、B18 四组电池的容量退化数据组成^[17]。NASA 电池组属于三元锂电池,其阳极材料为镍钴铝酸锂,阴极材料为石墨,额定容量为 2Ah 。试验过程为:首先以 1.5A 恒定电流充电,直至截止电压 4.2V ;然后恒压保持,直到充电电流降至 0.02mA ;最后以 2A 恒定电流进行放电,直到 B5、B6、B7、B18 电池电压分别降至 2.7V 、 2.5V 、 2.2V 和 2.5V 时停止。对于此数据集,阈值容量设置为其额定容量的 70%,即 1.38Ah 。由于 B7 号电池容量始终大于 1.38Ah ,所以其阈值容量设置为其额定容量的 74.5%,即 1.47Ah ^[18]。图 1 为两组数据的容量衰减曲线。

深度学习网络需要有足够多分布均衡的数据作为支撑才能够发挥较好的效果,但这两组数据集的数据量均较小,特别是 NASA 数据集,每个电池的退化数据不足 200 个,仅使用这些数据用来进行深度学习建模是远远不能满足建模要求的,因此需要

提出一种数据增强的方法来解决数据量少的问题。

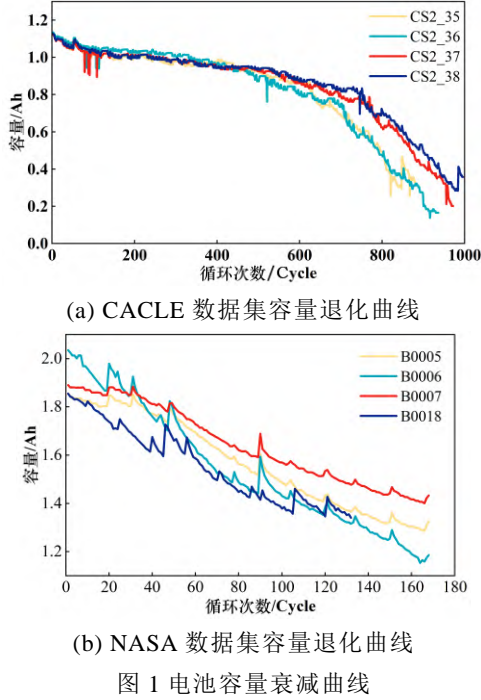


Fig.1 Decay curve of battery capacity

1.2 VAE-GAN 模型

深度学习领域常使用的生成模型包括 VAE^[19]和 GAN^[20], 虽然二者都可进行数据再生, 但是应用起来各自都有一定的缺陷。VAE 模型可以通过重采样得到原始数据的分布状况, 但生成数据的多样性较低; GAN 模型生成数据更具多样性, 但是训练过程异常困难, 生成器和判别器难以同时收敛。因此, 本文结合 VAE 模型的数据生成和 GAN 模型的对抗学习机制, 提出 VAE-GAN 生成模型。

VAE-GAN 模型总共分为三部分, 分别为编码网络、解码网络(生成网络)和判断网络, 对应 VAE 模型的 Encoder、Decoder 和 GAN 模型的

Discriminator 部分。可以理解为在 GAN 网络的基础上增添了真实数据的编码过程, 利用具有先验信息的隐式 z 代替原本输入生成器的随机向量, 使模型的表达能力大大提升, VAE-GAN 模型结构如图 2 所示。

编码网络由三个全连接层构成, 第一个全连接层对输入的高维数据进行下采样操作, 激活函数采用 Relu; 其余两个全连接层分别将下采样后的样本映射成两个低维的参数特征, 即正态分布的均值和方差。编码网络的损失函数为 KL 散度, 用来衡量隐式向量分布和标准正态分布之间的差异, KL 损失函数为

$$L_E = K_L(N(\mu, \sigma^2) \| N(0, 1)) = -\frac{1}{2} \left[1 + \log(\sigma_j^2) - \sigma_j^2 + \mu_j^2 \right] \quad (1)$$

式中, μ_j 和 σ_j^2 分别为编码网络输出的均值和方差。

解码网络(生成网络)由两层全连接网络构成, 这两层网络的参数设置和编码网络的参数设置相反, 将输入的低维隐藏变量进行特征放大, 最终生成和输入数据相同尺寸的生成数据, 两个网络层间的采用 Relu 激活函数, 最终的输出层采用 Sigmoid 激活函数。生成网络的优化目标既要保证最小化生成样本与真实样本之间的特征损失, 还要保证生成数据能够欺骗判别网络, 其损失函数为

$$L_G = (x_i - \hat{x}_i)^2 + E_{z \sim p(z)} [\log_2(1 - D(G(z)))] \quad (2)$$

式中, 左侧第一项表示编码器的损失重构; z 为参数重构生成的隐藏变量; $G(z)$ 为生成样本; $D(\cdot)$ 为判别网络对于生成数据的真伪判断。

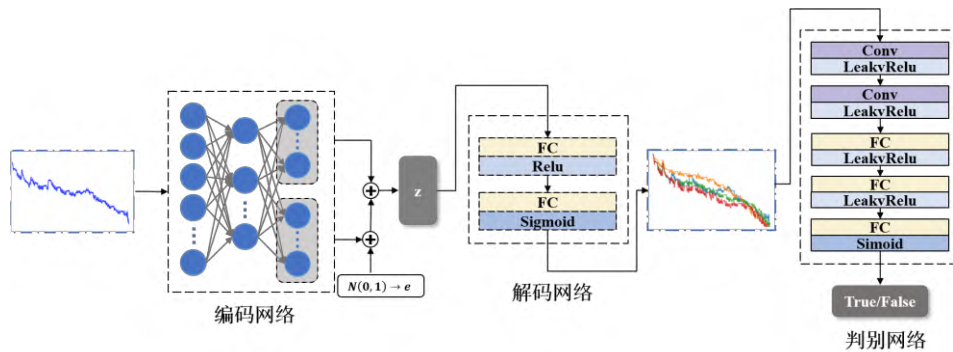


图 2 VAE-GAN 结构图

Fig.2 Structure diagram of VAE-GAN

判别网络由 2 个卷积层和 3 个全连接层组成, 每个网络层之间的激活函数采用 LeakyRelu, 输出

层通过 Sigmoid 激活函数输出真伪标签, 判别网络的损失函数采用更加稳定的最小二乘损失函数为

$$L_D = \frac{1}{2} E_{x \sim p_{data}} [(G(x))^2] + \frac{1}{2} E_{z \sim p(z)} [(D(z)-1)^2] \quad (3)$$


VAE-GAN 模型利用 VAE 的编码优势，将蕴含先验信息的隐藏向量代替随机向量输入给 GAN 模型进行数据生成，缓解模型训练不收敛的问题。GAN 网络通过对抗学习，改善生成数据的质量，完成对 VAE 模型的改善，二者相辅相成。

1.3VAE-GAN 数据扩充试验

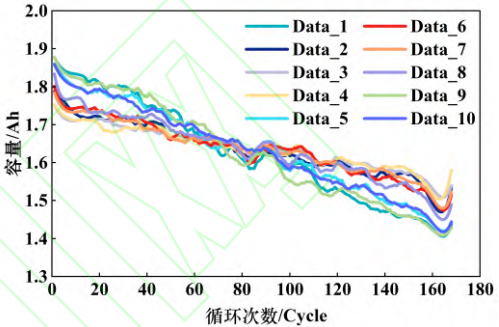
VAE-GAN 模型训练时的迭代次数设置为 500 次，由于总共只有四组数据，所以 Batchsize 设置为 2，采用 Adam 优化器进行参数优化，学习率设置为 1×10^{-4} ，训练前需要对输入数据进行归一化，不然生成网络的输出层所连接的 Sigmoid 激活函数无法对数据进行完整的映射，输出数据可进行反归一化还原到原来的值域。具体参数设置见表 1，其中神经元个数括号中的数值分别代表当前网络的输入节点数和输出节点数。

本文利用 VAE-GAN 模型分别对两组数据集各生成十组完整的退化数据，如图 3 所示。为了衡量生成数据与真实数据之间的相似性，采用文献[21]中的相似度算法，求解真实数据与生成数据的均方根误差并对其进行归一化，结果越接近 1 表示二

者的相似程度越高，相似度算法如式（4）所示。



(a) CACLE 十组生成数据



(b) NASA 十组生成数据

图 3 VAE-GAN 扩充数据

Fig.3 VAE-GAN expanded data

表 1 VAE-GAN 模型参数设置

Tab.1 Parameter setup of VAE-GAN

网络名称	结构组成	主要参数	输出尺寸
编码网络	输入层	神经元个数 630	630
	全连接层(隐层)	神经元个数(630,300)	300
	全连接层(输出 μ)	神经元个数(300,150)	150
	全连接层(输出 σ)	神经元个数(300,150)	150
生成网络	输入层		150
	全连接层+Relu	神经元个数(150,300)	300
	全连接层+ sigmoid	神经元个数(300,630)	630
判别网络	输入层		630
	一维卷积+LeakyRelu	卷积参数(1,32,12)	32×619
	一维卷积+LeakyRelu	卷积参数(32,1,12)	1×608
	全连接层+ Relu	神经元个数(630,256)	256
	全连接层+Relu	神经元个数(256,256)	256
	全连接层+ sigmoid	神经元个数(256,1)	1

$$u = \frac{1}{1 + \sqrt{\frac{1}{n} \sum_{i=1}^n (x_{\text{real}}^i - x_{\text{gen}}^i)^2}} \quad (4)$$

表 2 生成数据相似度计算

Tab.2 Similarity calculation of generated data

序号	平均相似度	序号	平均相似度
CS2_35	0.9668	B0005	0.965 6
CS2_36	0.9530	B0006	0.935 9
CS2_37	0.9712	B0007	0.967 2

CS2_38

0.9755

B0018

0.924 8

对比每组电池和所有生成数据之间的平均相似度, 结果如表 2 所示。可以看出, 十组生成样本与每组真实样本的平均相似度都达到了 0.95 以上, 可以有效表示出锂离子电池真实的退化趋势, 并且相较于原始数据而言, 生成数据更加符合产品退化的浴盆曲线^[22], 适合用来进行后续锂离子电池 RUL 预测的模型训练。

2 容量预测模型

2.1 DAE-LSTM 模型

容量大小可以直接反应锂离子电池的老化情况, 但电池的老化过程中容易出现容量回升现象, 并且试验过程中的电磁干扰、充放电倍率差异等因素会导致测得的电池容量数据波动较大, 这为电池 RUL 的精准预测增加许多难度。因此, 本文基于数据降噪和容量预测任务设计 DAE-LSTM 预测模型, 模型包括两部分: DAE 数据降噪和 LSTM 容量预测, 两个任务在一个模型框架中实现。DAE-LSTM 架构如图 4 所示。

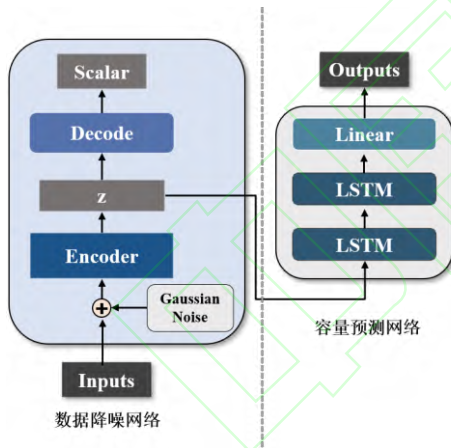


图 4 DAE-LSTM 网络架构

Fig.4 DAE-LSTM network architecture

2.2 DAE 数据降噪

降噪自编码器 (DAE) 是一种具有数据降噪功能的特征提取算法^[23], DAE 的编码器将充满噪声的输入数据压缩成低维向量, 尽量保留数据的原始特征, 然后解码器将低维向量还原成退化趋势明显的原始数据, 本文采用该算法作为容量数据的降噪算法。

DAE 的编码器在对原始数据进行压缩前, 会向输入数据 $x'_t = \{x_{t+1}, x_{t+2}, \dots, x_{t+n}\}$ 中加入高斯白噪声

使其变成输入向量 \hat{x}_t , 目的是为了增加模型的鲁棒性和非线性表达能力。然后编码器会将输入数据压缩成低维的中间向量, 过程如式 (5) 所示。

$$z = a(W^T \hat{x}_t + b) \quad (5)$$

式中, W 为编码器权重矩阵; b 为偏置项; $a(\cdot)$ 为激活函数; z 为压缩而成的隐藏向量。

然后解码器进行信息重构, 将携带原始数据信息的中间向量映射成与输入数据尺寸相同的输出向量, 过程如式 (6) 所示。

$$\hat{x}_t = f'(W'z + b') \quad (6)$$

式中, W' 为解码器的权重矩阵; b' 为偏置项; $f'(\cdot)$ 为激活函数; \hat{x}_t 为解码得到的输出向量。

为了增加网络的稀疏性, 缓解过拟合现象的出现, 选择 ReLU 函数作为编码器和解码器中隐藏层的激活函数。为了有效的将输出数据映射到有效的值域内, 输出层的激活函数选择 Sigmoid 函数。故此, DAE 部分的损失函数定义为

$$L_d = \frac{1}{n} \sum_{t=1}^n \ell(\tilde{x}_t - \hat{x}_t) + \lambda (\|W\|_F^2 + \|W'\|_F^2) \quad (7)$$

式中, $\ell(\cdot)$ 为损失的激活函数, 由于 DAE 模型结构的对称性, 编码矩阵 W 和解码矩阵 W' 的权重可以进行绑定, 减少模型的训练时间。

2.3 LSTM 网络层

锂离子电池的容量退化过程是一个具有时序特性的动态过程, 当前时刻的容量与之前多个历史时刻的退化容量均存在依赖关系。LSTM 网络的隐藏层具有记忆功能, 能够分析不同时刻容量的时序关系, 因此本文将 LSTM 网络用于单个锂离子电池容量的预测任务。

相较于 RNN 网络, LSTM 网络给原始的隐藏层 h_t 添加了一个单元状态 c_t , 单元状态 c_t 内部设置了三个类似于开关的门机制, 能够控制状态单元内信息流的更新与遗忘^[24], 具体公式原理如下:

$$\begin{cases} i_t = \sigma_g(W_i x_t + U_i h_{t-1} + b_i) \\ f_t = \sigma_g(W_f x_t + U_f h_{t-1} + b_f) \\ o_t = \sigma_g(W_o x_t + U_o h_{t-1} + b_o) \\ c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \\ h_t = o_t \odot \tanh(c_t) \\ \tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c) \end{cases} \quad (8)$$

式中, i_t 、 f_t 和 o_t 分别代表输入门、遗忘门和输出门的激活向量; x_t 和 h_t 分别表示当前时刻的输入和隐藏状态; W 和 b 分别代表网络中需要学习的权重矩阵和偏置向量; \tilde{c}_t 、 c_t 为单元的中间状态和输出状态; σ_g 为 sigmoid 激活函数。LSTM 的神经元内部结构如图 5 所示。

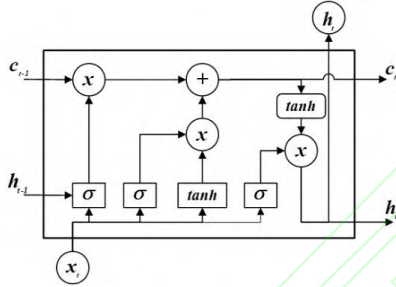


图 5 经典 LSTM 框图

Fig.5 The diagram of LSTM

容量预测阶段将 DAE 的 Encoder 生成的隐藏向量 z 作为输入数据, 通过 LSTM 层和全连接层建立预测数据与隐藏向量 z 之间的映射关系, 通过反向传播优化模型参数, 完成容量预测任务。

本文提出的 DAE-LSTM 模型没有将数据降噪和预测任务分割开来, 而是提出一个新的损失函数, 在训练过程中对两项任务同时进行优化, 最大程度的保证数据降噪和容量预测之间的关联性。均方根误差(RMSE)作为统一的损失重构函数, 进行降噪和预测部分的损失评估, DAE-LSTM 模型完整的损失函数为

$$L = \sum_{t=T+1}^n (x_t - \hat{x}_t)^2 + \alpha \sum_{i=1}^n \ell(\tilde{x}_i - \hat{x}_i) + \lambda \Omega(\theta) \quad (9)$$

式中, α 用来平衡两个任务之间的优化力度; $\Omega(\cdot)$ 为正则化项; λ 为正则化参数; θ 表示模型参数。DAE-LSTM 模型的参数设置见表 3(参数均为网格搜索优化结果, 详见后文)。

表 3 DAE-LSTM 模型参数

Tab.3 Parameter setup of DAE-LSTM

网络名称	结构	主要参数	输出尺寸
降噪网络	输入层	神经元个数 64	64
	噪声层	Noise level(0.01)	64
	编码层	Linear(64,32)	32
	解码层	Linear(32,64)	64
预测网络	LSTM	LSTM(32,64,2)	1×1×64
	输出层	Linear(64,1)	1

3. 预测模型训练

3.1 预测方法

锂离子电池 RUL 预测方法, 是将容量数据利用滑动窗口进行数据分割, 保留相邻容量间的关联性, 并将数据变为有监督学习的形式供模型训练。设置适当的迭代步长, 将预测数据替换到训练数据中并不断迭代, 最终可以获得长序列的预测结果。样本生成过程见图 6:




图 6 滑动窗口结构

Fig.6 Architecture of the sliding window

3.2 迁移学习

锂离子电池的寿命退化曲线是非线性的, 其寿命前中期的退化速度要低于寿命后期的退化速度, 单凭某一阶段的退化数据训练模型是有局限性的。因此, 本文为提高预测精度采用多组全周期退化数据训练模型。通过 VAE-GAN 生成十组电池退化数据进行数据增强, 然后利用迁移学习降低生成数据与实际数据的差异。

在迁移学习中, 首先会用大量数据训练一个基础模型, 面对新任务时, 基础模型的网络参数会做出针对性的修改。常见的迁移策略有两种: 一种是训练基础模型的输出层; 另一种是训练基础模型的全部层。但不论哪种迁移方式, 都要用较小的学习率进行训练, 充分利用模型预训练时学习到的知识。

3.2.1 基础模型

迁移学习的难点在于选择迁移策略的选择上, 考虑锂离子电池 RUL 预测的特殊性, 本文采取的迁移策略如下: 首先利用生成的十组数据对模型进行预训练, 然后利用真实退化数据对模型进行微调, 使得模型能够适应真实电池退化数据的噪声分布状

况和退化趋势。这样的训练方法能够保证模型从大量的先验数据中学习大概的退化趋势，然后通过针对性训练保证模型能够适应真实的退化情况。

以 CACLE 数据为例，训练数据可分为两部分，一个是由 VAE-GAN 模型生成的十组退化数据，称为生成数据集，用于基础模型的训练；另一个是由四组电池退化数据组成的数据集，称为真实数据集，用于模型的迁移。针对基础模型 DAE-LSTM 的训练，需要确定的超参数如下：(1)时间步长 $Inputsize$ ；(2)学习率 Lr ；(3)隐藏层数量 $Numlayers$ ；(4)神经元个数 $Hiddendim$ ；(5)高斯白噪声值域 $Noiselevel$ ；(6)正则化系数 α 。值得注意的是，关键参数 $Batchsize$ 并不在需优化的超参数中，原因是每组电池数据都会被滑动窗口分割成 566 组特征和标签对应的数组，为了保证数据的时序性， $Batchsize$ 设置为 566，这样可以让模型在每个 $epoch$ 中学习一组电池的全部数据。在生成数据集上确定模型的最优结构，以最小化交叉验证误差为优化目标，对模型的超参数进行优化。生成数据集需进行五折交叉验证以防止出现过拟合现象，优化器采用 Adam，迭代次数为 1500 次，由于基础模型的训练任务是对陌生数据进行拟合，不需要进行迭代预测，因此评价指标为 RMSE 和 MAE。超参数空间及最优值如表 4 所示：

表 4 超参数空间

Tab.4 Hyperparameter' range in hyperparameter space

Hyperparameters	Range	Value
Input size	[16,32,64]	64
Learning rate	[0.001,0.000 1,0.000 01]	0.000 1
Num layers	[1,2,4]	2
Hidden dim	[16,32,64]	64
Noise level	[0.001,0.01,0.1]	0.01
alpha	[0.001,0.01,0.1]	0.01

3.2.2 迁移策略

基础模型训练完毕后，需要确定合适的迁移策略，保证迁移学习的效果最佳。本文采用留一法训练全部网络层的迁移方式，完整的模型流程如图 7 所示：

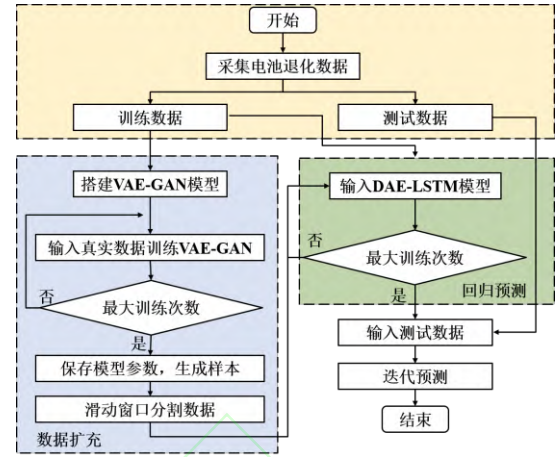


图 7 电池 RUL 预测流程

Fig.7 Prediction process of battery RUL

实际上我们尝试过多种迁移策略，包括：(1)只训练输出层，冻结其他网络层；(2)训练 VAE 部分和输出层，冻结 LSTM 网络层；(3)训练全部网络层。实验结果表示训练全部网络层的迁移方式最优，同时修改数据降噪和预测部分的网络权重，既能够使模型适应真实数据的噪声分布，又能学习真实数据的退化趋势，并且训练方式较为简单，不需要再进行额外的超参数优化，只需要降低迁移训练时的学习率即可，因此本文将迁移学习率设置为 1×10^{-5} ，迭代次数为 1500 次。

4 实验结果分析

4.1 评价指标

本文的模型评价指标采用回归问题中常用的平均绝对误差 MAE 、均方误差 $RMSE$ ，另外引入针对锂离子电池容量预测任务的 RUL 误差 RE (Relative Error)和相对精度 P_{re}

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (10)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (11)$$

$$RE = |RUL_{pred} - RUL_{true}| \quad (12)$$

$$P_{re} = 1 - \frac{|RUL^{pred} - RUL^{true}|}{RUL^{true}} \times 100\% \quad (13)$$

式中， y_i 和 \hat{y}_i 分别代表第 i 次循环时锂离子电池的真

实容量和预测容量， \hat{y} 表示真实容量的平均值， RUL^{pred} 和 RUL^{true} 分别代表电池容量达到失效阈值时，剩余寿命的预测值和实际值。在进行容量预测任务时， P_{re} 为主要的评价指标。

4.2 结果分析

为了验证本文提出的基于迁移学习和 DAE-LSTM 方法（M3）的可靠性，从训练数据和网络结构上设计了两组对照试验。M1 为未经迁移学习的 LSTM 方法；M2 为未经迁移学习的 DAE-LSTM 方法。通过 M1 和 M2 验证 DAE-LSTM 模型的优越性；通过 M2 和 M3 验证数据增强的优越性。评价指标为 MAE、RMSE、RE 和 P_{re} ，其中 RE 和 P_{re} 作为主要的参考目标。

4.2.1 CALCE 数据验证

首先在 CALCE 电池数据集上进行实验，每个测试电池设置两个不同的预测起点，分别为第 364 和第 464 次循环。表 5 和表 6 为不同起点预测结果。


表 5 CACLE 数据集在 364 次循环的实验结果
Tab.5 Experimental results of CACLE batteries at 364 cycles

SP	No.	Method	RE	MAE	RMSE	R_{re}
364	CS2_35	M1	25	0.023 4	0.027 0	0.846 9
		M2	25	0.023 7	0.027 4	0.846 9
		M3	13	0.009 6	0.012 3	0.917 7
	CS2_36	M1	26	0.045 0	0.055 0	0.795 5
		M2	12	0.032 6	0.040 7	0.909 1
		M3	6	0.015 6	0.019 0	0.953 1
	CS2_37	M1	21	0.015 7	0.022 1	0.893 7
		M2	20	0.036 5	0.041 6	0.890 7
		M3	3	0.009 0	0.010 6	0.989 2
	CS2_38	M1	31	0.015 2	0.020 4	0.852 5
		M2	21	0.021 6	0.025 1	0.899 1
		M3	5	0.009 7	0.011 6	0.976 3


表 6 CACLE 数据集在 464 次循环的实验结果
Tab.6 Experimental results of CACLE batteries at 464 cycles

SP	No.	Method	RE	MAE	RMSE	R_{re}
464	CS2_35	M1	10	0.009 3	0.0122	0.8275
		M2	14	0.006 8	0.0083	0.7586
		M3	6	0.009 5	0.0126	0.8966
	CS2_36	M1	33	0.033 3	0.037 1	-
		M2	75	0.056 9	0.061 7	-
		M3	41	0.039 2	0.035 8	-
	CS2_37	M1	13	0.012 3	0.0157	0.857 1
		M2	3	0.009 8	0.011 5	0.967 0
		M3	1	0.009 5	0.010 9	0.989 0
	CS2_38	M1	6	0.011 1	0.012 4	0.943 9
		M2	1	0.013 4	0.015 7	0.990 6
		M3	2	0.015 6	0.017 9	0.981 3

观察评价指标可以看出，M3 方法的所有评价指标在绝大部分任务中均为最优值，RE 和 P_{re} 值表明其预测精度高；MAE 和 RMSE 表明退化曲线拟合情况好。CS2_35 号电池在 364 预测起点前有一个幅度较大容量波动状况，对预测结果产生较大影响，但是 M3 方法仍然取得了较好的预测效果。CS2_36 号电池的退化曲线的单调性更强，不符合产品退化时中期退化慢、前期和后期退化快的特点，与其他数据相差较大，所以三种方法在 464 起点均有较大误差。图 8 至图 11 为三种方法在不同预测起点的迭代曲线。

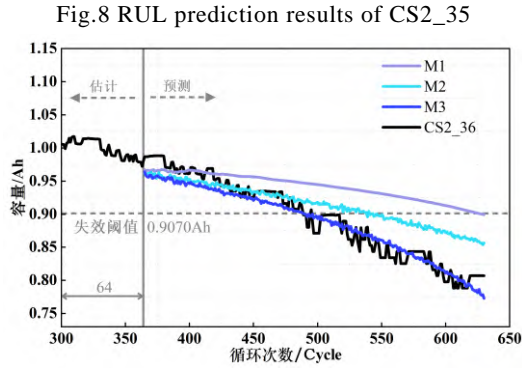


(a) SP=364




(b) SP=464

图 8 CS2_35 号电池 RUL 预测结果




(a) SP=364




(b) SP=464

图 9 CS2_36 号电池 RUL 预测结果




(a) SP=364



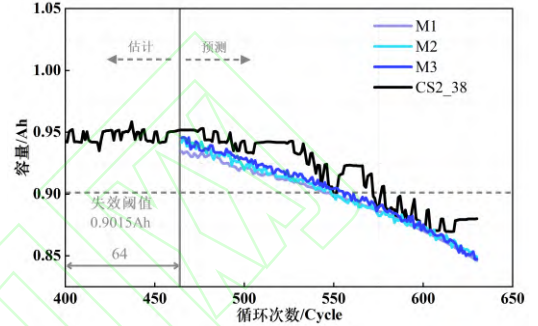
(b) SP=464

图 10 CS2_37 号电池 RUL 预测结果

Fig.10 RUL prediction results of CS2_37



(a) SP=364



(b) SP=464

图 11 CS2_38 号电池 RUL 预测结果

Fig.11 RUL prediction results of CS2_38

观察容量退化曲线可以看出, M3 方法可以准确的捕捉电池容量的退化趋势。不同预测起点的预测结果表明, 起始预测位置越靠近失效阈值, 其预测精度越高, 表明模型对于寿命后期退化趋势明显的的数据, 具有更加敏锐的识别能力。M1 和 M2 方法的实验结果表明, 加入降噪部分的 DAE-LSTM 方法可以有效的减少噪声干扰, 对退化数据进行准确的退化分析; M2 和 M3 方法的实验结果表明, 进行数据增强是有必要的, 通过生成数据预训练模型能够有效的缓和模型的过拟合现象, 并且对电池的整体退化趋势有更精准的把控。

CALCE 的电池退化趋势都有较大的起伏, 难以用简单的线性关系表示, 这对模型的鲁棒性有求极高。因此从预测结果中可以看出, 本文的预测方法具有较高的鲁棒性和预测精度。

4.2.2 NASA 数据验证

为了全面展示 M3 方法的适应性, 本文在数据量更少的 NASA 数据集上进行验证。数据增强实验见 1.3 节, 由于 NASA 数据的波动情况较大且数据长度较小, 所以 Noise level 设为 0.008; Input size 设为 48; Batch size 设为 168, 其他参数不变。预测起点设为 60, 评价指标选择 MAE、RMSE、 R^2 和 P_{re} 。为了提高说服力, 增设 100 次运行结果的 RUL 概率密度函数和 90%置信区间。图 12 为三种方法

在 NASA 四块电池上的迭代曲线，表 7 为所有的预测结果。

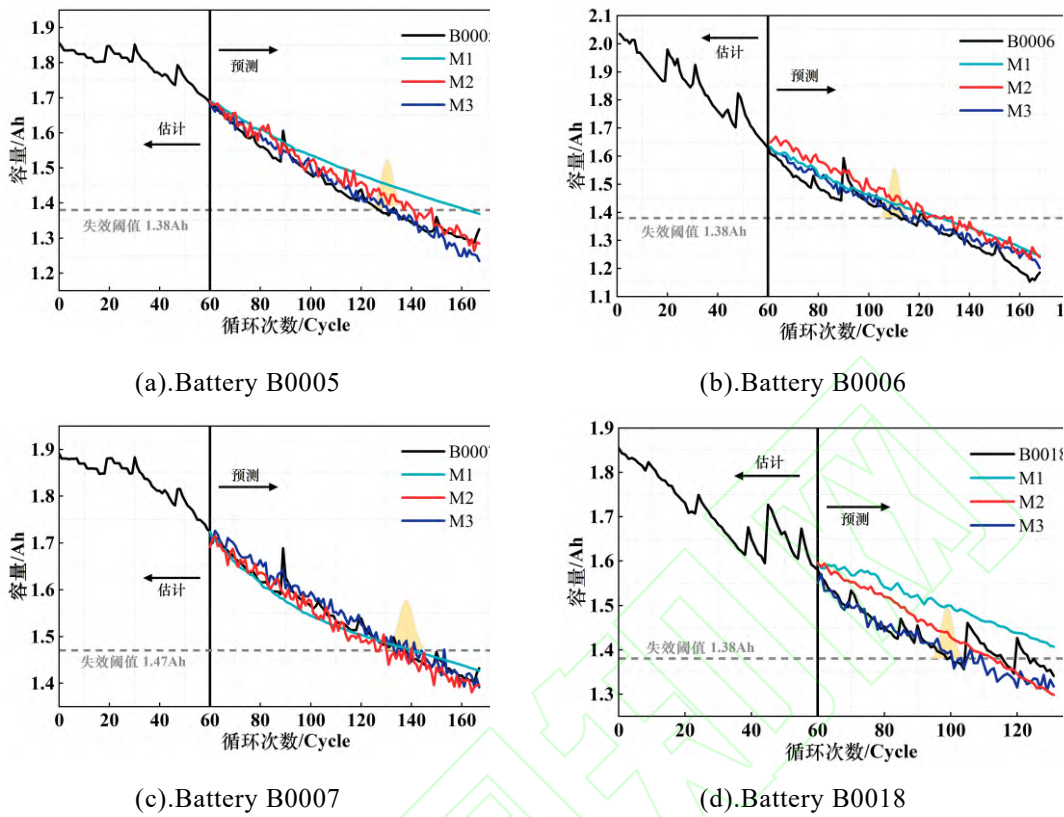


图 12 NASA 电池 RUL 预测结果

Fig.12 Prediction results for NASA batteries

表 7 NASA 数据集实验结果(起点为 60)

Tab.7 Experimental results of NASA batteries (the starting point is 60)

No.	M1				M2				M3			
	RE	MAE	RMSE	R_{re}	RE	MAE	RMSE	R_{re}	RE	MAE	RMSE	R_{re}
B5	35	0.059 4	0.684 1	0.437 5	9	0.028 7	0.034 1	0.887 5	2	0.022 4	0.028 6	0.970 5
B6	17	0.049	0.053 6	0.734 4	10	0.064 4	0.070 9	0.812 5	3	0.024 8	0.030 9	0.944 4
B7	9	0.014 7	0.020 1	0.892 9	6	0.016 9	0.021 7	0.928 6	2	0.016 8	0.020 2	0.976 2
B8	33	0.075	0.080 6	0.352 9	14	0.044 7	0.049	0.725 5	3	0.024 6	0.037 6	0.960 8

观察评价指标和退化曲线可以看出，M3 方法在 NASA 数据上同样具有优秀的预测精度和稳定性，其 MAE 、 $RMSE$ 、 R^2 和 P_{re} 四个评价指标均为对比方法中的最优值。表明本文所提方法具有良好的适应性，在不同的数据集上展现出较强的泛化能力。

另外，由于 B0018 电池在预测起点前的波动严重，未加降噪的 M1 方法预测效果格外糟糕，但 M3 方法仍然可以精准的捕捉到电池的退化趋势，这表明 DAE 部分具有极强的抗干扰能力，展现出降噪和预测阶段同处一个框架的统一性和关联性。表 8 为所有 NASA 数据集 100 次 RUL 预测结果 90%置信区间。

表 8 NASA 数据集的 RUL90%置信区间
(100 此运行结果)

Tab.8 The 90% confidence interval (100 run results) of NASA batteries

No.	置信区间
B0005	[133,139]
B0006	[103,109]
B0007	[107,113]
B0018	[133,143]

通过两组数据的仿真结果和评价指标对比可概括规律如下：

(1) 本文提出的基于迁移学习的 DAE-LSTM

模型的预测精度明显高于其他对照方法, 预测效果更加稳定, 除了 CACLE 数据中 CS2_36 号电池的退化趋势较为异常, 大部分电池的退化趋势都能被很好的捕捉, MAE 和 $RMSE$ 两个指标分别控制在 2.46% 和 3.76% 以内, 最低为 0.95% 和 1.06%。

(2) 通过观察不同预测起点的结果可以发现, 预测位置越靠近失效阈值预测精度越高, 表明模型对于寿命后期退化趋势明显的的数据具有敏锐的识别能力。

(3) 更换不同的实验数据集, 表明 M3 方法具有极强的适应能力和泛化能力, 能够有效的完成小数据样本下的锂离子电池 RUL 预测任务, NASA 预测任务中 RUL90% 置信区间范围较窄, 表明模型具有较强的鲁棒性。

为了进一步验证本文方法的性能, 在 NASA 数据集上与四种现有预测方法进行比较, 分别为 UPF-OCS^[25]、ALF-PF-LSTM^[26]、AUKF-GASVR^[27] 和 ICA-GPR^[28]。预测起点设为 60, 评价指标选用 $RMSE$ 和 P_{re} 。对比结果如表 9 所示, 可以看出本文所提方法具有最小的 P_{re} 值, 能够提供精度较高且稳定的预测效果。

表 9 其他方法的预测结果比较

Tab.9 Comparison of prediction results of other methods

No.	Method	MAE	RMSE	P_{re}
B0005	UPF-OCS	2	0.040	0.971
	ALF-PF-LSTM	2	0.018	0.971
	AUKF-GASVR	0	0.023	1
	ICA-GPR	10	0.039	0.857 1
	DAE-LSTM	2	0.028	0.971
B0006	UPF-OCS	3	0.044	0.944
	ALF-PF-LSTM	7	0.029	0.868
	AUKF-GASVR	10	0.051	0.689
	ICA-GPR	10	0.036	0.689
	DAE-LSTM	3	0.031	0.944
B0007	UPF-OCS	7	0.048	0.911
	ALF-PF-LSTM	3	0.005	0.961
	AUKF-GASVR	3	0.013	0.961
	ICA-GPR	—	—	—
	DAE-LSTM	2	0.020	0.976
B0018	UPF-OCS	5	0.044	0.875
	ALF-PF-LSTM	—	—	—

AUKF-GASVR	4	0.023	0.900
ICA-GPR	4	0.021	0.900
DAE-LSTM	3	0.038	0.961

此外, 本文统计了不同数据集完成 RUL 预测的耗时情况, 详见表 10。以 CACLE 数据的 364 次循环为起点的预测任务总耗时 190.64 秒, 以 NASA 数据的 60 次循环为起点的预测任务总耗时 69.95 秒。由于电池的剩余寿命预测是离线预测, 实时性要求较低, 模型的训练与测试时间符合离线预测要求。

表 10 耗时情况统计

Tab.10 Time consumption of the method

(单位: s)

数据集	数据再生	预训练	迁移训练	预测	总耗时
CACLE	22.08	152.13	15.46	0.97	190.64
NASA	15.66	50.16	4.09	0.04	69.95

5 结论

本文针对锂离子电池退化数据噪声大、数据量少以及不同生命时期的退化趋势不同而导致的模型预测精度低、泛化能力差等问题, 本文从数据预处理、预测模型的构建与训练三方面展开了研究:

1) 结合变分自编码器(VAE)和生成对抗网络(GAN)构建 VAE-GAN 模型, 少量电池全周期退化数据输入 VAE-GAN 网络模型中, 利用编码层、生成网络以及判别网络映射出原始数据的分布状态并生成新的退化数据。在两组数据集上的所有生成数据与真实数据之间的平均相关度均高于 0.92, 说明生成数据质量较好。

2) 利用降噪自编码器(DAE)和长短时记忆(LSTM)神经网络构建 DAE-LSTM 模型进行容量预测, 数据降噪阶段和预测阶段共享同一个损失函数, 使得降噪和预测过程得以同时优化。

3) 通过多组模型的不同训练方法, 确定出最优预测方案, 即先利用 VAE-GAN 模型的生成数据对 DAE-LSTM 网络进行模型预训练, 再利用真实数据迁移训练全部网络层。实验结果表明, 在相同的预测条件下, 基于迁移学习和 DAE-LSTM 方法总能取得最好的预测结果, 预测 RUL 的 90% 置信区间较窄反映本文方法具有强鲁棒性。

通过对比不同方法在不同起点的预测结果, 并且横向对比现有文献的预测结果, 证明本文提出的基于迁移学习的 DAE-LSTM 模型在保证鲁棒性的同时, 能够有效提高锂离子电池剩余寿命的预测效

果,为锂离子电池的 RUL 预测提供参考。此外,本文所提模型的结构待继续优化,降低模型耗时,以满足实时性要求较高的任务需求。

参考文献

- [1] 黄凯,丁恒,郭永芳,等.基于数据预处理和长短期记忆神经网络的锂离子电池寿命预测[J].电工技术学报,2022,37(15):3753-3766
Huang Kai, Ding Heng, Guo Yongfang, et al. Prediction of remaining useful life of lithium-ion battery based on adaptive data preprocessing and long short-term memory network[J]. Transactions of China Electrotechnical Society, 2022, 37(15):3753-3766
- [2] 肖迁,焦志鹏,穆云飞,等.基于 LightGBM 的电动汽车行驶工况下电池剩余使用寿命预测[J].电工技术学报,2021,36(24):5176-5185
Xiao Qian, Jiao Zhipeng, Mu Yunfei, et al. LightGBM based remaining useful life prediction of electric vehicle lithium-ion battery under driving conditions[J]. Transactions of China Electrotechnical Society, 2021, 36(24):5176-5185
- [3] 徐佳宁,倪裕隆,朱春波.基于改进支持向量回归的锂电池剩余寿命预测[J].电工技术学报,2021,36(17):3693-3704
Xu Jianing, Ni Yulong, Zhu Chunbo. Remaining useful life prediction for lithium-ion batteries based on improved support vector regression[J]. Transactions of China Electrotechnical Society, 2021, 36(17):3693-3704
- [4] 牛志远,姜欣,谢斌,等.电动汽车过充燃爆事故模拟及安全防护研究[J].电工技术学报,2022,37(1):36-47,57
Niu Zhiyuan, Jiang Xin, Xie Bin, et al. Study on simulation and safety protection of electric vehicle overcharge and explosion accident[J]. Transactions of China Electrotechnical Society, 2022, 37(1):36-47, 57
- [5] Ahmad Rahmoun, Helmuth Biechl. Modelling of li-ion batteries using equivalent circuit diagrams[J]. Przegląd Elektrotechniczny, 2012, 88(7):152-156.
- [6] Quentin Badey, Guillaume Cherouvrier, Yvan Reynier, et al. Ageing forecast of li-ion batteries for electric and hybrid vehicles[J]. Curr. Top. Electrochem, 2011, 16: 65-79.
- [7] 王义军,左雪.锂离子电池荷电状态估算方法及其应用场景综述[J].电力系统自动化,2022,46(14):193-207
Wang Yijun, Zuo Xue. Review on estimation methods for state of charge of lithium-ion battery and their application scenarios[J]. Automation of Electric Power Systems, 2022, 46(14):193-207
- [8] Shahid F, Zameer A, Muneeb M. A novel genetic LSTM model for wind power forecast[J]. Energy, 2021, 223: 120069.
- [9] Zhang Yongzhi, Xiong Rui, He Hongwen, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries[J]. IEEE Transactions on Vehicular Technology, 2018, 67(7): 5695-5705.
- [10] Khumprom P, Yodo N. A data-driven predictive prognostic model for lithium-ion batteries based on a deep learning algorithm[J]. Energies, 2019, 12(4): 660.
- [11] 李超然,肖飞,樊亚翔,等.基于卷积神经网络的锂离子电池 SOH 估算[J].电工技术学报,2020,35(19):4106-4119
Li Chaoran, Xiao Fei, Fan Yaxiang, et al. An approach to lithium-ion battery SOH estimation based on convolutional neural network[J]. Transactions of China Electrotechnical Society, 2020, 35(19):4106-4119
- [12] Yu Yong, Hu Changhua, Si Xiaosheng, et al. Averaged Bi-LSTM networks for RUL prognostics with non-life-cycle labeled dataset[J]. Neurocomputing, 2020, 402: 134-147.
- [13] Qiao Jianshu, Liu Xiaofeng, Chen Zehua. Prediction of the remaining useful life of lithium-ion batteries based on empirical mode decomposition and deep neural networks[J]. IEEE Access, 2020, 8: 42760-42767.
- [14] Wang Zhuqing, Liu Ning, Guo Yangming. Adaptive sliding window LSTM NN based RUL prediction for lithium-ion batteries integrating LTSA feature reconstruction[J]. Neurocomputing, 2021, 466: 178-189.
- [15] He Wei, Williard N, Osterman M, et al. Prognostics of lithium-ion batteries based on Dempster-Shafer theory and the Bayesian Monte Carlo method[J].

- Journal of Power Sources, 2011, 196(23): 10314-10321.
- [16] Wang Haiyang, Song Wanqing, Zio E, et al. Remaining useful life prediction for Lithium-ion batteries using fractional Brownian motion and Fruit-fly Optimization Algorithm[J]. Measurement, 2020, 161: 107904.
- [17] Saha B, Goebel K, Battery data set, in: NASA AMES Prognostics Data Repository, 2007.
- [18] Dong Hancheng, Jin Xiaoning, Lou Yangbing, et al. Lithium-ion battery state of health monitoring and remaining useful life prediction based on support vector regression-particle filter[J]. Journal of Power Sources, 2014, 271: 114-123.
- [19] Kingma D P, Welling M. Auto-encoding variational Bayes[J]. CoRR, 2013, abs/1312.6114.
- [20] Goodfellow Ian, Pouget-Abadie Ian, Mirza Mehdi, et al. Generative adversarial nets[C]// Neural Information Processing Systems. MIT Press, 2014.
- [21] 郑华林, 王超, 潘盛湖, 等. 基于 EEMD 和分层阈值的磁记忆信号降噪方法研究[J]. 工程设计学报, 2020, 27(4): 433-440.
- Zheng Hualin, Wang Chao, Pan Shenghu, et al. Research on noise reduction method of magnetic memory signal based on EEMD and layered threshold[J]. Chinese Journal of Engineering Design, 2020, 27(4): 433-440.
- [22] Frangopol D M, Lin K Y, Estes A C. Life-cycle cost design of deteriorating structures[J]. Journal of Structural Engineering, 1997, 123(10): 1390-1401.
- [23] Vincent P, Larochelle H, Bengio Y, et al. Extracting and composing robust features with denoising autoencoders[C]//Proceedings of the 25th international conference on Machine learning, Helsinki, Finland, 2008: 1096-1103.
- [24] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [25] Yang Jinsong, Fang Weiguang, Chen Jiayu, et al. A lithium-ion battery remaining useful life prediction method based on unscented particle filter and optimal combination strategy[J]. Journal of Energy Storage, 2022, 55: 105648.
- [26] Zhang Yong, Chen L, Li Yi, et al. A hybrid approach for remaining useful life prediction of lithium-ion battery with adaptive levy flight optimized particle filter and long short-term memory network[J]. Journal of Energy Storage, 2021, 44: 103245.
- [27] Xue Zhiwei, Zhang Yong, Cheng Cheng, et al. Remaining useful life prediction of lithium-ion batteries with adaptive unscented Kalman filter and optimized support vector regression[J]. Neurocomputing, 2020, 376: 95-102.
- [28] Pang Xiaoqiong, Liu Xiaoyan, Jia Jianfang, et al. A lithium-ion battery remaining useful life prediction method based on the incremental capacity analysis and Gaussian process regression[J]. Microelectronics Reliability, 2021, 127: 114405.

作者简介

尹 杰 男, 1999 年生, 硕士研究生, 研究方向为复杂系统可靠性与机器学习

E-mail: yin_jie1212@163.com

刘 博 男, 1979 年生, 副教授, 硕士生导师, 研究方向为复杂系统可靠性与机器学习。

E-mail: liubo1900@hrbust.edu.cn (通信作者)

Transfer Learning DAE-LSTM for Remaining Useful Life Prediction of Li-Ion Batteries

Yin Jie¹ Liu Bo¹ Sun Guobing² Qian Xiangwei¹

(1. School of Measurement and Control Technology and Communication Engineering Harbin

University of Science and Technology Harbin 150080 China

2. Electronic Engineering College of Heilongjiang University Harbin 150006 China)

Abstract Degradation data of battery capacity can be used to predict the battery remaining using life (RUL), but there

exist numerous noise data in the battery degradation process caused by factors such as ambient temperature, charge/discharge process and capacity recovery phenomenon. It makes prediction of data-driven life lithium-ion battery challenging. To improve the prediction accuracy and generalization ability of batteries RUL, we proposed a method based on Transfer Learning and Denoising AutoEncoder - Long Short Term Memory (DAE-LSTM).

Firstly, the variational autoEncoder - generative adversarial network (VAE-GAN) method was constructed designed. Encoding network was used to estimate the distribution of input data, and generating network and discriminant network were used for data regeneration. It improved the reliability of generated data by VAE method, and solved the problem that GAN method had been difficult to train. Secondly, the DAE-LSTM method was constructed for data denoising and capacity prediction. The DAE can reconstruct the input data and its encoder improved the robustness of the method by adding Gaussian noise. LSTM layer can analyze the temporal characteristics of data for capacity prediction. Due to the small amount of data, the network layer of the overall method was less to avoid overfitting. To reduce the parameters, the same loss function was used in both data denoising and capacity prediction. Finally, the optimal training scheme was determined through the different experiment: The data generated by VAE-GAN was used for method pre-training, then all network layers of the basic method were fine-tuned by actual data. This would effectively improve the prediction accuracy of the method, and ensure the reliability of the prediction results.

Experimental results showed that the proposed method has better predictive performance, and degradation trend of most batteries can be well predicted. MAE and RMSE were controlled within 2.46% and 3.76% respectively, and the lowest was 0.95% and 1.06%. Experimental results with different prediction starting points showed that the prediction were more accurate when the prediction starting point was closer to the failure threshold. This indicates that the method can accurately predict the degradation trend in later stages of battery life. Experimental results with other datasets showed that the proposed method has strong adaptability and generalization ability. It can effectively predict the lithium-ion battery RUL in small data samples. The 90% confidence interval of the prediction results with NASA dataset is narrow, indicating that the method has strong robustness. In addition, we counted the time taken to complete the RUL prediction for different datasets. As the RUL prediction of batteries is offline prediction with low real-time requirement, the training and testing time of the method meets the offline prediction requirement.

The following conclusions can be drawn from the simulation results: 1) The DAE-LSTM method can effectively denoising the degradation data of lithium-ion batteries, and making the prediction result more accurate. 2) VAE-GAN method can generate multiple groups of degradation data conforming to the real degradation to achieve the purpose of data enhancement. 3) Transfer Learning can ensure that the effective information of generated data and real data is fully utilized, so that the prediction model has higher accuracy and better generalization ability. By comparing the prediction results of other literatures, it is proved the proposed method has higher P_{re} and can be used to predict the RUL of lithium-ion batteries.

Keywords: Li-ion battery, remaining useful life, denoising, auto-encoder, long short-term memory, transfer learning