



引用格式: 王志福, 杨忠义, 罗巍, 等. 基于数据驱动的锂离子动力电池剩余使用寿命预测方法综述[J]. 科学技术与工程, 2023, 23(15) : 6279-6289.

Wang Zhifu, Yang Zhongyi, Luo Wei, et al. Review of remaining useful life prediction for lithium-ion battery based on data-driven[J]. Science Technology and Engineering, 2023, 23(15) : 6279-6289.

电工技术

基于数据驱动的锂离子动力电池剩余使用寿命预测方法综述

王志福^{1, 2}, 杨忠义¹, 罗巍¹, 卢彦希³

(1. 广西科技大学自动化学院, 柳州 545000; 2. 北京理工大学机械与车辆学院, 北京 100081;

3. 广西科技大学机械与汽车工程学院, 柳州 545000)

摘 要 准确预测锂离子动力电池的剩余使用寿命(remaining useful life, RUL) , 确保相关行业和设施的可靠性和安全性具有重要意义。数据驱动方法仅通过实验数据总结电池性能参数变化规律从而预测电池剩余寿命, 突破了传统基于模型方法精度低、难以建模、通用性差的局限。首先针对基于数据驱动的锂离子动力电池寿命预测的研究进行分析, 归纳总结出锂离子动力电池寿命预测建模思路。其次, 分类阐述了各种基于数据驱动的预测方法, 并对其优缺点进行了分析。最后, 给出了锂离子动力电池剩余寿命预测的发展趋势。

关键词 锂离子动力电池; 数据驱动; 剩余寿命预测; 建模

中图法分类号 TM912; **文献标志码** A

Review of Remaining Useful Life Prediction for Lithium-ion Battery Based on Data-driven

WANG Zhi-fu^{1, 2}, YANG Zhong-yi¹, LUO Wei¹, LU Yan-xi³

(1. School of Automation, Guangxi University of Science and Technology, Liuzhou 545000, China;

2. School of Machinery and Vehicle, Beijing Institute of Technology, Beijing 100081, China;

3. School of Mechanical and Automotive Engineering, Guangxi University of Science and Technology, Liuzhou 545000, China)

[Abstract] It is important to accurately predict the remaining useful life (RUL) of lithium-ion batteries to ensure the reliability and safety of related industries and facilities. The data-driven approach summarizes the changes of battery performance parameters only through experimental data so as to predict RUL, which breaks through the limitations of traditional model-based methods with low accuracy, difficult modeling and poor generality. The research on data-driven lithium-ion battery RUL prediction was analyzed, and the modeling ideas was summarized. Secondly, various data-driven prediction methods were categorized. Meanwhile, the advantages and disadvantages were analyzed. Finally, the development trend of the remaining life prediction of lithium-ion batteries was given.

[Keywords] lithium-ion battery; data-driven; remaining useful life; modeling

锂离子动力电池在消费电子产品、电网储能和电动汽车上的广泛应用, 深刻地改变了人类的生活方式。与其他储能设备相比, 锂离子动力电池具有能量密度高、寿命长、自放电率低等优点^[1-3]。然而, 电池在长期的使用过程中, 由于复杂的内部反应和外部干扰, 电池的容量持续下降^[4-5]。电池性能衰减影响着电池的寿命, 造成维护成本增加, 甚至设备故障^[6]。因此可靠的电池剩余使用寿命(re-

maining useful life, RUL) 预测方法可以保证更加规范有效地使用电池和降低故障率, 改善电池管理水平、提供维修策略和延长电池寿命^[7-10]。

锂离子动力电池的容量衰减是一个动态的非线性问题, 容量衰减趋势总体呈递减趋势, 多次波动。基于数据驱动预测的方法仅通过实验数据总结电池性能参数变化规律从而预测电池剩余寿命, 具有计算量小、过程简单等特点^[11]。因此, 用于健康估计和预

收稿日期: 2022-10-04 修订日期: 2023-03-23

基金项目: 国家自然科学基金(51775042)

第一作者: 王志福(1977—), 男, 汉族, 山东青岛人, 博士, 教授。研究方向: 智能电动车动力学、电机驱动系统控制与测试、多域分布式驱动平台等。E-mail: wangzhifu@bit.edu.cn。

投稿网址: www.stae.com.cn

测的数据驱动方法由于其灵活性和无模型的优势,越来越受到学术界和工业界的关注^[12]。

基于数据驱动法的锂离子动力电池 RUL 预测方法进行综述。首先给出了锂离子动力电池寿命预测的整体建模流程,并进行逐步的说明,形成普适的预测体系。重点介绍目前预测的主要方法,并对其优缺点进行分析,提出未来的发展趋势及挑战,为后续相关研究提供参考。

1 锂离子动力电池寿命预测建模

RUL 是指电池在当前时刻到寿命终止时刻前还能进行的充放电循环周期数^[13],基于数据驱动 RUL 预测能够根据过去的电池历史退化数据估计当前的退化状态,最大限度地降低维修成本并延长使用寿命。锂离子动力电池寿命预测建模流程的 4 个步骤主要过程如图 1 所示。

(1) 数据采集和处理:数据是基于数据驱动的 RUL 预测模型或算法的基础和源头,只有提取有效的电池退化数据并进行适当的预处理,包括降噪、缺失值填充、平滑等,才能获得期望的输出结果。随着电池技术的飞速发展,电池的性能和寿命得到很大的提高。然而,进行电池老化测试不但要求条件苛刻而且非常耗时。例如,Severson 等^[14]在 3.6C (C 为充放电倍率)循环充放电实验下,容量在 1 000 次循环内仅下降 4%,性能退化非常缓慢。因此大多数研究者使用美国航空航天局(National Aeronautics and Space Administration, NASA)或美国马里兰大学提供的数据集来验证他们的 RUL 预测算法。




图 1 建模流程的各个步骤
Fig. 1 Steps of the modeling process

(2) 健康指标和寿命终止:在锂离子动力电池使用过程中,其内部发生副化学反应会导致电解质、活性电极材料和锂离子损失,容量也会随着使用时间的增加而降低,因此,RUL 预测需要一个健康指标来量化电池的退化状态。在大多数研究中把容量作为直接健康指标^[15-16]。一般情况下,电池最大可用容量降为额定容量 70%~80% 时,电池寿命终止^[17]。然而,由于容量测试需要高精度和昂贵的测量仪器,难以应用于在线测量^[18]。因此,提取包含电池退化信息的间接测量参数,如充放电电压、电流、温度等反映锂离子动力电池的健康状况^[19],更具实用价值。

(3) 选择预测方法和预测剩余寿命:在基于数据驱动 RUL 预测流程中,选择预测算法是核心部分之一,决定 RUL 预测性能的关键^[20]。基于此,总结国内外基于数据驱动 RUL 预测方法的优缺点,如表 1 所示。详细内容将在第 2 节阐述。

实际工程中,电池实际 RUL 可以表示为从预测起点首次到达失效阈值的时间,预测 RUL 是预测起点首次到达预测终点的时间,预测过程如图 2 所示,其中电池真实数据来自 NASA PCoE 的 B5 号电池循环充放电的实验过程,失效阈值为额定容量下降到它的 30%,既额定容量从 2 A·h 下降到 1.4 A·h^[21]。




图 2 锂离子动力电池 RUL 预测过程
Fig. 2 RUL prediction process of lithium-ion battery

表 1 基于数据驱动的各种 RUL 预测方法优缺点对比

Table 1 Comparison of the advantages and disadvantages of various data-driven RUL prediction methods

预测方法	优点	缺点
经验预测法	经验模型简单,易于建立	忽略了电池的内部机制,鲁棒性较差
滤波预测法	在线应用,具备不确定性表示能力	依赖状态空间模型,模型自身存在缺陷
支持向量机回归模型	模型运行速度快,小样本预测效果佳	不能处理大量数据,预测精度受核函数影响
自回归模型	小样本预测效果佳,易于实施	容易欠拟合,长期预测能力差
高斯过程回归模型	适合高维样本数据,具备不确定性表达	计算成本高,缺乏稀疏性,核函数选择问题
循环神经网络	擅长处理时序数据	梯度消失或爆炸问题,丢失之前序列中的信息
卷积神经网络	自动提取退化特征信息,具有降噪的功能	时序特征提取能力不足
深度自编码网络	对数据进行降维,提取深层次的数据特征	参数选择困难
融合方法	有效,准确,稳定	不确定性融合,结构复杂,计算成本高

通过实际 RUL 与预测 RUL 做差可以得出模型或算法性能的优劣。一般来说预测有两种结果,预测 RUL 大于实际 RUL 或者小于实际 RUL,但在实际生活中,人们更期望预测 RUL 小于实际 RUL,这可以给维护者提前提供警告信息,及时维修电池,防止意外危险发生。

(4) 评估指标定义和性能评估: 实现模型与应用结合最关键的一步。在大多数工程项目中,研究者通常先在计算机上验证,再进行实物或半实物上进行模拟和评估。评估指标是为了定量评估预测模型的优劣,确保方法在实际中合理应用。文献中,常见的评估指标有均方根误差、平均绝对误差、和平均百分比误差等。这些评价指标都是误差的表现,值越小说明模型预测精度越高。

2 基于数据驱动法的锂离子动力电池 RUL 预测方法

2.1 经验退化模型预测方法

2.1.1 经验预测法

经验寿命估计模型旨在建立一个描述电池退化行为的数学模型,通过分析大量数据的相关性,以获得电池在其寿命期间的经验回归模型^[22]。之后通过外推来预测未来的电池性能。常用的模型有多项式模型^[23]、平方根模型^[24]、对数模型^[25]、单指数模型^[8]、双指数模型^[26]和混合模型^[27],如表 2 所示。经验模型简单、易于建立、适用性广,因为它忽略了电池的内部机制。然而,由于数据拟合和样本波动的不确定性,很难获得准确的 RUL 预测^[28],并且寿命估计模型的参数是通过大量老化数据拟合确定的,模型一旦建立就很难改变。

2.1.2 滤波预测法

基于滤波的算法分为卡尔曼滤波(Kalman filter, KF)、粒子滤波(particle filter, PF)和两者的改进算法^[29]。这些滤波算法都属于贝叶斯滤波算法体系,通过建立的状态方程和测量方程,模型参数会根据观测结果进行更新和估计。由于经验预测模型忽略了电池的内部机制,只建立 RUL 与电池特

性之间的相关性,而这种相关性随着电池老化和工作条件的变化而改变,因此,经验模型通常与滤波算法相结合。文献[30]考虑全局和局部回归特征,使用加权因子来结合指数模型和多项式模型,提出一个集成退化模型。通过将 PF 结合集成模型,预测结果比单指数模型和多项式模型在不同预测时间的结果进行比较,集成模型表现出更好的预测精度,PF 算法流程如图 3 所示。文献[31]对电池实验的参数变化和老化机制的相关性进行分析,通过采用 β 分布函数计算电容、电阻、和恒流充电,开发出一种综合的健康指标来预测 RUL,将三阶多项式模型拟合电池的健康状态退化过程,然后利用 PF 算法预测电池的 RUL,取得了较好的预测结果,但随着不断迭代,重要性权重将集中在少数粒子上,其余粒子的权重几乎为零。这个问题会使预测结果与实测值发生偏差。因此,文献[32]将无迹卡尔曼滤波算法(unscented Kalman filter, UKF)引入 PF 算法,提出一种改进的 PF 算法,无迹粒子滤波(unscented particle filter, UPF)。UPF 算法使用 UKF 生成一个提议分布,找到一组随机样本粒子来表示后验概率密度,使结果更符合真实情况,之后再使用标

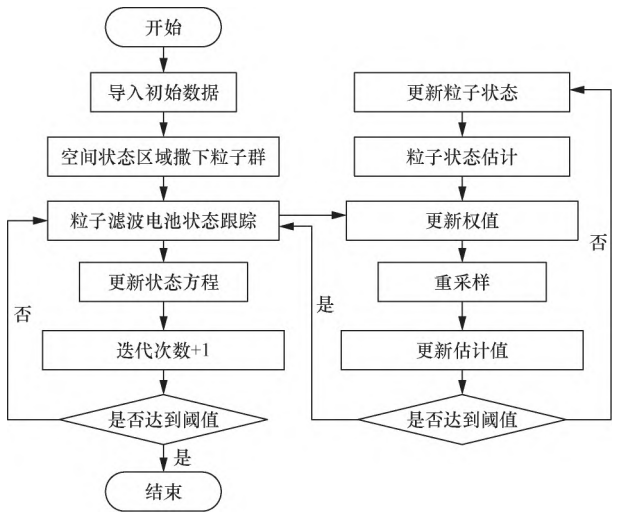


图 3 粒子滤波算法电池寿命预测步骤

Fig. 3 RUL prediction process of particle filter algorithm of lithium-ion battery

表 2 常用的电池寿命经验模型数学表达式

Table 2 Commonly mathematical expressions of empirical battery life model

名称	数学表达式	参数
多项式模型 ^[23]	$c_k = a_1 k^3 + a_2 k^2 + a_3 k + a_4$	a_1, a_2, a_3, a_4
平方根模型 ^[24]	$c_k = a_1 \sqrt{k} + a_2$	a_1, a_2
对数模型 ^[25]	$c_k = a_1 + a_2 \ln(k + m) + a_3 \ln(1 - a_4 k)$	a_1, a_2, a_3, a_4
单指数模型 ^[8]	$c_k = a_1 \exp(a_2 k)$	a_1, a_2
双指数模型 ^[26]	$c_k = a_1 \exp(a_2 k) + a_3 \exp(a_4 k)$	a_1, a_2, a_3, a_4
混合型模型 ^[27]	$c_k = 1 - a_1 [1 - \exp(a_2 k)] - a_3 k$	a_1, a_2, a_3

注: k 为循环数; c_k 为电池在 k 次循环时的容量; a_1, a_2, a_3, a_4 为待估计的模型参数; m 为一个恒定的正值。

准的 PF 算法进行预测。与传统的 PF 算法相比,UPF 算法预测实际失效时间误差小于 5%,优于 PF 算法。文献[33]建立描述锂电池退化的双指数状态空间模型,并引入自适应无迹卡尔曼滤波器(adaptive unscented Kalman filter,AUKF)算法,自适应更新过程噪声协方差和观测噪声协方差,然后利用遗传算法进行优化支持向量机回归算法,实现多步预测的关键参数获取,形成了 AUKF 与遗传算法优化支持向量回归相结合的综合算法。该算法的准确率至少可以达到 0.933。然而,无迹卡尔曼滤波算法对电池模型参数敏感、易受未知噪声影响的问题,文献[34]提出了一种结合等效电路模型和改进的卡尔曼滤波算法的混合模型来预测电池的充电状态。其中采用等效电路模型的用于电池的建模和参数辨识,综合各个参数对充电方式的影响。在改进的卡尔曼滤波算法中更新协方差时,直接对其进行线性传播,而不是无迹变换,从而简化了模型。改进的卡尔曼滤波方法克服了传统无迹卡尔曼滤波算法对电池模型和数据噪声的敏感性。复杂工况下的实验结果表明,与传统的无迹卡尔曼滤波算法相比,所提模型具有更好的预测精度和鲁棒性。

滤波算法属于递推算法能在线应用,可以对预测结果进行不确定性表示,避免单点预测带来的误差。然而 KF 算法虽然可以提高经验模型法的收敛性,但电池模型的精度容易受到电流、温度和外部干扰的影响,因此,很难准确地建立 RUL 预测模型。其次,广泛使用的 PF 算法 RUL 预测精度受到粒子退化和粒子多样性匮乏问题的限制。

2.2 浅层方法

经验预测模型需要大量数据进行建模,KF 不合适处理具有较强的非线性非高斯特征电池数据,UKF 仅在观测噪声方差较小时才能正常工作,而 PF 则受到自身模型缺陷影响,其改进算法也不能从根本上解决问题。因此,浅层方法由于其低数据依赖性和良好的非线性匹配能力在锂离子动力电池 RUL 预测领域得到进一步研究。

2.2.1 支持向量回归模型

支持向量回归(support vector regression,SVR)是支持向量机的推导,用于解决回归问题^[35]。在传

统回归模型中损失函数定义为 $f(x)$ 与其实际值 y 之间的误差,SVR 引入一个超参数 ε ,并且仅在 $|f(x) - y| > \varepsilon$ 时计算损失。通过构造拉格朗日损失函数,求得 SVR 的解。文献[36]采用粒子群优化算法(particle swarm optimization,PSO)优化 SVR 的方法,即使不对原始数据进行处理,也能准确掌握健康状态(state of health,SOH)的全局退化趋势而不受局部的容量再生波动影响。虽然,应用 PSO 能获得 SVR 内核的参数,但 PSO 算法存在局限性,不能充分利用迭代过程中的信息,在进行参数优化时容易陷入局部最优解的问题。此外,PSO-SVR 模型只注重捕捉电池容量的整体退化趋势而忽略了局部容量再生现象,这也导致其无法实现对 RUL 的准确预测。因此,之后的文献[37]采用人工蜂群算法(artificial bee colony,ABC)优化 SVR 的核参数,并与 PSO 优化的方法对比,验证了所提出的方法的优越性。文献[38]利用灰狼算法(gray wolf optimization,GWO)算法对 SVR 内核参数进行优化,此外,为了解决经验模态分解(empirical mode decomposition,EMD)方法的模态混叠问题,采用集成经验模态分解(ensemble empirical mode decomposition,EE-MD)用于解耦电池容量退化过程中的全局退化趋势和局部容量再生。然后,采用 GWO-SVR 模型预测全局恶化趋势和局部容量再生,实现电池 RUL 预测。各种不同优化方法的 SVR 模型在 NASA PCoE 数据集上以 68 循环次数为预测起点的不同编号电池 RUL 预测误差如表 3 所示^[39]。

SVR 在小样本、非线性、时间序列的数据上体现了明显优势,然而在大样本的情况下支持向量随着训练数据的增长线性增长,同时尽管利用优化算法去优化核参数目前已经取得很好的准确率,但是不可避免导致了计算的复杂性。

2.2.2 自回归模型

自回归模型(auto-regressive,AR)是基于可用数据构建的一种回归模型。即利用前一个时间步的观测值的线性组合作为输入预测未来的时间步值。文献[40]提出一种利用 PSO 算法搜索 AR 模型的最佳阶数,并根据迭代自适应地改变阶数。此外在预测阶段,通过把每个预测值插入到原数据并删

表 3 使用各类优化方法的 SVR 模型 RUL 预测误差
Table 3 RUL prediction errors for SVR models using various optimization methods

算法	B5		B6		B7		B18	
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
ABC-SVR ^[37]	0.007 1	0.013 2	0.041 8	0.046 3	0.007 5	0.014 4	0.030 2	0.033 2
PSO-SVR ^[37]	0.011 8	0.016 2	0.042 8	0.047 4	0.017 6	0.022 1	0.038 9	0.042 9
GWO-SVR ^[38]	0.011 4	0.012 8	0.021 2	0.026 3	0.011 4	0.015 7	0.023 5	0.026 2
EEMD-GWO-SVR ^[38]	0.009 6	0.011 3	0.007 5	0.009 6	0.013 1	0.015 0	0.010 1	0.012 7

除最早数据保证数据序列相同来迭代,实现 RUL 预测。虽然 AR 模型可以应用于时间序列分析中实现电池 RUL 趋势预测,但锂离子电池的退化趋势随着退化过程的进行,退化速率会随着循环次数的增加而加快。基本 AR 模型的预测函数无法跟踪“加速”的退化过程。因此,文献[41]分析了电池容量加速退化特征,将非线性退化因子与标准 AR 模型结合提出一种非线性退化自回归(nonlinear degradation auto-regressive, ND-AR)模型,有了这个加速退化因子,线性 AR 时间序列预测值就可以得到补充。解决了随着电池老化,线性 AR 模型无法处理电池容量非线性特征。锂离子电池在充放电循环过程中存在局部微小的容量恢复。这是由于一定的实验间隔导致电池容量部分恢复所致,由于这种特性它常常会改变 SOH 曲线的趋势,从而影响 SOH 估计和 RUL 预测。考虑到容量再生的影响,文献[42]将 SOH 序列视为具有多尺度分量的混合信号,利用 EMD 把全局退化部分和容量再生部分从原始 SOH 时间序列中解耦,使用自回归综合移动平均模型(auto-regressive integrated moving average, ARIMA)来预测全局退化趋势和局部容量再生,将所有单独的预测结果相加,得到全面真实的 SOH 预测,但是,这种方法并没有解决 EMD 方法的模态混叠问题,并且所提出模型缺乏对不确定性的估计。文献[43]提出了一种基于 ARMA 模型和 Elman 神经网络的融合模型。首先,通过电池生命周期数据获取电池的电压和容量退化的变化量,根据电压曲线的变化选择与电池老化相关的健康因子。其次,采用 EMD 对容量退化数据进行处理,提取多个数据序列以及相关残差,然后进行灰色关联分析(grey relational analysis, GRA),讨论了子序列和健康因子合理性。通过训练时间序列数据和残差数据,分别建立 AR-MA 模型和 Elman 神经网络模型。最后,将所有单独的预测组合起来估计 SOH 序列,进一步解决电池生命周期实验过程中出现微小容量恢复现象以及电池容量衰减过程中电压曲线的变化对预测精度的影响。然而在所提算法中没有考虑特殊条件下电池容量下降问题,此外只在单体电池上做了研究,对电池组的 SOH 研究还有待探讨。

AR 模型优点是所需样本不多,具有模型参数简单,计算量小的优点。然而由于其是线性回归类型,容易欠拟合。泛化能力和鲁棒性较差,并且预测结果是一定的点值,没有不确定表达。

2.2.3 高斯过程回归模型

高斯过程回归(Gaussian process regression, GPR)是一种基于核的机器学习方法,具有非参数建

模、概率预测和低计算负担的优点^[44],通过应用似然估计的训练过程和超参数优化获得高精度模型。GPR 模型简易流程如图 4 所示。文献[45]采用双 GPR 的电池模型,首先采用相关系数法从部分增量容量曲线中提取特征变量,可以避免使用复杂的信号处理技术来获取峰值,巧妙地处理噪声问题。高相关性特征用于构建 GPR 模型的输入,用于短期 SOH 估计,再将 SOH 估计结果作为建立电池 RUL 的自回归长期预测模型,克服了基于数据驱动和信号处理方法对处理敏感噪声和劣质特征变量的不足。之后的文献[46]在特征提取和模型构建等方面进行改进和增强。提出了一种新的多时间尺度框架来计算短期 SOH 并预测长期 RUL。通过分析部分增量容量,提取出 4 个重要特征,输入到高斯过程回归中。采用核修正高斯过程建立短期电池老化模型,结合非线性回归预测电池 SOH。长期 RUL 预测的平均绝对误差(mean absolute error, MAE)和均方根误差(root mean square error, RMSE)小于 26 个周期,电池 RUL 的误差主要集中在 5~20 次循环范围内。不过文中主要关注电压、电流和容量,忽视了温度效应的影响。为了解决容量再生导致容量曲线不稳定问题,文献[47]提出一种混合高斯过程模型(Gaussian process mixture, GPM),将曲线段分为多个不同特性的段,通过分别与不同的 GPR 模型拟合不同的片段,揭示了不同时间的微小差异,实现了较好的预测结果,更重要的是,与上述 SVR 和 AR 等非概率模型相比, GPM 模型可以生成预测置信区间。预测结果的可靠性可以用置信区间来衡量。文献[48]提出了一种基于多尺度逻辑回归(logic regression, LR)和 GPR 集成的锂离子电池 SOH 估计和预测的新方法。首先采用 EMD 来解耦电池容量时间序列中的全局退化、局部再生和各种波动。具有可变移动窗口的 LR 模型用于拟合残差(全局退化趋势)。GPR 用于递归地预测这些不同尺度的局部再生和波动。最后,将 LR 和 GPR 的预测结合起来实现电池 SOH 的预测。这种设计捕捉

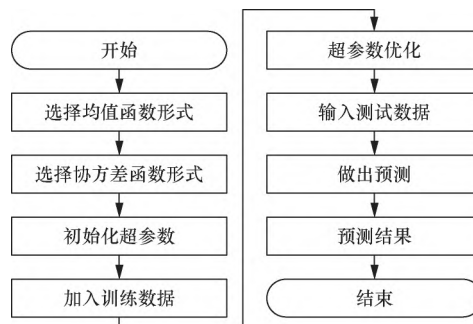


图4 GPR模型简易流程

Fig. 4 Simple process of GPR model

了锂离子电池随时间的退化行为,并减少了容量局部再生现象的影响。文献[49]提出了一种基于模糊评估高斯过程回归(fuzzy evaluation-gaussian process regression, FE-GPR)的RUL预测方法。基于GPR方法的特点,采用一种基于建立在专家知识的基础上的模糊评价方法对观测数据进行预处理。然后,通过引力搜索算法和历史数据进行优化分类节点。这种利用模糊逻辑结合专家知识的方法,可以避免数据受限情况下的过拟合,有效提高GPR模型的预测精度,在小样本回归分析值达到了0.739。

虽然GPR在处理高维和小样本数据集上具有准确、灵活和易于实现的优势,并能给出置信区间,然而其性能受核函数的影响很大,在大型数据集上计算成本高、缺乏稀疏性等缺点也限制了其应用。

2.3 深度学习方法

浅层方法虽然在锂离子动力电池RUL预测上取得了一定的成果,但是往往大多数模型在早期预测效果不好^[50-51]。深度学习具有更强的特征提取能力,克服了传统浅层模型方法学习能力不足问题^[52]。随着互联网的发展和计算机性能的进一步提高,锂离子动力电池RUL预测模型由“浅”入“深”势在必行。

2.3.1 循环神经网络

锂离子动力电池的容量降解数据是一种高非线性时间序列^[53],循环神经网络(recurrent neural network, RNN)作为一类包含前馈连接与内部反馈连接的前馈神经网络,能够保留隐含层上一时刻的状态信息,已经被研究者证明可以用于锂离子动力电池的RUL预测。文献[54]提出自适应递归神经网络(adaptive recurrent neural network, ARNN),对RNN结构的权值进行了多次修正,在锂离子动力电池RUL预测中获得了满意的结果。然而由于梯度消失和梯度爆炸的问题,传统的RNN在训练时,网络梯度往往会消失,在这种情况下,RNN将无法再学习。长短期记忆(long short-term memory, LSTM)网络是RNN的一种子类型,它通过引入的门的结构,结构如图5所示,能长时间记住信息,专门用于学习长期依赖关系。其中,遗忘门能够丢弃冗余信息,输入门能够选择关键信息存储在内部状态中,输出门用于确定输出信息。因此,文献[55]采用长短时记忆网络LSTM在训练时期利用均方反向传播方法,自适应优化算法,Dropout技术解决模型收敛缓慢和过拟合问题,并使用蒙特卡罗(Monte Carlo, MC)来预测RUL的不确定性。实验结果表明LSTM总体精度优于RNN。文献[56]利用EMD和GRA提取数据的时间序列特征并将其输入LSTM用于建

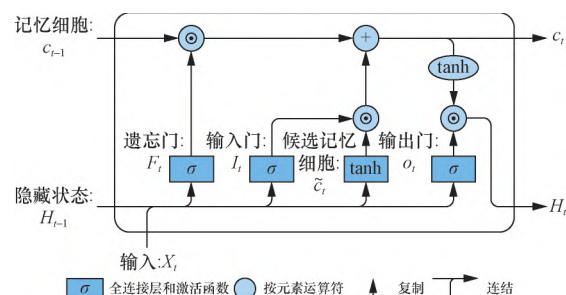


图5 LSTM结构

Fig. 5 The structure of LSTM

立电池的RUL预测模型,解决大多数文献将电池容量视为直接可获得的值并用于电池RUL预测。文献[57]首先采用EMD方法后,原始电池容量数据被分解为一些固有模态函数(intrinsic mode functions, IMFs)和一个残差。然后,应用LSTM子模型来估计残差,同时利用GPR子模型来拟合具有不确定性水平的IMF。解决容量的长期依赖性和容量再生引起的不确定性量化问题。在来自不同电池的实验老化数据上验证结果表明,LSTM-GPR组合模型优于其他模型,并且在一步和多步超前容量预测上都获得了准确的结果。即使在早期电池循环阶段预测RUL,所提出的方法也能表现出良好的预测精度和可靠的不确定性量化。不过尽管所提出的框架可以同时考虑容量长期依赖性和预测置信度,但相应的预测性能在很大程度上取决于数据的形式和测试实验的质量。在输入序列的所有时间步长可用的问题中,双向LSTM在输入序列上训练两个而不是一个LSTM。输入序列中的第一个是原样的,第二个是输入序列的反转副本。这可以为网络提供额外的上下文,并导致更快,甚至更充分的学习。文献[58]采用一种具有注意机制的双向长短期记忆(bidirectional long short-term memory with attention mechanism, Bi-LSTM-AM)模型,注意力机制识别每个特征的差异性,可以解决注意力分散问题,并且在模型训练前使用局部加权散点平滑法对数据进行平滑处理后带入Bi-LSTM-AM进行预测,在6个锂离子电池上验证所提出模型的优越性,其相对误差小于1.41%。

RNN因其自身结构特点在处理时间序列任务上有着先天的优势,但当处理长期依赖型退化数据时,常常面临着梯度消失或爆炸问题,导致之前序列中的信息丢失。即使其改进模型LSTM也不能完全避免此问题。同时,模型输出为点估计,难以评估预测结果的置信度。

2.3.2 卷积神经网络

卷积神经网络(convolutional neural network,

CNN) 是一类包含卷积计算且具有深度结构的前馈神经网络,通过局部连接、权值共享和下采样 3 个特性来降低模型的复杂度^[59]。与 RNN 相比,它避免了复杂的特征提取过程,同时可以有效减轻容量再生和少量数据引起的过拟合问题^[60]。文献[7]采用假最近邻法计算预测所需的滑动窗口大小,应用双层 CNN 提取特征,LSTM 对 CNN 提取的特征来建模。然而由于只采用了一个特征容量作为输入,模型不能学到更多的有用的信息,之后的文献[61]首先分析电池特征曲线,选择 6 个特征,包括时间序列特征和非时间序列特征,时间序列数据特征输入到被正交方法优化后的 CNN 模型后与非时间序列特征结合作为 LSTM 模型的输入,通过来自 NASA 数据集和 MIT 数据集在不同的老化条件下验证,结果表明电池 RUL 预测的误差可以降低到 1.5% 以下。文献[62]进一步在 CNN-LSTM 模型后加上 DNN 层,提出 CNN-LSTM-DNN 模型。通过与 LSTM、CNN-LSTM 相比,验证了在 CNN-LSTM 层后加上 DNN 层可以进一步提高预测精度。与基于模型的方法不同,基于数据驱动的方法,将模型视作黑盒模型,不能清楚的解释其模型对应电池退化的物理化学过程。文献[63]采用一种基于三维 CNN 和二维 CNN 混合的卷积神经网络。电池的电压、电流和温度首先由三维 CNN 层融合,隐藏在这些曲线中的特征及其循环之间的差异由两个 2DCNN 层自动提取和建模以进行预测。此外,采用充电特征注意力和多尺度充电循环注意力来动态估计充电过程中不同特征在电池寿命预测中的显著性和相关性和不同循环对电池寿命预测的显著性和相关性,取得较好的预测结果,不过即使文中将自注意力机制学习到的权重系数可视化,也难以将网络中的连接权重对预测结果的贡献及其相应的物理和化学意义进行说明。文献[64]还提出一种能在电池寿命预测中使用的膨胀卷积架构,膨胀卷积的前五层分析多变量输入序列中的时序模式。将每一层的扩张大小加倍,为 RUL 预测创建足够的感受野,保留了膨胀卷积的每个输出序列的长度,以在增加通道数量的同时保持时间信息。构建了一个从原始数据到预测结果的 RUL 预测模型,即“端到端”模型。所提出的模型仅需要少于 4 个周期的训练数据,而将预测误差降低到 10% 以下。与目前的许多研究相比,数据量减少,预测精度提高。

与其他深度学习网络相比,卷积神经网络能够更有效地处理锂离子动力电池高维原始数据,自动提取退化特征信息,具有降噪的功能。但是,电池老化数据是与时序相关的,而卷积神经网络对电池老化数据时序特征提取能力不足,造成重要时序特

征的丢失。因此卷积神经网络常常与其他模型组合使用。

2.3.3 深度自编码网络

深度自编码网络由多个自编码器或降噪自编码器堆叠组成,如图 6 所示,通过对原始数据特征进行重构得到深层次特征后输入逻辑回归层或全连接层实现剩余寿命预测^[65]。文献[66]提出一种深度自动编码器和高斯混合回归(stacked autoencoder and Gaussian mixture regression, SAE-GMR)的预测框架,引入 SAE 神经网络来降低维度和噪声,得到一个融合的健康指标后建立 GMR 模型进行 RUL 预测,通过与主成分分析法结合的 GMR 模型进行对比,所提出的方法估计结果与容量退化曲线基本重合,具有很强的融合退化信息和高精度预测性能。为了解决数据量的限制,文献[67]提出一种改进的 CNN 和 LSTM 数据驱动预测模型,采用自动编码器,通过增加数据的维度,用于从原始数据中提取更多信息,由 CNN 和 LSTM 模型进行特征扩展,CNN 挖掘深度信息,LSTM 提取数据之间的时序信息,将 CNN 和 LSTM 提取的特征组合送入 DNN 层进行预测。并使用一阶滤波器对预测结果进行平滑处理,预测结果 RMSE 为 4.8%,取得较好的预测结果,但忽略了数据去噪和模型预测两个任务之间的相关性。之后的文献[68]采用了一个目标函数来将去噪和预测任务结合起来,形成一个统一的框架。应用去噪自动编码器(denoising auto-encoder, DAE)处理原始数据,将重构的序列输入到 Transformer 网络后使用一个全连接层作为输出得到最终预测结果,在 NASA 和 CALCE 数据集上验证结果表明,所提出模型总体性能优于 RNN、LSTM。

自编码器以重构输入数据样本为学习目标,提取锂离子动力电池数据中深层的特征信息,对数据有更本质的刻画。然而,绝大多数自编码器在训练时采样参数随机初始化,增加了训练难度,影响模型的泛化性能。




图6 深度自编码器模型

Fig. 6 Deep self-encoder model

2.4 融合方法

融合预测方法是当前 RUL 预测领域研究的主要方向。总体思路是将多种模型融合,弥补单一模型的不足,充分发挥不同算法的优势,从而获得更好的性能^[29]。

文献[69]采用 KF 算法优化相关向量机(relevance vector machine, RVM)的预测输出结果,得到新的输出,重构训练集进行再训练,进而实现电池 RUL 的迭代预测,解决 RVM 算法长期预测性能较差的问题。文献[70]提出一种 UKF 和相关向量机回归(relevance vector regression, RVR)融合的算法,首先给定预测时间起点 T ,由 UKF 模型获得先验估计,随后与观测值进行比较得到滤波器的残差,再将残差数据作为历史样本训练 RVR 模型,得到残差的多步趋势后进行时变加权机制给残差赋权,之后使用赋权后的残差更新 UKF 模型,预测寿命周期。通过与 UKF、RVR 和 PF-RVR 方法相比,验证其可靠性。但该方法采用单核函数,只有单一的预测能力,对残差的预测效果不理想,文献[71]提出了一种具有不确定性评估能力的混合预测方法,该方法结合了 PF 和 RVM。通过 RVM 预测 PF 预测算法中的噪声干扰。预后结果包括一组确定性预测值来表示退化过程和一个预测区间来评估预测的不确定性。然而由于粒子退化、噪声干扰和未降低噪声干扰的预测误差,预测结果不尽如人意。考虑到上述文献的局限性,文献[72]提出一种(unscented particle filter and optimized multiple kernel relevance vector machine, UPF-OMKRVM)融合方法,结合 UPF 和 OMKRVM 的优点,并克服它们的局限性。首先,UPF 方法在滤波精度上有较好的效果,降低了粒子退化的影响,用于估计系统状态,从而跟踪退化过程。同时,可以获得估计值与真实值之间的原始误差数据。然后,对获得的误差数据进行互补集合模式分解(complementary ensemble empirical mode decomposition, CEEMD)方法降噪。为了准确预测错误的演变趋势,采用多核 RVM 而不是单核。最后,预测误差用于修正初始估计结果。通过及时纠错,可以显著提高预测的准确性。在两种公共实验数据上进行了对比实验,验证了所提混合方法的可靠性和鲁棒性。目前基于数据驱动的主流预测方法都可以给出令人较为满意的预测结果,但仍然存在一个共同的局限性,因为它们预测结果的精度往往取决于可供模型学习的数据长度。当训练数据的长度不足以让模型学习到数据的退化特征时,预测结果就很难达到预期的精度。因此,迁移学习受到更多关注,因为它可以通过预训练和微调找到源域

和目标域之间共享的参数信息。达到节省训练时间、提高模型通用性、减少训练数据的目的。文献[73]提出一种基于迁移学习(transfer learning, TL)、PF 和 LSTM 融合模型,将 TL-LSTM 对锂离子动力电池容量的长期预测值作为 PF 模型观测值,迭代更新 PF 模型参数,得到最终锂电池 RUL。解决了在不同工况下模型的泛化能力和小样本数据预测问题。文献[74]通过结合 Elman 神经网络和 LSTM 提出了一种混合模型,利用 EMD 算法能够将原始信号分解为各种高频子层和低频子层,分别作为 Elman 神经网络和 LSTN 的输入特征。Elman 神经网络可以描述短期信号波动,而 LSTM 可以捕捉长期信号的演化趋势,结合这两个子模型来预测电池 RUL,在两个未见数据集的相对预测误差分别为 3.3% 和 3.21%,实现较高精度的 RUL 预测。

混合方法是多个模型的组合,利用不同模型的优点,大大提高预测性能,具有有效、准确、稳点的优点。然而,因其是多模型结合,不可避免的增加了模型复杂性,存在计算成本高,不确定性融合等局限性。

3 未来发展趋势及挑战

目前,尽管在锂离子动力电池 RUL 预测上的研究取得了很大的进展,但仍有许多问题需要进一步研究。

(1) 根据上文所述,经验模型通过拟合大量老化数据来确定模型类型和参数,模型简单,易于建立,然而一旦模型构建完成,模型参数就无法更改。滤波模型属于递推算法能在线应用,可以对预测结果进行不确定性表示,避免单点预测带来的误差。浅层模型中,大多模型具有较低的计算成本和复杂度,算法运行时间短。不过 AR 模型由于其是线性回归类型,容易欠拟合,并且预测结果是一定的点值,没有不确定表达。SVR 和 GPR 模型都对其核函数高度敏感,因此选择合适的核函数对预测精度尤为重要。深度学习模型在不同寿命时期的电池 RUL 预测均有很好的效果,但模型的参数优化复杂,但运行时间较长,且依赖大量的训练数据。混合模型与用于 RUL 预测的单一模型结构相比,混合模型的效果更加稳定,预测精度更高,因此混合模型的发展意义重大,不过混合模型是通过组合两个模型或将优化技术与单个模型混合而来,两种不同模型的不确定组合可能会导致数据过拟合和计算复杂性的提高,因此,研究开发用于锂离子动力电池 RUL 预测的智能混合多种模型的技术是亟待开展的研究工作。

(2) 实际操作系统中,很难在线准确获取电池的直接性能退化参数。因此,为了方便快速实现电池性能的在线估计和预测,只能在线测量易于获取的电池性能退化的间接特征参数,例如,充放电电压、电流、温度等反映锂离子动力电池的健康状况。这些参数实时准确,可以从根本上提高预测精度和在线评估能力。然而,毫无疑问,通过合适的传感器准确测量电池中的物理化学反应,是获取电池寿命状态参数最直接、最准确的方法。因此开发先进的新型传感器,实时在线测量电池内部关键信息迫在眉睫。

(3) 目前讨论的 RUL 预测技术主要针对电池单体,然而,在实践中,通常将电池以串并联连接起来以构建满足特定能量和功率要求的电池组。由于各单体电池不同的材料成分和制造工艺差异,可能会出现个单体电池性能不一致的情况。此外,因为电池组中存在温度不一样和长久的循环充电和放电操作,单体电池会发生不均匀老化。因此需要进一步研究电池组的不一致性问题以预测电池 RUL。

(4) 快速 RUL 预测,即仅使用目标电池的几个数据周期即可完成的预测,可以在短时间内可靠地检测异常电池,从而显著降低生产成本并且用户还可以对现场使用的锂离子电池进行快速诊断,并提前将意外故障的可能性降到最低。例如,如果可以利用电池早期的 100 次循环来预测最终寿命为 2 000 次循环的电池的寿命,则可以避免 1 900 次循环测试,从而节省 95% 的测试时间和成本。

(5) 与电化学模型和半经验模型不同,数据驱动模型作为黑盒函数,不关注电化学知识或容量衰减的相关经验。难以说明基于数据驱动模型的连接权重或其他参数对预测结果的贡献及其对于电池退化过程中的物理和化学意义。未来应多关注充放电过程中的电化学物理反应过程,以增强模型在电池 RUL 预测中应用的可解释性。

4 结论

锂离子动力电池退化过程具有多物理、多尺度和高不确定性,特别是在噪声和不确定的环境下更难得到准确的分析模型来描述锂离子动力电池的退化过程。基于数据驱动的方法无需考虑电池内部的电化学特性,易于建模。因此越来越多研究者采用实验数据库的数据驱动方法来开展研究。详细阐述了基于数据驱动的锂离子动力电池寿命预测的建模流程,在总结目前主流方法优缺点的基础上,提出未来发展趋势及挑战,为后续开展相关研究提供参考。

参 考 文 献

- [1] 王志福,罗巍,闫愿,等. 锂离子动力电池传感器多故障诊断策略综述[J]. 科学技术与工程,2022,22(27): 11761-11773. Wang Zhifu, Luo Wei, Yan Yuan, et al. Summary of research on multi-fault diagnosis strategies of lithium-ion power battery sensors [J]. Science Technology and Engineering, 2022, 22(27): 11761-11773.
- [2] Gao Y, Zhang X, Guo B, et al. Health-aware multiobjective optimal charging strategy with coupled electrochemical-thermal-aging model for lithium-ion battery [J]. IEEE Transactions on Industrial Informatics, 2019, 16(5): 3417-3429.
- [3] Li Y, Liu K, Foley A M, et al. Data-driven health estimation and lifetime prediction of lithium-ion batteries: a review [J]. Renewable and Sustainable Energy Reviews, 2019, 113: 109254.
- [4] Zhao P, Tang B, Fang Z, et al. Structure, dielectric and relaxor properties of $\text{SrO} \cdot 7\text{BiO} \cdot 2\text{TiO}_3 \cdot 5\text{Bi} \cdot 5\text{TiO}_3$ lead-free ceramics for energy storage applications [J]. Journal of Materiomics, 2021, 7(1): 195-207.
- [5] Sun J L, Pei L, Liu R H, et al. Economic operation optimization for 2nd use batteries in battery energy storage systems [J]. IEEE Access, 2019, 7: 41852-41859.
- [6] Qi N, Dai K, Yi F, et al. An adaptive energy management strategy to extend battery lifetime of solar powered wireless sensor nodes [J]. IEEE Access, 2019, 7: 88289-88300.
- [7] Ma G, Zhang Y, Cheng C, et al. Remaining useful life prediction of lithium-ion batteries based on false nearest neighbors and a hybrid neural network [J]. Applied Energy, 2019, 253: 113626.
- [8] Zhang L, Mu Z, Sun C. Remaining useful life prediction for lithium-ion batteries based on exponential model and particle filter [J]. IEEE Access, 2018, 6: 17729-17740.
- [9] Wu Y, Li W, Wang Y, et al. Remaining useful life prediction of lithium-ion batteries using neural network and bat-based particle filter [J]. IEEE Access, 2019, 7: 54843-54854.
- [10] Xiong R, Li L, Tian J. Towards a smarter battery management system: a critical review on battery state of health monitoring methods [J]. Journal of Power Sources, 2018, 405: 18-29.
- [11] Lui Y H, Li M, Downey A, et al. Physics-based prognostics of implantable-grade lithium-ion battery for remaining useful life prediction [J]. Journal of Power Sources, 2021, 485: 229327.
- [12] Liu K, Shang Y, Ouyang Q, et al. A data-driven approach with uncertainty quantification for predicting future capacities and remaining useful life of lithium-ion battery [J]. IEEE Transactions on Industrial Electronics, 2020, 68(4): 3170-3180.
- [13] 戴海峰,张艳伟,魏学哲,等. 锂离子电池剩余寿命预测研究 [J]. 电源技术, 2019, 43(12): 2029-2035. Dai Haifeng, Zhang Yanwei, Wei Xuezhe, et al. A review of RUL prediction for lithium-ion battery [J]. Power Technology, 2019, 43(12): 2029-2035.
- [14] Severson K A, Attia P M, Jin N, et al. Data-driven prediction of battery cycle life before capacity degradation [J]. Nature Energy, 2019, 4(5): 383-391.
- [15] 李军,李虎林. 电动汽车锂离子电池荷电状态估算方法综述 [J]. 科学技术与工程, 2022, 22(6): 2147-2158. Li Jun, Li Hulin. Review of state of charge estimation methods for

- electric vehicle lithium-ion batteries[J]. Science Technology and Engineering ,2022 ,22(6) : 2147-2158.
- [16] Fan J , Fan J , Liu F , et al. A novel machine learning method based approach for Li-ion battery prognostic and health management[J]. IEEE Access ,2019 ,7: 160043-160061.
- [17] White C ,Thompson B ,Swan L G. Comparative performance study of electric vehicle batteries repurposed for electricity grid energy arbitrage[J]. Applied Energy ,2021 ,288: 116637.
- [18] 林慧龙,李赛. 基于粒子滤波的锂离子电池剩余使用寿命预测[J]. 科学技术与工程,2017 ,17(29) : 296-301.
Lin Huilong , Li Sai , Remaining useful life prediction of the lithium-ion battery based on particle filter algorithm [J]. Science Technology and Engineering ,2017 ,17(29) : 296-301.
- [19] Chen Y , He Y , Li Z , et al. Remaining useful life prediction and state of health diagnosis of lithium-ion battery based on second-order central difference particle filter[J]. IEEE Access ,2020 ,8: 37305-37313.
- [20] Wang S , Jin S , Deng D , et al. A critical review of online battery remaining useful lifetime prediction methods[J]. Frontiers in Mechanical Engineering ,2021 ,7: 719718.
- [21] Saha B , Goebel K. Battery data set: NASA ames prognostics data repository [DB/OL]. NASA Ames Research Center (2007) [2020-10-22]. <https://ti.arc.nasa.gov/tech/dash/groups/pcoe/prognostic-data-repository>.
- [22] Hu X , Xu L , Lin X , et al. Battery lifetime prognostics [J]. Joule ,2020 ,4(2) : 310-346.
- [23] Sun Y , Hao X , Pecht M , et al. Remaining useful life prediction for lithium-ion batteries based on an integrated health indicator [J]. Microelectronics Reliability ,2018 ,88: 1189-1194.
- [24] Yang F , Song X , Dong G , et al. A coulombic efficiency-based model for prognostics and health estimation of lithium-ion batteries [J]. Energy ,2019 ,171: 1173-1182.
- [25] Yang F , Wang D , Xing Y , et al. Prognostics of Li (NiMnCo) O₂-based lithium-ion batteries using a novel battery degradation model[J]. Microelectronics Reliability ,2017 ,70: 70-78.
- [26] 陈万,蔡艳平,苏延召,等. 锂离子电池的多状态模型剩余寿命预测方法 [J]. 科学技术与工程,2021 ,21 (10) : 4078-4083.
Chen Wan , Cai Yanping , Su Yanzhao et al. Model for predicting useful life of lithium-ion battery based on multi-state model [J]. Science Technology and Engineering ,2021 ,21(10) : 4078-4083.
- [27] Su X , Wang S , Pecht M , et al. Interacting multiple model particle filter for prognostics of lithium-ion batteries [J]. Microelectronics Reliability ,2017 ,70: 59-69.
- [28] Chen Z , Xue Q , Xiao R , et al. State of health estimation for lithium-ion batteries based on fusion of autoregressive moving average model and elman neural network [J]. IEEE access ,2019 ,7: 102662-102678.
- [29] Ge M F , Liu Y , Jiang X , et al. A review on state of health estimations and remaining useful life prognostics of lithium-ion batteries[J]. Measurement ,2021 ,174: 109057.
- [30] Xing Y , Ma E W M , Tsui K L , et al. An ensemble model for predicting the remaining useful performance of lithium-ion batteries [J]. Microelectronics Reliability ,2013 ,53(6) : 811-820.
- [31] Sun Y , Hao X , Pecht M , et al. Remaining useful life prediction for lithium-ion batteries based on an integrated health indicator [J]. Microelectronics Reliability ,2018 ,88: 1189-1194.
- [32] Miao Q , Xie L , Cui H , et al. Remaining useful life prediction of lithium-ion battery with unscented particle filter technique [J]. Microelectronics Reliability ,2013 ,53(6) : 805-810.
- [33] Xue Z , Zhang Y , Cheng C , et al. Remaining useful life prediction of lithium-ion batteries with adaptive unscented Kalman filter and optimized support vector regression [J]. Neurocomputing ,2020 ,376: 95-102.
- [34] Wang S , Fernandez C , Yu C , et al. A novel charged state prediction method of the lithium ion battery packs based on the composite equivalent modeling and improved splice Kalman filtering algorithm [J]. Journal of Power Sources ,2020 ,471: 228450.
- [35] Patil M A , Tagade P , Hariharan K S , et al. A novel multistage support vector machine based approach for Li ion battery remaining useful life estimation[J]. Applied Energy ,2015 ,159: 285-297.
- [36] Qin T , Zeng S , Guo J. Robust prognostics for state of health estimation of lithium-ion batteries based on an improved PSO-SVR model [J]. Microelectronics Reliability ,2015 ,55 (9-10) : 1280-1284.
- [37] Wang Y , Ni Y , Lu S , et al. Remaining useful life prediction of lithium-ion batteries using support vector regression optimized by artificial bee colony [J]. IEEE Transactions on Vehicular Technology ,2019 ,68(10) : 9543-9553.
- [38] Yang Z , Wang Y , Kong C. Remaining useful life prediction of lithium-ion batteries based on a mixture of ensemble empirical mode decomposition and GWO-SVR model[J]. IEEE Transactions on Instrumentation and Measurement ,2021 ,70: 1-11.
- [39] Pang X , Zhong S , Wang Y , et al. A review on the prediction of health state and serving life of lithium-ion batteries [J]. The Chemical Record ,2022 ,22(10) : e202200131.
- [40] Long B , Xian W , Jiang L , et al. An improved autoregressive model by particle swarm optimization for prognostics of lithium-ion batteries [J]. Microelectronics Reliability ,2013 ,53 (6) : 821-831.
- [41] Liu D , Luo Y , Liu J , et al. Lithium-ion battery remaining useful life estimation based on fusion nonlinear degradation AR model and RPF algorithm[J]. Neural Computing and Applications ,2014 ,25 (3) : 557-572.
- [42] Zhou Y , Huang M. Lithium-ion batteries remaining useful life prediction based on a mixture of empirical mode decomposition and ARIMA model [J]. Microelectronics Reliability ,2016 ,65: 265-273.
- [43] Chen Z , Xue Q , Xiao R , et al. State of health estimation for lithium-ion batteries based on fusion of autoregressive moving average model and elman neural network [J]. IEEE Access ,2019 ,7: 102662-102678.
- [44] Deng Z , Hu X , Lin X , et al. General discharge voltage information enabled health evaluation for lithium-ion batteries[J]. IEEE/ASME Transactions on Mechatronics ,2020 ,26(3) : 1295-1306.
- [45] Li X , Wang Z , Yan J. Prognostic health condition for lithium battery using the partial incremental capacity and Gaussian process regression[J]. Journal of Power Sources ,2019 ,421: 56-67.
- [46] Li X , Yuan C , Wang Z. Multi-time-scale framework for prognostic health condition of lithium battery using modified Gaussian process regression and nonlinear regression[J]. Journal of Power Sources ,2020 ,467: 228358.

- [47] Li L, Wang P, Chao K H, et al. Remaining useful life prediction for lithium-ion batteries based on Gaussian processes mixture [J]. Plos One, 2016, 11(9): e0163004.
- [48] Yu J. State of health prediction of lithium-ion batteries: multiscale logic regression and Gaussian process regression ensemble [J]. Reliability Engineering & System Safety, 2018, 174: 82-95.
- [49] Kang W, Xiao J, Xiao M, et al. Research on remaining useful life prognostics based on fuzzy evaluation-Gaussian process regression method [J]. IEEE Access, 2020, 8: 71965-71973.
- [50] 张若可, 郭永芳, 余湘媛, 等. 基于数据驱动的锂离子电池 RUL 预测综述 [J/OL]. 电源学报: 1-15 [2022-10-02]. <http://kns.cnki.net/kcms/detail/12.1420.tm.20210824.1932.014.html>.
- Zhang Ruoke, Guo Yongfang, Yu Xiangyuan, et al. A review of RUL prediction for lithium-ion battery based on data-driven [J/OL]. Journal of Power Supply: 1-15 [2022-10-02]. <http://kns.cnki.net/kcms/detail/12.1420.tm.20210824.1932.014.html>.
- [51] Yang H, Wang P, An Y, et al. Remaining useful life prediction based on denoising technique and deep neural network for lithium-ion capacitors [J]. ETransportation, 2020, 5: 100078.
- [52] Zhao G, Zhang G, Ge Q, et al. Research advances in fault diagnosis and prognostic based on deep learning [C]//2016 Prognostics and System Health Management Conference (PHM-Chengdu). New York: IEEE, 2016: 1-6.
- [53] Catelani M, Ciani L, Fantacci R, et al. Remaining useful life estimation for prognostics of lithium-ion batteries based on recurrent neural network [J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-11.
- [54] Liu J, Saxena A, Goebel K, et al. An adaptive recurrent neural network for remaining useful life prediction of lithium-ion batteries [R]. Silicon Valley: National Aeronautics and Space Administration Moffett Field CA Ames Research Center, 2010.
- [55] Zhang Y, Xiong R, He H, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries [J]. IEEE Transactions on Vehicular Technology, 2018, 67(7): 5695-5705.
- [56] Chen J C, Chen T L, Liu W J, et al. Combining empirical mode decomposition and deep recurrent neural networks for predictive maintenance of lithium-ion battery [J]. Advanced Engineering Informatics, 2021, 50: 101405.
- [57] Liu K, Shang Y, Ouyang Q, et al. A data-driven approach with uncertainty quantification for predicting future capacities and remaining useful life of lithium-ion battery [J]. IEEE Transactions on Industrial Electronics, 2020, 68(4): 3170-3180.
- [58] Wang F K, Amogne Z E, Chou J H, et al. Online remaining useful life prediction of lithium-ion batteries using bidirectional long short-term memory with attention mechanism [J]. Energy, 2022, 254: 124344.
- [59] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [60] Shen S, Sadoughi M, Li M, et al. Deep convolutional neural networks with ensemble learning and transfer learning for capacity estimation of lithium-ion batteries [J]. Applied Energy, 2020, 260: 114296.
- [61] Li D, Yang L. Remaining useful life prediction of lithium battery based on sequential CNN-LSTM method [J]. Journal of Electrochemical Energy Conversion and Storage, 2021, 18(4): 041005.
- [62] Zraïbi B, Okar C, Chaoui H, et al. Remaining useful life assessment for lithium-ion batteries using CNN-LSTM-DNN hybrid method [J]. IEEE Transactions on Vehicular Technology, 2021, 70(5): 4252-4261.
- [63] Yang Y. A machine-learning prediction method of lithium-ion battery life based on charge process for different applications [J]. Applied Energy, 2021, 292: 116897.
- [64] Hong J, Lee D, Jeong E R, et al. Towards the swift prediction of the remaining useful life of lithium-ion batteries with end-to-end deep learning [J]. Applied Energy, 2020, 278: 115646.
- [65] Al-Dulaimi A, Zabihi S, Asif A, et al. A multimodal and hybrid deep neural network model for remaining useful life estimation [J]. Computers in Industry, 2019, 108: 186-196.
- [66] Wei M, Ye M, Wang Q, et al. Remaining useful life prediction of lithium-ion batteries based on stacked autoencoder and gaussian mixture regression [J]. Journal of Energy Storage, 2022, 47: 103558.
- [67] Ren L, Dong J, Wang X, et al. A data-driven auto-cnn-lstm prediction model for lithium-ion battery remaining useful life [J]. IEEE Transactions on Industrial Informatics, 2020, 17(5): 3478-3487.
- [68] Chen D, Hong W, Zhou X. Transformer network for remaining useful life prediction of lithium-ion batteries [J]. IEEE Access, 2022, 10: 19621-19628.
- [69] Song Y, Liu D, Hou Y, et al. Satellite lithium-ion battery remaining useful life estimation with an iterative updated RVM fused with the KF algorithm [J]. Chinese Journal of Aeronautics, 2018, 31(1): 31-40.
- [70] Zheng X, Fang H. An integrated unscented kalman filter and relevance vector regression approach for lithium-ion battery remaining useful life and short-term capacity prediction [J]. Reliability Engineering & System Safety, 2015, 144: 74-82.
- [71] Chang Y, Fang H. A hybrid prognostic method for system degradation based on particle filter and relevance vector machine [J]. Reliability Engineering & System Safety, 2019, 186: 51-63.
- [72] Sun X, Zhong K, Han M. A hybrid prognostic strategy with unscented particle filter and optimized multiple kernel relevance vector machine for lithium-ion battery [J]. Measurement, 2021, 170: 108679.
- [73] Pan D, Li H, Wang S. Transfer learning-based hybrid remaining useful life prediction for lithium-ion batteries under different stresses [J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-10.
- [74] Li X, Zhang L, Wang Z, et al. Remaining useful life prediction for lithium-ion batteries based on a hybrid model combining the long short-term memory and Elman neural networks [J]. Journal of Energy Storage, 2019, 21: 510-518.