

学校代号 10532

分 类 号 TM911

学 号 S190900725

密 级 公 开



湖南大学
HUNAN UNIVERSITY

硕士学位论文

锂电池健康状态估计及剩余使用寿命 预测研究

学位申请人姓名 薛瑾

培 养 单 位 电气与信息工程学院

导师姓名及职称 刘波峰 副教授

学 科 专 业 电气工程

研 究 方 向 电力电子与电力传动

论文提交日期 2020 年 4 月 22 日

学校代号：10532

学 号：S190900725

密 级：公 开

湖南大学硕士学位论文

锂电池健康状态估计及剩余使用寿命 预测研究

学位申请人姓名：薛瑾

导师姓名及职称：刘波峰 副教授

培 养 单 位：电气与信息工程学院

专 业 名 称：电气工程

论文提交日期：2020 年 4 月 22 日

论文答辩日期：2020 年 5 月 15 日

答辩委员会主席：温和 教授

Research on state of health estimation and remaining useful life
prediction of lithium-ion battery

by

XUE Jin

B.E. (Ningxia University) 2019

A thesis submitted in partial satisfaction of the

Requirements for the degree of

Master of Engineering

in

Electrical Engineering

in the

Graduate School

of

Hunan University

Supervisor

Associate Professor LIU Bofeng

May, 2022

摘 要

锂电池广泛应用于新能源汽车和电网储能领域，电池状态监控是保障电池安全可靠运行的前提，为预防电池老化导致设备性能下降，避免因电池故障引起事故，需要对电池的健康状态（State of Health, SOH）及剩余使用寿命（Remaining Useful Life, RUL）进行实时监测，及时更换老化或故障电池，保障系统安全稳定运行。锂电池的 SOH 和 RUL 在实际使用过程中无法直接获得，主要通过电池建模和数据驱动的方法量化健康状态和剩余使用寿命指标，电池建模的方法由于建模过程复杂、泛化能力差、无法实时更新导致精度不高且局限性较大，传统的数据驱动方法由于电池容量再生现象导致局部数据波动预测精度较差，因此如何提高模型预测精度，解决电池容量再生现象导致的局部波动预测困难的问题是当前锂电池 SOH 估计及 RUL 预测的研究热点。本文主要研究内容分为以下几个方面：

首先，介绍电池状态监测对系统安全运行的重要性，阐述锂电池健康状态估计和剩余使用寿命预测的国内外研究现状，分析总结 SOH 估计方法与 RUL 预测方法的优点与不足。

其次，针对锂电池健康状态关键影响因素筛选不全面的问题，对锂电池工作原理及老化机理进行研究，总结导致电池老化的主要因素，以电压、电流、温度参数曲线及容量增量曲线、差分电压曲线为分析对象，提取了包含电池老化状态信息的容量增量峰、差分电压拐点、恒流充电时间等 9 个特征参数，对特征进行标准化，采用箱型图方法剔除异常值，利用 K 最邻近法和随机森林处理缺失数据，通过皮尔森相关系数筛选与电池健康状态指标强相关特征，并建立锂电池 SOH 估计与 RUL 预测模型的评价指标体系，为模型有效性评估提供理论依据。

然后，针对 SOH 估计模型在实际使用过程中实用性差的问题，完成了在鲸鱼优化算法（Whale Optimization Algorithm, WOA）基础上对轻梯度提升模型（Light Gradient Boosting Machine, LightGBM）改进，得到了优化的 WOA-LightGBM 模型。为进一步提升 LightGBM 模型性能，利用 WOA 算法的全局寻优和局部挖掘能力，寻找模型最优参数。实验结果表明，相比极限梯度提升机、轻梯度提升机和贝叶斯优化算法改进的 LightGBM 模型，本文方法的拟合优度最大，均方根误差最小，建模速度最快，能实现自动调参并快速准确地估计 SOH 值。

最后，针对 RUL 局部波动预测较差的问题，研究一种注意力机制改进的一维卷积双向长短时记忆神经网络用于 RUL 的预测。考虑到电池 SOH 与 RUL 间存在映射关系，利用 SOH 数据对 RUL 进行预测。通过一维卷积神经网络（Convolutional Neural Network, CNN）提取 SOH 数据的局部特征，利用双向长短时记忆神经网络

络（Bidirectional Long Short Term Memory Network, BiLSTM）模型提取局部特征的时序特征，引入注意力机制（Attention Mechanism），通过对特征赋予权重和自适应增强特征对模型的影响，提高模型对局部波动预测的准确性。对比实验表明，本文模型 CNN-BiLSTM-Attention 在不同电池数据下的 RUL 预测平均误差分别为 1.35%、0.20%、0.16%和 0.51%，说明本文采用的模型具有很高的预测精度和很强的泛化能力。在同一个电池数据集下，本文模型的 RUL 预测平均误差为 0.45%，与 BiLSTM、CNN-BiLSTM、BiLSTM-Attention 相比，误差分别降低了 1.34%、0.98%、0.59%，表明加入注意力机制后模型可有效捕捉局部特征，解决了容量再生现象导致的局部波动预测困难的问题。

关键词：锂电池；健康状态估计；剩余使用寿命预测；WOA-LightGBM 模型；CNN-BiLSTM-Attention 模型；注意力机制

Abstract

Lithium-ion batteries are widely used in the new energy vehicles and energy storage areas. Battery status monitoring is the premise to ensure the safe and reliable operation of batteries. In order to prevent battery aging from deteriorating device performance, and to avoid disaster caused by the failures of the battery, we need to monitor battery state of health(SOH) and remaining useful life(RUL). So, we can replace the aging or failure batteries, ensure the system run safely. We can't get the SOH and RUL parameters in actual using process, mainly through the battery modeling and data driving method to quantify them. Due to the complex modeling process, poor generalization ability and inability to update in real time, the battery modeling method has low accuracy and great limitations. The traditional data-driven approach also have poor prediction accuracy due to battery capacity regeneration. In result, how to improve prediction accuracy, solve the difficulty of predicting local fluctuation caused by battery capacity regeneration, is the current research hotspot. The main research contents of this paper are as follows:

Firstly, introduce the importance of battery status monitoring to the safe operation of the system and the research status from domestic and abroad. Summarize the advantages and disadvantages of SOH estimation method and RUL prediction method.

Secondly, focus on the problem of incomplete screening of key influencing factors of SOH, the working principle and aging mechanism of Li batteries were studied, and the main factors leading to battery aging were summarized. The curves of voltage, current and temperature parameters, capacity increment curve(IC) and differential voltage(DV) curve, which reflect the aging status of batteries were taken as analysis objects. Nine characteristic parameters including IC peak, DV inflexion point and constant charging time were extracted and standardized. The box graph method was used to eliminate outliers. K nearest neighbor method and random forest were used to process missing data. Pearson correlation coefficient was used to filtrate the characteristics strongly correlated with the SOH index. The evaluation index system of SOH estimation and RUL prediction model for lithium-ion battery was established to provide theoretical basis for the validity evaluation of the model.

And then, aiming at the problem of poor practicability of SOH estimation model in practical use, the light gradient boosting machine(LightGBM) model was improved based on whale optimization algorithm(WOA), and the optimized WOA-LightGBM model was obtained. In order to further improve the performance of LightGBM model,

the whale algorithm's global optimization and local mining capabilities are used to find the optimal parameters of the model. The experimental results show that compared with XGBoost, LightGBM and bayes optimization algorithm improved LightGBM model, the proposed method has the highest fitting accuracy, the smallest root mean square error, the fastest modeling speed, and can realize automatic parameter adjustment and at the same time estimate SOH value quickly and accurately.

Finally, a one-dimensional convolutional bidirectional short and long time memory neural network with improved attention mechanism is proposed to predict RUL. Considering the mapping relationship between SOH and RUL, the SOH data was used to predict RUL. Local features of SOH data were extracted by one-dimensional convolutional neural network(CNN), and time-order character of local features were extracted by bidirectional long short term memory network(BiLSTM). Attention mechanism was introduced to enhance the influence of features on the model by giving weight to features and adaptive enhancement, so as to improve the prediction accuracy of local fluctuation of the model. The experimental results show that the average error of RUL prediction for different battery data is 1.35%, 0.20%, 0.16% and 0.51%, respectively, indicating that the model adopted in this paper CNN-BiLSTM-Attention has high prediction accuracy and strong generalization ability. Under the same battery data set, the average error of RUL prediction of this model is 0.45%, which is reduced by 1.34%, 0.98% and 0.59% respectively compared with BiLSTM, CNN-BiLSTM and BiLSTM-Attention, indicating that the model can effectively capture local features with the addition of attention mechanism. The difficulty of predicting local fluctuation caused by capacity regeneration is solved.

Key Words: Lithium-ion Battery; SOH estimation; RUL prediction; WOA-LightGBM model; CNN-BiLSTM-Attention model; Attention Mechanism

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 研究现状.....	2
1.2.1 SOH 估计方法研究现状.....	2
1.2.2 RUL 预测方法研究现状.....	3
1.2.3 发展趋势研究.....	8
1.3 论文主要内容与结构安排	8
第 2 章 锂电池工作机理与特征参数研究	10
2.1 锂电池原理.....	10
2.1.1 锂电池内部结构及工作原理.....	10
2.1.2 锂电池老化及容量衰减机理.....	11
2.2 锂电池性能参数分析.....	11
2.3 实验对象与实验数据介绍	13
2.4 锂电池特征参数.....	14
2.4.1 特征选择.....	15
2.4.2 特征参数分析.....	20
2.5 特征数据预处理.....	22
2.5.1 数据清洗.....	22
2.5.2 SOH 和 RUL 评价指标体系分析.....	26
2.6 本章小结.....	27
第 3 章 锂电池 SOH 估计方法研究与优化	28
3.1 鲸鱼优化算法原理.....	28
3.2 LightGBM 算法原理.....	30
3.3 基于 WOA-LightGBM 的 SOH 估计模型.....	32
3.3.1 SOH 估计模型框架.....	32
3.3.2 基于 WOA 算法的 LightGBM 超参数优化	33
3.4 算法仿真与结果分析.....	34
3.4.1 仿真设置.....	35
3.4.2 不同模型 SOH 估计结果比较.....	35
3.4.3 不同数据集 SOH 估计结果比较.....	39
3.5 本章小结.....	41
第 4 章 RUL 预测方法研究与优化	42
4.1 卷积神经网络原理.....	42
4.2 双向长短期记忆网络.....	43

4.3 注意力机制实现.....	45
4.4 基于 CNN-BiLSTM-Attention 的 RUL 预测模型研究.....	45
4.4.1 RUL 预测融合模型结构设计.....	46
4.4.2 基于预测融合模型的 RUL 预测流程	46
4.5 预测仿真实验与分析.....	47
4.5.1 仿真设置.....	48
4.5.2 不同电池预测效果比较.....	49
4.5.3 消融实验.....	51
4.6 本章小结.....	55
结论.....	56
参考文献.....	58

第 1 章 绪 论

1.1 研究背景及意义

21 世纪，随着全球人口的不断增加和经济飞速发展，对能源的需求也随之增加。目前，以矿物能源为主的能源结构导致了温室效应、环境污染等严峻问题。温室效应并不意味着温度升高，而是容易出现极端天气，并演变为气候灾害。近几年极端天气频发，2021 年北美、欧洲出现极寒天气，印度遭受酷暑，造成当地天然气、煤炭等资源的短缺。极端天气引发燃料和电力需求跃升，但是以可再生能源为主体的能源结构使得未来我们需要面对能源短缺这一大挑战。为了加快能源转型，发展低碳经济，我国提出了双碳政策。碳中和碳达峰可以减缓碳排放量，减缓全球变暖的速度，也是实现能源自主的必经之路。因此，新能源取代传统的矿物能源已成为今后发展的必然趋势。

新能源的发展主要有能源生产和能源消费两个领域。从能源生产的角度出发，近年新能源发电技术发展迅速，其中以风电、光电为主体。而储能能显著提高风电、光电的稳定性，是新能源发电中重要的一环。能源产业新能源发电，电池储能的这一转型使储能型锂电池的规模大幅增长，我国储能锂电池产量预计 2025 年达到 114.7GWh。从能源消费的角度出发，新能源汽车代替燃油车是目前的趋势，而易于成组、循环寿命高、环境温度变化适应性强的特点也能使动力电池很好的在乘用车领域代替传统燃料。根据 HIS Markit 数据，我国电动汽车销量预计至 2025 年突破 400 万辆。锂电池技术在储能和新能源车领域都扮演着重要的角色，是实现双碳目标的关键。2020 年以来，电池领域头部企业加速对电池新技术的研究，例如在电池中使用固态电极和电解质。提升电池的能量密度和降低生产成本这两个发展方向将使锂电池有更强的竞争力和应用潜力。

当前，电池负极材料和结构等方面虽然进行着不断地改进，但是再好的锂电池也会面临失效和老化问题。智能电表内的锂电池没电或者电压不足，会导致数据丢失、时钟错误并影响数据的远程采集。2013 年波音 787 客机上的锂电池单元内部短路，系统热失控产生大量烟雾导致飞机紧急降落。2016 年，三星手机因电池故障原因召回 100 万部手机。2021 年，北京集美储能电站爆炸，在过去十年间全球共发生至少 32 起储能电站起火爆炸事故。总结事故原因，主要是储能系统安全性退化和电池管理系统的可靠性不足引起，系统未在电池处于过充过放或异常状态及时预警，加剧了电池失控的风险。因此，对电池进行状态监测与评估，从而进一步指导电池的运行维护，可以防止电池过充、电压升高形成内短路造成安全事故，对保障电池管理系统安全、稳定、可靠运行具有重要意义。

1.2 研究现状

锂电池状态监测主要包括 SOH 估计和 RUL 预测。锂电池 SOH 反映了电池相对于初始状态存储电能的能力，定义为满电电池完全放电放出的容量与新电池容量的比值。电池的 SOH 随着使用次数增加，总体呈现下降趋势。锂电池 RUL 预测的研究主要基于电池的标准循环寿命，指在设定的充放电制度下电池从能正常工作的全新状态到退化到不能维持设备正常工作期间经历的充放电循环次数^[1]。通常认为，寿命终止的条件为电池容量降至原来的 70%-80%，即剩余使用寿命为零^[2]。接下来主要介绍锂电池健康状态估计及剩余使用寿命预测的国内外研究现状。

1.2.1 SOH 估计方法研究现状

锂电池的 SOH 与电池老化过程密切相关，电池老化外部特征表示为满充后能完全释放的能量降低，内部特征表征为电池容量衰减、内阻增加，因此常将容量和内阻作为 SOH 的评价指标。基于实验分析和模型的方法是当前主流的 SOH 估计方法^[3]。

1. 实验分析法

实验分析法包括直接测量和间接分析两种，主要区别在于选择了不同的用来评价电池 SOH 的参数。这些参数能反映电池的退化状态，通过对电池的实验数据进行分析 and 提取得到。

(1) 直接测量法。直接测量法选择的参数是容量和内阻，这两个参数在实际使用的过程中较难测得，需要在实验室使用专业设备测量。锂电池容量的单位为安时 (A·h)，数值上等于电池在一定的实验条件下充入或释放的能量。周頔等人研究了一种基于蒙特卡罗方法的不确定度修正锂电池等效电路模型的方法，避免了测量精确度的不确定性对电池模型的干扰。^[4]卢成等人围绕在线测量电池容量精度提升的问题，提出修正由于电池内阻变化和超出规定范围内使用电池的温度对容量测量的干扰。^[5]

由于锂电池两端存在直流电压，因此普通电表无法测量电池内阻。由于电池存在不一致性，其内阻也不相同，但都处于规定范围内。电池内阻在充放电过程中不断变化，欧姆内阻遵循欧姆定律，由电池内部正负极材料、电解液和隔膜的接触电阻构成；极化电阻指电池内部极化反应产生的电阻，随电流密度增大而增大。郭庆等为了消除测量误差，测量电阻时同时使用了交流注入法和开尔文四线检测法^[6]。高金辉等提出一种通过改变电池充电电流的大小的方法，实现了在线测量电池组中的每个电池^[7]。直接测量法容易实现，能直接反映锂电池老化状态，但是容易受不确定性因素影响，对数据采集精度有一定的要求，并且实验时间长，实验设备成本较高。

(2) 间接分析法。间接分析法通过设计的健康因子来间接反映电池的老化情况,例如固体电解质界面膜阻抗、恒压充电时间、增容增量(Incremental Capacity, IC)或差分电压(Differential Voltage, DV)等。SEI膜具有阻挡电子和允许锂离子通过的功能,这两个功能的退化是电池退化最常见的原因。张铮等选择电化学阻抗谱(Electrochemical Impedance Spectroscopy, EIS)作为研究方法,研究固体电解质界面膜阻抗在电池充电过程中的变化,发现电荷转移电阻主导电池总体阻抗,使其总体呈降低趋势^[8]。IC曲线描述 $dQ/dV-V$, DV曲线描述 $dV/dQ-Q$,这两种曲线可由恒流充放电数据变换而得。周坤等对实车的三元锂电池包的IC曲线通过高斯滤波法处理,总结发现IC峰随电池包循环次数的增加有规律地变化^[9]。杨胜杰等选择IC曲线峰值区间的电压数据作为特征提取的对象,结合高斯过程回归估计SOH,研究结果表明来源于不同电压区间的特征对SOH影响不同,在敏感区间内得到的SOH估计值准确率更高^[10]。间接分析法精度较高,能反映电池的老化机理,但是需要大量实验数据,并且实验时间长。

2. 基于模型的方法

基于模型的方法首先需要模型对电池的参数进行估算,然后再进行SOH估计,主要有自适应状态估计及基于数据驱动估计的方法。

(1) 自适应状态估计法。自适应状态估计法通过辨识电池模型模型的参数,然后外推得到SOH的估计值,常用的有电化学模型和等效电路模型。张吉昂等围绕IC曲线展开研究,提取电池充电过程中的IC曲线峰值作为特征参数,采用卡尔曼滤波方法去除IC曲线中的噪声,然后通过Box-Cox变换增强特征与SOH的相关性,容量退化数据的前半部分作为训练数据,线性拟合预测剩余周期的SOH,实验证明提出的这种方法估计精度高、运算时间短并且鲁棒性强^[11]。自适应算法的精度较高,但是模型参数需要反复调整,对模型准确度依赖较高。

(2) 基于数据驱动的方法。从大量历史数据中通过算法学习其中的老化特征,而不需要精确的数学模型描述电池内部状态。王宇胜等提出长短期记忆神经网络(Long Short-Term Memory, LSTM)与支持向量机(Support Vector Machine, SVM)的融合模型用于估计SOH,解决了传统机器学习记忆力差的问题,并且不需要建立复杂的模型,也避免了测量法实验步骤复杂的缺点^[12]。张婷婷等针对SOH估计问题样本量较小的特点,提出采用在小样本问题上效果较好的SVM作为基础模型,采用改进的鸡群算法对其超参数进行优化,从而得到模型的最优参数,提高了拟合精度^[13]。基于数据驱动的方法精度高,预测结果比较稳定,但是需要大量的离线数据,算法的时间复杂度较高。

1.2.2 RUL 预测方法研究现状

锂电池RUL预测利用电池运行状态的历史信息,预测锂电池的最大可用容量从当前时刻衰减退化到某一失效或者设定阈值需要经历的循环周期数^[14]。准确的

RUL 预测有利于电池安全可靠地运行。目前锂电池 RUL 预测方法主要包括以下三种^[15]。

1. 基于模型驱动的方法

基于模型驱动的预测方法利用锂电池组的组成材料、成组方式、电池外形、使用环境、失效机制等方面的先验知识进行 RUL 预测^[15]，这种预测方法的研究开始较早，发展到目前整体体系比较成熟，接下来对这种方法进行简要介绍。基于模型的方法可进一步分为以下三种方法^[16]。

(1) 电化学模型法。锂电池电化学模型研究锂电池在使用过程中的全生命周期内部化学机理和外部环境因素耦合对状态变量的影响，建立电池故障机理模型的一般过程为先建立电池单体充放电模型，然后将能表示电池退化因素的参数加入到模型中，这样就完成了能准确反映电池状态参数随时间变化的电池电化学机理模型。Qi Zhang 等发现在电池老化过程中固体电解质膜的状态会随之发生变化，由此建立了电池退化模型^[17]。Tasaki 等研究在电池老化过程中锂盐在电解液中溶解度的变化^[18]。运用锂电池电化学模型预测 RUL 时需要对模型进行修正，因为这种模型没有考虑到时变因素的影响。并且这种方法对求解偏微分方程要求较高，模型参数也比较多。虽然能反映电池内部物化状态，但是由于实时性差，求解难度高，只适合短时间内描述电池的工作状态，因此只适用于离线仿真。

(2) 等效电路模型法。基于等效电路模型的 RUL 预测通过理想电压源、电容、电阻等电器元件搭建锂电池等效电路模型，搭建锂电池试验台进行电池容量加速退化实验等，模拟锂电池在工作过程中的退化状态，并通过实验数据拟合出仿真模型参数。Eric Walker 等验证了在锂电池 RUL 预测问题上，粒子滤波方法相比非线性最小二程和无迹卡尔曼滤波有更好的预测性能^[19]。电池 RC 等效电路模型由于其简单且易于实现应用广泛，He H 等建立不同阶次的动力电池等效模型进行对比，得出二阶 RC 模型具有更好的效果^[20]。该方法模型简单，但是锂电池实际使用过程中内部状态变化复杂，模型参数需要实时修正，因此这种方法预测精度差，模型泛化能力不强。

(3) 经验退化模型法。首先通过拟合采集的状态数据得到经验退化模型，然后采用滤波算法得到模型的最优参数，最后外推得到预测的 RUL 值^[21]。目前常用的滤波算法主要有粒子滤波 (Particle Filter, PF)、卡尔曼滤波 (Kalman Filter, KF) 及这两种算法的改进算法，如无迹卡尔曼滤波 (Unscented Kalman Filter, UKF)、扩展卡尔曼 (Extended Kalman Filter, EKF) 滤波等。锂电池 RUL 为非线性问题，可以采用粒子滤波和改进的卡尔曼滤波算法，但是常规的卡尔滤波在该问题上效果并不理想。Tain Y 等针对提升粒子滤波算法收敛度和预测精度的问题，利用人工鱼群算法使粒子分布更具合理性^[22]。Guha A 等在粒子滤波算法的基础上，以实验数据来识别和更新锂电池的容量衰减模型参数，通过设置失效阈值预测了电池

的 RUL^[23]。Zhang H 等提出一种基于无迹卡尔曼滤波的锂电池模型参数和 RUL 联合预测的方法^[24]。基于经验退化模型的方法不需要考虑电池内部复杂的物理结构及化学特性，因此相较于前两种模型方法复杂度更低。滤波方法提高了经验退化模型预测方法的精度，在一些研究中预测效果较好，但是这种方法过于依赖模型精度，当电池使用环境发生改变，先前建立的模型就不再适用，需要重新建立新的模型，但是模型预测法在预测阶段无法更新，因此长期预测精度不高。

2. 基于数据驱动的方法

基于数据驱动的方法是近年的研究热点，实验不需要破坏电池，不需要考虑锂电池内部物理化学机理和失效机制，而是将锂电池看做一个黑箱模型，使用大数据技术挖掘锂电池性能测试数据和状态监测数据中包含的锂电池退化状态信息，建立电池 RUL 预测模型，得到电池从预测起始到电池达到老化阈值经历的所有循环周期。

锂电池的容量退化是一个随着使用时间缓慢发展的过程，锂电池剩余寿命的预测本质上是一个时间序列预测问题。时间序列预测和回归分析的预测不同，数据之间存在时间的先后顺序，同样的数据打乱输入顺序后模型的输出的结果不同。时间序列预测方法主要有传统时序建模方法及深度学习网络。时间序列预测方法可以简单表示为：

$$C_{N+1} = f(C_{N-M}, \dots, C_{N-2}, C_{N-1}, C_N), N > M \quad (1.1)$$

式中， C_N 为第 N 次循环电池的最大使用容量， C_{N+1} 为时间序列模型预测出的第 $N+1$ 次循环锂电池容量预测值， f 为时间序列模型，模型输入为按时间顺序排列的前 $N-M$ 次循环锂电池的容量数据。

传统的时序预测方法主要有支持向量回归 (Support Vector Regression, SVR)、相关向量回归 (Relevance Vector Regression, RVR)、高斯过程回归 (Gaussian Process Regression, GPR)、自回归 (Auto Regressive, AR) 模型及其变体等。

(1) 支持向量回归。SVR 是 SVM 在回归分析中的变体，SVR 的目标是通过考虑最大化间隔，找到一个分离超平面，使绝大多数样本位于决策边界内，使期望风险最小，最终得到全局的最优解^[25]。SVR 适合用于锂电池寿命预测问题，由于其在样本量较小的非线性问题中具有优势。Saha 等利用电池 EIS 测试数据，通过 SVM 建立锂电池指数模型^[26]。Nuhic A 等针对实车动力电池包的 SOH 估计及 RUL 预测问题，提出了一种将支持向量机与一种新的基于负荷集合的训练和测试数据处理方法相结合的新数据驱动方法，避免了环境和负载条件的影响^[27]。Dong H 等将 SVM 模型与粒子滤波框架结合建立锂电池寿命预测模型^[28]。虽然 SVM 在处理锂电池寿命预测问题上具有一定的优势，但是这种方法自身也存在着核函数必须满足 Mercer 定理、惩罚函数难以确定等问题。

(2) 相关向量回归。RVR 算法虽然和 SVR 相似，但是通过结合马尔可夫性质、零均值不同方差高斯先验分布和最大似然估计等方法使得 RVR 算法具有比 SVR 更稀疏的解，预测结果更精确，超参数不需要通过交叉验证得到等优点。由于 RVR 概率预测的特点，其应用于锂电池 RUL 预测的研究较多。Widodo 等利用电池放电电压的样本熵作为特征，RVR 算法实现剩余寿命的预测，并与 SVR 算法预测的结果进行对比，RVR 的预测效果更好，精度更高^[29]。虽然较 SVR 算法 RVR 算法有很多优势之处，但是由于算法的稀疏性及锂电池容量数据的再生现象，导致预测结果的稳定性较差。

(3) 高斯过程回归。GPR 算法建立在贝叶斯框架下，能估计出预测结果的不确定性，对于任意线性或非线性系统都能实现预测且预测精度较高。Li Lingling 等采用 IC 分析法从锂电池实验数据电压、电流等时间序列中提取特征参数，采用 GPR 算法估计锂电池健康状态，进一步使用健康状态估计值作为特征建立锂电池剩余寿命预测的自回归模型^[30]。Saha 等使用 GPR 算法对阻抗进行预测，然后利用阻抗和剩余容量的关系推出容量的预测值，进而预测出锂电池的剩余使用寿命。GPR 算法核函数的选择和超参数的调整对预测精度影响较大，短期容量预测精度较大，但是进行长期预测时计算量和复杂度增大，预测精度也不高，在 RUL 长期预测方面效果不理想。

(4) 自回归模型及其变体。AR 模型描述当前值与历史值之间的关系，利用时间序列的历史数据和线性函数对当前系统状态进行预测，由此推导出的结果与目前数据特征的模型阶次和参数一致，以此建立出含有最多数据特征的时序模型。AR 算法满足当前样本数量较少情形的要求，参数辨识简单。AR 模型将随机部分简化，保留历史序列，对偶地，移动平均法模型（Moving Average, MA）将历史序列值简化，保留随机部分。自回归移动平均模型结合了 AR 和 MA 模型，锂电池寿命预测问题为非线性回归问题，而自回归移动平均模型为线性模型，基于这一问题，罗悦等提出正则化粒子滤波融合 AR 模型的方法，很好地改善了随着电池循环周期的增加，电池退化速率加快导致的预测精度差的问题^[31]。AR 模型与其变体具备简单计算和低复杂性的优势，但是预测 AR 模型的结果显示置信区间将很大。简单地通过数据建模将导致一个问题，即估计结果和实际数据偏差很大，单纯依靠数据进行建模会导致估计结果与实际数据偏差较大的问题，需要引入锂电池的物理信息来提高预测精度。

(5) 深度学习算法。传统时序预测算法应用于锂电池 RUL 预测在短期预测中具有较强的预测精度和可解释性，但不适用于电池寿命的长期预测，并且传统算法通常存在稳定性差、泛化能力不强等问题。深度学习与传统时序预测算法相比预测精度、稳定性和泛化能力都有很大提升，并且在长期时序预测问题上更适用，因此近年应用于锂电池 RUL 预测领域的研究逐渐增多。

胡天中等提出了一种多尺度深度神经网络的锂电池健康退化预测模型，将采集的锂电池能量数据通过经验模态分解和相关性分析方法分解为主趋势数据和波动数据，分别采用深度置信网络和长短期记忆网络对分解后的数据进行建模，然后将预测结果进行有效集成得到最终的预测结果，通过与其他模型的实验对比，证明了这种集成模型具有更稳定的预测性能，长期预测的准确性也相对较高，能更好的预测电池未来的健康退化趋势^[32]。Ji Wu 等提出了一种基于前馈神经网络（Feed-forward Neural Network, FNN）和重要性采样（Important Sampling, IS）的锂电池 RUL 在线估计方法，通过分析不同循环周期下锂电池充电电压曲线来量化定义锂电池 RUL，FFNN 构建 RUL 与充电电流曲线关系的模型，考虑到锂电池充电电流的非线性特性，采用 IS 方法进行 FFNN 的输入选择^[33]。Zhang Y 等研究了一种基于深度学习的锂电池 RUL 预测方法，利用 LSTM 和递归神经网络（Recursive Neural Network, RNN）学习锂电池退化状态数据之间潜在的长期依赖关系，并结合蒙特卡洛模拟给出 RUL 的概率预测结果，采用弹性均方反向传播对 LSTM-RNN 进行自适应优化，并采用 Dropout 技术解决过拟合问题，将模型与支持向量机、粒子滤波模型进行对比，LSTM-RNN 模型的长期预测能力更强^[34]。深度学习算法通过构建具有多个隐含层的多层的非线性网络模型然后输入大量的训练数据，学习容量退化数据的分布式特征表示。自动学习数据中的特征而不需要人工提取，具有特征提取的完备性。另一方面，深度学习的前提是有大量的历史数据，否则效果不如传统方法。

3. 基于融合的方法

基于融合的方法将各种方法的优点集中到一起，规避了单一算法的缺点，使得融合算法与单一算法相比，模型的预测效果有很大提升。主流的融合方法主要有两种，一种是将模型融合数据驱动，另一种是将不同的数据驱动方法互相进行融合。

（1）模型与数据驱动算法融合。Zhouxiao Xiao 等人将无迹卡尔曼滤波算法与反向传播（Back Propagation, BP）神经网络结合，BP 神经网络采用自回归形式预测 UKF 的残差，UKF 利用预测残差迭代更新退化模型参数，这种方法能适应不同电池个体、不同预测起点的退化特性^[35]。Saha 等提出了一种 RVM-PF 框架的 RUL 预测方法，将基于贝叶斯核的 RVM 整合到粒子滤波器框架中，其中噪声和环境干扰的静态估计以概率密度函数的形式融入 RUL 的估计，通过实验对比证明这种方法比 ARIMA 和 EKF 更具优势，贝叶斯方法很适合用来处理数据来源的不确定性并定义了参数和变量随时间变化的概率分布，很好地表达了模型和预测中的不确定性^[36]。ARIMA 作为一种纯粹的数据驱动方法，没有将任何物理过程纳入计算，存在很大的不确定性，不适合长期预测，并且重复差分也不能消除数据集的非平稳性，EKF 对非平稳数据具有鲁棒性，但是收敛性较差。

(2) 不同数据驱动算法融合。Zheming Tong 等提出了一种带有贝叶斯优化和均方根误差传播优化的自适应 Dropout 方法优化 LSTM 网络, 通过蒙特卡罗模拟方法对预测结果的不确定性进行描述, 采用 18 个常用的机器学习算法进行对比, 说明这种方法在电池早期剩余使用寿命预测方面效果较好^[37]。丁攀等采用小波分解与卷积神经网络相结合的方法预测电池循环寿命, 将一维数据通过小波分解组成二维卷积神经网络处理, 对比了不同的分解算法、校正算法及概率预测算法的效果, 验证了该模型的优越性和预测的稳定性^[38]。

基于融合的方法取长补短, 提高了模型的预测精度, 加强了模型的泛化能力, 但是提高了模型的复杂程度, 计算量也大大增加, 未来需要在这些方面做更深入的改进。

1.2.3 发展趋势研究

针对目前数据驱动方法在锂电池健康状态估计及剩余使用寿命预测中的问题, 对进一步的研究提出几点建议。

首先, 锂电池容量衰退的过程中会出现容量再生现象导致电池容量的长期多步预测困难, 未来应针对锂电池容量再生现象研究合适的方法, 加强对容量再生部分的预测。其次, 未来锂电池健康状态估计及剩余使用寿命预测应借鉴其他领域的相关方法, 合理地使用在锂电池领域, 比如图像处理领域中的注意力机制。另外, 电池的 SOH 与 RUL 之间存在关联, 可以利用这一关系进行电池 SOH-RUL 联合预测, 以解决实际使用过程中无法直接测得电池内部老化状态的问题。目前主要的研究大多基于单体电池, 但是实际使用过程中电池单体往往组成模组使用, 这增加了 SOH 估计与 RUL 预测的难度, 因此未来应开展电池模组的相关实验, 探究电池模组的 SOH 估计及 RUL 预测。最后, 数据驱动的方法往往需要大量的离线数据, 这导致了对电池早期 SOH 估计与 RUL 预测的难度, 为了减少对数据的依赖, 未来应开发参数更少的模型。

1.3 论文主要内容与结构安排

本文主要研究锂电池健康状态估计及剩余使用寿命预测。选取 NASA 公开锂电池老化数据集作为研究对象, 从数据集中提取特征参数, 然后首先建立 WOA 算法改进 LightGBM 的 SOH 估计模型, 将预测结果与决策树 (Decision Tree)、随机森林 (Random forest)、极致梯度提升 (eXtreme Gradient Boosting, XGBoost)、LightGBM 模型预测结果对比, 验证改进算法的优越性。根据数据集中提取的容量退化数据, 构建 CNN-BiLSTM-Attention 模型预测 RUL, 分别用原容量退化数据和第三章建立的 SOH 模型估计结果进行预测, 一方面验证 CNN-BiLSTM-Attention 模型的预测精度及鲁棒性等, 另一方面探索 SOH-RUL 联合预测的可能性。

本文总共分为四章, 主要内容如下:

第一章：绪论部分。首先介绍了论文研究背景及意义，然后分别介绍了锂电池健康状态估计及剩余使用寿命预测的研究现状。

第二章：分析锂电池老化机理及工作原理，选取锂电池特征参数。使用 NASA 公开锂电池老化数据，基于这一公开数据集分析并选择了用于电池 SOH 估计的特征参数。

第三章：建立基于 WOA-LightGBM 的锂电池 SOH 估计模型。将模型预测结果与 XGBoost、LightGBM 和贝叶斯（Bayesian optimization algorithm, BOA）优化的 LightGBM 模型 BOA-LightGBM 预测 SOH 的结果进行对比，验证了 WOA-LightGBM 模型在 SOH 估计问题上的优势。

第四章：建立基于 CNN-BiLSTM-Attention 的锂电池 RUL 预测模型。针对锂电池 RUL 预测长期预测精度差的问题，引入 BiLSTM 模型；针对锂电池容量再生现象，利用注意力机制对 CNN-BiLSTM 模型进行改进。

最后，总结全文工作及创新点，对未来改进方向做出展望。

第 2 章 锂电池工作机理与特征参数研究

本章对锂电池的原理及电池老化机理进行分析, 采用美国 NASA 公开的锂电池老化数据集, 分析实验中电池充放电实验参数, 从中提取包含电池老化状态信息的特征参数, 然后对提取的特征进行相关性分析, 保留与电池健康状态相关度高的特征, 对特征数据进行预处理, 最后建立了锂电池 SOH 估计与 RUL 预测模型的评价指标体系。


2.1 锂电池原理

2.1.1 锂电池内部结构及工作原理

锂电池内部材料主要有正负电极、隔膜和电解液组成, 锂化合物构成锂电池的正极, 锂电池的负极一般为炭电极。由于没有金属锂存在, 只有锂离子, 因此锂电池的安全性能较高。正极材料是决定锂电池性能的关键材料之一, 也是电池中主要的锂离子来源。三元材料是锂镍钴锰氧化物的俗称, 这种材料在比能量、循环性、安全性和成本方面可以进行均衡和调控, 也是 NASA 锂电池老化数据集中锂电池的正极材料。负极材料主要起储存锂离子的作用, 有碳材料 (石墨类)、金属氧化物材料以及合金材料, 在充放电时锂离子在负极材料中不断地进行着嵌入与脱出。隔膜是一种具有微孔结构的高分子薄膜, 可以避免电池内部短路, 通锂离子而阻电子。电解液在电池中起到传导锂离子的作用。

锂离子的嵌入、脱嵌在充放电过程中不断进行。充电时, 正极中的锂离子脱嵌进入电解液, 在充电回路外电场作用下向负极移动, 通过隔膜上的微孔结构运动到负极。锂离子的插入炭负极中的微孔结构, 充电容量与负极中的锂离子数呈正比。

充电过程中正极上的化学方程式为:



负极上的化学反应式为:



电池放电时电子从负极通过外部电路流向正极, 锂离子从负极脱插运动回正极, 与已经流到正极的电子结合。放电容量与正极结构中锂离子的数量正相关。分析锂电池充放电工作过程可以总结得到, 锂电池具有理想的电化学可逆反应, 在整个过程中锂离子只是从正极/负极移动到负极/正极, 没有消耗电解液也没有产生气体^[39]。

一般锂电池充电倍率设定在 0.2C-1C, 充电电流越大充电时间越短, 同时电池发热也越多。过大的充电电流会导致电池充电容量变小, 因为电池内部的电化

学反应需要一定的时间。电池的放电电流也不能过大,否则会导致电池内部发热,可能会造成永久性损害。

2.1.2 锂电池老化及容量衰减机理

在锂电池的工作过程中发生的电化学反应不仅包含锂离子嵌入脱嵌的氧化还原反应,还包含一些副反应,随着电池循环次数的增加造成了锂电池内部的不可逆的老化和容量衰减。目前已知的导致锂电池老化和容量衰减的主要因素包含电极活性材料溶解、过充过放、自放电、SEI膜增厚、金属锂沉积、温度等^[40-41]。

1. 电池过充过放

不合理的充电截止电压和放电截止电压将会影响到电池的寿命。过低的放电截止电压,导致电池内部电阻过大,电池发热,高温老化副反应加剧。同时电池内部副反应增加,活性物质减少,炭负极结构坍塌。与放电截止电压相反,充电截止电压会提高内阻,使电池内部过热。过度充会电引起负极产生金属锂的沉积现象,同时,过压充电会带来正极材料的相变问题,正极容纳锂离子的空位减少,电芯最大可用容量减小。

2. 自放电

在搁置状态下,电池内部也会自发的进行电化学反应,降低电池的最大可用容量,这种现象称为自放电^[43]。当温度高且荷电量高时,自放电过程也明显。由自放电产生的物质附着在电极的表面,阻塞了锂离子的通道,占据了锂离子的位置,导致电芯永久容量减少。

3. 高温老化

锂电池的最高温度为 50℃-60℃,锂电池在较高的温度下使用时,电解液活性更强,易于分解反应,分解产物的一部分和正极材料的反应消耗了正极材料。正极材料被腐蚀,缺乏支撑的晶格材料发生坍塌,锂离子空位降低了,正极容纳锂离子的能力下降。有一部分分解产物可能会吸附在正负电极的表面,阻碍了锂离子嵌入脱嵌的氧化还原反应过程,使得电芯内阻增加。

4. 低温老化

当周围温度下降至零度以下时,锂电池的性能会受到很大的影响。SEI膜为电解液与负极材料发生反应生成的钝化膜,能够保护负极材料。低温环境中工作,SEI膜将变厚,增厚反应将消耗电解液中的锂离子,降低电解液的导电能力,并且使锂离子难以穿过SEI膜到达负极,总体反映为电芯的内阻增大。

2.2 锂电池性能参数分析

不同材料的锂电池的性能参数不完全相同,本节介绍常用的锂电池性能参数。

1. 电压

开路电压是电池即电池外部不接任何负载或电源,测量得到的电池正负极之

间的电位差。工作电压是电池外部接上负载或电源有电流流过电池，测量所得的正负极之间的电位差。充电截止电压指电池充电时，电压上升到电池不宜再充电的最高工作电压值，放电截止电压与之相反，为放电时电池最低工作电压。

2.容量

容量指电池能容纳或者释放的电荷，电池的额定容量指电池在设计和生产时规定的电池容量。实际容量指电池当前最大的可用容量，随电池的老化逐渐减小。

3.比能量

锂电池比能量是单位质量电池释放的能量，单位为瓦时/千克（Wh/kg）。

4.充放电倍率

锂电池充放电倍率数值上等于电池额定容量的倍数，单位为库伦（C），与电池充电或者放电时间积分可得到电池的额定容量。

5.健康状态

SOH 是电池在当前循环周期下的容量值与电池额定容量的比值，如：

$$SOH = \frac{C_i}{C_N} \times 100\% \quad (2.3)$$

式中， C_i 为当前环境下电池满电状态的容量， C_N 为电池额定容量。

6.剩余使用寿命

RUL 指电池在一定的充放电电压、电流、温度等条件下，实际容量衰减到规定的寿命终止（End OF Life, EOL）标准所经历的完整充放电周期数，如：

$$RUL = N_{EOL} - N_i \quad (2.4)$$

式中， N_{EOL} 为新电池实际容量衰减到 EOL 标准经历的循环周期数， N_i 为当前电池已经经历的循环周期数。

本文的实验数据来源采集镍钴铝酸锂作为正极材料的三元锂电池的实验数据，这种电池具有较高的比能量和使用寿命，特性参数具体如表 2.1：

表 2.1 三元锂电池特性参数

特性参数	详细描述
额定电压（V）	3.6
额定容量（Ah）	2
工作电压（V）	2.5-4.2
比能量（Wh/kg）	200-260
充电（C）	0.7
放电（C）	1
循环寿命（次）	500
温度（℃）	0-45

2.3 实验对象与实验数据介绍

本文研究数据来源于美国 NASA 艾姆斯预测中心定制的电池测试台测试的锂电池实验数据。使用该研究中心的实验数据，一方面是因为实验条件设置的放电截止电压不同，并且电池一致性的不同，导致每块电池的老化状态不同，这种差异使得该数据集能体现实际使用过程中电池不确定的老化状态。另一方面，选择两组在不同实验条件下的锂电池数据进行实验，可以验证算法的泛化性，使用公开数据集也有利于检验方法的有效性。

实验台由锂电池、可编程四通道直流电子负载、可编程 4 通道直流电源、电压表、电流表、恒温箱和定值 EIS 设备等组成^[42]。实验对象为 8 个相同型号的锂电池，型号为商用 18650 型，分别编号为 B5、B6、B7、B18、B29、B30、B31、B32。B5-B18 号电池在室温 24℃ 下进行实验，电池 B29-B32 的实验环境温度设置为高温 43℃，然后分别依次进行充电、放电和 EIS 阻抗测试。EIS 阻抗测试的正弦波交流电势频率从 0.1Hz 变化到 5kHz，表征锂电池内部参数随着老化进展的变化趋势。

充电实验采用恒流恒压充电模式。首先将完全放电的新电池在 1.5A 的恒流（Constant Current, CC）模式下充电，直到电池电压达到 4.2V。然后将电池电压保持在 4.2V，在恒压（Constant Voltage, CV）模式下充电，直到电池电流下降到 20mA。放电实验采用恒流放电模式，B5-B18 号电池的放电电流为 2A，B29-B32 号电池的放电电流为 4A，在放电电压达到设定的放电截止电压阈值时终止本次循环。B5 号电池的一个充放电周期如图 2.1 所示。




图 2.1 锂电池 B6 充放电实验曲线

随着电池充放电循环实验的进行，电池老化程度加深。规定 EOL 标准为 70% 的额定容量，电池额定容量为 2Ah，当实际容量为 1.4Ah 时电池达到 EOL 标准，实验终止。

实验条件如表 2.2 所示，B5-B18 号电池实验的环境温度设为 24℃，充电电流、

充电电压和放电电流条件都保持一致，但是设置了不同的放电截止电压阈值，即分别以 2A 恒定电流放电至电池电压降至 2.7V、2.5V、2.2V 和 2.5V。B29-B32 号电池实验的环境温度为 43℃，接近电池使用环境温度上限，放电电流设置为恒流 4A，比 B5-B18 号电池的放电电流大一倍，相应的在电池容量相同的情况下，电池完全放电的时间缩短一倍。为了诱发深度放电加速电池老化，B6、B7、B18、B30、B31 号电池的放电截止电压阈值低于设备制造商推荐的 2.7V。

表 2.2 锂电池组实验条件

编号	环境温度	充电电流	充电电压	放电电流	放电截止电压阈值
B5	24℃	1.5A	4.2V	2A	2.7V
B6					2.5V
B7					2.2V
B18					2.5V
B29	43℃	1.5A	4.2V	4A	2.0V
B30					2.2V
B31					2.5V
B32					2.7V

充放电实验记录的实验参数如表 2.3 所示。实验记录了充电时电池的端电压、输出电流、充电电压、充电电流和电池表面温度。放电时电池的端电压、输出电流、负载电压、负载电流和温度，放电时记录的电池容量数据为电池这一循环下的最大可用容量。

表 2.3 充放电实验参数

实验	参数名称	描述
充放电	Voltage_measured	电池端电压 (V)
	Current_measured	电池输出电流 (A)
	Temperature_measured	电池温度 (℃)
	Current_charge/load	充电电流/负载电流 (A)
	Voltage_charge/load	充电电压/负载电压 (V)
	Time	时间 (s)
放电	Capacity	放电电压到达 2.7V 时的电池容量

2.4 锂电池特征参数

从锂电池实验数据中提取用于锂电池 SOH 估计的特征参数有利于减少数据的维度，反映电池老化状态的信息。随着电池循环次数的增多，电流、电压、温度等参数有规律的变化。本节研究这些易于测量的外部参数，从而构建能反映电池老化状态的特征参数，如表 2.4 所示。

表 2.4 锂电池健康状态特征参数

特征参数	数据来源
IC 峰横坐标	充电电压与容量
IC 峰纵坐标	充电电压与容量
充电 DV 拐点横坐标	充放电电压与容量
放电 DV 拐点横坐标	充放电电压与容量
恒流充电时间	充电测量电流
恒压充电时间	充电测量电压
恒流放电时间	放电电流
充电回路电压到达峰值的时间	充电回路电压
放电电池温度到达峰值的时间	放电电池温度

2.4.1 特征选择

分析 NASA 数据集中各个参数，为后续的特征提取作准备。图 2.2 展示了 B6 电池充电过程中的参数随循环次数增多的变化规律，B5/7/18 和 B29-B32 号电池的充放电参数变化规律与 B6 电池相同，因此这里只分析 B6 电池参数。充电测量电压即电池的工作电压，充电测量电压指的是电池工作时的电压，即电流穿过电池正负极之间测量出的电势差，充电时设置充电回路电压为电池开路时的端电压。

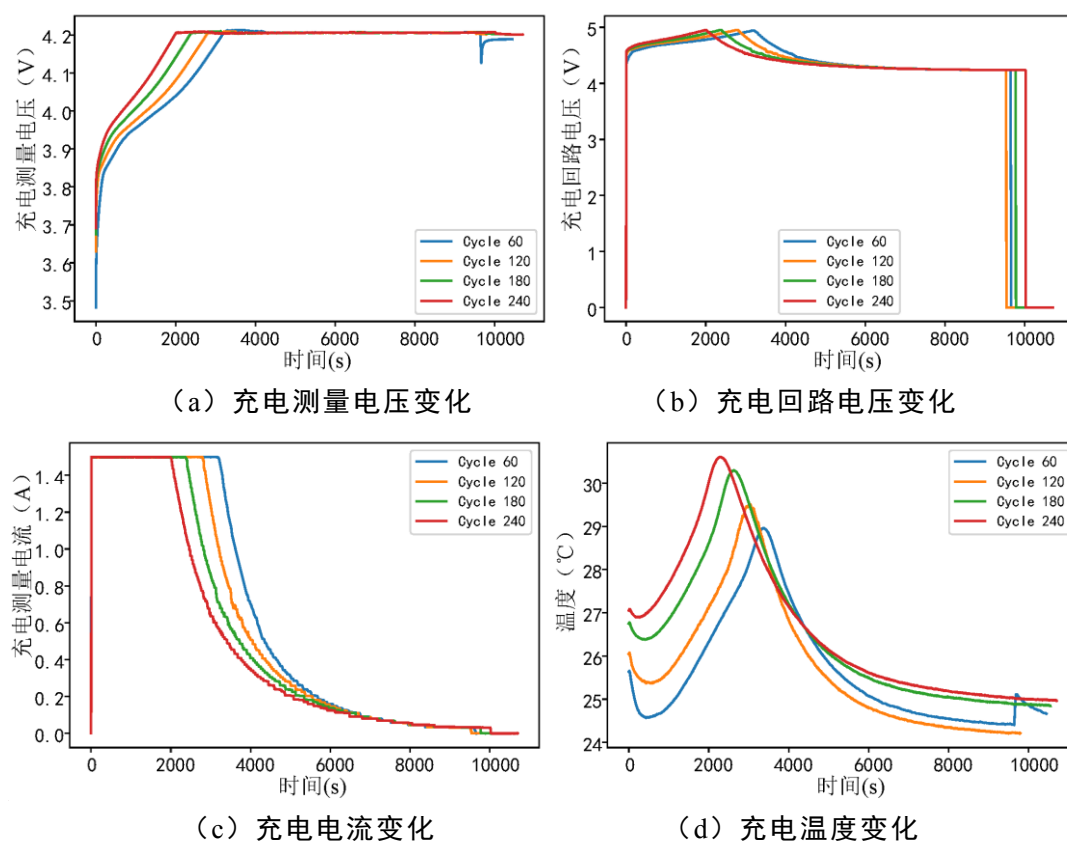


图 2.2 充电参数

如图 2.2 所示，在一个充电周期中，锂电池的充电测量电压先缓慢上升，到达

电压阈值 4.2V 后电压保持不变。随着循环次数的增多, 电池到达电压阈值的时间有规律地减小。充电回路电压先缓慢上升再缓慢下降到 4.5V, 电压存在峰值, 峰值点纵坐标对应的充电电压为 5V, 峰值点横坐标对应的时间随着电池循环不断减小。充电电流与测量电流数据接近, 故只选取充电电流参数。电池在充电过程中先恒流充电, 因此充电电流在前期保持为 1.5A, 当充电电压达到 4.2V 后充电电流开始下降直到电流值为零。恒流充电的时间随循环次数的增多不断减小, 表明电池的充电容量随电池老化而减小。电池温度在循环次数未达到 100 时温度先下降后上升, 再下降最后保持在一个稳定的水平; 当循环次数超过 100 时电池温度先上升后下降, 没有一开始下降的过程。电池温度到达极大值的时间随循环次数的增加逐渐减小。

图 2.3 展示了 B6 电池放电过程参数的变化。放电测量电压为放电时电池的开路电压, 负载电压为放电时电池的工作电压。在放电过程中测量电压从 4.2V 开始下降, 下降速率逐渐增大, 到达放电截止电压阈值后上升, 到达阈值的时间随循环次数增加而减小。电池以 2A 恒定电流放电, 直到测量电压到达放电截止电压阈值, 从图中可以看出放电时间逐渐减小, 反映出锂电池放电容量随电池老化不断减小。

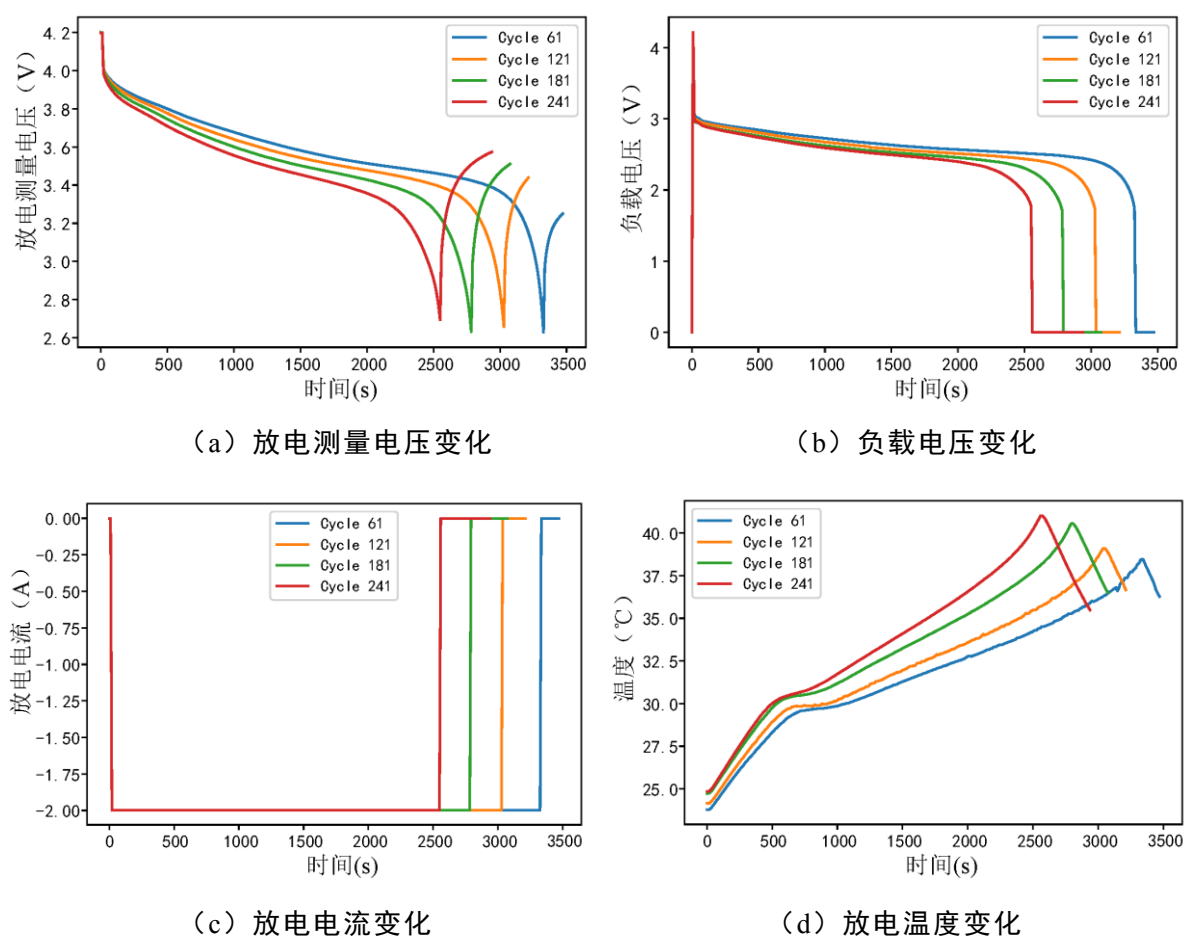


图 2.3 放电参数

如图 2.3 所示, 放电时电池的温度和充电时电池温度的变化相似点在于温度都

有一个最大临界值，超过临界值温度就开始下降，但是放电时电池的温度是从一开始就不断上升的，这个现象可能由于在放电过程中电能除了被负载消耗有一部分被电池内阻转化为热能，而在充电过程中循环次数少时电池内部活性物质较多，电能一开始大量被转化为电化学反应能，少部分被内阻消耗变为热能。

根据以上分析可知，恒流充电时间、恒压充电时间、恒流放电时间、充电回路电压到达峰值的时间、放电电池温度到达峰值的时间随电池循环周期的增加，电池老化程度的加深有规律的变化，因此将这些参数设为特征参数。选取的特征参数分布如图 2.4 (a-e) 所示。

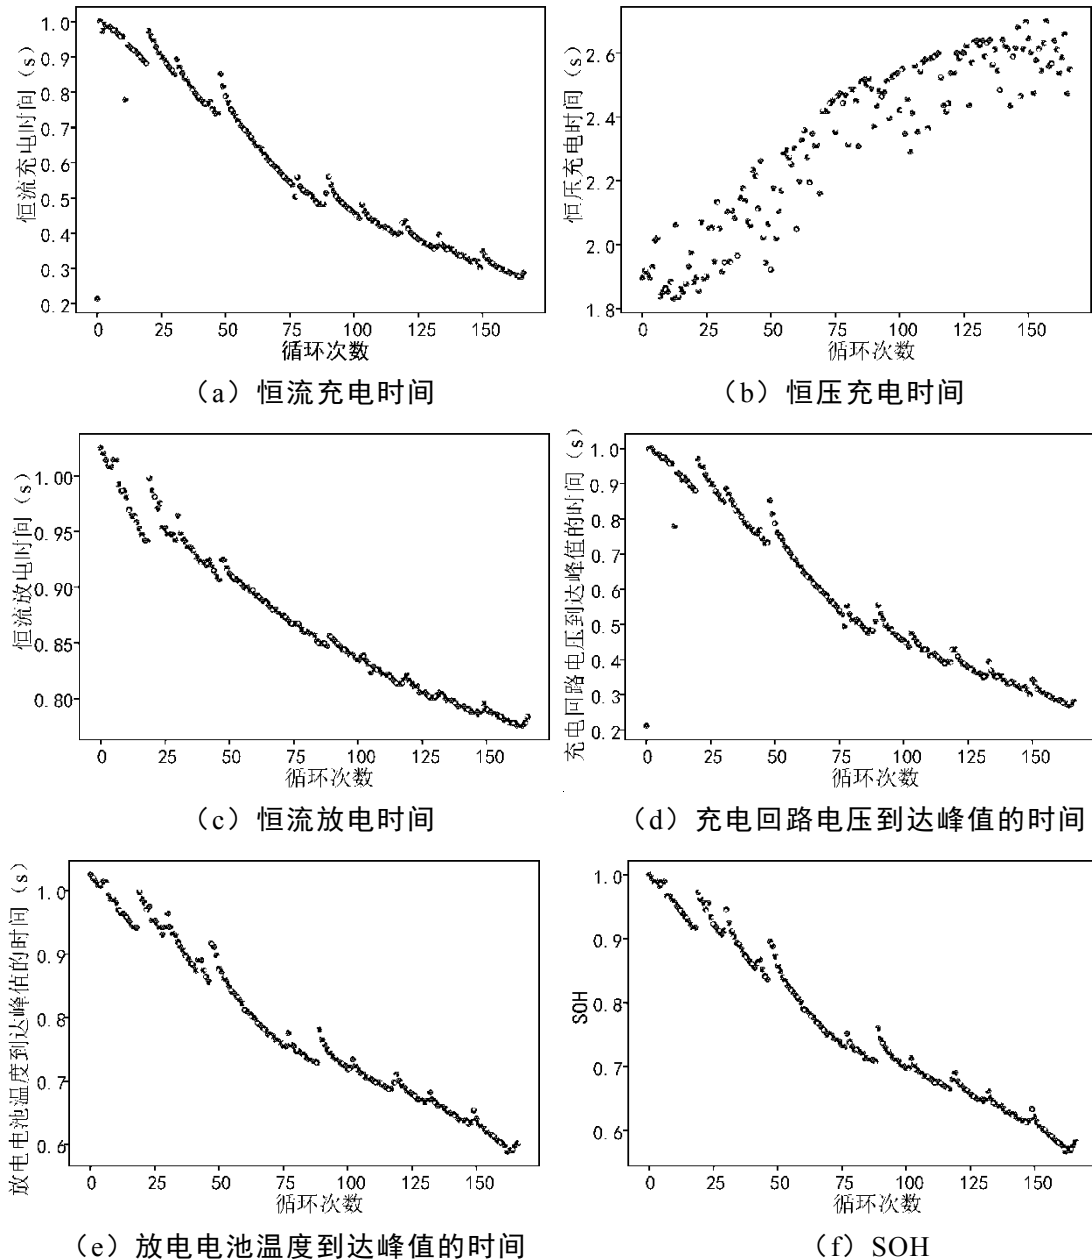


图 2.4 特征参数分布

容量增量分析法通过研究 IC 曲线来了解电池老化过程中内部状态的变化，是研究电池老化和 SOH 的有效方法。该方法通过绘制 IC 曲线将缓慢变化的充电电

压平台转化为 IC 峰，每个 IC 峰都代表电池内部发生的电化学反应，并且 IC 峰的位置和形状的变化反映了锂电池的老化信息^[3]。因此，IC 峰的数值和位置常被作为特征参数。

为了得到 IC 曲线首先需要了解充电电压与容量之间的关系。当电池充电一段时间后充电测量电压上升速率减小，利用测量电压未升到充电截止电压的数据作出电压-容量曲线。NASA 数据集中没有容量数据，通过安时积分法求得充电时电池容量，如：

$$Q(t) = \int_{t=0}^T i(t) dt \quad (2.5)$$

数据集中参数按一定频率采样，为离散数据，安时积分法中的积分运算应转换为叠加运算，如：

$$Q(t) = \sum_{t=1}^T I(t) * [T(t) - T(t-1)] + I(0) \quad (2.6)$$

电压-容量曲线如图 2.5 所示。IC 曲线描述 $dQ/dV-V$ 的关系，需要对电压-容量曲线拟合求导。




图 2.5 电压-容量曲线

利用 python 软件的函数 np.polyfit、np.poly1d 拟合曲线，当拟合阶次为 7 时拟合优度判定系数为 0.9997，拟合精度最高。利用函数 deriv() 对拟合曲线进行求导，得到 IC 曲线如图 2.6 所示。




图 2.6 IC 曲线

如图 2.6 所示，IC 曲线每个峰值下的区域代表整个反应过程中容量的变化量，

IC 峰的变化显示了锂电池电压响应与电池老化的关系。

IC 老化曲线如图 2.7 (a) 所示, 在电池老化前期 IC 曲线中只有一个明显的 IC 峰, 老化后期出现两个 IC 峰, 随循环次数增多第二个 IC 峰位置有规律地向右下方移动, 因此可将 IC 峰位置作为特征参数。提取的 IC 峰坐标分布如图 2.7 (b) 所示, 第二个 IC 峰不易缺失且随电池老化变化规律最为明确, 因此将第二个 IC 峰的位置作为特征参数。

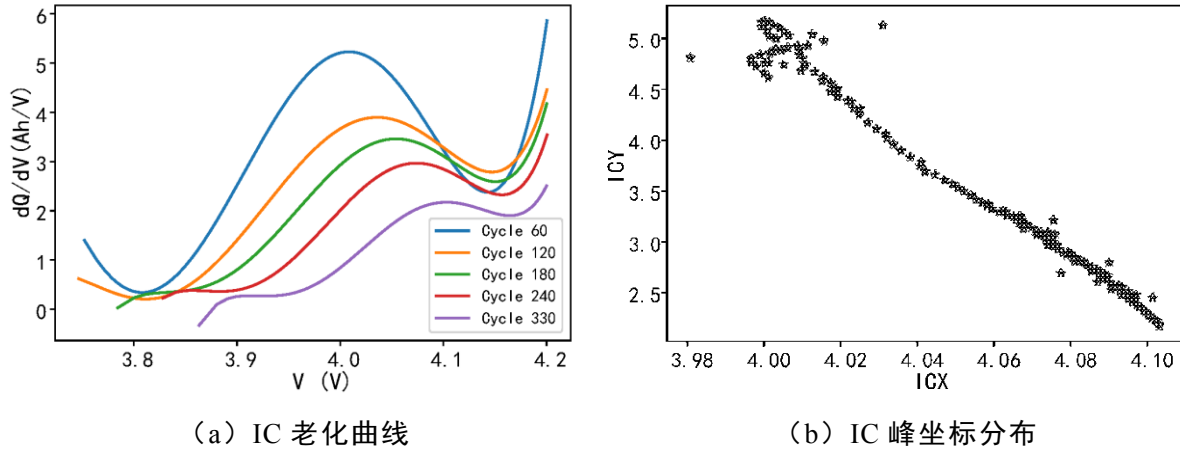


图 2.7 IC 老化曲线特征提取

差分电压分析与容量增量分析类似, 同样可以用于电池衰退机理的研究。DV 分析法描述 $dV/dQ-Q$ 的关系, 表示出电压响应对于容量变化的敏感程度。DV 曲线的特点在于会出现可辨识的峰, DV 峰描述夹层反应。DV 曲线的波谷与 IC 曲线的峰对应, 描述相变现象。DV 曲线与 IC 曲线都可以反映电池老化过程中内部状态的变化, 为电池老化机理的研究提供依据。

充电过程中电池电压-容量曲线及相应的 DV 曲线如图 2.8 所示。由图 2.8 (a) 拟合充电电压-容量曲线, 当拟合阶次为 11 时拟合效果最好, 拟合优度达到 0.9999。对拟合函数进行求导, 得到如图 2.8 (b) DV 曲线, 导数变换将平稳增长的电压-容量曲线转化为波动较明显的 DV 曲线。




图 2.8 充电 DV 曲线

不同循环次数下的 DV 曲线如图 2.9 所示。




图 2.9 DV 老化曲线

由图 2.9 可以观察到 DV 曲线的第一个拐点随着循环次数的增加有逐渐向右上方移动的趋势，但是不是每次循环都存在第一个拐点。又观察到每次循环的末期都存在明显的拐点，且拐点横坐标位置有逐渐减小的趋势，因此选择 DV 曲线的最后一个拐点横坐标作为特征参数。放电阶段的 DV 曲线变化与充电阶段相似，但是放电阶段 DV 曲线第一个拐点位置的变化规律较明显，因此选择放电阶段第一个拐点的横坐标作为特征参数。提取的充放电 DV 曲线拐点特征的数据分布如图 2.10 所示。




图 2.10 充放电 DV 曲线拐点分布

2.4.2 特征参数分析

数据和特征决定了模型精度的上限，为了从所有特征中选出相关特征，需要对提取的特征参数与电池 SOH 之间的相关性进行分析，在不引起重要信息丢失的前提下去除无关特征，采用皮尔森相关系数对特征的相关性进行定量分析。

在进行特征分析之前首先对特征数据进行标准化处理，消除特征之间量纲和数量级等的差异。在进行综合分析时，若直接采用原始特征数据进行分析，会突出

数值较大的特征在分析中的作用、削弱数值较小指标的作用，因此需要对原始特征数据进行标准化处理。

采用 Z-score 准化方法处理特征，以保证数据之间的可比性，为：

$$z = \frac{\bar{x} - \mu}{\sigma} \quad (2.7)$$

其中， \bar{x} 为数据观测值， μ 为该组数据的平均数， σ 为标准差， z 为标准分数。

连续变量之间可以用皮尔森相关系数检验相关性，取值范围为 $[-1,1]$ ，符号为正表示正相关，为负表示负相关，绝对值越大相关程度越高。样本间的皮尔森相关系数通过估算样本的协方差和标准差得到，为：

$$r_{x,y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.8)$$

分别将特征参数与 SOH 的值代入式(2.8)，计算得到特征参数与 SOH 的皮尔森相关系数分析结果如表 2.5 所示。

表 2.5 Pearson 相关性分析结果

特征参数	相关系数	特征参数	相关系数
IC 峰横坐标 (ICX)	-0.97	恒压充电时间 (CV)	-0.94
IC 峰纵坐标 (ICY)	0.95	恒流放电时间 (CC_dis)	0.99
充电 DV 拐点横坐标 (DV1_X)	0.99	充电回路电压峰值时间 (VC_peaktime)	0.95
放电 DV 拐点横坐标 (DV2_X)	0.99	放电温度峰值时间 (Tem_dispeaktime)	0.99
恒流充电时间 (CC)	0.99	SOH	1.0

将特征参数两两代入式(2.8)，得到特征参数之间和特征参数与 SOH 之间的皮尔森相关系数，根据皮尔森相关系数作热度图如图 2.11。相关性系数的绝对值一般在 0.8 以上认为具有强相关性，根据热度图最右侧指标颜色变化，设置皮尔森相关系数在 0-0.4 为不相关，0.4-0.8 为弱相关，0.8 以上为强相关。由图可知，提取的特征参数与 SOH 指标之间的相关性均大于 0.9，说明特征参数与 SOH 具有强相关性，包含电池老化各个阶段的信息。其中 IC 峰位置参数与充放电 DV 拐点参数的相关性达到 0.85 以上，是因为在参数提取的过程中这两个参数都采用了电压和容量数据，并进行了差分运算。但是由于这两个参数代表的电池内部电化学反应不同，因此虽然相关性较高依然需要保留，也增加了模型的物理解释性。

由图 2.11 分析可得，充放电 DV 拐点 DV1_X 和 DV2_X 相互之间强相关，相关性达到 0.99。这两个参数分别描述充电和放电过程中电池内部的夹层现象，由于所处的工作阶段不同，考虑到实际使用过程的使用特性将这两个参数保留。恒流充电和恒压充电是充电过程中的两个阶段，由于容量的退化，充电时间总体上

是呈减小趋势，并且恒流充电时间减小，恒压充电时间缩短，因此恒流充电时间 CC 和恒压充电时间 CV 的相关性强，CV 与 SOH 呈负相关性。




图 2.11 相关系数热度图

充电回路电压达到峰值的时间 VC_peaktime 与放电电池温度达到峰值的时间 Tem_dispeaktime 相关性强，电池温度和电压对于电池不同老化阶段展现的规律相同，但是这两个物理量反映的物理特性不同，虽然变化规律相似也需要保留。通过上述分析，提取得到的特征参数虽然有的相关性强，但是由于包含了老化过程中电池内部不同的电化学现象和电池不同的工作阶段，增强了模型的可解释性，因此全部保留作为影响电池健康状态的关键因素。

2.5 特征数据预处理

提取的特征数据中可能存在缺失、噪声等问题，因此需要对特征数据进行预处理，有利于提高模型的预测效果。本节主要对上一节提取的特征数据进行数据清洗，并建立模型的评价指标体系。

2.5.1 数据清洗

f0-f8 与提取的特征参数对应，如表 2.6 所示。

表 2.6 特征对应表

f0	f1	f2	f3	f4	f5	f6	f7	f8
ICX	ICY	DV1_X	DV2_X	CC	CV	CC_dis	VC_peaktime	Tem_dispeaktime

B6 号电池提取到的特征参数经 Z-score 标准化后如表 2.7 所示。部分特征数据中存在可以观察到的离群数据，这些少量的离群数据会导致整体特征的偏移。

表 2.7 B6 电池特征参数数据

	f0	f1	f2	f3	f4	f5	f6	f7	f8	SOH
0	0.28	-0.08	-0.52	-2.08	-1.62	-1.63	2.27	-1.61	1.95	1.94
1	0.07	-0.08	0.93	-1.84	1.87	-1.55	2.20	1.87	1.91	1.90
2	-10.36	-0.08	0.45	-1.87	1.75	-1.59	2.12	1.88	1.86	1.85
3	0.04	-0.08	1.17	-1.88	1.83	-1.63	2.04	1.84	1.82	1.85
4	0.03	-0.08	0.95	-1.89	1.79	-1.50	2.03	1.80	1.81	1.80
...
162	0.20	-0.08	-0.44	-0.15	-1.32	0.80	-1.36	-1.31	-1.55	-1.56
163	0.21	-0.08	-0.44	-0.12	-1.33	0.98	-1.36	-1.33	-1.53	-1.52
164	0.21	-0.08	-0.45	-0.13	-1.34	1.26	-1.37	-1.35	-1.53	-1.54
165	0.21	-0.08	-0.45	-0.15	-1.35	0.55	-1.33	-1.34	-1.46	-1.47
166	0.20	-0.08	-0.43	-0.09	-1.30	0.84	-1.25	-1.30	-1.44	-1.43

利用箱型图得到只经过 Z-score 标准化处理的特征参数分别如图 2.12 所示。




图 2.12 特征参数箱型图

如图 2.12，箱型图不会受到异常值的影响，能够以较为稳定的形式表示出数据的离散分布情况，超过箱型图上下限的数据为离群值，IC 峰位置参数、充放电拐点参数存在离群数据。箱型图上下限计算公式如(2.9)，按式将离群值剔除，被剔除的数据位置视为缺失值。

$$\begin{aligned}
IQR &= Q3 - Q1 \\
UpLimit &= Q3 + IQR \times 1.5 \\
LowLimit &= Q1 - IQR \times 1.5 \\
x &> UpLimit \& \ x < LowLimit
\end{aligned}
\tag{2.9}$$

式中, $Q3$ 为 75%分位数, $Q1$ 为 25%分位数, x 为数据集中的数据, $UpLimit$ 和 $LowLimit$ 为箱型图上下限数据, 当超过上下限时视为离群数据。

数据缺失使特征数据维数改变, 与标签数据维数不同会导致无法进行预测。为了使特征数据维数保持一致, 需要对缺失数据进行插补。缺失特征的处理方式会影响模型效果, 因此对剔除的异常值要选择合理的方法进行填补。常用的方法有平均值填充、K 最近距离法、回归法、极大似然估计法等。本文选择均值 (Mean Value)、K 最近邻 (K Nearest Neighbor, KNN) 及随机森林 (Random Forest, RF) 的方法进行填充, 比较这三种方法的填充效果, 选择在该数据集上效果最好的方法进行插值。

Mean 插值法是利用样本数据平均值作为替代值对缺失值进行插值。

数据集中的缺失值可通过数据集中的近邻点的观察值推算, KNN 插值算法基于这一思想, 通过距离测量识别临近点, 利用相邻观测值来估计缺失值。特征空间中的两个点之间的距离是两者相似度的反映, 欧式距离是最常见的距离度量方法, 衡量多维空间中的两个样本之间的绝对距离。假设多维空间维数为 N , x_1 和 x_2 是两个样本点, 则 x_1 和 x_2 之间的欧式距离 L_2 为(2.10):

$$L_2(x_1, x_2) = \sqrt{\sum_{n=1}^N (x_{1n} - x_{2n})^2} \tag{2.10}$$

欧式距离由两个样本之间每一维度差的平方和计算得到, 当维度之间的取值范围差别太大时, 欧式距离易被取值范围大的变量主导, 因此采用欧式距离作为相似度度量需要对数据进行标准化转换。在前一节特征分析中已对特征数据集进行 Z-score 标准化转换, 因此可以直接使用以欧式距离为度量方法的 KNN 插值算法。

随机森林算法中的每棵树都依赖一个随机向量, 所有向量都是独立同分布的。随机森林在构建决策树的过程中不进行剪枝, 随机挑选列变量和行观测形成树, 利用单棵树的平均值来预测。回归算法从特征矩阵中学习, 然后求解连续性标签的值。之所以利用回归算法填补缺失值是因为在回归算法中特征矩阵和标签之间存在关联, 可以相互之间转化。

利用随机森林插补缺失值步骤:

- (1) 遍历所有特征参数, 从缺失值最少的特征开始填补;
- (2) 填补当前特征时, 将其他特征缺失值用 0 代替;
- (3) 完成一次回归预测, 将预测值放到原特征矩阵, 然后返回步骤 1;
- (4) 遍历完所有特征, 数据无缺失值, 插值结束。

利用 Mean、KNN、RF 对锂电池特征参数 IC 峰位置、DV 拐点横坐标数据插

值的效果如图 2.13 所示。

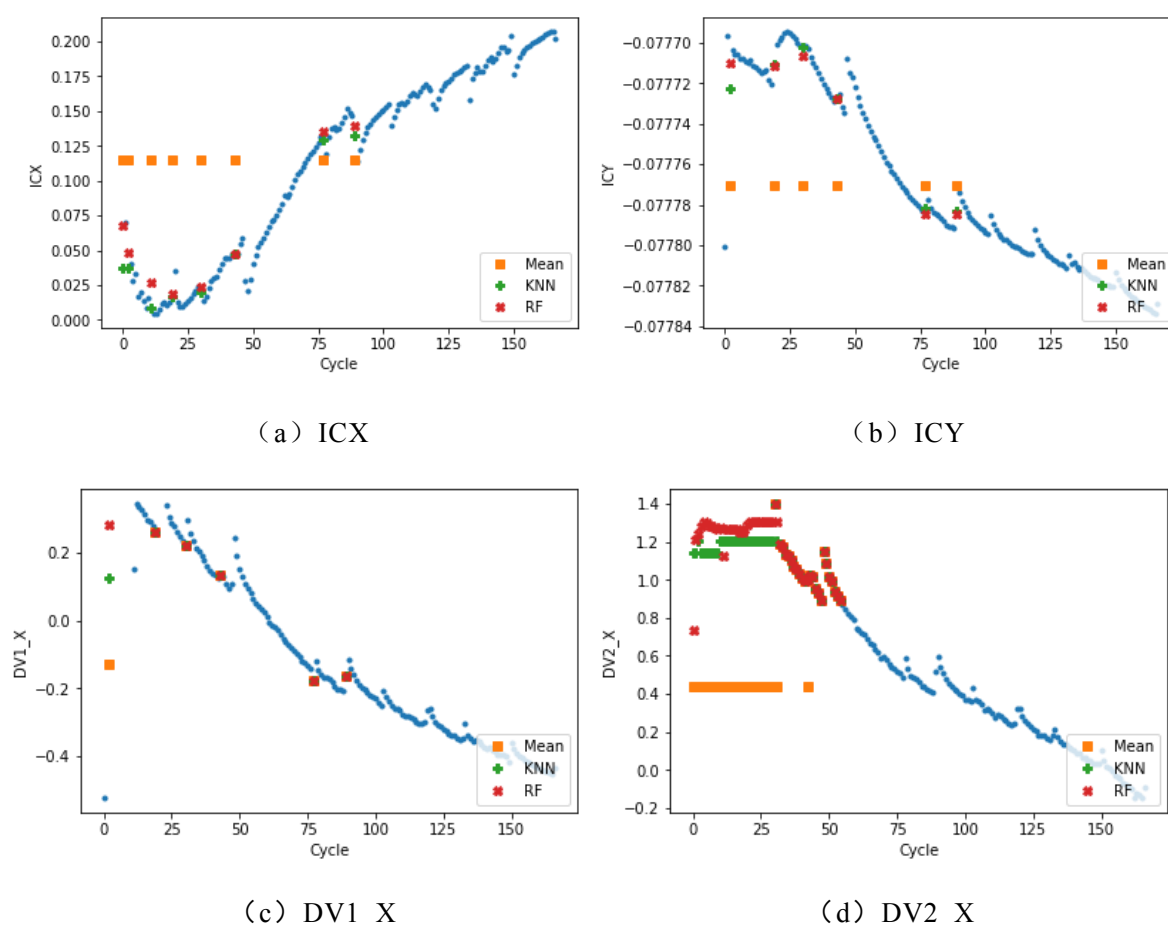


图 2.13 插值效果图

为了衡量插值的效果，采用均方误差（Mean Square Error, MSE）进行评估。MSE 计算模型预测值与真实值之间的接近程度，范围在 $[0, +\infty]$ ，当预测值与真实值完全相同为 0，预测值偏离真实值越大该值越大。MSE 的计算公式如(2.11)：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.11)$$

三种方法对四个参数插值的均方误差评估结果如表 2.8 所示。

表 2.8 MSE 评估结果

特征参数	Mean	KNN	RF
ICX	0.53	0.32	0.35
ICY	0.64	0.50	0.44
DX1_X	0.93	0.48	0.38
DX2_X	0.63	0.21	0.22

MSE 指标越小，表明插值数据与真实值越接近。因此对于四个参数，各选择 MSE 值最小的方法作为插值方法。ICX 和 DX2_X 选择 KNN 算法，ICY 和 DX1_X 选择 RF 算法。将填充完数据的特征参数与原先没有离群数据的特征放入同一个数据集，分别对 B5、B7、B18 电池特征参数数据集做同样的处理，为接下来的建模

和预测做准备。

图 2.14 为处理后的 B6 锂电池特征数据箱型图，由图可知数据中异常值已全部被处理完毕。由于该特征经标准化处理，因此原本为正的物理量被处理为数据中心在 0 值左右均匀分布的无量纲数据。前四个特征的数据分布情况与后六个特征的分布差异较大，后六个特征的数据分布情况较为接近。




图 2.14 B6 特征箱型图

2.5.2 SOH 和 RUL 评价指标体系分析

为了衡量 SOH 估计和 RUL 预测的效果，针对这两个指标分别建立评价指标体系。

1. 锂电池 SOH 估计

(1) 均方根误差。均方根误差 (Root Mean Square Error, RMSE) 衡量预测值与真实值之间的偏差，由 MSE 开方得到，消除了 MSE 对量纲的影响。RMSE 范围为 $[0, +\infty]$ ，值越小模型预测结果越好，误差越小。定义为：

$$RMSE(y, \hat{y}) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.12)$$

式中， y_i 为真实值， \hat{y}_i 为预测值， n 为样本数量。

(2) 拟合优度 R^2 。拟合优度用来衡量模型预测的准确率，将预测值与只用样本均值进行预测的情况进行比较，范围为 $[0, 1]$ ，越接近 1 则说明模型的拟合效果越好，定义为：

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=0}^n (y_i - \bar{y})^2}{\sum_{i=0}^n (y_i - \bar{y})^2} \quad (2.13)$$

2. 锂电池 RUL 预测

RUL 预测对预测起点前的 SOH 数据进行分析，通过寿命退化模型对预测起点后的 SOH 变化进行预测。

(1) 绝对误差的绝对值。将绝对误差 (Absolute Error, AE) 的绝对值作为 RUL 预测的评价指标, 如:

$$|AE(y_i, y_i)| = |y_i - y_i| \quad (2.14)$$

式中, y_i 为 RUL 实际值, 表示预测起点到实际终点的循环周期, y_i 为 RUL 预测值, 表示预测起点到预测终点的充放电循环周期。

(2) 均方误差。均方误差 (Mean Square Error, MSE) 范围为 $[0, +\infty]$, 当预测值与真实值越接近, 该值越小, 定义为:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - y_i)^2 \quad (2.15)$$

(3) 平均绝对误差。平均绝对误差 (Mean Absolute Error, MAE) 范围为 $[0, +\infty]$, 当为 0 时表示预测值与真实值相等, 误差越大该值越大, 定义为:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - y_i| \quad (2.16)$$

(4) 平均绝对百分比误差。平均绝对百分比误差 (Mean Absolute Percentage Error, MAPE) 范围为 $[0, +\infty]$, 值为 0% 时表示完美模型, 越小表示预测精度越高, 定义为:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - y_i}{y_i} \right| \quad (2.17)$$

综上, 锂电池 SOH 估计的结果通过 RMSE 和 R^2 这 2 个指标进行评价, RUL 预测的结果通过 AE、MSE、MAE 和 MAPE 这 4 个指标进行评价。

2.6 本章小结

本章从 NASA 数据集的电压、电流、温度等参数中提取了 IC 峰横纵坐标、充放电 DV 拐点横坐标、恒流充电时间、恒压充电时间、恒流放电时间、充电回路电压到达峰值的时间、放电电池温度到达峰值的时间这 9 个特征参数。将特征参数通过 Z-score 方法进行标准化, 然后利用皮尔森相关性系数进行分析。皮尔森相关性系数显示这 9 个参数与电池健康状态指标 SOH 的相关性都达到 0.9 以上, 因此可以全部保留作为特征参数。对提取的特征参数数据集进行预处理, 剔除离群值, 通过 KNN、RF 插值算法进行插值, 处理完的数据作为模型输入的数据来源。最后分别建立了锂电池 SOH 估计与 RUL 预测的模型结果评价指标体系, 为接下来的模型建立和结果评价做准备。

第 3 章 锂电池 SOH 估计方法研究与优化

本章介绍了鲸鱼优化算法、极致梯度提升模型和轻梯度提升模型，利用鲸鱼优化算法对轻梯度提升模型超参数进行优化，构建了基于 WOA-LightGBM 的 SOH 估计模型。阐述了 SOH 估计模型的结构、整体框图和 SOH 估计流程，将 XGBoost、LightGBM 模型作为对比进行仿真，验证 WOA-LightGBM 模型在预测性能上的优越性。

3.1 鲸鱼优化算法原理

WOA 算法由 Mirjalili^[43]等人提出，是一种群体智能优化算法，通过模仿自然界中座头鲸的群体捕食行为的生物特性提出，该算法具有参数少、收敛速度快、精度高等优点。鲸鱼的捕食行为包含包围猎物、发泡网攻击和搜索捕食，在使用 WOA 算法求解问题之前需要对三种捕食行为进行建模。WOA 算法的一个解可以用一个鲸鱼个体表示，使用 WOA 搜索问题解的过程可以看做若干个鲸鱼个体不断更新个体位置，直至搜索到满意的解为止。算法包含三种搜索机制，通过收缩包围机制和螺旋更新机制实现局部搜索后，采用随机搜索策略实现算法的全局搜索。

1. 包围猎物

假设在 d 维空间中，当前最佳鲸鱼个体 $X^* = \{X_1^*, X_2^*, \dots, X_d^*\}$ ，鲸鱼个体 $X^j = \{X_1^j, X_2^j, \dots, X_d^j\}$ ， X^j 在 X^* 的影响下的下一个位置 X^{j+1} 更新为：

$$\begin{aligned} X_k^{j+1} &= X_k^* - A \cdot D_k \\ D_k &= |C_1 \cdot X_k^* - X_k^j| \\ A &= 2a \cdot r_1 - a \\ a &= 2 - \frac{2t}{T_{\max}} \\ C &= 2r_2 \end{aligned} \quad (2.18)$$

式中， X_k^{j+1} 表示空间坐标 X^{j+1} 的第 k 个分量， a 为收敛因子， r_1 和 r_2 为 0-1 之间的随机数， t 为当前迭代次数， T_{\max} 为最大迭代次数。

2. 发泡网攻击

发泡网攻击是座头鲸特有的吐气泡捕食行为，通过两种数学模型表达上述捕食行为。

(1) 收缩包围。这种捕食行为与上述包围猎物的行为数学模型几乎相同，区别在于 A 的取值范围。因为收缩包围的含义为将当前位置的鲸鱼个体向当前最佳位置的鲸鱼个体靠近，所以将 A 的取值范围由原来的 $[-a, a]$ 调整为 $[-1, 1]$ ，其他公式保持不变。

(2) 螺旋式位置更新。当前鲸鱼个体以螺旋式方式向当前最佳鲸鱼个体靠近，

位置更新为:

$$\begin{aligned} X_k^{j+1} &= X_k^* + D_k \cdot e^{bl} \cdot \cos(2\pi l) \\ D_k &= |X_k^* - X_k^j| \end{aligned} \quad (2.19)$$

式中, b 为对数螺旋形状常数, l 为 $[-1,1]$ 之间的随机数。

座头鲸在围捕猎物时, 不仅收缩包围圈, 同时以螺旋形式向猎物游走。因此各鲸鱼以一定的概率选择收缩包围圈, 的概率选择以螺旋形式向猎物游走, 数学模型为:

$$X_k^{j+1} = \begin{cases} X_k^* - A \cdot D_k, & p < 0.5 \\ X_k^* + D_k \cdot e^{bl} \cdot \cos(2\pi l), & p \geq 0.5 \end{cases} \quad (2.20)$$

3. 搜索捕食

在收缩包围的捕食行为的数学模型中, A 的取值范围限制为 $[-1,1]$, 但是当 A 的取值范围不在 $[-1,1]$ 时, 当前鲸鱼个体可能不会向当前最佳鲸鱼个体靠近, 而是从当前鲸鱼群体中随机选择一条鲸鱼个体靠近, 这就是搜索捕食。虽然搜索捕食会使当前鲸鱼个体偏离目标猎物, 但是会增强算法的全局搜索能力。假设在 d 维空间中, 当前鲸鱼群体中随机一个鲸鱼个体 $X^{rand} = \{X_1^{rand}, X_2^{rand}, \dots, X_d^{rand}\}$, 鲸鱼个体 $X^j = \{X_1^j, X_2^j, \dots, X_d^j\}$, 搜索捕食的数学模型, 有:

$$\begin{aligned} X_k^{j+1} &= X_k^{rand} - A \cdot D_k \\ D_k &= |C_1 \cdot X_k^{rand} - X_k^j| \end{aligned} \quad (2.21)$$

WOA 算法流程图如图 3.1 所示。

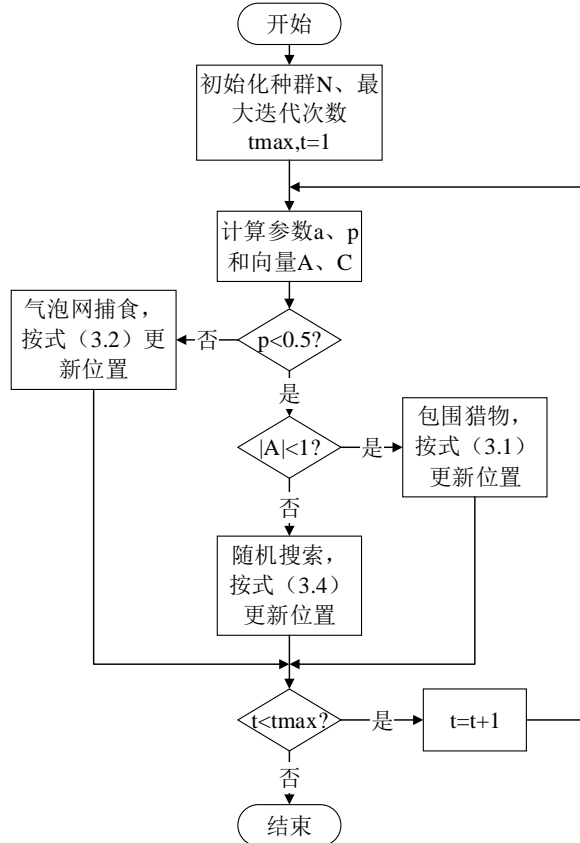


图 3.1 WOA 算法流程

WOA 算法步骤如下：

- (1) 设置种群规模大小 N 和最大迭代次数 T_{max} ，初始化鲸鱼种群位置；
- (2) 计算鲸鱼群体适应度值并排序，找到当前最优鲸鱼位置并保留；
- (3) 计算参数 a 、 p 和系数向量 A 、 C ，判断概率 p 是否小于 50%，若是则转入步骤 4；否则采用气泡网捕食机制，利用式 (3.2) 进行位置更新；
- (4) 判断系数向量 A 的绝对值是否小于 1，是则包围猎物，按式 (3.1) 更新位置；否则全局随机搜索猎物，按式 (3.4) 更新位置；
- (5) 位置更新结束，计算每只鲸鱼的适应度，与原先保留的最优鲸鱼位置比较，若优于则利用最新位置替换；
- (6) 判断当前计算是否达到最大迭代次数，若是则获得最优解，计算结束；否则进入下一次迭代，并返回步骤 3。

3.2 LightGBM 算法原理

LightGBM 是基于决策树算法的梯度提升框架，可用于排序，分类，回归以及很多其他的机器学习任务中^[44]。LightGBM 支持高效的并行训练，具有更快的训练速度、更低的内存消耗、更好的准确率和分布式支持，更容易在大规模数据集中做模型的快速迭代。在希格斯数据集上 LightGBM 比 XGBoost 快将近 10 倍，内存占用率大约为 XGBoost 的，并且准确率有所提升，在其他数据集上也可以观察到相似的结论。LightGBM 之所以具有如此优越的性能，主要基于以下几个算法^[46]。

1. 直方图优化

直方图优化算法的基本思想是在训练之前，对样本中每一维特征进行排序，将连续的特征值离散化为 k 个整数，同时构造一个宽度为 k 的直方图。对特征进行直方图划分，在之后的训练过程中，将直方图作为特征进行决策树的构建，这种方式大大减小了对样本集的遍历次数。对特征进行直方图划分的过程如图 3.2 所示。

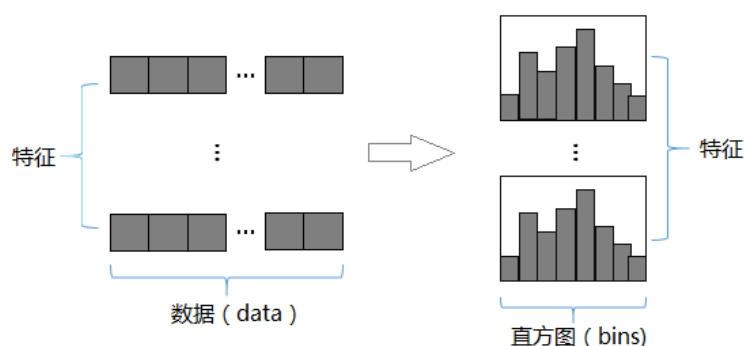


图 3.2 直方图划分

直方图优化可能造成决策树分裂不能使用全局最优的分裂点，会对结果产生影响。但在不同的数据集上的实验证明，这种不准确的分裂策略在一些情况下反

而有更好的效果。这是因为不准确的分裂点能起到正则化的作用，可以有效防止过拟合，从而提升了模型的鲁棒性。

2. 基于梯度的单边采样

基于梯度的单边采样（Gradient-based One-Side Sampling, GOSS）算法认为梯度大的样本会贡献更多的信息增益，为保持信息增益评估精度，下采样时保留梯度大的样本点，按比例对于梯度小的样本点随机采样。

GOSS算法根据样本的绝对值梯度对样本降序排序，选取前 $a \times 100\%$ 样本为大梯度样本子集，随机选取剩余样本集合中 $b \times (1-a) \times 100\%$ 个样本作为小梯度样本子集。合并大梯度样本和降采样后的小梯度样本，以权重系数 $(1-a)/b$ 为小梯度样本权重，利用合并后的样本集合训练新的弱学习器，重复上述步骤，直到达到迭代次数或收敛为止。

其他基于 Boosting 框架的树模型算法与 LightGBM 相比，通过随机采样抽取样本进行梯度更新，完成决策树的构建，LightGBM 算法采用单边采样策略，将梯度较大的样本全部用于决策树构建，为避免样本的数据分布被破坏，同时随机选取梯度较小的样本参与构建决策树。

3. 互斥特征捆绑策略

互斥特征捆绑策略（Exclusive Feature Bundling, EFB）对样本中不同维度的稀疏特征合并后输入模型参与决策树构建。特征维度较高的数据通常较稀疏，而稀疏特征空间中多数特征为互斥关系。通过加入偏移常量的方式将原始特征合并起来，减少了特征维度，绑定互斥特征为单一特征，参与直方图的构建。

确定哪些特征用于融合属于一个 NP-Hard (Non-deterministic Polynomial-Hard) 问题，将特征看作图中的点，特征之间的总冲突看作图中的边，可以将问题转换为图着色问题，使用近似的贪心算法完成。按照度对每个点做降序排序，然后将特征合并到冲突数小于 K （最大冲突数）的集合。

4. 深度优先分裂策略

多数树模型构建决策树时采用层次宽度优先分裂（Level-wise）策略，遍历一次数据即可完成同一层节点的分裂，易实现多线程优化，控制模型复杂度。但 Level-wise 不加区分的对待同层节点，而许多节点分裂增益较低，带来非必要开销，使 Level-wise 实际使用效率降低，LightGBM 抛弃了 Level-wise 生长策略，使用带深度限制的按叶子生长（Leaf-wise）算法。

Leaf-wise 找到当前所有叶子中分裂增益最大的叶子进行分裂，循环此过程。同 Level-wise 相比，在分裂次数相同的情况下，Leaf-wise 可降低更多的误差，得到更高精度。缺点是可能会生成较深的决策树，导致过拟合。因此，LightGBM 在 Leaf-wise 策略上增加了最大深度的限制，保证高效率的同时防止过拟合。

综上，LightGBM 采用直方图优化算法减少对样本集的遍历次数，EFB 策略减

少特征维度，绑定互斥特征为单一特征；GOSS 算法使大梯度样本全部参与决策树构建，小梯度样本随机参与，保证了样本的数据分布。leaf-wise 策略按信息增益最大的单个结点进行分裂并循环，在分裂次数相同的情况下，比 level-wise 减少更多的损失。LightGBM 在不降低模型精度的情况下显著提高了运算速度，适合处理高维数据。

3.3 基于 WOA-LightGBM 的 SOH 估计模型

本节建立基于 WOA-LightGBM 的 SOH 估计模型。模型中包含模型参数与超参数，模型参数通过从数据中学习得到；超参数是模型外部的配置，需要人为设定。超参数的值对模型性能有着重要的影响，针对 LightGBM 超参数个数较多、值难以确定的问题，利用 WOA 算法对 LightGBM 超参数进行寻优，使模型在具有较快运行速度的同时提升 SOH 估计模型的效率和准确率。NASA 锂电池数据中电池 B5、B6、B7 在同一实验环境下同时开展实验，B18 号电池为同一实验条件下单独开展的实验。因此将第二章中 B5、B6、B7 电池的特征参数数据集作为 SOH 估计模型的训练数据，对应的 SOH 值作为样本标签，B18 电池的特征参数数据作为测试集。为了验证模型在不同数据集上的效果，选择实验条件不同的 B29-B32 数据集进行对比实验，其中 B29、B30 和 B31 作为训练集，B32 作为测试集。SOH 估计模型学习训练集中的特征参数并估计 SOH 值，与训练集标签中的实际 SOH 值进行比较，通过不断缩小两者之间的差距来得到模型参数。训练好的模型具有最优的模型参数与超参数，将测试集数据输入模型，来测试模型的性能。

3.3.1 SOH 估计模型框架

SOH 估计模型框架如图 3.3 所示，在 B5-B18 数据集中，B5、B6、B7 训练集数据训练 WOA-LightGBM 模型，然后输入 B18 测试集数据测试训练好的模型性能。B29-B32 数据集中，B29-B31 作为训练集，B32 作为测试集。

基于 WOA 优化的 LightGBM 模型用于锂电池 SOH 估计的具体过程如下：

首先根据第二章内容对 NASA 数据集进行预处理。预处理过程包括通过分析数据提取包含电池老化信息的特征参数，为了方便后面的数据清洗和分析对特征数据进行 Z-score 标准化处理，利用箱型图删除离群数据完成数据清洗操作，将处理完的数据分为训练集和测试集。

然后利用 WOA 算法优化 LightGBM 超参数。输入训练集数据，利用 WOA 算法得到最优的 LightGBM 超参数，完成模型的训练，得到基于 WOA-LightGBM 算法的 SOH 估计模型。

最后进行 SOH 模型的性能评估和结果分析。将测试集数据输入训练好的模型，输出得到 SOH 的估计结果。计算出 SOH 估计的评价指标，对估计结果进行分析。

锂电池 SOH 估计框架如图 3.3 所示。

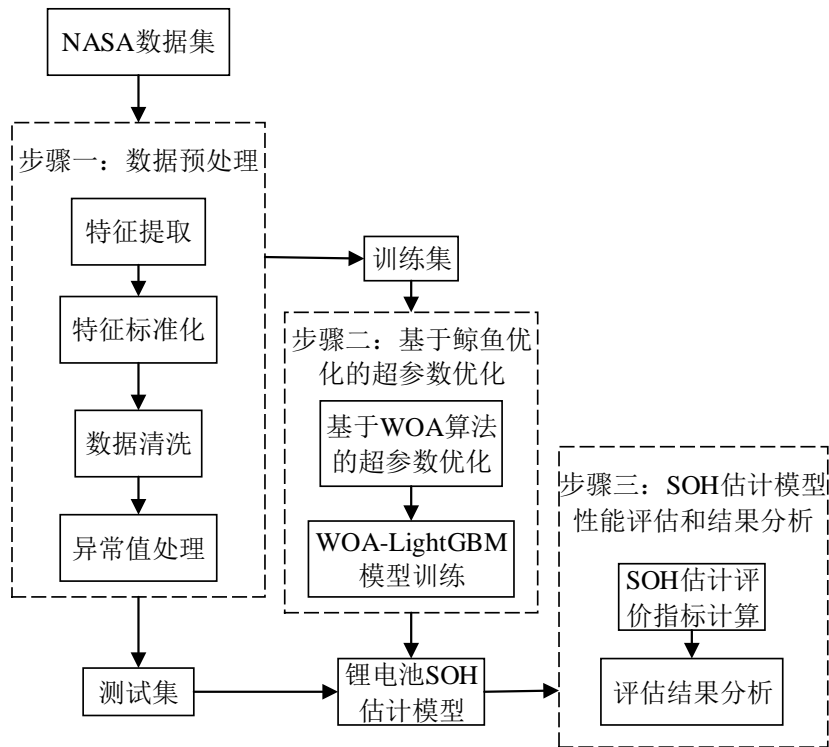


图 3.3 SOH 估计模型框架

3.3.2 基于 WOA 算法的 LightGBM 超参数优化

XGBoost 和 GBDT 等集成算法在学习时对于每一个特征需要遍历所有样本，计算所有可能分割节点的信息增益，这使得算法的效率降低^[45]。LightGBM 通过 GOSS 算法和 EFB 策略对这个问题进行了改进，降低了计算的复杂度。但是在利用 LightGBM 解决问题时存在超参数较多，调参难且耗时长的问题。由于超参数的选择对模型的最终效果有极大的影响，因此本节阐述采用智能算法 WOA 对 LightGBM 超参数进行寻优，从而简化调参过程，提高模型性能。WOA 算法流程如图 3.4 所示。

结合 WOA 算法流程图 3.1，设计的 WOA-LightGBM 算法流程如图 3.4，对改进算法的实现流程阐述如下：

步骤 1：初始化 WOA 的种群大小和最大迭代次数，设置 LightGBM 初始参数。

步骤 2：将 B5/6/7 特征参数构成的训练集输入 LightGBM 模型进行训练，将 SOH 估计值与真实值之间的误差 RMSE 设为目标函数。

步骤 3：将 RMSE 的倒数作为适应度函数，计算当前种群每个鲸鱼个体的适应度值。

步骤 4：对计算得到的适应度值由大到小进行排序，选择适应度值最大的作为最优鲸鱼位置即 LightGBM 最优参数。

步骤 5：计算 WOA 参数和向量，根据和的值更新个体位置。时采用气泡网捕食机制，按式（3.2）更新位置；且时包围猎物，按式（3.1）更新位置；且时进行随机搜索，按式（3.4）更新位置。

步骤 6: 更新后的个体位置即参数组的值, 计算每个参数的适应度, 与原先保留的最优参数比较, 若优于则更新最优参数值。

步骤 7: 循环步骤 2-6, 直到当前迭代次数达到最大值。

步骤 8: 设置模型参数值为经 WOA 算法寻优得到的在当前数据集上 LightGBM 最优参数, 对模型进行训练, 输出 SOH 估计值。

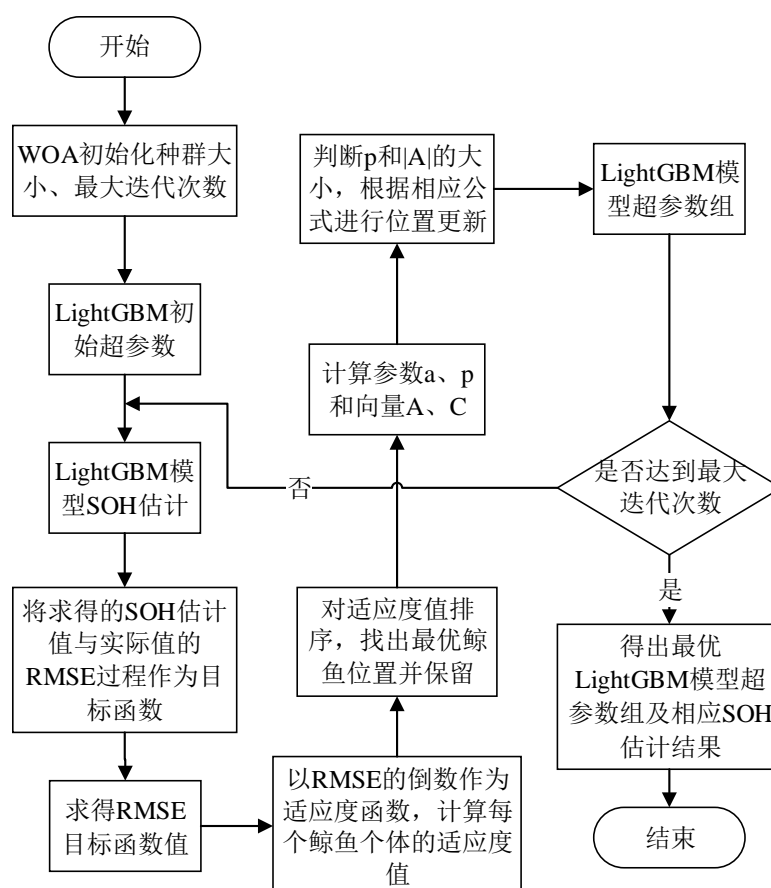


图 3.4 WOA-LightGBM 算法流程

WOA 算法操作简单、参数少以及跳出局部最优的能力强, 在多目标参数优化问题中具有优势。WOA-LightGBM 模型与 LightGBM 模型相比, 实现了模型超参数的自动调整, 简化了调参过程, 降低了调参难度, 易于获得最优的模型超参数, 能提高模型预测的准确率。

3.4 算法仿真与结果分析

本节采用 NASA 锂电池数据集, 使用基于 WOA-LightGBM 框架搭建锂电池 SOH 估计模型并进行仿真。设置 DecisionTree、RandomForest、XGBoost、LightGBM 模型作为对比, 验证 WOA-LightGBM 模型在估计精度和运行速度上的优越性。使用人工超参数调试法、贝叶斯优化算法及 WOA 智能优化算法进行超参数优化算法对比实验, 验证 WOA 算法在超参数优化问题上的具有一定的优势。

3.4.1 仿真设置

本节在 PyCharm 环境下，使用 Scikit-learn 库实现模型的构建。NASA 数据集中提取 IC 峰横纵坐标、DVX 等 9 个特征参数。B5、B6、B7 号电池的特征参数数据共 501×9 维，SOH 标签数据 501×1 维；B18 号电池特征数据有 132×9 维，SOH 标签数据 132×1 维，数据的维度表示为数据的行数和列数。B5、B6、B7 号电池数据共维构成训练集，用于 SOH 估计模型训练。B18 号电池数据单独构成测试集，用于分析比较不同估计模型的性能。B29-B32 号电池数据用来验证模型的泛化性，B29、B30、B31 号电池共同构成的训练集数据特征共 117×9 维，SOH 标签数据 117×1 维；B32 构成的训练数据特征维数为 39×9 维，SOH 标签数据 39×1 维。

根据 WOA-LightGBM 算法流程，设置 WOA 初始化种群大小 $N=60$ ，最大迭代次数 $t_{\max}=30$ 。使用 WOA 对 LightGBM 在 Scikit-learn 库下的四个关键超参数进行寻优，包括学习率 (learning_rate)、Boosting 迭代次数 (n_estimators)、树模型的最大深度 (max_depth) 和下采样参数 (subsample)，这 4 个超参数的寻优范围如表 3.1 所示。

表 3.1 模型超参数寻优范围

模型超参数	寻优范围
learning_rate	[0.01,1]
n_estimators	[2,400]
max_depth	[3,5]
subsample	[0.1,1]

如表 3.1，学习率默认值为 0.1，选择较小的学习率可以获得更稳定的模型性能。迭代次数默认值为 100，根据数据集和特征数据选择范围在 [2,400]，较大的迭代次数在训练集会获得比较好的性能但是容易过拟合造成测试集的性能下降。通常在学习率较小的时候迭代次数会变大，而学习率大时迭代次数会减小，因此需要在这两个参数中找到一对最优参数，使模型在稳定性和准确性中维持一定的平衡。树模型的最大深度是防止过拟合的重要参数，对模型的性能和泛化能力具有决定性的作用。叶子节点个数也是非常重要的参数，和最大深度参数配合来控制树的形状，一般设置为 $(0, 2^{\max_depth}-1]$ ，这里设置为 $2^{\max_depth}-1$ ，不作单独调整。下采样参数设置为小于 1 的数，这样 LightGBM 在每次迭代中在不进行重采样的情况下随机选择部分数据，有利于加速训练并且防止模型过拟合。

3.4.2 不同模型 SOH 估计结果比较

为了验证 WOA-LightGBM 模型的性能，将 WOA-LightGBM 模型与 DecisionTree、RandomForest、XGBoost、LightGBM 和贝叶斯优化的 LightGBM 模型进行对比实验。LightGBM 模型的手动调参取值如表 3.2 所示。

表 3.2 LightGBM 模型超参数

模型	超参数	取值
LightGBM	learning_rate	0.25
	n_estimators	100
	max_depth	10
	subsample	0.8

通过训练集数据 B5、B6、B7 分别训练不同的模型，输入测试集数据 B18 得到的 SOH 估计结果如图 3.5 所示。

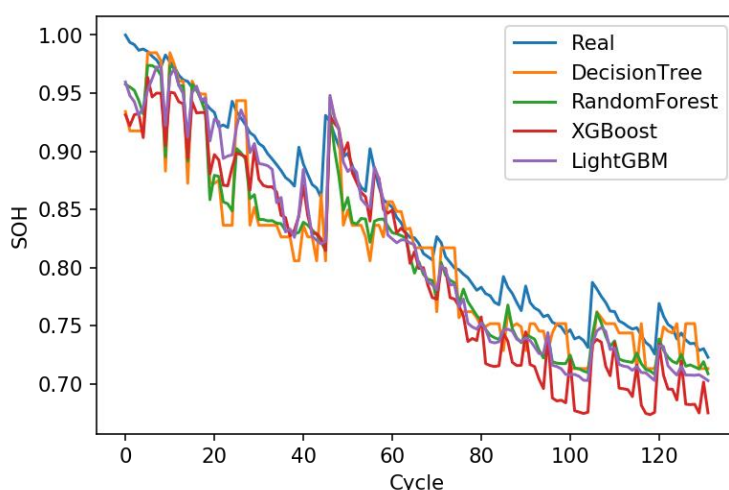


图 3.5 不同模型 SOH 估计效果

如图 3.5 所示，这四种模型得到的 SOH 估计值的总体趋势和真实值的趋势都是随着循环次数的增多而逐渐下降的，但是不同模型对真实值的波动规律预测效果不同，估计误差也有很大的差别。决策树对整个寿命周期的 SOH 预测数据波动都很大，且波动规律呈现为不规则的矩形波状，与真实值规律有较大的差异。随机森林和 XGBoost 在整个寿命周期的前半段都有很大的估计误差，但是 XGBoost 在这一区域的估计误差比随机森林更小；在锂电池寿命周期的后半段，XGBoost 的波动仍较剧烈，随机森林的估计效果明显更好，能很好地估计出真实值的波动规律，但是仍有一定的误差。从整体上来看，LightGBM 虽然在老化前期没有很好地估计出 SOH 的波动规律，但是预测误差相对来说是最小的，在老化后期 LightGBM 的波动趋势与原数据波动趋势接近，在这个数据集上 LightGBM 的预测效果明显优于其他三种模型，因此将性能更优的 LightGBM 作为初始模型进行优化。

超参数是定义模型属性或者控制训练过程的参数，对模型的最终效果有很大的影响。常用的自动调参算法有网格搜索、随机搜索、贝叶斯优化等。普遍认为随机搜索比网格搜索效果好，但是实际上这两种都是普通且效果一般的方法，在资源有限的情况下不一定比凭借经验调参效果更好。而贝叶斯方法则有可能优于经验调参。

使用贝叶斯优化方法首先需要定义一个目标函数，目标函数的输入为需要优化的 4 个 LightGBM 超参数，输出为利用 LightGBM 模型进行 SOH 估计的 R^2 值。超参数的范围与表 3.1 的规定相同，调用 Bayesian-Optimization 函数进行参数优化。贝叶斯优化 LightGBM 模型得到的最优参数如表 3.3 所示。

表 3.3 Bayes-LightGBM 模型超参数

模型	超参数	取值
Bayes-LightGBM	learning_rate	1
	n_estimators	112
	max_depth	4
	subsample	1

记录 WOA-LightGBM 模型在迭代过程中的 R^2 ，随迭代次数的增多 R^2 值变化曲线如图 3.6 所示。由图 3.6 可知，在迭代到第 14 次时 R^2 达到最大值 0.912，说明此时模型的拟合效果已经达到最好，得到的最优模型参数如表 3.4 所示。




图 3.6 优化迭代图

表 3.4 WOA-LightGBM 模型超参数

模型	超参数	取值
WOA-LightGBM	learning_rate	0.999
	n_estimators	194.438
	max_depth	4.843
	subsample	0.999

使用人工调参、贝叶斯优化和 WOA 算法优化 LightGBM 模型超参数，并进行 SOH 估计的结果如图 3.7 所示。

由图 3.7 可知，不同调参方法改进 LighGBM 的 SOH 估计结果总体趋势和原 SOH 值相同，都是随着循环次数的增加逐渐减小，总体呈下降趋势。其中人工调参的效果最差，在整个电池寿命的前半周期，三种方法的 SOH 估计效果相近；在

循环的后半周期，贝叶斯优化和 WOA 智能算法优化方法的效果均有显著提升，与原 SOH 数据的误差开始缩小，而人工调参的效果仍与原数据有较大的误差。




图 3.7 不同调参方法改进模型的 SOH 估计结果

不同模型对 B18 号电池 SOH 估计结果的评价指标如表 3.5 所示，对估计结果进行分析。这六种模型均能实现对锂电池 SOH 的估计，但是不同模型在数据集上展现的性能不同。

表 3.5 不同模型 B18 的 SOH 估计结果评价指标

模型	R^2	RMSE (%)	训练时间 (s)
DecisionTree	0.754	4.1	0.162
RandomForest	0.801	3.7	9.610
XGBoost	0.721	4.3	0.069
LightGBM	0.861	3.1	0.043
Bayes-LightGBM	0.910	2.5	0.042
WOA-LightGBM	0.911	2.4	0.042

如表 3.5 所示，决策树的训练时间为 0.162s，随机森林的训练时间为 9.610s，与其他四种方法相比训练时间大大增加。 R^2 指标越接近 1 说明模型拟合精度越好，XGBoost 在这个指标上的值为 0.72，超过了 0.5 说明模型可以用于该数据集，但是结合 4.3% 的 RMSE 值来看，作为初始模型精度相对较差。决策树和随机森林的 R^2 值都大于 0.75，RMSE 值分别为 4.1% 和 3.7%，比 XGBoost 4.3% 的误差都更小。在拟合优度和误差这两个指标上决策树和随机森林比 XGBoost 表现更好，但是 XGBoost 的训练时间远小于这两种模型，XGBoost 牺牲了一部分的精度但是大大提升了训练速度。在实际使用的过程中，需要快速得到 SOH 的估计值，因此虽然决策树和随机森林的误差相对较小，但是在锂电池 SOH 的估计问题上，需要选择能快速得到估计值的模型。

LightGBM 在各个指标上的数据与其他未改进的模型相比都相对更好， R^2 指

标的值超过了 0.85, RMSE 为 3.1%, 训练时间为 0.043s。通过 WOA 智能算法优化 LightGBM 的超参数后模型性能有了很大的提升, 超过了 0.9 说明参数优化提高了模型的估计精度。RMSE 降低到 2.4%, SOH 估计的误差也有所减小。由于 LightGBM 本身是并行计算, 运行速度本身很快因此在训练速度上的改进不明显, 但是相对来说也有所提升。基于 WOA 智能算法的超参数优化方法在这六种方法中表现最好, 贝叶斯优化方法略逊于 WOA 方法, 人工调参的效果相对最差。由此可见, WOA 智能算法可以有效确定 LightGBM 算法中重要超参数的最优取值, 从而提高 SOH 估计的精度。

在训练 XGBoost 模型后可以得到特征对模型的重要性排序, 虽然由第二章的相关性分析可知提取的特征参数与 SOH 之间的相关性都很高, 但是在训练模型的作用上每个特征的重要性并不相同, 图 3.8 显示了不同特征的重要性分布。




图 3.8 特征重要性分布

在特征重要性分布图中, F score 代表了每个特征对于决策树节点分裂的重要程度^[39]。IC 峰横坐标参数对模型训练的重要性尤为突出, 可能一方面是因为 IC 峰包含的与 SOH 相关的电池老化信息较多, 另一方面可能是由于这个参数是首先输入模型的, 模型最先对这个特征进行学习。恒压充电时间、充电 DV 曲线拐点横坐标、恒流放电时间和 IC 峰纵坐标的重要性相近, 这 4 个参数表示的物理特性不同, 补充了 IC 峰横坐标所不包含的老化信息。恒流充电时间和充电回路电压到达峰值的时间对模型最不重要, 可能是由于这两个参数包含的老化信息与前面的特征有重叠所以模型在这两个参数中所能学习到的新的信息较少。

3.4.3 不同数据集 SOH 估计结果比较

为了验证模型在不同数据集上的性能, 采用与 B5-B18 实验条件不同的电池数据集 B29-B32 对模型进行训练和测试, B29、B30、B31 数据构成训练集, B32 构成测试集。对 B29-B32 号电池进行老化实验, 电池经历的充放电循环次数较少, 共 39 次。与 B5-B18 号电池相比, B29-B32 号电池的老化程度在实验终止时明显更低, 因此电池 SOH 数据展现的老化规律不明显, 但是总趋势仍为下降的。不同

模型对 B32 号电池 SOH 的估计值如图 3.9 所示。

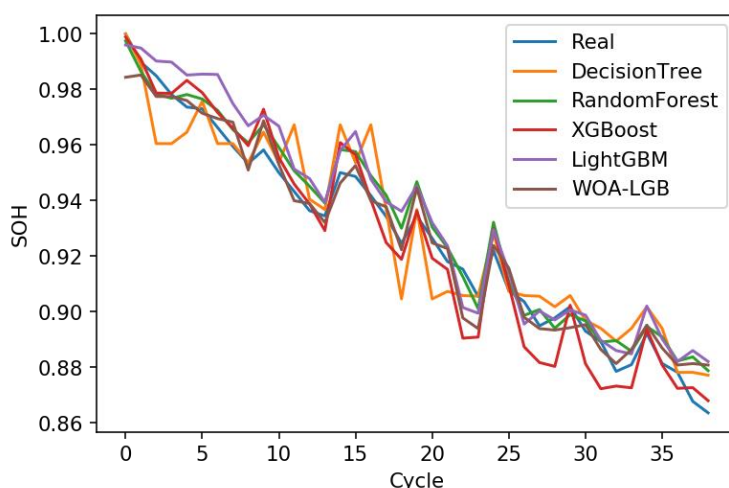


图 3.9 B32 号电池 SOH 估计值

由图 3.9 可知，这五种模型都能很好地完成对 B32 号电池 SOH 的估计。决策树的预测效果最差，与真实值之间有较大的误差，并且对数据的波动规律的预测效果也不好。随机森林在该数据集上表现较好，不仅能很好地拟合了原数据的容量再生现象，估计误差也比较小。XGBoost 和 LightGBM 的估计效果都较好，但是与 SOH 真实值相比仍有误差。WOA-LightGBM 在五种模型中效果最好，不仅对数据的波动有较好的估计，在全部的循环周期中的估计误差也最小。B32 号电池的 SOH 估计值评价指标如表 3.6 所示。

表 3.6 不同模型 B32 的 SOH 估计评价指标

模型	R^2	RMSE (%)	训练时间 (s)
DecisionTree	0.904	0.011	0.002
RandomForest	0.960	0.007	5.993
XGBoost	0.937	0.009	0.999
LightGBM	0.920	0.010	0.179
WOA-LightGBM	0.961	0.007	0.179

由表 3.6 可知，这五种模型的拟合优度都大于 0.9，说明在这个数据集上这几种模型的估计效果都很好。但是综合考虑 B5-B18 数据集的模型效果，在数据量更大的数据集上决策树和随机森林的预测效果没有这么突出，说明这两种模型并不是普遍适用的，因此在实际使用的过程中这两种模型不会被优先考虑。本文研究的 WOA-LighGBM 模型的 R^2 指标为 0.961，拟合优度最大；RMSE 指标为 0.007%，估计误差很小，虽然随机森林的估计误差也是 0.007%，但是在模型泛化性和训练时间方面，本文研究的模型都更有优势。XGBoost 与 LightGBM 相比，虽然 R^2 和 RMSE 指标都更好，但是训练时间慢了 0.82s，这是因为 LightGBM 对 XGBoost 进行了改进，模型更轻量化训练速度也更快。并且在 B5-B18 数据集上，LightGBM

的预测效果比 XGBoost 更好，因此选择估计效果更稳定的 LightGBM 模型作为基础模型改进得到的 WOA-LighGBM 模型，在估计精度、模型泛化性、训练速度指标上与其他模型比较，相对而言有更大的优势。

3.5 本章小结

本章建立了基于 WOA-LightGBM 框架的 SOH 估计模型。根据第二章得到的训练集和测试集数据输入模型，对模型进行训练和测试，实现了基于 XGBoost、LightGBM 和 WOA-LightGBM 模型的 SOH 估计。通过对比实验分析得到，WOA-LightGBM 模型相比于其他模型，具有更高的估计精度和更短的训练时间。引入不同的自动调参方式，对比人工调参、贝叶斯优化和 WOA 智能算法，验证了 WOA 优化算法在 LightGBM 超参数优化问题上具有更好的效果，能够发挥自身优势得到最优参数组合，从而提高 SOH 估计精度。

第 4 章 RUL 预测方法研究与优化

NASA 锂电池老化试验规定,当电池容量达到额定容量的 70%即电池 SOH 为 0.7 时,认为电池寿命终止。根据电池 SOH 与 RUL 之间的这一映射关系,利用电池 SOH 数据进行 RUL 的预测。电池的寿命老化与时间有关,RUL 预测本质是时间序列预测问题。本章针对传统时序预测方法对电池容量再生现象反映的波动数据预测不理想的问题,研究一种基于 CNN-BiLSTM-Attention 融合模型的 RUL 预测方法。

4.1 卷积神经网络原理

卷积神经网络是从图像处理领域发展而来的一种深度学习网络,可以通过不同尺寸的卷积核从数据中提取深层特征,避免人工提取特征带来的误差。CNN 包括用于时间序列分析的一维 CNN 和用于图像处理的二维 CNN 和三维 CNN,针对锂电池 RUL 预测问题,使用一维 CNN 来提取特征^[47]。

一维 CNN 主要由卷积层、池化层和 Dropout 层构成。卷积层的作用主要是学习输入数据的特征,由很多卷积核构成,卷积核按时序数据的时间轴方向沿一维滑动。激活函数将非线性特性引入 CNN 使网络可以逼近任意函数,常用的激活函数有 S 型函数 (sigmoid)、双曲正切函数 (tanh) 和分段线性函数 (Relu) 函数。卷积层的特征映射公式为:

$$y^{k(j)} = X * W = g(\sum W^{k(i,j)} \cdot X^{k(i)} + b^{k(j)}) \quad (3.1)$$

式中, $X * W$ 表示输入数据与卷积核的卷积运算, k 表示第 k 层网络, $W^{k(i,j)}$ 表示第 k 层的第 i 个卷积核的第 j 个权值, $X^{k(i)}$ 为第 k 层中第 i 个被卷积的局部区域, $b^{k(i)}$ 为偏置项, g 为非线性激活函数,本文采用 tanh,限制值域在 $[-1,1]$ 之间。

池化层的作用主要是降低卷积层输出的特征向量维数,从而加快运算速度,防止过拟合。最常用的池化操作有平均池化和最大池化,为了保留更多的特征信息,采用最大池化方式。最大池化公式如:

$$p^{k(i,j)} = \max \{a^{k(i,t)} | (j-1)n+1 \leq t \leq jn\} \quad (3.2)$$

式中, $a^{k(i,t)}$ 为第 k 层第 i 帧第 t 个神经元的激活值, n 为池化区域的宽度, $p^{k(i,j)}$ 为相应池化层的输出。

Dropout 机制如图 4.1 所示。Dropout 层通过随机删除神经元来避免过拟合,常用在全连接层这样参数较多的层中。假设原始神经网络如图 4.1 (a),一共有 4 个输入 1 个输出,设定每一个神经网络层 dropout 概率后根据概率删除一部分神经元如图 4.1 (b),然后进行网络训练,更新保留的神经元的权重。参数全部更新后又根据相应概率去除神经元,然后开始训练,如果用于训练的神经元已经在第一

次当中训练过，那么继续更新它的参数。而第二次被删除的神经元，同时第一次已经更新过参数的，保留它的权重，不做修改，直到第 n 次进行 dropout 时没有将其删除。




图 4.1 Dropout 机制

4.2 双向长短期记忆网络

BiLSTM 就是由前向的 LSTM 与后向的 LSTM 结合而成，由自然语言处理任务中的情感分类应用发展而来，用于捕捉双向的语义依赖^[48]。基于全连接神经网络参数太多，无法利用数据中时间序列信息等问题，RNN 被提出，RNN 可以有效挖掘数据中的时序信息，并在语音识别、机器翻译、时序分析领域广泛应用。RNN 的网络结构使其能记忆之前的信息，并利用之前的信息影响后面的输出，但是这也导致了梯度消失的问题。长短期记忆（LSTM）网络解决了 RNN 神经元短期记忆的问题，通过增加门结构避免了距离当前时刻较近的数据的影响，使网络能够记住距离当前时刻较远但是对此刻输入比较重要的信息，适合用于长时间序列预测。

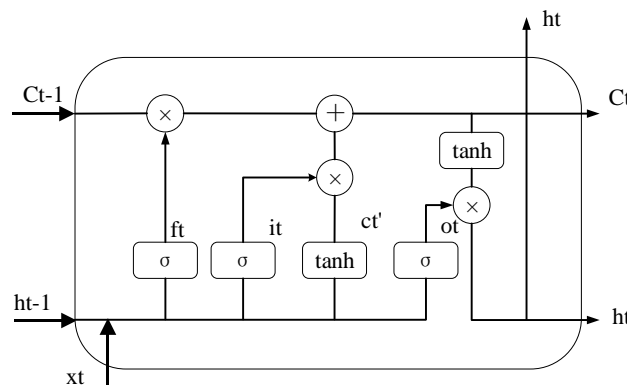


图 4.2 LSTM 结构

LSTM 主要由遗忘门、输入门和输出门构成^[49]。在每个时间点 T_n 都有对应的状态 C_t 记录之前的信息，可以通过调节权重的输入、遗忘等方式修正 C_t 的状态。通过 sigmoid 门来控制每个输入因素对 C_t 的影响，随着时间 C_t 的值不停变化但是会在网络中一直传播。遗忘门表示上一个时间的状态应该遗忘多少，对于 C_{t-1} 首先看上一阶段的输出 h_{t-1} 和这个阶段的输入 x_t 。通过 sigmoid 确定 C_{t-1} 忘记多少信息，

sigmoid=1 表示保存的 C_{t-1} 比重较高, sigmoid=0 表示完全忘记之前的 C_{t-1} 。遗忘门更新公式如:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (3.3)$$

输入门首先将 h_{t-1} 和 x_t 通过 sigmoid 门控制进入 C_t 的大小, 然后创建备选 C'_t , 用 tanh 函数控制加入 C_t 的部分。将两部分相乘再与遗忘门的输入相加, 得到 C_t 的值, 输入门更新公式如:

$$\begin{aligned} i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\ C'_t &= \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \\ C_t &= f_t * C_{t-1} + i_t * C'_t \end{aligned} \quad (3.4)$$

最后输出门通过 sigmoid 函数决定 C_t 的哪一部分需要被输出, 然后用 tanh 控制最后输出 C_t 的部分, 与 o_t 相乘得到 h_t 。输出门更新公式为:

$$\begin{aligned} o_t &= \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \\ h_t &= o_t * \tanh(C_t) \end{aligned} \quad (3.5)$$

式中, f_t 、 i_t 、 o_t 分别代表遗忘门、输入门和输出门, 这些门的范围为[0,1], W_f 、 W_i 、 W_c 、 W_o 和 b_f 、 b_i 、 b_c 、 b_o 表示各个门的权重和偏差, σ 表示 sigmoid 函数。

LSTM 通过遗忘门、输入门和输出门对状态 C_t 的影响最终实现在每个时间点的记忆、遗忘和输出, 将状态一直传递, 从而实现长期记忆且避免短时间内其他信息干扰的作用。BiLSTM 在 LSTM 的基础上改进, 结合过去与未来的信息得到当前时刻的结果, 因此时间序列问题上 BiLSTM 往往能比 LSTM 的效果更好, BiLSTM 的结构如图 4.3 所示。

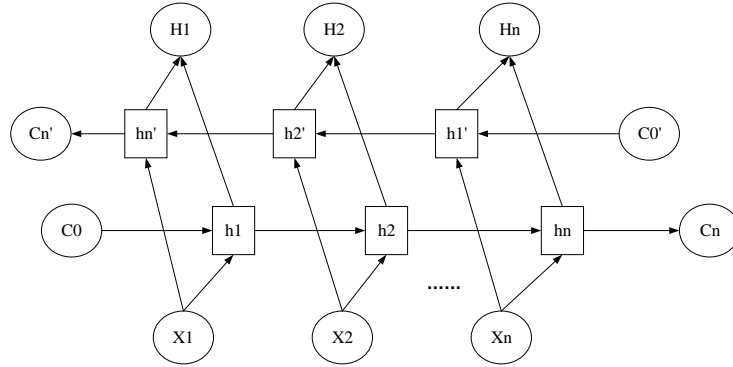


图 4.3 BiLSTM 结构

由图 4.3 可知, BiLSTM 由两个信息传递方向相反的 LSTM 循环层构成, 前向传播层按时间顺序传递信息, 反向传播层按时间逆序传递信息, 这两个层共同连接成输出层, 这一原理的数学表达如下:

$$\begin{aligned} \text{forward_layer} : C_t &= f(UX_t + WC_{t-1}) \\ \text{backward_layer} : C'_t &= f(U'X_t + W'C_{t-1}') \end{aligned} \quad (3.6)$$

式中, X_t 为输入特征, U 、 U' 、 W 和 W' 为门的权重, f 为激活函数。

BiLSTM 的每个循环层中有两个隐藏状态, 长期状态用于内部传递信息, 短期

状态作为该层循环层的输出，用于其他循环层或全连接层的计算。

4.3 注意力机制实现

注意力机制借鉴了人类视觉的选择性注意力机制，视觉通过快速扫描全局图像，获得需要重点关注的区域，并对这一区域投入更多的注意力资源，以取得关注目标的细节，忽略其他不重要的部分。深度学习中的注意力机制与视觉注意力机制的本质相同，核心都是从大量的信息中找到对当前任务目标最重要的信息。通过在深度学习模型中嵌入注意力机制模块，实现自动学习和计算特征数据对输出标签的贡献大小，从而对特征赋予不同的权重，提高重要信息的影响^[50]。

本文使用 SOH 数据进行 RUL 的预测，为了提取 SOH 时序数据的特征，设计了一维 CNN 捕捉短期局部依赖关系，BiLSTM 捕捉长期宏观依赖的模型结构。对于 CNN-BiLSTM 网络，输入的 SOH 数据的权重相同，不同循环次数下的 SOH 对当前 RUL 的影响视为一致。但是可以观察到，电池 SOH 数据存在周期性的数据波动现象，这一现象被称为容量再生。容量再生现象对电池 RUL 预测有很大影响，这使得在 SOH 的值相同的情况下，电池有不同的剩余使用寿命，因此容量再生部分的数据相较于其它部分对 RUL 预测更重要。为此需要注意力机制，给容量再生部分的重要时间段特征赋较大的权重，提高这一部分特征对 RUL 预测的影响，给其他部分特征赋较小的权重来弱化影响。

本文为了实现注意力机制，将经过 CNN-BiLSTM 层后得到的特征输入 sigmoid 函数计算不同特征维度各自的权重系数，然后将该系数与输入 BiLSTM 层的对应特征相乘得到被赋予权重的新特征。设计的注意力机制的表达式如下：

$$\begin{cases} c_t = \tanh(vh_t + v'h'_t + b) \\ h_t = \tanh(wh_{t-1} + ux_t) \\ h'_t = \tanh(w'h'_{t+1} + u'x_t) \\ q_t = \frac{1}{1 + e^{-c_t}} \\ z_t = \sum_{t=1}^n c_t q_t \end{cases} \quad (3.7)$$

式中， h_t 、 h'_t 为输入特征值对应隐藏层状态值， C_t 为 BiLSTM 层的输出特征， Z_t 为注意力层的输出， v 、 w 、 u 等值和 b 分别为 BiLSTM 层的权重和偏差。

4.4 基于 CNN-BiLSTM-Attention 的 RUL 预测模型研究

本节建立基于 CNN-BiLSTM-Attention 融合模型用于 RUL 预测，B5、B6、B7、B18 号电池的 SOH 数据作为模型输入数据来源。SOH 与电池的循环次数有关，数据之间存在时间上的先后，因此不可以随机划分训练集和测试集。针对这样的时间序列预测问题首先确定预测起点，对预测起点前的数据进行分析，通过 CNN-

BiLSTM-Attention 模型提取电池剩余使用寿命的相关特征并对预测起点后的 SOH 进行预测。

4.4.1 RUL 预测融合模型结构设计

RUL 预测融合模型主要分为输入层、一维 CNN 层、BiLSTM 层、Attention 层和输出层。数据集通过输入层输入模型，经过一维 CNN 层进行特征提取，生成的特征向量输入 BiLSTM 层，BiLSTM 层输出的特征经 Attention 层的作用被赋予不同的权重，新的特征输入至全连接层得到 RUL 的预测结果。预测融合模型结构如图 4.4 所示。




图 4.4 CNN-BiLSTM-Attention 模型结构

如图 4.4，将电池 SOH 数据通过滑动时间窗处理成符合模型输入要求的数据格式，由于电池 SOH 取值范围在 $[0,1]$ ，因此不需要再进行归一化，处理完的数据通过输入层输入一维 CNN 层。

一维 CNN 层由卷积层、池化层和 Dropout 层构成。为了能学习到 SOH 数据更多的特征，卷积层的卷积核个数为 128，时域窗长度设置为 1，使用 tanh 函数作为激活函数。尽可能保留更多的数据波动信息，池化层采用最大池化方式，窗口大小设置为 5。由于参数过多而训练样本较少，模型容易产生过拟合，因此加入 Dropout 层防止模型过拟合。

经一维 CNN 提取的特征输入到 BiLSTM 层，学习数据样本关系并且提取包含长期依赖关系信息的相关特征。Attention 层通过对 CNN-BiLSTM 提取的特征进行权值计算，赋予特征不同的权重。经注意力机制处理的特征输入全连接层，得到 RUL 的预测值。

4.4.2 基于预测融合模型的 RUL 预测流程

基于融合模型的 RUL 预测将 SOH 数据直接输入到模型，通过 CNN-BiLSTM 自动提取原始数据的时序信息，从训练数据中快速学习到新的有效特征。结合 Attention 机制使得模型能突出关键的特征信息，提高了特征提取的能力。本节主

LightGBM 模型得到的 B18 号电池 SOH 估计数据，搭建基于 CNN-BiLSTM-Attention 的 RUL 预测模型并进行仿真。通过在不同电池、同一预测起点上的预测结果，验证混合模型的预测精度和泛化性。进行消融实验，对比 BiLSTM、CNN-BiLSTM、BiLSTM-Attention 模型和本文使用的 CNN-BiLSTM-Attention 模型在同一数据集下的预测效果。

4.5.1 仿真设置

深度学习可以自动学习数据集中的特征而不需要人工特征提取，这一优势的前提是数据量达到一定的大小。本文采用的 NASA 数据集中 SOH 数据由电池放电实验中测得的容量 (Capacity) 经过归一化后得到。SOH 数据曲线如图 4.6 所示，图 4.6 中的五条数据曲线包括 B5、B6、B7、B18 电池数据和第三章中用 WOA-LightGBM 模型的 B18 号电池的 SOH 估计值。

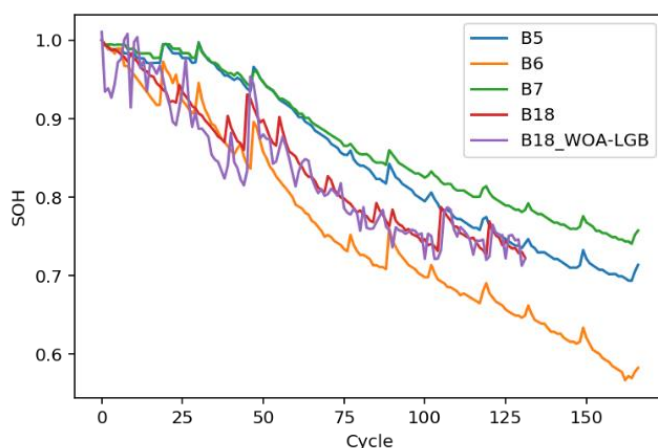


图 4.6 SOH 数据

由图 4.6 可知，每个电池的 SOH 数据量在 150 个以内，若要采用深度学习的方法这一数据量远远不够，因此采用卷积插值的方法对 SOH 数据进行数据增强处理，采用 matlab 插值函数 interp1，方法选择卷积插值法 cubic 对 SOH 数据进行插值。经数据增强后的 SOH 数据如图 4.7 所示。

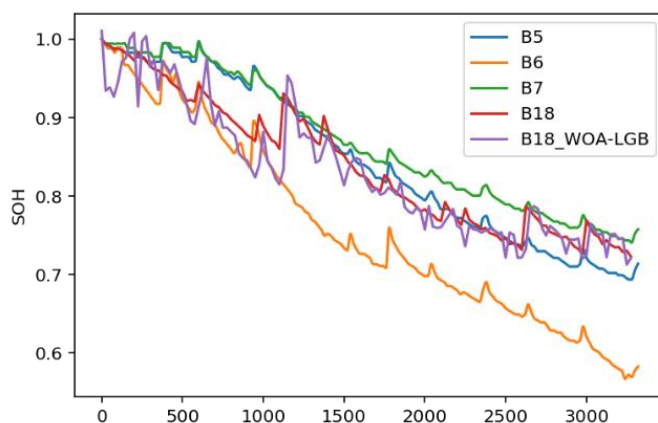


图 4.7 SOH 数据增强

CNN-LSTM-ATTENTION 模型的参数设置和模型每层的输出维度如表 4.1 所示。

表 4.1 模型每层参数设置和输出维度

名称	参数	输出维数
输入层	shape= (5,1)	(5,1)
一维卷积层	fliter=128, kernel_size = 1, activation = 'tanh'	(5,128)
最大池化层	pool_size =5	(1,128)
Dropout 层	dropout=0.01	(1,128)
BiLSTM 层	units=32, activation='tanh'	64
Attention 层	units=64, activation='sigmoid'	64
Multiply 层		64
输出层	units=1, activation='tanh'	1

如表 4.1，以 B6 电池的 SOH 数据为例，经数据增强后 SOH 的数据维数为 3321×1 维，若将预测起始位置定为 60% 的位置，即前 60% 的数据作为训练集，后 40% 数据作为测试集。那么经滑动窗函数处理后，训练集有 1989 个 5×1 的数据作为训练参数，1989 个 1 维数据作为对应的训练标签；测试集有 1326 个 5×1 的数据作为测试参数，1326 个 1 维数据作为对应的测试标签。一维卷积层共有 129 个 1 维卷积核对输入的参数进行卷积，输出维的特征向量。

最大池化层和 Dropout 层减少特征的维度，使模型不容易过拟合且去除了冗余特征，提高模型训练的速度，输出特征维数为 1×128 维。BiLSTM 层学习局部特征的时序特征，进一步降低了特征维数。Attention 层利用全连接层实现，通过激活函数 sigmoid 对输入特征打分，赋不同的权重。Multiply 层其实属于 Attention 层的一部分，但是为了使模型结构更清楚因此单独列出。这一层将权重与 BiLSTM 层对应的中间特征进行张量相乘，输出维数为 64 的新特征。输出层通过全连接层实现，将 64 为的特征输出为 1 维的 RUL 预测值。

4.5.2 不同电池预测效果比较

NASA 公开数据集中实验规定电池的 SOH 达到 0.7 时视为寿命终止，但是 B5、B7、B18 电池在老化实验结束时电池寿命仍保持在 0.7 以上，若采用 0.7 的寿命终止标准进行 RUL 预测则预测寿命与实际寿命相同，都等于从预测起点到预测终点。而对于 B6 电池，实验终止时 SOH 达到 0.6 以下，在整个老化实验的中期 B6 电池的 SOH 就已经达到了 0.7。这种差异导致了在实验中，对于不同的电池需要设置不同的寿命终止标准。在不同电池、同一预测起点的实验条件下，倾向于比较同一寿命标准下的预测效果，因此采用 B5、B7、B18 号电池 SOH 数据用于本次实验，电池的寿命终止标准设置为 $\text{SOH}=0.75$ ，预测起点设置为 70%。B5、B7、B18 电池

的 RUL 预测结果如图 4.8 所示。

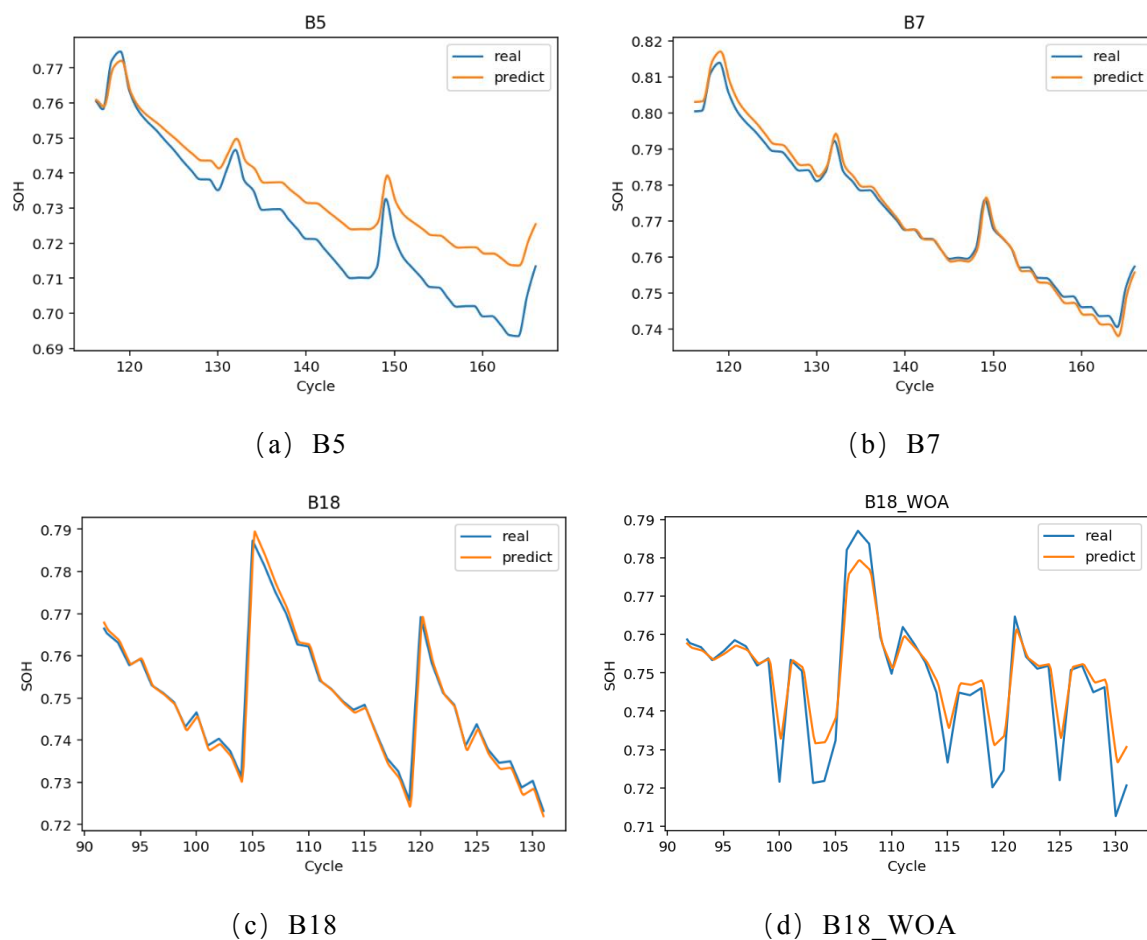


图 4.8 不同电池同一预测起点 RUL 预测结果

由图 4.8 可知，混合模型在这三个电池上的预测性能都很好，证明模型的具有很强的泛化能力。不仅在总体的变化趋势上能实现跟踪，而且对于电池再生现象体现的局部波动也能实现精度很高的预测。RUL 预测结果的评价指标如表 4.2 所示。根据评价指标表可以定量判断 RUL 预测的误差，表格中前四个指标都是越小越好，越小说明模型预测的精度越高。

表 4.2 RUL 预测结果评价指标

电池	MAE	MSE	MAPE	AE	RUL 预测值	RUL 实际值
B5	0.0098	10.000e-04	0.0135	1.30	40.85	42.15
B7	0.0015	3.5356e-06	0.0020	0.30	8.80	8.50
B18	0.0012	3.5721e-06	0.0016	0.08	33.52	33.44
B18_WOA	0.0038	2.9410e-06	0.0051	0.20	31.68	31.88

B5 电池的误差相对其他电池的预测误差较大，RUL 的实际值与预测值的绝对误差 AE 也相对较大但是这个误差大小实际上是可以接受的。使用第三章 WOA-LightGBM 模型估计 B18 的 SOH 值，得到 B18_WOA。使用本章混合模型分别使用 B18_WOA、B18 数据做对比实验，是为了探索进行 SOH-RUL 联合估计的可能

性。因为在实际的使用过程中，电池容量数据难以测得，可以使用容易测量的电流、电压等数据先通过特征提取、SOH 估计得到电池的 SOH 估计值，再使用混合模型对 SOH 估计值的历史数据进行 RUL 的预测。B18 的实际剩余寿命为 33.44，通过 B18_WOA 数据得到的 RUL 预测值为 31.68，两者的绝对误差在 1.76，相差不到两个循环次数，因此可以证明，SOH-RUL 联合估计是可行的。

4.5.3 消融实验

为了验证融合模型各个部分在模型中的作用，使用同一电池、相同预测起点，分别通过 BiLSTM、CNN-BiLSTM、BiLSTM-Attention 和 CNN-BiLSTM-Attention 模型对 RUL 进行预测，对比 RUL 的预测结果。消融实验选择 B6 电池 SOH 数据，预测起点设为 0.7，寿命终止标准为 SOH=0.6。消融实验的评价指标结果如表 4.3。

表 4.3 消融实验评价指标

模型	MAE	MSE	MAPE	AE	RUL 预测值	RUL 实际值
BiLSTM	0.0112	0.0001	0.0179	4.35	7.55	11.90
CNN-BiLSTM	0.0088	0.0001	0.0143	6.40	5.50	
BiLSTM-Attention	0.0063	6.22 e-05	0.0104	3.45	8.45	
CNN-BiLSTM-Attention	0.0027	8.85 e-06	0.0045	1.15	13.05	

消融实验结果如图 4.9 所示。

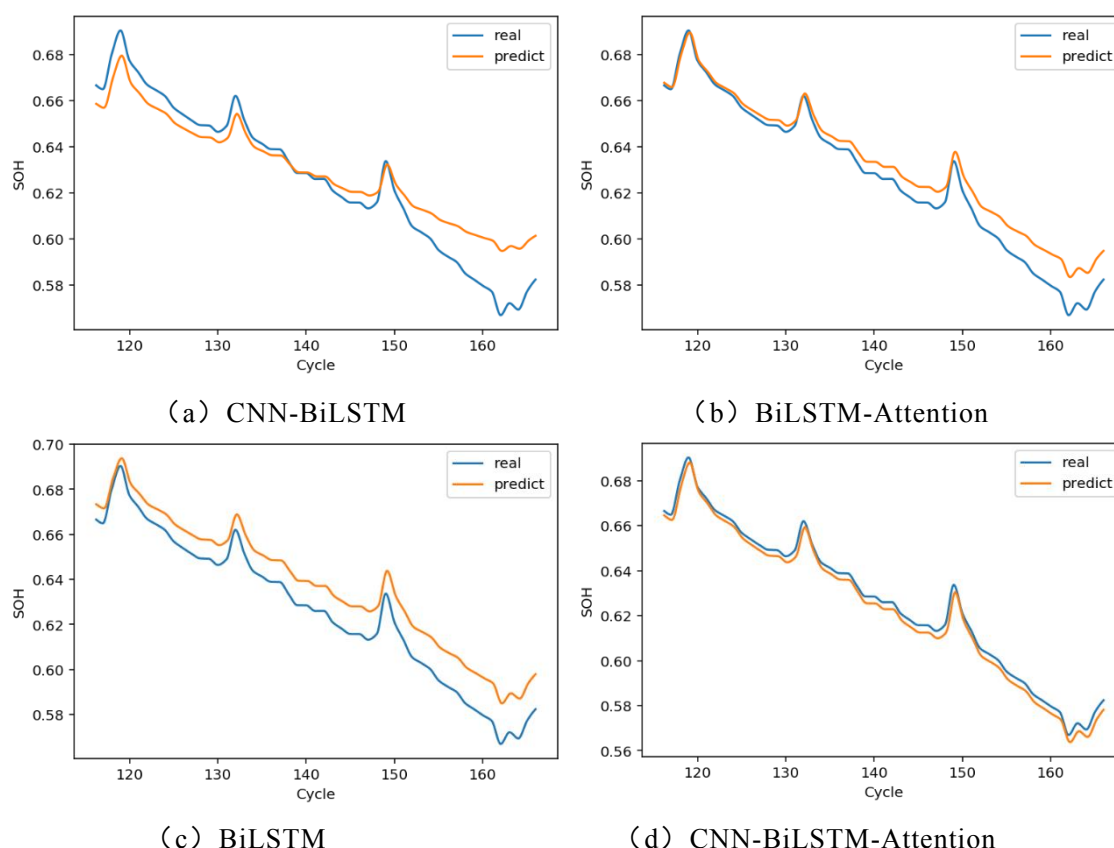


图 4.9 消融实验

由消融实验得到的不同模型对 RUL 的预测结果可以看出，融合模型的不同部

分对模型的作用不同。首先从预测精度来看，本文提出的 CNN-BiLSTM-Attention 融合模型在各个评价指标上的值都是最小的，从图片展现的预测效果看，融合模型的效果也是最好的。简而言之，本文提出的融合模型充分发挥了各个组成部分的作用，使得模型在预测精度、鲁棒性和泛化性上都具有很大的优势。不同模型的 RUL 预测效果如图 4.10 所示。




图 4.10 消融实验不同模型对比

对比另外三种模型的预测效果，BiLSTM 作为基本模型，对于 RUL 的预测在总体趋势和局部波动方面都体现了一定的优越性，但是与 RUL 真实值相比还是有较大的误差。加入一维 CNN 后，CNN-BiLSTM 对于局部波动现象有了更好的预测效果，对 BiLSTM 的预测结果整体上进行了一定的平衡，预测误差也有了一定的减小。但是在预测的后期表现不佳，与 BiLSTM 模型相比误差有增大的趋势。加入 Attention 机制后，不仅对于局部波动的预测更精确，整体的预测误差也有了很大的改善，这是由于 Attention 赋予中间特征不同的权重，增强了有效特征的作用。本文提出的融合模型不仅在局部波动数据上具有优越的预测效果，在预测后期的精度也没有降低，发挥了 CNN、Attention 层的优势。

为了深入分析模型的预测效果，采用 STL (Seasonal and Trend decomposition using Loess) 分解法对四种模型得到的预测值分解为趋势数据、周期信息数据和局部波动信息数据。不同模型对 SOH 趋势信息数据的预测效果如图 4.11 所示。




图 4.11 SOH 趋势数据

如图 4.12 所示，四种模型对 SOH 的趋势预测效果不同。BiLSTM 对 SOH 趋势信息的预测有较大的误差，但是能很好的预测趋势信息数据的变化规律。在 BiLSTM 基础上增加 Attention 模块后，趋势数据整体向下平移，预测误差减小。CNN-BiLSTM 模型在预测周期的前半段 SOH 预测值与 BiLSTM 相比，降低了约 15% 的 SOH 值，而在后半段增加了约 10% 的 SOH，整体上对 BiLSTM 的预测结果进行了一个平衡。本文研究的 CNN-BiLSTM-Attention 模型对 SOH 的总体趋势的预测效果最好，误差相对也是最小的。

表 4.4 不同模型对 SOH 趋势数据预测的评价指标

模型	MAE	MSE	MAPE
BiLSTM	0.011	0.0001	0.018
CNN-BiLSTM	0.008	0.0001	0.012
BiLSTM-Attention	0.006	5.624e-05	0.010
CNN-BiLSTM-Attention	0.002	7.524e-06	0.004

如表 4.4 所示，BiLSTM 的预测误差指标 MAE、MSE 和 MAPE 与其他模型相比都是最大的，CNN-BiLSTM 的预测误差与 BiLSTM 相比有了一定的改善，MAE 指标降低了 0.003，MAPE 指标降低了 0.006。BiLSTM-Attention 模型的 MSE 指标为 5.624e-05，比增加 CNN 模块对 BiLSTM 预测精度更高，说明 Attention 模块对模型预测精度提升的贡献比 CNN 模块大。CNN-BiLSTM-Attention 的 MAE、MSE 和 MAPE 指标分别为 0.002、7.524e-06 和 0.004，比 BiLSTM 模型的预测指标分别降低了 0.108、9.3e-05 和 0.014，说明增加了 CNN 和 Attention 模块后模型对 SOH 整体趋势的预测精度有了很大的提升。

不同模型对 SOH 周期信息的预测效果对比如图 4.12 所示。




图 4.12 SOH 周期信息数据

由图 4.12 可知，SOH 数据包含了一个峰值在 0.0025 左右，谷值为-0.001，周期约为 5 次循环的周期信息。在每个周期的前 2.5 次循环中，包含一个峰值较小的先上升，后下降的尖波，在后 2.5 次循环中包含一个峰值较大的尖波。SOH 的周

期信息对应原 SOH 数据中, SOH 的值随电池实验循环次数的增加而有规律地波动下降, 周期信息反映了 SOH 数据波动的规律。这四种模型都能很好地预测出 SOH 的周期信息, 从未分解的不同模型对 SOH 的预测效果图也能看出虽然都有一定的预测误差, 但是都能预测出 SOH 的变化规律。需要指出, 预测 SOH 值是为了得到电池 RUL 的值, 即通过预测出的 SOH 对应循环次数与未来达到失效阈值时 SOH 对应循环次数作差得到电池在预测位置的 RUL。

表 4.5 不同模型对 SOH 周期信息预测指标

模型	MAE	MSE	MAPE
BiLSTM	0.0001	6.129e-08	1.759
CNN-BiLSTM	0.0002	8.803e-08	1.640
BiLSTM-Attention	0.0001	6.097e-08	1.028
CNN-BiLSTM-Attention	0.0001	6.571e-08	0.849

由表 4.5 可知, 四种模型对 SOH 周期信息的预测误差结果相近, 并且指标的值都很低, 说明对 SOH 的周期信息预测效果好。BiLSTM、CNN-BiLSTM 和 CNN-BiLSTM-Attention 的 MAE 指标为 0.001, MSE 指标都在 $6\text{e-}08$ 左右, CNN-BiLSTM 的 MAE 和 MSE 与其他模型相比更大, 说明对 SOH 的周期性规律预测效果没有其他模型好。CNN-BiLSTM-Attention 模型的 MAPE 指标为 0.849 与其他四种模型相比分别降低了 0.91、0.791 和 0.179。

不同模型对 SOH 局部波动信息的预测效果如图 4.13 所示。




图 4.13 SOH 局部波动信息数据

图 4.13 反映了电池容量再生现象展现的 SOH 数据局部波动信息, 这种数据的局部有较大的回升然后下降的现象与电池循环次数之间没有呈现特殊的规律, 也就是说, 这是随机现象。模型从训练数据中学习这种随机特征, 然后预测出之后的循环中可能发生的容量再生规律。这四种模型对电池 SOH 的局部波动信息预测效果较好, 在容量再生的峰值处的预测效果有较大的差异。

不同模型对 SOH 局部波动信息预测的指标如表 4.6 所示。

表 4.6 不同模型对 SOH 局部波动信息预测指标

模型	MAE	MSE	MAPE
BiLSTM	0.0005	6.592e-07	1.052
CNN-BiLSTM	0.0007	1.439e-06	3.541
BiLSTM-Attention	0.0005	7.463e-07	1.291
CNN-BiLSTM-Attention	0.0005	6.402e-07	1.031

由表 4.6 可知,在预测误差指标 MAE 和 MSE 上,BiLSTM、BiLSTM-Attention 和 CNN-BiLSTM-Attention 模型的预测效果接近,MAE 的值都为 0.0005,MSE 指标在 6.402e-07 至 7.463e-07 之间,MAPE 的值都接近 1。CNN-BiLSTM 模型对 SOH 局部波动数据的预测效果最差,MAE 值增加了 0.0002,MSE 指标大了一个数量级,MAPE 指标增加了 2 以上。与其他模型相比,CNN-BiLSTM-Attention 模型对 SOH 的局部波动预测效果最好,说明增加 CNN 和 Attention 模块后能很好地对电池的容量再生现象进行预测。

4.6 本章小结

本章研究了基于 CNN-BiLSTM-Attention 融合模型的 RUL 预测方法,利用一维 CNN 在特征提取上的优势及 BiLSTM 在时序特征提取方面的优势,引入注意力机制对中间特征进行赋权,解决了传统时序分析方法对电池容量再生现象预测精度差的问题。通过不同电池、同一预测起点实验,探讨了 SOH-RUL 联合估计的可行性,验证了模型的预测精度和泛化能力。通过消融实验,验证了融合模型各部分之间对模型预测的影响不同,而本文提出的融合模型能发挥各个部分的作用,在预测精度、泛化能力上都具有显著的优势。

结 论

锂离子电池的安全性和可靠性在使用过程中至关重要, 电池管理中的核心部分电池健康状态估计及剩余使用寿命预测提供了当前电池的内部信息, 作为评价电池性能的依据。本文通过 NASA 公开的电池老化数据集, 采用基于数据驱动的方法, 分别构建了 SOH 估计模型和 RUL 预测模型, 通过实验验证了这两种模型在预测精度和性能方面都具有一定的优势。

本文首先对 NASA 电池老化数据集中的实验参数进行分析, 通过电池的充放电电压、电流和温度曲线, 提取了 8 个包含电池老化状态信息的特征参数。Z-score 标准化处理后对提取到的这些特征进行处理和分析操作。通过箱型图判断和处理特征参数数据中的离群值, 对比了均值、KNN 和随机森林插值算法, 通过 MSE 指标判断选择的插值算法, 对特征中的原离群值位置进行插值。然后对特征使用皮尔森相关性系数进行分析, 得到这 8 个特征参数与电池健康状态的相关性都达到 0.9 以上, 考虑到每个特征包含的不同物理状态信息, 将这些特征全部保留, 用于电池 SOH 的估计。

然后建立了基于 WOA-LightGBM 的 SOH 估计模型, 设计了电池 SOH 估计模型的框架和 WOA 算法对 LightGBM 超参数寻优的流程图。WOA 算法将超参数看作鲸鱼个体, SOH 估计值与真实值之间的 RMSE 指标的倒数作为个体的适应度值, 设置每个超参数的取值范围, 使算法依据捕食机制对参数的值进行更新, 最终得到模型的最优超参数。用 B5,B6,B7 号电池特征数据和 SOH 值作为训练集样本和标签, B18 号电池的数据作为测试集验证模型性能。通过与 Decision Tree、Random forest、XGBoost 和 LightGBM 模型的对比, WOA-LightGBM 模型的 R^2 指标达到 0.911, 其他四种模型分别为 0.754、0.801、0.721 和 0.861, 说明鲸鱼优化算法优化超参数能明显提高模型性能, 提高预测的精度。采用实验条件不同的 B29-B32 号电池数据进行模型的训练和测试, 本文研究的模型在该数据集上的 R^2 值为 0.961, RMSE 值为 0.007%, 训练时间为 0.179s, 说明 WOA-LightGBM 模型具有较高的预测精度和泛化能力, 可以适用于不同的电池数据集中。

最后建立了基于 CNN-BiLSTM-Attention 的 RUL 预测模型。基于 SOH 与 RUL 之间存在的映射关系, 利用 SOH 数据进行 RUL 预测, 设置不同的 SOH 值来表示电池寿命终止的条件。一维 CNN 层提取时序数据中的局部特征, BiLSTM 学习局部特征中的时间序列信息, 通过 Attention 机制将原本对标签一样重要的特征有了不同的权重, 使得模型更加关注重要的特征信息。由于电池 SOH 数据量不够, 因此使用卷积插值对原数据进行增强, 将 150 左右的数据量增加到 3000 以上。通过三组实验测试模型的性能, 分别进行了不同电池、同一预测起点的实验, 用于验证

模型的泛化能力和预测精度,实验结果证明提出的融合模型精度高,泛化能力强,在四组数据中的误差指标均接近于 0,剩余使用寿命的绝对误差也在 2 个循环次数内。将之前 SOH 估计模型得到的 B18 电池的 SOH 估计值也使用融合模型进行预测,得到的 RUL 预测值与 B18 电池 RUL 真实值进行对比,绝对误差为 1.76,误差在可接受的范围内。这个实验探索了在实际使用过程中 SOH-RUL 联合预测的可能性,即经在线监测系统测得电池的电压、电流、温度等参数后,提取特征参数,经 SOH 估计模型进行估计,再将数据量达到一定程度的历史 SOH 估计值输入 RUL 融合模型进行 RUL 的预测,这样就能实现在线的 SOH-RUL 联合估计。然后进行了同一电池、不同预测起点的实验,采用数据变化范围大且波动明显的 B6 电池 SOH 数据,预测起点分别设为 40%、55%、60%和 70%,RUL 预测的误差随预测起点的提升,训练数据的增多而减小。最后进行模型消融实验,对比 BiLSTM、CNN-BiLSTM、BiLSTM-Attention 和所提出的融合模型的预测效果,验证了一维 CNN 在提取局部特征,BiLSTM 提取时序信息,Attention 对特征赋权的特性,融合模型将不同部分的优势集于一身,具有优良的预测精度、很强的泛化能力,对于解决 RUL 预测问题具有一定的参考价值。

本论文的研究内容有以下几个方面可以继续探讨。首先 SOH-RUL 联合预测本文只是提出了设想,并没有在实际中具体实现,可以在电池管理系统中设计相应的算法,实现 SOH-RUL 联合预测。其次,在同一电池、不同预测起点的实验中可以知道,训练数据的大小对模型的效果有很大的影响,这实际上限制的了模型对早期电池剩余使用寿命的预测,当电池循环次数不多,但是需要知道剩余使用寿命的环境下,深度学习模型会受到限制。可以设计一个不需要很多历史数据的模型,这种模型的参数比较少,这样在很少的历史数据中不会过拟合。

参考文献

- [1] 郑文芳,付春流,张建华,等.锂离子电池剩余寿命预测方法研究综述[J].计算机测量与控制,2020,28(12):1-6.
- [2] 李玲玲,谢阳,曹丽鹏,等.不同正极材料的锂离子电池容量特性分析.电源技术,2017,41(12): 1677-1680.
- [3] 熊瑞.动力电池管理系统核心算法.北京:机械工业出版社,100-101.
- [4] 周頔,卢文斌,付平.锂电池容量测量不确定度评定与等效模型验证方法.储能科学与技术,2019,8(5): 862-867.
- [5] 卢成,袁明辉.锂离子电池容量动态测量研究.上海理工大学学报,2013,35(2): 165-168.
- [6] 郭庆,李敬,胡鸿志,等.锂离子电池内阻测量系统设计.仪表技术与传感器,2020(11): 54-58+63.
- [7] 高金辉,石松,郑晓彦.直流充电法测量锂离子电池内阻.电源技术,2018,42(7): 962-963+1026.
- [8] 张峥,李丽娟,朱振东,等.SEI膜成膜过程阻抗变化研究.电池工业,2020,24(6): 288-291.
- [9] 周坤,彭杨茗,刘爽,等.基于容量增量法对三元锂离子动力电池寿命预测分析研究.见:2020中国汽车工程学会年会论文集(2).上海:机械工业出版社,2020,326-330.
- [10] 杨胜杰,罗冰洋,王菁,等.基于容量增量曲线峰值区间特征参数的锂离子电池健康状态估算.电工技术学报,2021,36(11): 2277-2287.
- [11] 张吉昂,王萍,程泽.基于ICA和Box-Cox变换的锂离子电池SOH估计方法.电力系统及其自动化学报,2022,34(2): 9-15.
- [12] 王宇胜,陈德旺,蔡俊鹏,等.基于LSTM-SVR的锂电池健康状态预测研究.电源技术,2020,44(12): 1784-1787.
- [13] 张婷婷,于明,李宾,等.基于Wavelet降噪和支持向量机的锂离子电池容量预测研究.电工技术学报,2020,35(14): 3126-3136.
- [14] 熊瑞.动力电池管理系统核心算法.北京:机械工业出版社,100-101.
- [15] 白爽.基于深度学习的锂离子电池寿命预测方法研究:[哈尔滨工业大学硕士学位论文].哈尔滨:哈尔滨工业大学,2020,2-4.
- [16] 卢成,袁明辉.锂离子电池容量动态测量研究[J].上海理工大学学报,2013,35(2):165-168.

- [17] 郭庆,李敬,胡鸿志,等.锂离子电池内阻测量系统设计[J].仪表技术与传感器,2020(11):54-58+63.
- [18] 杨立峰,吕卫民,肖阳.基于故障机理和伪失效寿命的电子产品剩余寿命预测.海军航空工程学院学报,2017,32(2):246-250.
- [19] Walker E, Rayman S, White R E. Comparison of a particle filter and other state estimation methods for prognostics of lithium-ion batteries. *Journal of Power Sources*, 2015, 287: 1-12.
- [20] 刘大同,周建宝,郭力萌,等.锂离子电池健康评估和寿命预测综述.仪器仪表学报,2015,36(1):1-16.
- [21] 姚芳,张楠,黄凯.锂离子电池状态估算与寿命预测综述.电源学报,2020,18(3):175-183.
- [22] Tian Y, Lu C, Wang Z, et al. Artificial Fish Swarm Algorithm-Based Particle Filter for Li-Ion Battery Life Prediction. *Mathematical Problems in Engineering*, 2014, (1): 1-10.
- [23] Guha A, Vaisakh K V, Patra A. Remaining useful life estimation of lithium-ion batteries based on a new capacity degradation model. In: 2016 IEEE Transportation Electrification Conference and Expo, Asia-Pacific (ITEC Asia-Pacific). Busan: IEEE, 2016, 555-560.
- [24] Zhang H, Hu C, Kong X, et al. Online updating with a wiener-process-based prediction model using UKF algorithm for remaining useful life estimation. In: 2014 Prognostics and System Health Management Conference (PHM-2014 Hunan). Zhangjiajie: IEEE, 2014, 305-309.
- [25] Vapnik V. The nature of statistical learning theory. New York: Springer-Verlag, 1999,23-24.
- [26] Saha B, Goebel K, Poll S, et al. Prognostics Methods for Battery Health Monitoring Using a Bayesian Framework. *IEEE Transactions on Instrumentation and Measurement*, 2009, 58(2): 291-296.
- [27] Nuhic A, Terzimehic T, Soczka-Guth T, et al. Health diagnosis and remaining useful life prognostics of lithium-ion batteries using data-driven methods. *Journal of Power Sources*, 2013, 239: 680-688.
- [28] Dong H, Jin X, Lou Y, et al. Lithium-ion battery state of health monitoring and remaining useful life prediction based on support vector regression-particle filter. *Journal of Power Sources*, 2014, 271: 114-123.
- [29] Widodo A, Shim M C, Caesarendra W, et al. Intelligent prognostics for battery health monitoring based on sample entropy. *Expert Systems with Applications An International Journal*, 2011, 38(9): 11763-11769.

- [30] 张若可, 郭永芳, 余湘媛, 等. 基于数据驱动的锂离子电池 RUL 预测综述. 电源学报 :1-15.
- [31] 罗悦. 基于粒子滤波的锂离子电池剩余寿命预测方法研究: [哈尔滨工业大学硕士学位论文]. 哈尔滨: 哈尔滨工业大学, 2012, 15-16.
- [32] 胡天中, 余建波. 基于多尺度分解和深度学习的锂电池寿命预测. 浙江大学学报(工学版), 2019, 53(10): 1852-1864.
- [33] Wu J, Zhang C, Chen Z. An online method for lithium-ion battery remaining useful life estimation using importance sampling and neural networks. *Applied Energy*, 2016, 173(1): 134-140.
- [34] Zhang Y, Xiong R, He H, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries. *IEEE Transactions on Vehicular Technology*, 2018, 67(7): 5695-5705.
- [35] Xiao Z, Fang H, Li Z, et al. Remaining Useful Life Prediction of Lithium-ion Battery Based on Unscented Kalman Filter and Back propagation Neural Network. In: 2019 IEEE 8th Data Driven Control and Learning Systems Conference (DDCLS). Dali: IEEE, 2019, 47-52.
- [36] Saha B, Goebel K, Christophersen J. Comparison of prognostic algorithms for estimating remaining useful life of batteries. *Transactions of the Institute of Measurement and Control*, 2009, 31: 293-308.
- [37] Tong Z, J Miao, Tong S, et al. Early prediction of remaining useful life for Lithium-ion batteries based on a hybrid machine learning method. *Journal of Cleaner Production*, 2021, 317: 128265-128265.
- [38] Ding P, Liu X, Li H, et al. Useful life prediction based on wavelet packet decomposition and two-dimensional convolutional neural network for lithium-ion batteries. *Renewable and Sustainable Energy Reviews*, 2021, 148: .
- [39] 张志. 锂电池工作机理与模型简述. 电子技术与软件工程, 2018, (11): 103.
- [40] 纪常伟, 潘帅, 汪硕峰, 等. 动力锂离子电池老化速率影响因素的实验研究. 北京工业大学学报, 2020, 46(11): 1272-1282.
- [41] 闫啸宇, 周思达, 卢宇, 等. 锂离子电池容量衰退机理与影响因素研究. 北京航空航天大学学报, 2022, 1-13.
- [42] Bhaskar Saha KG, Modeling Li-Ion Battery Capacity Depletion in a Particle Filtering Framework, in Annual Conference of the Prognostics and Health Management Society. 2009.
- [43] Mirjalili, Seyedali, Lewis, et al. The Whale Optimization Algorithm. *Advances in engineering software*, 2016, 95: 51-67.

- [44] 任志航. 面向电力客户侧终端网络的高效入侵检测模型研究. 电测与仪表, :1-13.
- [45] 冯易, 王杜娟, 胡知能, 等. 基于改进 LightGBM 集成模型的胃癌存活性预测方法. 中国管理科学, 2022,1-15.
- [46] 肖迁, 穆云飞, 焦志鹏, 等. 基于改进 LightGBM 的电动汽车电池剩余使用寿命在线预测. 电工技术学报. 2022,1-11.
- [47] 张帅涛, 蒋品群, 宋树祥, 等. 基于注意力机制和 CNN-LSTM 融合模型的锂电池 SOC 预测. 电源学报, 2022,1-15.
- [48] 王欢, 李鹏, 曹敏, 等. 基于 CNN__BiLSTM 的长短期电力负荷预测方法. 计算机仿真, 2022,39(03):96-103.
- [49] 刘树鑫, 高士珍, 刘洋, 等. 基于 LSTM 的交流接触器剩余寿命预测. 高电压技术, 2022,1-11.
- [50] 朱浩, 宁芊, 雷印杰, 等. 基于注意力机制-Inception-CNN 模型的滚动轴承故障分类. 振动与冲击, 2020,39(19):84-93.